

Étude statistique des préférences professionnelles dans les métiers du numérique au sein du secteur public

Analyse de données et imputations statistiques réalisées avec RStudio

Samuel Le Nenes et Jules Bouscaud

2025-12-17

Sommaire

1	Introduction	3
2	Jeu de données et premier traitement	3
2.1	Importation des packages	3
2.2	import des données	4
2.3	Suppressions de certaines colonnes et renommage des variables	4
2.4	Ajout de nouvelles variables à partir de celles existantes	4
2.4.1	SOUHAITS	4
2.4.2	SECTEUR	5
2.4.3	CRITERE	5
2.4.4	RAISON	6
3	Présentation des variables	8
3.1	Préférences professionnelles	8
3.2	Critères d'acceptation d'un emploi	9
3.3	Secteurs les plus demandés	9
3.4	Motivations ("raisons")	10
3.5	Données socio-professionnelles	10
4	Ajout des NA (suppressions de certaines données)	10
5	Analyse univariée :	11
5.1	Variables qualitatives	11
5.1.1	Genre	11

5.1.2	Métier	13
5.1.3	Type de contrat	14
5.1.4	Consultation de l'offre publique	15
5.2	Variables quantitatives	16
5.2.1	Tableau analytique des variables quantitatives	16
5.2.2	Attentes salariales : salaire_min et salaire_max	17
5.2.3	Expérience professionnelle : nb_exp	18
5.2.4	Nombre de secteurs potentiellement attractifs : nb_secteur	19
5.2.5	Nombre de critères jugés importants pour un emploi : nb_critère	20
5.2.6	Nombre de raisons pouvant motiver l'acceptation d'un emploi : nb_theme_raison	21
5.2.7	Conclusion de l'analyse univariée de ces six variables quantitatives	21
6	Analyse bivariable :	22
6.0.1	Variables quantitatives	22
6.0.2	Variables qualitatives	24
6.1	Variables qualitatives-quantitatives	27
6.1.1	Boxplot des variables quantitatives selon le genre	27
6.1.2	Violin plot	29
7	Aperçu des NA :	31
8	Traitement de NA :	33
8.1	Traitement des "NA" sur la colonne "consul_offre_pu"	33
8.1.1	Première méthode : Méthode de régression sur les NA de la variable "consul_offre_pu"	33
8.1.2	Seconde méthode : formulation d'hypothèse à l'aide de tendance observées	36
8.1.3	Troisième méthode : Utilisation de la fonction mice	37
8.1.4	Tableaux de comparaison des trois méthodes :	38
8.2	Traitement des "Na" sur les colonnes "salaire_min"	42
8.2.1	Préambule : traitement des valeurs aberrantes	42
8.2.2	Première méthode : régression linéaire	42
8.2.3	Deuxième méthode : médiane sur le genre et le nombre d'expérience	54
8.3	Traitement des "Na" sur la colonne "salaire_max"	56
8.3.1	Première méthode régression	57
8.3.2	Deuxième méthode : médiane sur le genre et le nombre d'expérience	71
8.3.3	Troisième méthode avec le package {mice}	73
8.4	Tableau de comparaison des différentes méthodes	77
8.4.1	Comparaison des différentes méthodes pour le salaire min	77
8.4.2	Comparaison des différentes méthodes pour le salaire max	77
8.5	Calcul des écarts moyen	78
9	Valeurs manquantes sur les variables souhaits	79
10	Conclusion	80

1 Introduction

Dans un contexte où les compétences numériques deviennent essentielles au sein des administrations publiques, la question de l’attractivité des métiers du numérique dans le secteur public occupe une place croissante. Afin de mieux comprendre les attentes, motivations et préférences de celles et ceux susceptibles de rejoindre ces métiers, Etalab a mené un sondage du premier au 22 juillet 2019 auprès d’un public intéressé par les fonctions de datascientist, designer, développeuse ou développeur au sein du service public. Diffusée largement via les réseaux sociaux d’Etalab, cette enquête a permis de recueillir 448 réponses, constituant ainsi un matériau riche pour analyser l’intérêt des professionnels du numérique envers la fonction publique.

Le questionnaire abordait plusieurs dimensions clés : les thématiques de travail privilégiées, les attentes relatives à l’environnement professionnel, les préférences en matière de localisation, ainsi que les prétentions salariales. Ces informations offrent une meilleure compréhension du profil des personnes susceptibles de se tourner vers les métiers publics du numérique, mais aussi des facteurs susceptibles de favoriser ou de freiner leur engagement.

Dans le cadre de ce travail, nous proposons d’analyser de manière approfondie la base de données issue de cette enquête. Dans un premier temps, nous organiserons et structurerons la base de données afin de garantir la qualité et la cohérence des informations exploitées. Nous mènerons ensuite une analyse descriptive univariée et bivariée afin d’examiner les caractéristiques des répondants, leurs motivations et leurs préférences professionnelles. Enfin, nous traiterons les différentes valeurs manquantes pour assurer la fiabilité de l’ensemble des analyses réalisées.

2 Jeu de données et premier traitement

2.1 Importation des packages

Nous importons les packages suivants :

```
library(tidyverse)
library(dplyr)
library(rcompanion)
library(reshape2)
library(viridis)
library(naniar)
library(stringr) library(leaps) library(mice)
```

2.2 import des données

```
chemin <- "C:/Users/samue/OneDrive/Documents/Cours/M1 ECAP/Bio statistiques/Projet/data.csv"
base <- read.csv(chemin)
```

2.3 Suppressions de certaines colonnes et renommage des variables

```
base$text.condition <- NULL
base$date <- NULL
base$text.autre.metier <- NULL
base$text.lieu <- NULL
```

```
base <- base |>
  rename(
    secteur = checkbox.themes,
    consul_offre_pu = radio.consulter.offres.publiques,
    rejoindre_pu = radio.rejoindre,
    raison = checkbox.pourquoi,
    type_contrat = radio.type.contrat,
    lieu = radio.lieu,
    salaire_min = number.salaire.min,
    salaire_max = number.salaire.souhait,
    genre = radio.genre,
    metier = radio.metiers,
    nb_exp = number.experience,
    critere = checkbox.acceptation,
    souhait = checkbox.souhaits
  )
```

2.4 Ajout de nouvelles variables à partir de celles existantes

2.4.1 SOUHAITS

On crée quatre nouvelles colonnes qui présente les différents souhaits formulés par chaque individu

2.4.2 SECTEUR

2.4.2.1 Secteurs les plus demandés

Les secteurs les plus demandés sont :

Écologie	Éducation nationale
319	239
Enseignement supérieur et recherche	Santé
224	205
Culture	lutte contre la fraude
186	160
Renseignement	Agriculture et alimentation
160	153
Interministériel	Justice
150	137
Sécurité / secours	Défense
126	117
Économie	Affaires étrangères
116	106
Sports	
98	

2.4.3 CRITERE

2.4.3.1 Critères les plus demandés

Les critères les plus demandés sont :

Avoir des horaires de travail flexibles	305
Être libre d'installer les logiciels dont j'ai besoin sur mon poste de travail	305
Pouvoir travailler 1-2 jours par semaine en télétravail	230
Avoir un accès à Internet sans aucun filtrage	224
Pouvoir utiliser mes logiciels habituels	213
Travailler en méthodes agiles	

	175
Pouvoir travailler sous GNU/Linux	172
conseil)	142
Pouvoir avoir une activité annexe (enseignement	142
Pouvoir démarrer en autonomie des serveurs	127
Pouvoir travailler à 80-100% en télétravail	114
Pouvoir prendre des jours de congés sans solde	108
Pouvoir travailler sous MacOS	87
Travailler 35h / semaine	67
Ne pas être soumis à des habilitations de sécurité / défense	47
Autre	22

2.4.4 RAISON

2.4.4.1 Raisons les plus demandées

Les raisons les plus demandées sont :

Servir l'intérêt général	374
Donner du sens à mon travail	261
Avoir un impact sur le quotidien	235
Travailler au côté de métiers différents du mien	89
Pour avoir un travail stable	81
Pour réorienter ma carrière	68
Pour ne pas faire uniquement des tâches techniques	

À partir de la base initiale composée de 13 variables, plusieurs transformations ont été réalisées afin d'enrichir l'analyse. La variable `souhait` a été décomposée en quatre variables ordinales (`souhait_1` à `souhait_4`), puis supprimée, tandis que de nouvelles variables qualitatives ont été créées pour coder les critères, secteurs et motivations déclarés. Des variables quantitatives supplémentaires ont également été générées, notamment le nombre de critères (`nb_critere`), le nombre de secteurs sélectionnés (`nb_secteur`) et le nombre de thèmes de motivation (`nb_theme_raison`). Au total, 15 nouvelles variables ont été ajoutées : 11 qualitatives (binaires ou catégorielles) et 4 quantitatives. La base finale comprend ainsi 28 variables.

```
# A tibble: 5 x 7
  secteur      consul_offre_pu rejoindre_pu raison souhait_1 souhait_2 souhait_3
  <chr>      <fct>      <fct>      <chr> <fct>      <fct>      <fct>
1 Écologie, J~ Non      Oui      Donne~ Au sein ~ Au sein ~ Au sein ~
2 Écologie, J~ Non      Je ne sais ~ Servi~ Au sein ~ Au sein ~ Au sein ~
3 Écologie, S~ Non      Oui      Donne~ Au sein ~ Au sein ~ <NA>
4 Écologie, É~ Non      Je ne sais ~ Donne~ Au sein ~ Au sein ~ Au sein ~
5 Éducation n~ Oui      Oui      Pour ~ Au sein ~ <NA>      <NA>
```

```
# A tibble: 5 x 8
  souhait_4      type_contrat lieu  salaire_min salaire_max critere genre metier
  <fct>      <fct>      <chr>      <dbl>      <dbl> <chr>  <fct> <fct>
1 Au sein d'une~ CDD (2-3 an~ En r~      3500      3900 Travail~ Un h~ Dével~
2 <NA>          CDI          En m~      3000      3500 Pouvoi~ Un h~ Dével~
3 <NA>          CDD (2-3 an~ En m~      2000      3000 Pouvoi~ Un h~ Dével~
4 <NA>          CDI          En m~      2000      2600 Pouvoi~ Une ~ Autre
5 <NA>          CDI          En m~      1800      2500 Avoir ~ Un h~ Admin~
```

```
# A tibble: 5 x 7
  nb_exp nb_secteur Écologie `Éducation nationale` Enseignement supérieur et r~1
  <dbl>      <dbl> <fct>      <fct>      <fct>
1 11 10 1 1 1
2 15 13 1 1 1
3 1 5 1 1 0
4 12 3 1 1 0
5 17 2 0 1 1
# i abbreviated name: 1: `Enseignement supérieur et recherche`
# i 2 more variables: nb_critere <dbl>,
# `Avoir des horaires de travail flexibles` <fct>
```

3 Présentation des variables

3.1 Préférences professionnelles

secteur Cette variable décrit le ou les secteurs d'activité dans lesquels les individus souhaiteraient travailler. De nature catégorielle multiple, elle permet de mesurer l'orientation professionnelle des répondants et d'identifier les domaines perçus comme les plus attractifs. Elle offre également la possibilité de repérer des affinités pour des secteurs associés au numérique, à l'écologie ou à l'éducation.

consul_offre_pu Cette variable indique si l'individu a déjà consulté des offres d'emploi dans le numérique au sein de la fonction publique. De type binaire, elle sert d'indicateur d'exposition préalable aux carrières publiques et peut refléter un intérêt ou une connaissance déjà existante du secteur public.

rejoindre_pu Elle précise si la personne envisage de rejoindre la fonction publique. Également binaire, cette variable mesure l'attractivité générale du secteur public et permet de mettre en perspective l'intention déclarée avec des comportements antérieurs, comme la consultation d'offres.

raison Cette variable regroupe les motivations exprimées pour travailler dans la fonction publique. Sous forme de texte ouvert (ou de thèmes catégorisés), elle permet d'analyser les motivations profondes telles que le sens du travail, l'impact sociétal ou la stabilité professionnelle. Elle est particulièrement utile pour une analyse qualitative.

souhait_1, souhait_2, souhait_3, souhait_4 Ces variables correspondent aux préférences concernant le lieu de travail. Elles permettent une analyse fine des préférences géographiques, l'identification des zones attractives et l'évaluation de la mobilité potentielle des répondants.

type_contrat Cette variable informe sur le type de contrat recherché (CDI, CDD, stage, apprentissage...). De nature catégorielle, elle permet d'évaluer les attentes de stabilité ou de flexibilité et peut être mise en relation avec le niveau d'expérience professionnelle.

lieu Elle décrit le lieu précis où l'individu souhaiterait travailler. En tant que variable catégorielle géographique, elle permet d'identifier des régions attractives et peut être croisée avec des critères comme le télétravail ou la mobilité.

salaire_min Cette variable représente le salaire minimum acceptable pour le répondant. Il s'agit d'une donnée quantitative continue qui renseigne sur le seuil de rémunération jugé acceptable et permet d'évaluer la correspondance entre attentes personnelles et marché de l'emploi.

salaire_max Elle indique le salaire idéal souhaité. De type quantitatif continu, elle permet d'appréhender les aspirations salariales. L'écart entre `salaire_min` et `salaire_max` constitue un indicateur de flexibilité ou d'ambition financière.

3.2 Critères d'acceptation d'un emploi

critere Cette variable regroupe l'ensemble des éléments jugés importants par les répondants pour accepter un poste. Issue de réponses multiples, elle permet d'identifier les attentes essentielles telles que la flexibilité, l'environnement de travail ou l'autonomie. Elle renseigne sur la compatibilité entre les attentes des candidats et les réalités de l'emploi public.

nb_critère Elle représente le nombre total de critères cités par une personne. De type quantitatif discret, ce décompte constitue un indicateur du niveau d'exigence professionnelle : plus ce nombre est élevé, plus l'individu se montre sélectif.

Avoir des horaires de travail flexibles Cette variable binaire indique si la personne a mentionné l'importance d'horaires flexibles, critère le plus cité dans l'échantillon. Elle souligne l'importance accordée à l'équilibre entre vie professionnelle et vie personnelle, particulièrement centrale dans les métiers du numérique.

Être libre d'installer les logiciels dont j'ai besoin Variable binaire également, elle indique si l'individu souhaite disposer d'une autonomie technique. Elle reflète une attente forte d'indépendance informatique, souvent associée à des profils technophiles ou expérimentés.

Pouvoir travailler 1–2 jours par semaine en télétravail Cette variable indique l'importance accordée au télétravail partiel. De type binaire, elle reflète les attentes actuelles en matière de flexibilité organisationnelle et permet de comparer les pratiques du secteur public avec celles du privé.

3.3 Secteurs les plus demandés

nb_secteur Cette variable indique le nombre total de secteurs qui intéressent la personne. De nature quantitative discrète, elle permet de mesurer l'étendue des intérêts professionnels et de distinguer les individus plutôt spécialisés de ceux plus polyvalents.

Écologie Il s'agit d'une variable binaire indiquant si l'écologie fait partie des secteurs sélectionnés. Très fréquemment citée, elle mesure l'attrait pour les métiers liés à l'environnement et peut signaler une sensibilité écologique marquée.

Éducation nationale Cette variable binaire indique si le secteur de l'éducation nationale a été choisi. Elle renseigne sur l'intérêt pour les métiers liés à la pédagogie, à l'encadrement ou au soutien scolaire.

Enseignement supérieur et recherche Variable également binaire, elle signale un intérêt pour les métiers du supérieur ou de la recherche, souvent associés à des profils diplômés ou orientés vers l'innovation et la production de connaissances.

3.4 Motivations (“raisons”)

nb_theme_raison Cette variable correspond au nombre total de raisons évoquées pour justifier un intérêt envers la fonction publique. Elle fournit un indicateur du niveau de motivation ou du degré d’argumentation apporté par les répondants.

Servir l’intérêt général Variable binaire indiquant si cette motivation — la plus citée — a été mentionnée. Elle mesure l’attachement aux valeurs de service public et caractérise souvent des profils engagés socialement.

Donner du sens à mon travail Cette variable indique si le répondant a mentionné la recherche de sens au travail. Très fréquemment citée, elle témoigne d’une volonté d’exercer une activité en cohérence avec des convictions personnelles.

Avoir un impact sur le quotidien Elle renseigne sur la volonté d’avoir une utilité sociale concrète. Cette motivation, également courante, est souvent associée à des profils orientés vers l’opérationnel et l’action directe.

3.5 Données socio-professionnelles

genre Cette variable catégorielle indique le genre déclaré de la personne. Elle permet d’intégrer une perspective d’analyse genrée, notamment en comparant tendances, préférences et attentes salariales entre groupes.

metier Elle correspond au métier actuellement exercé. De type catégoriel texte, elle fournit des informations sur le parcours professionnel d’origine et peut éclairer les attentes sectorielles et salariales.

nb_exp Cette variable indique le nombre d’années d’expérience professionnelle. Quantitative continue, elle constitue un indicateur de niveau d’expertise qui influence généralement les critères recherchés, les prétentions salariales et le type de contrat souhaité.

4 Ajout des NA (suppressions de certaines données)

Notre base ne contenant pas assez de valeurs manquantes, nous avons décidé de supprimer aléatoirement 15 % des données présentes parmi les variables :

-salaire_min
-salaire_max
-consul_offre_pu

Cette suppression aléatoire permet de conserver la structure globale des données tout en créant de véritables problématiques de valeurs manquantes.

Ce choix méthodologique nous permet d'obtenir des valeurs manquantes à la fois sur des variables quantitatives, comme les salaires, et sur une variable qualitative binaire, ce qui rend l'exercice plus complet et plus réaliste, car il reflète les situations fréquemment rencontrées dans des bases de données réelles.

De plus, le type de données manquantes identifié pourrait correspondre aux trois catégories classiques de valeurs NA : not applicable (non applicable), available but not answered (disponible mais non renseigné) et answered (renseigné), dans le cas où ces dernières étaient effectivement présentes initialement dans la base de données. Cette distinction est essentielle, car elle permet de mieux comprendre l'origine des valeurs manquantes et d'éviter toute confusion entre une absence réelle d'information et une donnée non pertinente ou omise lors de la collecte

```
set.seed(123)

base <- base |>
  mutate(salaire_min = replace(salaire_min,
                              sample(1:n(), size = 0.15 * n()),
                              NA))

base <- base |>
  mutate(salaire_max = replace(salaire_max,
                              sample(1:n(), size = 0.15 * n()),
                              NA))

base <- base |>
  mutate(consul_offre_pu = replace(consul_offre_pu,
                                   sample(1:n(), size = 0.15 * n()),
                                   NA))
```


5 Analyse univariée :

5.1 Variables qualitatives

Notre échantillon est constitué de 448 individus distincts. Une analyse descriptive univariée permet d'obtenir une première vision claire de la composition de cette population et de mieux comprendre ses caractéristiques générales.

5.1.1 Genre


Le graphique et le tableau ci-dessous présentent la distribution des genres au sein de notre échantillon :



```
# A tibble: 3 x 2
  genre      n
  <fct>    <int>
1 Refuse de se prononcer 18
2 Un homme             323
3 Une femme            107
```

On observe que l'échantillon est très majoritairement composé d'hommes, avec 323 individus masculins recensés. Les femmes représentent 107 personnes, soit une proportion nettement plus faible. Enfin, 18 répondants ont choisi de ne pas renseigner leur genre, ce qui constitue une part marginale de l'échantillon.

5.1.2 Métier



A tibble: 12 x 2

metier	n
<fct>	<int>
1 Administration système	41
2 Autre	106
3 Communication	17
4 Data scientist	60
5 Design de services	20
6 Design UI/UX	7
7 Développement backend	35
8 Développement frontend	10
9 Développement fullstack	88
10 Développement mobile	6
11 Marketing	13
12 Product management	45


Nous pouvons également examiner les professions exercées par les individus. Cette variable met en évidence plusieurs groupes professionnels dominants :

- Les data scientists,
- les développeurs full stack,

- les métiers de product management,
- les professions liées à l'administration système.

On note également une proportion importante de réponses classées dans la catégorie « autre », ce qui témoigne de la diversité des métiers exercés par les participants, certains n'entrant pas directement dans les catégories proposées dans le questionnaire.



5.1.3 Type de contrat



Les données recueillies permettent aussi d'analyser la nature des contrats des individus. La très grande majorité des répondants sont employés en CDI, ce qui suggère une population relativement stable professionnellement. Les autres modalités sont réparties entre :

- des CDD de 2 à 3 ans,
- des statuts de freelance ou encore du portage salarial.

5.1.4 Consultation de l'offre publique



L'objectif principal du questionnaire étant d'évaluer l'attractivité des métiers du numérique dans le secteur public, deux variables sont particulièrement pertinentes :

1. La consultation d'offres d'emploi du secteur public
2. L'envie de rejoindre le secteur public

L'analyse montre que les répondants sont majoritairement indécis quant à leur volonté de rejoindre le secteur public. Parmi ceux qui prennent position, les individus déclarant vouloir rejoindre le public sont plus nombreux que ceux affirmant ne pas être intéressés. Concernant la consultation d'offres, la distribution est équilibrée : on observe autant de personnes ayant déjà consulté des offres publiques que de personnes ne l'ayant jamais fait. Cela suggère que, même si l'intérêt explicite pour le secteur public reste flou, une partie significative des individus manifeste malgré tout de la curiosité pour les opportunités disponibles.

5.2 Variables quantitatives

Le questionnaire nous fournit initialement des informations sur trois variables de nature quantitative. À partir des données recueillies, nous avons également créé trois variables quantitatives supplémentaires : le nombre de secteurs pouvant intéresser un individu, le nombre de critères jugés importants pour rejoindre un emploi, et le nombre de raisons pouvant motiver une personne à accepter un poste.



5.2.1 Tableau analytique des variables quantitatives

Le tableau ci-dessous présente les indicateurs descriptifs principaux de ces six variables, permettant une compréhension fine des profils et attentes des répondants.

```
# A tibble: 6 x 4
```

	variable	Moyenne	Minimum	Maximum
	<chr>	<dbl>	<dbl>	<dbl>
1	salaire_min	2985.	1	8000
2	salaire_max	3629.	1400	10000
3	nb_exp	10.9	1	40
4	nb_secteur	5.57	1	15
5	nb_critère	5.54	1	14
6	nb_theme_raison	2.6	1	6


5.2.2 Attentes salariales : salaire_min et salaire_max



Les répondants indiquent un salaire minimum moyen de 2 985 € et un salaire maximum moyen de 3 628 €. L'écart d'environ 643 € représente la marge de flexibilité que les individus


s'accordent lors d'une négociation salariale. Les maxima relevés (jusqu'à 8 000 € pour le salaire minimum et 10 000 € pour le salaire maximum) montrent que certains participants visent des postes très qualifiés ou à forte responsabilité. À l'inverse, les minima extrêmement faibles (1 € pour le salaire minimum et 1 400 € pour le salaire maximum) sont probablement des erreurs de saisie ou des valeurs manquantes codées, et ne reflètent pas la réalité. Malgré cela, la tendance générale indique que la population interrogée présente des attentes salariales relativement élevées, en cohérence avec les métiers du numérique représentés dans l'échantillon.

5.2.3 Expérience professionnelle : nb_exp



Le nombre moyen d'années d'expérience est de 10,88 ans, avec des valeurs allant de 1 à 40 ans. Cette dispersion importante constitue un avantage analytique : elle permet d'inclure à la fois des personnes très expérimentées et des profils débutants. Cela enrichit l'étude, car les motivations, attentes salariales ou encore l'intérêt pour certains secteurs peuvent varier fortement en fonction du niveau d'expérience. Cette variable est donc essentielle pour interpréter les comportements et attentes observés dans les autres dimensions du questionnaire.


5.2.4 Nombre de secteurs potentiellement attractifs : nb_secteur



Les individus déclarent en moyenne être intéressés par 5,57 secteurs, avec des valeurs allant de 1 à 15 secteurs. Ces résultats révèlent plusieurs éléments importants :

- les répondants ne se limitent pas à un domaine professionnel unique -ils présentent une ouverture professionnelle marquée, pouvant refléter une recherche active ou une volonté de reconversion
- cette variable pourra enrichir l'analyse de l'attractivité du secteur public, car un individu ouvert à de nombreux secteurs peut avoir davantage de chances de considérer également le secteur public.

5.2.5 Nombre de critères jugés importants pour un emploi : nb_critère




Les répondants identifient en moyenne 5,54 critères essentiels, avec une amplitude de 1 à 14 critères. Cette variable apporte un éclairage précieux sur la complexité du processus de décision professionnelle :

- les individus ne se focalisent pas sur un seul aspect (par exemple le salaire),
- mais prennent en compte plusieurs dimensions simultanées : conditions de travail, équilibre vie professionnelle/vie personnelle, missions proposées, sécurité de l'emploi, possibilités d'évolution, culture organisationnelle ...

Le nombre élevé de critères chez certains répondants indique une vision exigeante et multidimensionnelle du travail, susceptible d'influencer leur perception de l'offre publique.

5.2.6 Nombre de raisons pouvant motiver l'acceptation d'un emploi : nb_theme_raison



Les individus citent en moyenne 2,60 raisons, avec des valeurs allant de 1 à 6 raisons. Cette variable met en évidence que les motivations professionnelles reposent sur un ensemble de leviers potentiels, tels que :

- une meilleure rémunération,
- des missions plus stimulantes,
- un environnement de travail plus agréable,
- des opportunités d'évolution,
- la stabilité ou la sécurité de l'emploi.

La diversité des raisons exprimées permet de mieux comprendre les dynamiques d'attractivité et de mobilité professionnelle dans le secteur du numérique.

5.2.7 Conclusion de l'analyse univariée de ces six variables quantitatives

Ces six variables quantitatives apportent une vision riche et détaillée des répondants :

- des attentes salariales élevées,
- une forte diversité d'expérience,
- une ouverture marquée à de nombreux secteurs,
- une prise de décision reposant sur plusieurs critères,
- et plusieurs facteurs de motivation potentiels.

Ces éléments constituent un socle essentiel pour l'analyse de l'attractivité du secteur public dans le domaine numérique, car ils permettent d'interpréter de manière fine les choix, hésitations et préférences des individus.

6 Analyse bivariable :

6.0.1 Variables quantitatives

Variable : salaire_min

Shapiro-Wilk normality test

```
data: base[[var]]  
W = 0.89689, p-value = 2.251e-15
```

Variable : salaire_max

Shapiro-Wilk normality test

```
data: base[[var]]  
W = 0.87642, p-value < 2.2e-16
```

Variable : nb_exp

Shapiro-Wilk normality test

```
data: base[[var]]  
W = 0.9337, p-value = 3.246e-13
```

Variable : nb_secteur

Shapiro-Wilk normality test

```
data: base[[var]]  
W = 0.91502, p-value = 3.524e-15
```

Variable : nb_critère

Shapiro-Wilk normality test

data: base[[var]]

W = 0.96567, p-value = 9.786e-09

Variable : nb_thème_raison


Shapiro-Wilk normality test

data: base[[var]]

W = 0.90703, p-value = 6.301e-16

Les tests de Shapiro-Wilk montrent des p-values très faibles pour les différentes variables quantitatives, indiquant que ces variables ne suivent pas une loi normale. Par conséquent, l'hypothèse de normalité nécessaire à la corrélation de Pearson n'est pas respectée. Il est donc préférable d'utiliser une corrélation non paramétrique, comme celle de Spearman.

Corrélations entre variables quantitatives



La matrice de corrélation de Spearman met en évidence plusieurs relations intéressantes entre les variables quantitatives. On observe d'abord une corrélation très forte et positive entre le salaire minimum et le salaire maximum ($p = 0,93$), ce qui indique que les personnes qui

exigent un salaire minimal plus élevé formulent également des attentes salariales maximales plus importantes.


L'expérience professionnelle présente une corrélation modérée avec les salaires proposés ($p = 0,32/0,33$), suggérant que les individus ayant davantage d'expérience tendent à demander une rémunération plus élevée, ce qui est cohérent avec les tendances du marché du travail.

Il existe également une faible corrélation entre le nombre de motivations exprimées et le nombre de secteur demandé par l'individu. Quand le nombre de secteurs d'intérêt augmente, le nombre de motivations exprimées tend aussi à augmenter.

Les autres corrélations sont faibles, voire proches de zéro.

Ainsi, en dehors du lien attendu entre les deux variables salariales et de l'effet modéré de l'expérience, les relations entre les différentes variables apparaissent globalement faibles, indiquant que ces dimensions reflètent des aspects assez indépendants du profil et des préférences des répondants.

6.0.2 Variables qualitatives



	Var1	Var2	value
1	consul_offre_pu	consul_offre_pu	1.00000
2	rejoindre_pu	consul_offre_pu	0.16430
3	type_contrat	consul_offre_pu	0.01462

4	lieu	consul_offre_pu	0.09445
5	genre	consul_offre_pu	0.13200
6	consul_offre_pu	rejoindre_pu	0.16430
7	rejoindre_pu	rejoindre_pu	1.00000
8	type_contrat	rejoindre_pu	0.10570
9	lieu	rejoindre_pu	0.03755
10	genre	rejoindre_pu	0.09102
11	consul_offre_pu	type_contrat	0.01462
12	rejoindre_pu	type_contrat	0.10570
13	type_contrat	type_contrat	1.00000
14	lieu	type_contrat	0.04409
15	genre	type_contrat	0.09191
16	consul_offre_pu	lieu	0.09445
17	rejoindre_pu	lieu	0.03755
18	type_contrat	lieu	0.04409
19	lieu	lieu	1.00000
20	genre	lieu	0.09321
21	consul_offre_pu	genre	0.13200
22	rejoindre_pu	genre	0.09102
23	type_contrat	genre	0.09191
24	lieu	genre	0.09321
25	genre	genre	1.00000

L'analyse de la matrice de corrélation basée sur le coefficient de Cramer V met en évidence des associations globalement faibles, mais néanmoins informatives, entre les variables qualitatives étudiées.


La relation la plus marquée concerne rejoindre_pu (l'intention de rejoindre le secteur public) et consul_offre_pu (la consultation d'offres d'emploi publiques), avec un coefficient de 0,164. Bien que modérée, cette association est la plus élevée du tableau et traduit une cohérence comportementale : les individus intéressés par le secteur public sont plus enclins à consulter des offres correspondantes.

Une association plus limitée apparaît également entre rejoindre_pu et type_contrat (Cramer V 0,106). Cela suggère que le type de contrat recherché joue un rôle, certes modeste, dans l'intérêt pour le secteur public, sans pour autant constituer un facteur déterminant. Les variables consul_offre_pu et genre présentent aussi une relation faible (0,132), indiquant que le genre pourrait marginalement être associé au fait de consulter des offres publiques, mais sans différence structurante.

En revanche, la variable lieu affiche des coefficients très faibles avec l'ensemble des autres variables (tous inférieurs à 0,10). Cela indique que le lieu de travail souhaité est largement indépendant de la motivation à rejoindre le secteur public, de la consultation d'offres, du type de contrat recherché ou du genre.

De manière générale, cette matrice montre que les comportements et préférences liés au secteur public sont faiblement interconnectés. Les associations observées vont dans un sens logique et attendu, mais leur intensité reste limitée, suggérant que d'autres facteurs non observés jouent probablement un rôle plus important dans les décisions et motivations étudiées.

Matrice de corrélation des variables qualitatives (Cramer's V)



Cette matrice de corrélation des variables qualitatives révèle que la plupart des variables sont faiblement associées entre elles, comme le montre la prédominance de couleurs sombres. Cela indique que les préférences géographiques (souhait_1, souhait_2, souhait_3), les secteurs d'intérêt (écologie, educ_nat, ens_sup_rech), les critères d'acceptation d'un poste et les motivations personnelles constituent des dimensions relativement indépendantes.

Quelques relations plus marquées apparaissent néanmoins, notamment entre certains critères et motivations. On observe par exemple une proximité entre les variables liées à la recherche de sens au travail, au service de l'intérêt général et à l'impact au quotidien, suggérant qu'elles décrivent un même ensemble de valeurs professionnelles. De même, les critères tels que les horaires flexibles, l'autonomie logicielle ou la possibilité de télétravailler présentent des liens plus visibles avec le nombre total de critères déclarés.


En revanche, les préférences de lieu (souhait_1 à souhait_3) et les secteurs souhaités semblent peu corrélés avec ces éléments, ce qui montre que les choix géographiques ou sectoriels des répondants ne dépendent pas fortement de leurs motivations ou de leurs conditions de travail recherchées.

Dans l'ensemble, la matrice suggère que seules certaines familles de variables — en particulier les motivations et quelques critères de travail — présentent des liens cohérents, tandis que la

majorité des autres variables qualitatives restent indépendantes, traduisant la diversité des profils et des attentes des répondants.

6.1 Variables qualitatives-quantitatives

6.1.1 Boxplot des variables quantitatives selon le genre



Analyse comparative des boxplots selon le genre

L'analyse des boxplots met en évidence les différences et similitudes entre les répondants selon le genre pour plusieurs variables quantitatives liées au parcours professionnel, aux critères de choix et aux attentes salariales. Globalement, on observe un chevauchement important des distributions entre hommes et femmes, suggérant des profils relativement proches sur de nombreux indicateurs. Néanmoins, certaines variables présentent des écarts plus marqués, notamment en matière d'expérience et de rémunération.

Critères et diversité des motivations

Le nombre de critères pris en compte (nb_critère) est relativement comparable entre les genres. Les médianes sont proches, bien que les hommes présentent une dispersion légèrement plus importante, indiquant une plus grande variabilité dans le nombre de critères mobilisés. Les femmes semblent davantage concentrées autour de valeurs intermédiaires, traduisant une plus grande homogénéité dans leurs réponses.

De même, le nombre de thèmes évoqués parmi les raisons (nb_theme_raison) est globalement similaire entre hommes et femmes. Toutefois, la médiane apparaît légèrement plus élevée chez les femmes, ce qui pourrait suggérer une diversité un peu plus grande dans les motivations exprimées.

Expérience professionnelle et parcours

Concernant le nombre d'années d'expérience (nb_exp), les distributions révèlent une variabilité plus forte chez les hommes, avec des valeurs extrêmes plus élevées. Les médianes restent néanmoins relativement proches entre hommes et femmes, ce qui indique que, en moyenne, leurs niveaux d'expérience sont comparables. Cette dispersion accrue chez les hommes peut traduire des parcours professionnels plus hétérogènes.

Le nombre de secteurs d'activité (nb_secteur) montre une structure similaire. Les hommes présentent à nouveau une dispersion plus importante, tandis que les femmes se concentrent davantage autour de valeurs centrales. Cela suggère que les femmes ont des parcours légèrement plus homogènes en termes de mobilité sectorielle.

Salaires déclarés

Les différences les plus nettes apparaissent pour les variables salariales. Les boxplots de salaire_min et salaire_max indiquent que les hommes déclarent des salaires plus élevés, avec des médianes supérieures et une dispersion plus large. Les femmes, quant à elles, présentent des distributions plus resserrées et des valeurs centrales plus faibles. Ces écarts peuvent refléter des différences de rémunération, de positionnement professionnel ou de négociation salariale, phénomènes largement documentés dans la littérature sur le marché du travail.

Le groupe « refuse de se prononcer »


La catégorie des répondants ayant refusé de se prononcer sur leur genre est de taille réduite. Cette faiblesse des effectifs se traduit par des boxplots plus instables et une variabilité parfois marquée. Les résultats concernant ce groupe doivent donc être interprétés avec une grande prudence, sans en tirer de conclusions générales.

Conclusion générale


Dans l'ensemble, l'analyse montre que les priorités professionnelles, la diversité des critères et les parcours sont globalement similaires entre hommes et femmes, avec des différences limitées en termes de médianes. Les écarts les plus significatifs concernent les variables salariales, où les hommes déclarent des niveaux plus élevés et plus dispersés. On observe également une tendance des femmes à exprimer une diversité légèrement plus importante dans leurs motivations, tandis que les hommes présentent des parcours professionnels plus hétérogènes.

6.1.2 Violin plot


Distribution des variables quantitatives selon le fait d'avoir con




Distribution des variables quantitatives selon l'envie de rejoindre



Distribution des variables quantitatives selon le type de contrat



Distribution des variables quantitatives selon le lieu de travail



Dans l'ensemble, les différentes segmentations étudiées (la consultation d'offres publiques, l'intention de rejoindre le secteur public, le type de contrat et le lieu de résidence) montrent que les variables quantitatives du questionnaire présentent des distributions largement similaires entre les groupes. Les individus, quel que soit leur profil, évaluent un emploi avec un nombre

comparable de critères importants, se montrent intéressés par un éventail similaire de secteurs et évoquent un nombre voisin de raisons pour accepter un poste.


Les différences observées restent globalement modestes. Selon les sous-groupes, quelques variations apparaissent concernant l'expérience professionnelle : les freelances disposent souvent d'une expérience plus importante, et les habitants de la région parisienne ou ceux souhaitant y travailler montrent aussi une tendance à être plus expérimentés. Toutefois, ces écarts n'altèrent pas la structure générale, marquée par une forte homogénéité.

Les attentes salariales, minimales comme maximales, sont elles aussi très proches entre les catégories, avec seulement quelques nuances : les freelances affichent une dispersion salariale supérieure, et les habitants ou personnes souhaitant travailler en région parisienne expriment des attentes plus hautes, probablement liées au coût de la vie. Ces tendances restent néanmoins limitées.

Globalement, ces résultats indiquent que les attentes professionnelles, les motivations et les comportements déclarés demeurent largement comparables, indépendamment du rapport au secteur public, du type de contrat ou du lieu de vie. Les différences perçues tiennent davantage à des contextes spécifiques (freelance, région parisienne) qu'à des ruptures nettes entre les groupes.

7 Aperçu des NA :

```
#| echo: false  
  
gg_miss_upset(base, nset = 7)
```



Le graphique permet d'analyser la structure des valeurs manquantes dans les sept variables de la base de données. Parmi celles-ci, trois variables (**souhait_2**, **souhait_3** et **souhait_4**) correspondent respectivement au deuxième, troisième et quatrième choix de structure où les répondants souhaiteraient travailler. Les valeurs manquantes dans ces variables ne constituent pas un problème d'information manquante au sens strict : elles apparaissent de manière logique, puisque lorsqu'un répondant n'exprime pas de deuxième souhait, il ne peut pas non plus formuler de troisième ou de quatrième. Ces NA reflètent donc simplement l'absence de rangs supplémentaires de préférences et ne doivent pas être interprétés comme des données perdues.

En conséquence, l'analyse des valeurs manquantes doit se concentrer sur les autres variables réellement concernées : **salaire_min**, **salaire_max** et **consul_offre_pu** (ainsi que sa version binaire, qui reprend mécaniquement les mêmes NA). Pour ces variables, le graphique montre que les données manquantes ne sont pas réparties de façon aléatoire. Certaines variables présentent un volume important de NA, et plusieurs intersections regroupent un nombre élevé d'observations partageant exactement les mêmes colonnes manquantes (jusqu'à plus de 80 cas dans une même combinaison). Cela indique l'existence de patterns cohérents, suggérant que les valeurs manquantes pourraient être liées à un même contexte ou un même comportement de réponse.

Ces résultats invitent à porter une attention particulière au traitement des NA dans ces variables clés : soit en envisageant une imputation, soit en étudiant les raisons possibles de l'absence de réponse (par exemple réticence à déclarer un salaire, difficulté à estimer une fourchette, ou non-consultation des offres publiques). Comprendre ces mécanismes sera essentiel pour garantir la qualité et l'interprétabilité des analyses ultérieures.

8 Traitement de NA :

8.1 Traitement des “NA” sur la colonne “consul_offre_pu”

8.1.1 Première méthode : Méthode de régression sur les NA de la variable “consul_offre_pu”

8.1.1.1 Ajout de la variable binaire

Dans un premier temps, on crée une nouvelle variable binaire `consul_offre_pu_bi` à partir de la variable catégorielle `consul_offre_pu` :

- “Oui” est codé en 1
- “Non” est codé en 0

Cette variable servira de variable dépendante pour la régression logistique.

8.1.1.2 Création du jeu de donnée entraînement

Ensuite, nous constituons le jeu de données d’entraînement `consul_offre_entrainement` en conservant uniquement les lignes pour lesquelles `consul_offre_pu_bi` n’est pas manquante. On obtient ainsi un jeu de données complet, utilisable pour entraîner le modèle.

8.1.1.3 Choix du modèle de régression selon la méthode step

On réalise ensuite plusieurs étapes pour sélectionner le modèle optimal à notre régression :

1. On ajuste un modèle de régression logistique complet (`modele`) :
 - variable à expliquer : `consul_offre_pu_bi` (Oui/Non codé en 1/0),
 - variables explicatives : caractéristiques du poste, du répondant, motivations ...
 - On sélectionne entraînement qui ne contient pas de NA pour notre modèle de régression qui doit être entraîné uniquement sur les données qui ont une valeur connue (non NA) pour la variable à prédire.
2. On ajuste un modèle nul (`modele0`) qui ne contient qu’une constante.
3. On applique ensuite une sélection de variables pas à pas (`step`) en partant du modèle nul et en explorant tous les modèles possibles entre `modele0` et `modele` (direction “both” autrement dit “dans les deux sens”).
4. L’objet `reg_step` contient le modèle final retenu selon le critère AIC, et `summary(reg_step)` en affiche le résumé (coefficients, significativité, etc.).

Notre modèle final est donc :

```
Call:
glm(formula = consul_offre_pu_bi ~ `Enseignement supérieur et recherche` +
  `Pouvoir travailler 1-2 jours par semaine en télétravail` +
  genre + Écologie + nb_secteur, family = binomial, data = consul_offre_entrainement)
```

Coefficients:

	Estimate	Std. Error
(Intercept)	0.64431	0.70827
`Enseignement supérieur et recherche`1	0.63198	0.23647
`Pouvoir travailler 1-2 jours par semaine en télétravail`1	0.54171	0.21839
genreUn homme	-1.67082	0.68034
genreUne femme	-1.34110	0.70052
Écologie1	-0.63296	0.25646
nb_secteur	0.12260	0.04082

	z value	Pr(> z)
(Intercept)	0.910	0.36298
`Enseignement supérieur et recherche`1	2.673	0.00753 **
`Pouvoir travailler 1-2 jours par semaine en télétravail`1	2.480	0.01312 *
genreUn homme	-2.456	0.01405 *
genreUne femme	-1.914	0.05556 .
Écologie1	-2.468	0.01359 *
nb_secteur	3.004	0.00267 **

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 527.86 on 380 degrees of freedom
 Residual deviance: 486.19 on 374 degrees of freedom
 AIC: 500.19

Number of Fisher Scoring iterations: 4

La méthode STEP a ainsi permis de sélectionner le modèle le plus pertinent : on constate que l'ensemble des variables retenues pour notre modèle de régression apparaissent comme étant significatives.

8.1.1.4 Création de la colonne avec les valeurs prédites

Dans notre cas, il n'est pas nécessaire de passer par un jeu de test classique pour évaluer la performance du modèle. En effet, nous disposons d'une version de la base initiale sans valeurs

manquantes : nous pouvons donc appliquer directement notre modèle sur la base contenant les NA imputés, puis comparer les valeurs prédites aux valeurs réelles de la base initiale. Cette comparaison permet de mesurer précisément l'accuracy de l'imputation, sans nécessiter de séparation supplémentaire entre entraînement et test.

On crée donc une nouvelle colonne qui contient les valeurs prédites "Oui" ou "Non" par notre modèle en fonction de la probabilité déterminée par notre modèle de régression.

8.1.1.5 Evaluation de la qualité de notre modèle

Confusion Matrix and Statistics

```

      Reference
Prediction Oui Non
      Oui 128  98
      Non  72 150

      Accuracy : 0.6205
      95% CI : (0.5738, 0.6657)
      No Information Rate : 0.5536
      P-Value [Acc > NIR] : 0.002408

      Kappa : 0.2418

      McNemar's Test P-Value : 0.055186

      Sensitivity : 0.6400
      Specificity : 0.6048
      Pos Pred Value : 0.5664
      Neg Pred Value : 0.6757
      Prevalence : 0.4464
      Detection Rate : 0.2857
      Detection Prevalence : 0.5045
      Balanced Accuracy : 0.6224

      'Positive' Class : Oui

```

Le modèle utilisé pour imputer les valeurs manquantes de la variable « consulter l'offre publique » présente une accuracy de 62,05 %, ce qui signifie qu'il parvient à retrouver correctement la valeur réelle dans un peu plus de six cas sur dix. La balanced accuracy (62,24 %) montre que les performances sont relativement équilibrées entre la détection des « Oui » et des « Non ».

Les indicateurs de sensibilité (0,64) et de spécificité (0,6048) indiquent que le modèle distingue les deux modalités avec une efficacité modérée, sans déséquilibre majeur entre faux positifs et faux négatifs.


Même si les performances sont moins élevées qu'un modèle très prédictif, elles restent suffisantes pour fournir une imputation cohérente et limiter l'impact des valeurs manquantes dans l'analyse. Le modèle offre donc une solution raisonnablement fiable pour compléter la variable indiquant si les individus ont consulté ou non des offres publiques.

8.1.2 Seconde méthode : formulation d'hypothèse à l'aide de tendance observées

Etant donné que quelqu'un qui regarde les offres d'emploi public est corrélé avec le fait d'avoir envie de rejoindre le public (voir matrice de cramer dans l'analyse descriptive bivariée), on peut émettre une hypothèse comme quoi les valeurs manquantes de la variable `consul_offre_pu` pourraient être remplacé comme ceci :

-Oui : si la personne est intéressée par le fait de rejoindre le public
-Non : si l'individu n'est pas intéressée par l'envie de rejoindre le public

De plus dans le graphique ci-dessous :



On observe que si une personne a désigné plus de 6 secteurs (ou elle souhaiterait travailler) dans le questionnaires, il est plus probable que cette dernière est déjà consulté l'offre public.

On pourrait donc formuler l'hypothèse suivante :

Si l'individu a envie de rejoindre le public ou a plus de 6 secteurs pour la variable `nb_secteur` on remplace la valeur manquante par **Oui**.

Si l'individu n'a pas envie de rejoindre le public ou a moins de 6 secteurs pour la variable `nb_secteur` on remplace la valeur manquante par **Non**.

8.1.3 Troisième méthode : Utilisation de la fonction `mice`

On utilise l'algorithme du package `mice` afin de déterminer quelle serait la technique d'imputation optimale pour la variable selon la méthode statistique MICE (Multiple Imputation by Chained Equations).

```
secteur
""
consul_offre_pu
"logreg"
rejoindre_pu
""
raison
""
souhait_1
""
souhait_2
"polyreg"
souhait_3
"logreg"
souhait_4
""
type_contrat
""
lieu
""
salaire_min
"pmm"
salaire_max
"pmm"
critere
""
genre
""
metier
""
nb_exp
```

```

        ""
        nb_secteur
        ""
        Écologie
        ""
        Éducation nationale
        ""
        Enseignement supérieur et recherche
        ""
        nb_critère
        ""
        Avoir des horaires de travail flexibles
        ""
Être libre d'installer les logiciels dont j'ai besoin sur mon poste de travail
        ""
        Pouvoir travailler 1-2 jours par semaine en télétravail
        ""
        nb_theme_raison
        ""
        Servir l'intérêt général
        ""
        Donner du sens à mon travail
        ""
        Avoir un impact sur le quotidien
        ""
        consul_offre_pu_prédit_méthode_1
        ""
        consul_offre_pu_prédit_méthode_2
        ""

```

L'algorithme mice attribue automatiquement une méthode d'imputation à chaque variable en fonction de son type. Dans notre cas, la variable `consul_offre_pu`, qui est binaire (« Oui » / « Non »), a été associée à la méthode “logreg”, comme l'indique la sortie de `mice$method`. Cela signifie que mice recommande d'utiliser un modèle de régression logistique pour imputer les valeurs manquantes de cette variable. Étant donné que mice recommande la méthode “logreg” pour imputer la variable `consul_offre_pu`, nous allons donc pouvoir comparer le modèle de régression logistique généré par mice avec celui que nous avons réalisé précédemment, afin d'évaluer la cohérence des prédictions obtenues par les deux approches.

8.1.4 Tableaux de comparaison des trois méthodes :

```
# A tibble: 5 x 2
```

	valeur_réelle	valeur_régression
	<fct>	<chr>
1	Oui	Non
2	Oui	Non
3	Non	Non
4	Oui	Oui
5	Non	Non

```
# A tibble: 5 x 2
  valeur_hypothétique valeur_mice
  <chr>               <fct>
1 Oui                Oui
2 Oui                Non
3 Oui                Oui
4 Oui                Non
5 Oui                Oui
```

On réalise donc trois matrices de confusion (respectivement dans l'ordre pour la méthode 1 ; 2 et 3) afin de comparer les trois méthodes de remplacement :

Confusion Matrix and Statistics

	Reference	
Prediction	Non	Oui
Non	15	11
Oui	21	20

Accuracy : 0.5224
 95% CI : (0.3967, 0.646)
 No Information Rate : 0.5373
 P-Value [Acc > NIR] : 0.6442

Kappa : 0.0605

McNemar's Test P-Value : 0.1116

Sensitivity : 0.4167
 Specificity : 0.6452
 Pos Pred Value : 0.5769
 Neg Pred Value : 0.4878
 Prevalence : 0.5373
 Detection Rate : 0.2239

Detection Prevalence : 0.3881
Balanced Accuracy : 0.5309

'Positive' Class : Non

Confusion Matrix and Statistics

	Reference	
Prediction	Oui	Non
Oui	33	8
Non	14	12

Accuracy : 0.6716
95% CI : (0.546, 0.7815)
No Information Rate : 0.7015
P-Value [Acc > NIR] : 0.7508

Kappa : 0.2782

McNemar's Test P-Value : 0.2864

Sensitivity : 0.7021
Specificity : 0.6000
Pos Pred Value : 0.8049
Neg Pred Value : 0.4615
Prevalence : 0.7015
Detection Rate : 0.4925
Detection Prevalence : 0.6119
Balanced Accuracy : 0.6511

'Positive' Class : Oui

Confusion Matrix and Statistics

	Reference	
Prediction	Non	Oui
Non	11	15
Oui	20	21

Accuracy : 0.4776

95% CI : (0.354, 0.6033)
No Information Rate : 0.5373
P-Value [Acc > NIR] : 0.8648

Kappa : -0.0625

McNemar's Test P-Value : 0.4990

Sensitivity : 0.3548
Specificity : 0.5833
Pos Pred Value : 0.4231
Neg Pred Value : 0.5122
Prevalence : 0.4627
Detection Rate : 0.1642
Detection Prevalence : 0.3881
Balanced Accuracy : 0.4691

'Positive' Class : Non

L'analyse des matrices de confusion obtenues sur les valeurs manquantes uniquement met en évidence des différences importantes entre les trois méthodes d'imputation testées. Les méthodes 1 et 3 (respectivement le modèle de régression construit manuellement et l'imputation par régression via MICE) présentent une accuracy relativement faible (environ 52 % et 55 %). Ces performances ne sont que légèrement supérieures à ce que l'on obtiendrait par simple hasard, ce qui suggère que ces approches peinent à prédire correctement les valeurs réellement manquantes de la variable `consul_offre_pu`. Autrement dit, même si ces méthodes semblaient performantes lorsqu'elles étaient évaluées sur l'ensemble des données, elles se révèlent moins efficaces lorsqu'on se concentre uniquement sur la tâche d'imputation.

À l'inverse, la méthode fondée sur les tendances observées (méthode 2) obtient une accuracy nettement plus élevée (environ 67 %). Cette performance supérieure indique que cette approche capture mieux la structure réelle des données et produit des imputations plus cohérentes avec les comportements observés dans la base initiale. Ainsi, malgré sa simplicité, cette méthode s'avère la plus réaliste et la plus fiable pour remplacer les valeurs manquantes dans ce contexte précis.

En résumé, si les modèles de régression (méthodes 1 et 3) ne dépassent que modestement le niveau du hasard, la méthode basée sur les tendances observées constitue une alternative plus robuste pour l'imputation de la variable `consul_offre_pu`.

Concordance des bases

Maintenant, passons aux données manquantes présentes sur les variables quantitatives `salaire_min` et `salaire_max`.

8.2 Traitement des “Na” sur les colonnes “salaire_min”

8.2.1 Préambule : traitement des valeurs aberrantes

Dans la colonne salaire_min, nous avons pu remarquer la présence de valeurs incohérentes. Nous avons donc décidé de remplacer l'ensemble des valeurs inférieures au seuil du SMIC en 2019 par cette valeur. Le SMIC mensuel brut en France en 2019 s'élevait à 1 521,22 € pour un temps plein (35 heures). Nous obtenons ainsi des valeurs plus cohérentes et plus réalistes.

Suite à cela, nous testerons trois méthodes différentes pour imputer les valeurs manquantes. L'objectif est de comparer ces méthodes et de voir laquelle est la plus satisfaisante.

8.2.2 Première méthode : régression linéaire

Dans cette partie, l'objectif est de remplacer les valeurs manquantes en régressant la variable salaire minimum (salaire_min) sur les autres variables du modèle. Afin d'avoir les résultats les plus proches possibles des vraies valeurs, le meilleur modèle à estimer a été sélectionné par les méthodes “stepwise” du package {leaps}.

```
[1] "nombre de valeurs manquantes dans la colonne salaire_min :"
```

1400	1550	1600	1700	1800	1950	2000	2100	2200	2300	2400	2500	2600
1	1	4	3	2	1	9	4	8	6	6	31	9
2670	2696	2700	2750	2788	2800	2850	2900	2999	3000	3100	3197	3200
1	1	8	1	1	10	1	3	1	43	1	1	13
3300	3400	3490	3496	3497	3498	3500	3595	3600	3700	3800	3900	4000
6	2	1	1	1	1	52	1	4	3	5	1	43
4100	4200	4400	4479	4500	4600	4700	4986	5000	5200	5500	5600	6000
1	3	1	1	17	1	2	1	34	1	4	1	7
6499	6500	7000	8000	9000	10000	<NA>						
1	3	4	4	1	3	67						

Création d'un jeu d'entraînement sans valeurs manquantes pour entraîner le modèle. On crée également un jeu test pour pouvoir tester la prédiction de notre modèle. Si la prédiction est bonne alors nous pourrions généraliser la méthode à l'ensemble du jeu de données.

On régresse la variable salaire_min sur le jeu d'entraînement.

Call:

```
lm(formula = salaire_min ~ nb_exp + lieu + genre + nb_secteur +  
    nb_critère + nb_thème_raison + métier + type_contrat + rejoindre_pu +  
    consul_offre_pu, data = jeu_entrainement)
```

Residuals:

Min	1Q	Median	3Q	Max
-1804.2	-515.7	-55.0	445.5	4364.9

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1638.709	452.953	3.618	0.000365
nb_exp	53.870	8.257	6.524	4.28e-10
lieuEn outre-mer	-228.054	526.613	-0.433	0.665377
lieuEn région parisienne	846.455	119.846	7.063	1.90e-11
genreUn homme	406.431	329.022	1.235	0.217984
genreUne femme	90.123	344.202	0.262	0.793685
nb_secteur	25.914	18.012	1.439	0.151598
nb_critère	-15.038	21.313	-0.706	0.481152
nb_thème_raison	-65.877	51.747	-1.273	0.204278
metierAutre	205.309	235.029	0.874	0.383272
metierCommunication	-104.602	340.988	-0.307	0.759301
metierData scientist	674.465	260.442	2.590	0.010217
metierDesign de services	237.887	362.140	0.657	0.511904
metierDesign UI/UX	-38.355	462.277	-0.083	0.933948
metierDéveloppement backend	112.459	290.641	0.387	0.699160
metierDéveloppement frontend	169.910	419.087	0.405	0.685537
metierDéveloppement fullstack	202.584	238.077	0.851	0.395698
metierDéveloppement mobile	-648.147	559.591	-1.158	0.247958
metierMarketing	-344.986	380.293	-0.907	0.365269
metierProduct management	250.228	276.131	0.906	0.365778
type_contratCDI	-25.046	183.211	-0.137	0.891384
type_contratFreelance, portage salarial	231.201	241.076	0.959	0.338543
rejoindre_puNon	17.685	175.302	0.101	0.919730
rejoindre_puOui	-183.636	125.198	-1.467	0.143799
consul_offre_puOui	49.314	116.516	0.423	0.672512

(Intercept)	***
nb_exp	***
lieuEn outre-mer	
lieuEn région parisienne	***
genreUn homme	

```

genreUne femme
nb_secteur
nb_critère
nb_theme_raison
metierAutre
metierCommunication
metierData scientist          *
metierDesign de services
metierDesign UI/UX
metierDéveloppement backend
metierDéveloppement frontend
metierDéveloppement fullstack
metierDéveloppement mobile
metierMarketing
metierProduct management
type_contratCDI
type_contratFreelance, portage salarial
rejoindre_puNon
rejoindre_puOui
consul_offre_puOui
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

```

Residual standard error: 868.7 on 231 degrees of freedom
Multiple R-squared:  0.3562,    Adjusted R-squared:  0.2894
F-statistic: 5.326 on 24 and 231 DF,  p-value: 2.419e-12

```

Pour sélectionner le meilleur modèle, nous utilisons les methodes de sélections des variables du package {leaps} et anova.

```

Start:  AIC=3553.13
salaire_min ~ 1

```

	Df	Sum of Sq	RSS	AIC
+ nb_exp	1	32609532	238155548	3522.3
+ lieu	2	31530820	239234261	3525.4
+ nb_theme_raison	1	2136714	268628367	3553.1
<none>			270765081	3553.1
+ genre	2	3797359	266967722	3553.5
+ nb_secteur	1	1539462	269225619	3553.7
+ nb_critère	1	249683	270515398	3554.9
+ rejoindre_pu	2	2318414	268446666	3554.9

+ consul_offre_pu	1	6778	270758302	3555.1
+ type_contrat	2	1602274	269162806	3555.6
+ metier	11	15842890	254922191	3559.7

Step: AIC=3522.27
salaire_min ~ nb_exp

	Df	Sum of Sq	RSS	AIC
+ lieu	2	39234332	198921216	3480.2
<none>			238155548	3522.3
+ nb_secteur	1	1677945	236477603	3522.5
+ genre	2	2759889	235395659	3523.3
+ nb_theme_raison	1	523329	237632220	3523.7
+ nb_critere	1	194005	237961544	3524.1
+ consul_offre_pu	1	9098	238146450	3524.3
+ type_contrat	2	513666	237641882	3525.7
+ rejoindre_pu	2	405026	237750522	3525.8
+ metier	11	16054400	222101149	3526.4

Step: AIC=3480.19
salaire_min ~ nb_exp + lieu

	Df	Sum of Sq	RSS	AIC
+ genre	2	6623321	192297895	3475.5
+ nb_secteur	1	1573302	197347914	3480.2
<none>			198921216	3480.2
+ nb_theme_raison	1	742455	198178761	3481.2
+ nb_critere	1	54558	198866658	3482.1
+ consul_offre_pu	1	25853	198895363	3482.2
+ type_contrat	2	1019027	197902189	3482.9
+ rejoindre_pu	2	835775	198085441	3483.1
+ metier	11	13329579	185591637	3484.4

Step: AIC=3475.52
salaire_min ~ nb_exp + lieu + genre

	Df	Sum of Sq	RSS	AIC
<none>			192297895	3475.5
+ nb_secteur	1	1283695	191014200	3475.8
+ nb_theme_raison	1	629787	191668108	3476.7
+ consul_offre_pu	1	138393	192159502	3477.3
+ nb_critere	1	52994	192244900	3477.5
+ type_contrat	2	933996	191363898	3478.3

```
+ rejoindre_pu      2      821915 191475980 3478.4
+ metier            11 11910755 180387139 3481.2
```

Call:

```
lm(formula = salaire_min ~ nb_exp + lieu + genre, data = jeu_entrainement)
```

Coefficients:

	(Intercept)	nb_exp	lieuEn outre-mer
	1699.69	53.63	-352.78
lieuEn région parisienne		genreUn homme	genreUne femme
	839.99	413.82	52.71

Start: AIC=3488.37

```
salaire_min ~ nb_exp + lieu + genre + nb_secteur + nb_critère +
  nb_theme_raison + metier + type_contrat + rejoindre_pu +
  consul_offre_pu
```

	Df	Sum of Sq	RSS	AIC
- metier	11	13594458	187901146	3485.6
- consul_offre_pu	1	135170	174441859	3486.6
- type_contrat	2	1577985	175884673	3486.7
- nb_critère	1	375674	174682363	3486.9
- rejoindre_pu	2	1857504	176164193	3487.1
- nb_theme_raison	1	1222916	175529605	3488.2
<none>			174306689	3488.4
- nb_secteur	1	1561791	175868480	3488.7
- genre	2	4884238	179190926	3491.4
- nb_exp	1	32115579	206422268	3529.7
- lieu	2	38658702	212965391	3535.7

Step: AIC=3485.6

```
salaire_min ~ nb_exp + lieu + genre + nb_secteur + nb_critère +
  nb_theme_raison + type_contrat + rejoindre_pu + consul_offre_pu
```

	Df	Sum of Sq	RSS	AIC
- rejoindre_pu	2	882776	188783922	3482.8
- type_contrat	2	924267	188825413	3482.9
- nb_critère	1	30849	187931995	3483.6
- consul_offre_pu	1	197861	188099007	3483.9
- nb_theme_raison	1	826802	188727949	3484.7
<none>			187901146	3485.6

- nb_secteur	1	2036567	189937714	3486.4
- genre	2	6171072	194072218	3489.9
- nb_exp	1	33991848	221892994	3526.2
- lieu	2	43552403	231453550	3535.0

Step: AIC=3482.8

salaire_min ~ nb_exp + lieu + genre + nb_secteur + nb_critère +
nb_theme_raison + type_contrat + consul_offre_pu

	Df	Sum of Sq	RSS	AIC
- type_contrat	2	1010622	189794544	3480.2
- nb_critère	1	3134	188787056	3480.8
- consul_offre_pu	1	94084	188878006	3480.9
- nb_theme_raison	1	943808	189727730	3482.1
<none>			188783922	3482.8
- nb_secteur	1	1867983	190651905	3483.3
- genre	2	6090214	194874136	3486.9
- nb_exp	1	36034604	224818526	3525.5
- lieu	2	43182815	231966737	3531.5

Step: AIC=3480.17

salaire_min ~ nb_exp + lieu + genre + nb_secteur + nb_critère +
nb_theme_raison + consul_offre_pu

	Df	Sum of Sq	RSS	AIC
- nb_critère	1	31614	189826158	3478.2
- consul_offre_pu	1	78039	189872583	3478.3
- nb_theme_raison	1	1147991	190942535	3479.7
<none>			189794544	3480.2
- nb_secteur	1	1607493	191402036	3480.3
- genre	2	6191361	195985905	3484.4
- nb_exp	1	36986102	226780646	3523.7
- lieu	2	42885029	232679573	3528.3

Step: AIC=3478.21

salaire_min ~ nb_exp + lieu + genre + nb_secteur + nb_theme_raison +
consul_offre_pu

	Df	Sum of Sq	RSS	AIC
- consul_offre_pu	1	74580	189900738	3476.3
- nb_theme_raison	1	1128257	190954415	3477.7
<none>			189826158	3478.2
- nb_secteur	1	1671928	191498086	3478.5

- genre	2	6187854	196014012	3482.4
- nb_exp	1	36954862	226781019	3521.7
- lieu	2	43167602	232993759	3526.7

Step: AIC=3476.31

salaire_min ~ nb_exp + lieu + genre + nb_secteur + nb_theme_raison

	Df	Sum of Sq	RSS	AIC
- nb_theme_raison	1	1113462	191014200	3475.8
<none>			189900738	3476.3
- nb_secteur	1	1767370	191668108	3476.7
- genre	2	6117253	196017991	3480.4
- nb_exp	1	36917449	226818187	3519.8
- lieu	2	43101883	233002620	3524.7

Step: AIC=3475.81

salaire_min ~ nb_exp + lieu + genre + nb_secteur

	Df	Sum of Sq	RSS	AIC
- nb_secteur	1	1283695	192297895	3475.5
<none>			191014200	3475.8
- genre	2	6333714	197347914	3480.2
- nb_exp	1	39011101	230025301	3521.4
- lieu	2	42944498	233958698	3523.7

Step: AIC=3475.52

salaire_min ~ nb_exp + lieu + genre

	Df	Sum of Sq	RSS	AIC
<none>			192297895	3475.5
- genre	2	6623321	198921216	3480.2
- nb_exp	1	39062285	231360180	3520.9
- lieu	2	43097764	235395659	3523.3

Call:

lm(formula = salaire_min ~ nb_exp + lieu + genre, data = jeu_entrainement)

Coefficients:

(Intercept)	nb_exp	lieuEn outre-mer
1699.69	53.63	-352.78
lieuEn région parisienne	genreUn homme	genreUne femme
839.99	413.82	52.71

Start: AIC=3553.13

salaire_min ~ 1

	Df	Sum of Sq	RSS	AIC
+ nb_exp	1	32609532	238155548	3522.3
+ lieu	2	31530820	239234261	3525.4
+ nb_theme_raison	1	2136714	268628367	3553.1
<none>			270765081	3553.1
+ genre	2	3797359	266967722	3553.5
+ nb_secteur	1	1539462	269225619	3553.7
+ nb_critère	1	249683	270515398	3554.9
+ rejoindre_pu	2	2318414	268446666	3554.9
+ consul_offre_pu	1	6778	270758302	3555.1
+ type_contrat	2	1602274	269162806	3555.6
+ metier	11	15842890	254922191	3559.7

Step: AIC=3522.27

salaire_min ~ nb_exp

	Df	Sum of Sq	RSS	AIC
+ lieu	2	39234332	198921216	3480.2
<none>			238155548	3522.3
+ nb_secteur	1	1677945	236477603	3522.5
+ genre	2	2759889	235395659	3523.3
+ nb_theme_raison	1	523329	237632220	3523.7
+ nb_critère	1	194005	237961544	3524.1
+ consul_offre_pu	1	9098	238146450	3524.3
+ type_contrat	2	513666	237641882	3525.7
+ rejoindre_pu	2	405026	237750522	3525.8
+ metier	11	16054400	222101149	3526.4
- nb_exp	1	32609532	270765081	3553.1

Step: AIC=3480.19

salaire_min ~ nb_exp + lieu

	Df	Sum of Sq	RSS	AIC
+ genre	2	6623321	192297895	3475.5
+ nb_secteur	1	1573302	197347914	3480.2
<none>			198921216	3480.2
+ nb_theme_raison	1	742455	198178761	3481.2
+ nb_critère	1	54558	198866658	3482.1
+ consul_offre_pu	1	25853	198895363	3482.2
+ type_contrat	2	1019027	197902189	3482.9

+ rejoindre_pu	2	835775	198085441	3483.1
+ metier	11	13329579	185591637	3484.4
- lieu	2	39234332	238155548	3522.3
- nb_exp	1	40313045	239234261	3525.4

Step: AIC=3475.52

salaire_min ~ nb_exp + lieu + genre

	Df	Sum of Sq	RSS	AIC
<none>			192297895	3475.5
+ nb_secteur	1	1283695	191014200	3475.8
+ nb_theme_raison	1	629787	191668108	3476.7
+ consul_offre_pu	1	138393	192159502	3477.3
+ nb_critère	1	52994	192244900	3477.5
+ type_contrat	2	933996	191363898	3478.3
+ rejoindre_pu	2	821915	191475980	3478.4
- genre	2	6623321	198921216	3480.2
+ metier	11	11910755	180387139	3481.2
- nb_exp	1	39062285	231360180	3520.9
- lieu	2	43097764	235395659	3523.3

Call:

lm(formula = salaire_min ~ nb_exp + lieu + genre, data = jeu_entrainement)

Coefficients:

(Intercept)	nb_exp	lieuEn outre-mer
1699.69	53.63	-352.78
lieuEn région parisienne	genreUn homme	genreUne femme
839.99	413.82	52.71

Anova Table (Type II tests)

Response: salaire_min

	Sum Sq	Df	F value	Pr(>F)
nb_exp	32115579	1	42.5612	4.280e-10 ***
lieu	38658702	2	25.6162	8.955e-11 ***
genre	4884238	2	3.2364	0.04109 *
nb_secteur	1561791	1	2.0698	0.15160
nb_critère	375674	1	0.4979	0.48115
nb_theme_raison	1222916	1	1.6207	0.20428
metier	13594458	11	1.6378	0.08925 .

```

type_contrat      1577985    2  1.0456   0.35313
rejoindre_pu      1857504    2  1.2308   0.29396
consul_offre_pu   135170     1  0.1791   0.67251
Residuals        174306689 231

```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Call:

```

lm(formula = salaire_min ~ nb_exp + lieu + genre + nb_secteur +
    nb_critère + nb_thème_raison + métier + type_contrat + rejoindre_pu +
    consul_offre_pu, data = jeu_entrainement)

```

Residuals:

```

      Min       1Q   Median       3Q      Max
-1804.2  -515.7   -55.0    445.5   4364.9

```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1638.709	452.953	3.618	0.000365
nb_exp	53.870	8.257	6.524	4.28e-10
lieuEn outre-mer	-228.054	526.613	-0.433	0.665377
lieuEn région parisienne	846.455	119.846	7.063	1.90e-11
genreUn homme	406.431	329.022	1.235	0.217984
genreUne femme	90.123	344.202	0.262	0.793685
nb_secteur	25.914	18.012	1.439	0.151598
nb_critère	-15.038	21.313	-0.706	0.481152
nb_thème_raison	-65.877	51.747	-1.273	0.204278
metierAutre	205.309	235.029	0.874	0.383272
metierCommunication	-104.602	340.988	-0.307	0.759301
metierData scientist	674.465	260.442	2.590	0.010217
metierDesign de services	237.887	362.140	0.657	0.511904
metierDesign UI/UX	-38.355	462.277	-0.083	0.933948
metierDéveloppement backend	112.459	290.641	0.387	0.699160
metierDéveloppement frontend	169.910	419.087	0.405	0.685537
metierDéveloppement fullstack	202.584	238.077	0.851	0.395698
metierDéveloppement mobile	-648.147	559.591	-1.158	0.247958
metierMarketing	-344.986	380.293	-0.907	0.365269
metierProduct management	250.228	276.131	0.906	0.365778
type_contratCDI	-25.046	183.211	-0.137	0.891384
type_contratFreelance, portage salarial	231.201	241.076	0.959	0.338543
rejoindre_puNon	17.685	175.302	0.101	0.919730

rejoindre_puOui	-183.636	125.198	-1.467	0.143799
consul_offre_puOui	49.314	116.516	0.423	0.672512

(Intercept)	***
nb_exp	***
lieuEn outre-mer	
lieuEn région parisienne	***
genreUn homme	
genreUne femme	
nb_secteur	
nb_critère	
nb_theme_raison	
metierAutre	
metierCommunication	
metierData scientist	*
metierDesign de services	
metierDesign UI/UX	
metierDéveloppement backend	
metierDéveloppement frontend	
metierDéveloppement fullstack	
metierDéveloppement mobile	
metierMarketing	
metierProduct management	
type_contratCDI	
type_contratFreelance, portage salarial	
rejoindre_puNon	
rejoindre_puOui	
consul_offre_puOui	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 868.7 on 231 degrees of freedom

Multiple R-squared: 0.3562, Adjusted R-squared: 0.2894

F-statistic: 5.326 on 24 and 231 DF, p-value: 2.419e-12

Après avoir fait tourner les méthodes d'auto sélection des variables, nous estimons le meilleur modèle proposé par celles ci, qui est le suivant :

salaire_min ~ lieu + nb_exp + genre + nb_secteur

Régression finale sur le jeu d'entraînement

Call:

```
lm(formula = salaire_min ~ lieu + nb_exp + genre + nb_secteur,  
    data = jeu_entrainement)
```

Residuals:

Min	1Q	Median	3Q	Max
-2343.8	-562.5	-128.4	404.7	4880.6

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1607.657	344.258	4.670	4.93e-06 ***
lieuEn outre-mer	-280.986	518.718	-0.542	0.589
lieuEn région parisienne	841.402	114.172	7.370	2.52e-12 ***
nb_exp	53.592	7.515	7.131	1.08e-11 ***
genreUn homme	380.115	319.582	1.189	0.235
genreUne femme	22.768	333.000	0.068	0.946
nb_secteur	22.268	17.214	1.294	0.197

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 875.9 on 249 degrees of freedom

Multiple R-squared: 0.2945, Adjusted R-squared: 0.2775

F-statistic: 17.33 on 6 and 249 DF, p-value: < 2.2e-16

On test les prédictions de notre modèle sur un jeu test pour voir s'il y a un grand écart entre les vraies valeurs et les valeurs prédites.

Pour vérifier si les prédictions sont correctes, on calcule les résidus entre les valeurs prédites et réelles. On calcule également les RMSE qui est un indicateur de la qualité de la prévision.

```
[1] "RMSE : "
```

```
[1] 1014.568
```

Mauvaise qualité de prédiction RMSE, le RMSE est trop élevé (1014.568) donc le modèle se trompe en moyenne de 1000€.

Même si la qualité de prédiction n'est pas très bonne, nous allons tout de même appliquer le modèle à l'ensemble du jeu de données.

Call:

```
lm(formula = salaire_min ~ nb_exp + lieu, data = base_na)
```

Residuals:

Min	1Q	Median	3Q	Max
-2340.8	-626.7	-126.7	439.5	4777.5

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	2102.189	98.150	21.418	< 2e-16 ***
nb_exp	47.917	6.531	7.337	1.35e-12 ***
lieuEn outre-mer	-495.590	544.229	-0.911	0.363
lieuEn région parisienne	880.722	98.145	8.974	< 2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 935.4 on 377 degrees of freedom

(67 observations effacées parce que manquantes)

Multiple R-squared: 0.247, Adjusted R-squared: 0.241

F-statistic: 41.23 on 3 and 377 DF, p-value: < 2.2e-16

On impute les valeurs manquantes par les valeurs prédites par la MCO. Donc on remplace les NA dans salaire_min.

A tibble: 1 x 29

secteur	consul_offre_pu	rejoindre_pu	raison	souhait_1	souhait_2	souhait_3
<chr>	<fct>	<fct>	<chr>	<fct>	<fct>	<fct>
1 Éducation n~	<NA>	Oui	Pour ~ Au sein ~	<NA>	<NA>	<NA>

i 22 more variables: souhait_4 <fct>, type_contrat <fct>, lieu <chr>,

salaire_min <dbl>, salaire_max <dbl>, critere <chr>, genre <fct>,

metier <fct>, nb_exp <dbl>, nb_secteur <dbl>, Écologie <fct>,

`Éducation nationale` <fct>, `Enseignement supérieur et recherche` <fct>,

nb_critère <dbl>, `Avoir des horaires de travail flexibles` <fct>,

`Être libre d'installer les logiciels dont j'ai besoin sur mon poste de travail` <fct>,

`Pouvoir travailler 1-2 jours par semaine en télétravail` <fct>, ...


8.2.3 Deuxième méthode : médiane sur le genre et le nombre d'expérience

La deuxième méthode d'imputation proposée est une médiane sur le genre des individus et sur le nombre d'année d'expérience de ces dernier.


Pour cela, on va créer une variables catégorielle afin de regrouper le nombre d'année d'expérience en trois catégories : débutant, junior et senior. Les classes sont assez arbitraire mais dépendante tout de même de la distribution de la variables années d'expérience.

On calcule la moyenne et la médiane des individus en fonction du genre et du nombre d'année d'expérience.

On peut représenter graphiquement la moyenne du salaire min en fonction du sexe et de la catégorie d'expérience



Même chose pour la médiane du salaire min.



On voit nettement que la médiane du salaire minimum déclarée par les femmes est inférieure aux deux autres groupes.

Il est donc pertinent de remplacer les Na par la médiane calculée en fonction du genre et du nombre d'année d'expérience.

On vérifie qu'il n'y ait plus de valeurs manquantes dans la colonne salaire min

```
[1] "nombre de valeurs manquantes:"
```

```
[1] 0
```

On voit qu'il n'y en a plus aucunes.

8.3 Traitement des “Na” sur la colonne “salaire_max”

Cette partie est globalement, un copié-collé de la partie sur le remplacement des valeurs manquantes sur le salaire minimum à la différence que maintenant on s'intéresse au salaire maximum déclaré.

8.3.1 Première méthode régression

On utilise encore la méthode de régression linéaire (MCO) afin de prédire des valeurs susceptibles de pouvoir convenir là où des valeurs manquantes sont présentes.

```
[1] "nombre de valeurs manquantes dans la colonne salaire_min :"
```

1400	1550	1600	1700	1800	1950	2000	2100	2200	2300	2400	2500	2600
1	1	4	3	2	1	9	4	8	6	6	31	9
2670	2696	2700	2750	2788	2800	2850	2900	2999	3000	3100	3197	3200
1	1	8	1	1	10	1	3	1	43	1	1	13
3300	3400	3490	3496	3497	3498	3500	3595	3600	3700	3800	3900	4000
6	2	1	1	1	1	52	1	4	3	5	1	43
4100	4200	4400	4479	4500	4600	4700	4986	5000	5200	5500	5600	6000
1	3	1	1	17	1	2	1	34	1	4	1	7
6499	6500	7000	8000	9000	10000	<NA>						
1	3	4	4	1	3	67						

Comme pour la partie précédente, on crée un jeu d'entraînement ainsi qu'un jeu test.

On régresse sur le jeu d'entraînement.

Call:

```
lm(formula = salaire_max ~ nb_exp + lieu + genre + nb_secteur +
    nb_critère + nb_theme_raison + metier + type_contrat + consul_offre_pu +
    rejoindre_pu, data = jeu_entrainement)
```

Residuals:

Min	1Q	Median	3Q	Max
-2923.0	-667.7	-159.2	529.5	5147.7

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1820.714	583.858	3.118	0.00205
nb_exp	60.365	10.715	5.634	5.06e-08
lieuEn outre-mer	-84.169	599.022	-0.141	0.88838
lieuEn région parisienne	1181.933	157.990	7.481	1.50e-12
genreUn homme	981.921	415.289	2.364	0.01888
genreUne femme	604.248	437.613	1.381	0.16867
nb_secteur	25.690	24.157	1.063	0.28868

nb_critère	39.769	28.880	1.377	0.16983
nb_theme_raison	-148.790	70.248	-2.118	0.03523
metierAutre	-20.405	291.582	-0.070	0.94427
metierCommunication	-262.522	477.016	-0.550	0.58261
metierData scientist	399.227	340.896	1.171	0.24275
metierDesign de services	312.264	489.908	0.637	0.52449
metierDesign UI/UX	-222.495	743.864	-0.299	0.76512
metierDéveloppement backend	-90.583	371.670	-0.244	0.80766
metierDéveloppement frontend	300.243	735.921	0.408	0.68366
metierDéveloppement fullstack	114.531	306.905	0.373	0.70935
metierDéveloppement mobile	220.214	647.522	0.340	0.73410
metierMarketing	-134.439	452.826	-0.297	0.76682
metierProduct management	-147.884	331.182	-0.447	0.65563
type_contratCDI	-68.107	253.031	-0.269	0.78804
type_contratFreelance, portage salarial	511.859	328.151	1.560	0.12016
consul_offre_puOui	5.887	152.875	0.039	0.96932
rejoindre_puNon	-146.276	244.403	-0.599	0.55009
rejoindre_puOui	-333.291	164.073	-2.031	0.04335
(Intercept)	**			
nb_exp	***			
lieuEn outre-mer				
lieuEn région parisienne	***			
genreUn homme	*			
genreUne femme				
nb_secteur				
nb_critère				
nb_theme_raison	*			
metierAutre				
metierCommunication				
metierData scientist				
metierDesign de services				
metierDesign UI/UX				
metierDéveloppement backend				
metierDéveloppement frontend				
metierDéveloppement fullstack				
metierDéveloppement mobile				
metierMarketing				
metierProduct management				
type_contratCDI				
type_contratFreelance, portage salarial				
consul_offre_puOui				
rejoindre_puNon				

```
rejoindre_pu0ui          *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 1152 on 233 degrees of freedom
Multiple R-squared:  0.3487,    Adjusted R-squared:  0.2816
F-statistic: 5.198 on 24 and 233 DF,  p-value: 5.258e-12
```

On sélectionne ensuite le meilleur modèle grâce aux mêmes méthode d'auto sélection des variables vu précédemment.

```
Start:  AIC=3723.85
salaire_max ~ 1
```

	Df	Sum of Sq	RSS	AIC
+ lieu	2	63062633	411887295	3691.1
+ nb_exp	1	45900047	429049881	3699.6
+ type_contrat	2	17839562	457110366	3718.0
+ nb_theme_raison	1	10507107	464442821	3720.1
+ genre	2	8964261	465985667	3722.9
+ rejoindre_pu	2	8806710	466143218	3723.0
<none>			474949928	3723.8
+ nb_critère	1	2793486	472156442	3724.3
+ consul_offre_pu	1	423325	474526603	3725.6
+ nb_secteur	1	273777	474676152	3725.7
+ metier	11	7525848	467424080	3741.7

```
Step:  AIC=3691.09
salaire_max ~ lieu
```

	Df	Sum of Sq	RSS	AIC
+ nb_exp	1	52118266	359769029	3658.2
+ type_contrat	2	19538711	392348584	3682.6
+ genre	2	15071356	396815939	3685.5
+ nb_theme_raison	1	11715677	400171618	3685.6
+ rejoindre_pu	2	9759102	402128194	3688.9
+ nb_critère	1	4460171	407427124	3690.3
<none>			411887295	3691.1
+ nb_secteur	1	268647	411618648	3692.9
+ consul_offre_pu	1	20	411887275	3693.1
+ metier	11	12786806	399100489	3705.0

Step: AIC=3658.19

salaire_max ~ lieu + nb_exp

	Df	Sum of Sq	RSS	AIC
+ genre	2	14515796	345253233	3651.6
+ type_contrat	2	12789804	346979225	3652.8
+ nb_theme_raison	1	5844570	353924459	3656.0
+ nb_critère	1	5628498	354140531	3656.1
+ rejoindre_pu	2	6780739	352988290	3657.3
<none>			359769029	3658.2
+ nb_secteur	1	883305	358885724	3659.6
+ consul_offre_pu	1	97318	359671711	3660.1
+ metier	11	14782641	344986389	3669.4

Step: AIC=3651.56

salaire_max ~ lieu + nb_exp + genre

	Df	Sum of Sq	RSS	AIC
+ type_contrat	2	13027778	332225455	3645.6
+ nb_theme_raison	1	5440721	339812512	3649.5
+ nb_critère	1	5242810	340010423	3649.6
+ rejoindre_pu	2	7122930	338130303	3650.2
<none>			345253233	3651.6
+ nb_secteur	1	436436	344816797	3653.2
+ consul_offre_pu	1	82080	345171153	3653.5
+ metier	11	9872228	335381005	3666.1

Step: AIC=3645.64

salaire_max ~ lieu + nb_exp + genre + type_contrat

	Df	Sum of Sq	RSS	AIC
+ rejoindre_pu	2	6366639	325858816	3644.6
+ nb_theme_raison	1	3568395	328657059	3644.9
+ nb_critère	1	3016000	329209455	3645.3
<none>			332225455	3645.6
+ nb_secteur	1	698850	331526604	3647.1
+ consul_offre_pu	1	32231	332193224	3647.6
+ metier	11	8983438	323242017	3660.6

Step: AIC=3644.65

salaire_max ~ lieu + nb_exp + genre + type_contrat + rejoindre_pu

	Df	Sum of Sq	RSS	AIC
--	----	-----------	-----	-----

+ nb_theme_raison	1	2920181	322938635	3644.3
<none>			325858816	3644.6
+ nb_critère	1	2462083	323396733	3644.7
+ nb_secteur	1	1397592	324461224	3645.5
+ consul_offre_pu	1	181893	325676923	3646.5
+ metier	11	8444608	317414208	3659.9

Step: AIC=3644.32

salaire_max ~ lieu + nb_exp + genre + type_contrat + rejoindre_pu +
nb_theme_raison

	Df	Sum of Sq	RSS	AIC
+ nb_critère	1	3668859	319269776	3643.4
+ nb_secteur	1	2580527	320358108	3644.3
<none>			322938635	3644.3
+ consul_offre_pu	1	203654	322734981	3646.2
+ metier	11	9509089	313429547	3658.6

Step: AIC=3643.38

salaire_max ~ lieu + nb_exp + genre + type_contrat + rejoindre_pu +
nb_theme_raison + nb_critère

	Df	Sum of Sq	RSS	AIC
+ nb_secteur	1	2484259	316785517	3643.4
<none>			319269776	3643.4
+ consul_offre_pu	1	223701	319046075	3645.2
+ metier	11	8392586	310877191	3658.5

Step: AIC=3643.36

salaire_max ~ lieu + nb_exp + genre + type_contrat + rejoindre_pu +
nb_theme_raison + nb_critère + nb_secteur

	Df	Sum of Sq	RSS	AIC
<none>			316785517	3643.4
+ consul_offre_pu	1	70115	316715402	3645.3
+ metier	11	7449131	309336386	3659.2

Call:

```
lm(formula = salaire_max ~ lieu + nb_exp + genre + type_contrat +  
rejoindre_pu + nb_theme_raison + nb_critère + nb_secteur,  
data = jeu_entrainement)
```

Coefficients:

```
              (Intercept)
                1863.60
        lieuEn outre-mer
                -10.78
    lieuEn région parisienne
                1148.13
                nb_exp
                56.33
        genreUn homme
                937.84
        genreUne femme
                506.24
        type_contratCDI
                -44.44
type_contratFreelance, portage salarial
                538.12
        rejoindre_puNon
                -180.53
        rejoindre_puOui
                -330.17
        nb_theme_raison
                -137.79
        nb_critère
                45.21
        nb_secteur
                31.99
```

Start: AIC=3661.22

```
salaire_max ~ nb_exp + lieu + genre + nb_secteur + nb_critère +
  nb_theme_raison + metier + type_contrat + consul_offre_pu +
  rejoindre_pu
```

	Df	Sum of Sq	RSS	AIC
- metier	11	7380985	316715402	3645.3
- consul_offre_pu	1	1969	309336386	3659.2
- nb_secteur	1	1501427	310835844	3660.5
<none>			309334418	3661.2
- nb_critère	1	2517394	311851811	3661.3
- rejoindre_pu	2	5486053	314820471	3661.8
- type_contrat	2	8040548	317374965	3663.8

```

- nb_theme_raison 1 5955972 315290390 3664.1
- genre           2 12080342 321414760 3667.1
- nb_exp          1 42138428 351472846 3692.2
- lieu           2 75630931 384965349 3713.7

```

Step: AIC=3645.3

```

salaire_max ~ nb_exp + lieu + genre + nb_secteur + nb_critère +
  nb_theme_raison + type_contrat + consul_offre_pu + rejoindre_pu

```

	Df	Sum of Sq	RSS	AIC
- consul_offre_pu	1	70115	316785517	3643.4
- nb_secteur	1	2330673	319046075	3645.2
<none>			316715402	3645.3
- rejoindre_pu	2	5817959	322533362	3646.0
- nb_critère	1	3585511	320300913	3646.2
- nb_theme_raison	1	5393897	322109300	3647.7
- type_contrat	2	8397065	325112467	3648.1
- genre	2	14305528	331020930	3652.7
- nb_exp	1	42723758	359439160	3676.0
- lieu	2	78368520	395083923	3698.3

Step: AIC=3643.36

```

salaire_max ~ nb_exp + lieu + genre + nb_secteur + nb_critère +
  nb_theme_raison + type_contrat + rejoindre_pu

```

	Df	Sum of Sq	RSS	AIC
<none>			316785517	3643.4
- nb_secteur	1	2484259	319269776	3643.4
- rejoindre_pu	2	5755191	322540708	3644.0
- nb_critère	1	3572591	320358108	3644.3
- nb_theme_raison	1	5411248	322196765	3645.7
- type_contrat	2	8463498	325249015	3646.2
- genre	2	14414337	331199854	3650.8
- nb_exp	1	42915590	359701107	3674.1
- lieu	2	78756301	395541818	3696.6

Call:

```

lm(formula = salaire_max ~ nb_exp + lieu + genre + nb_secteur +
  nb_critère + nb_theme_raison + type_contrat + rejoindre_pu,
  data = jeu_entrainement)

```

Coefficients:

```

              (Intercept)
              1863.60
              nb_exp
              56.33
    lieuEn outre-mer
              -10.78
    lieuEn région parisienne
              1148.13
              genreUn homme
              937.84
              genreUne femme
              506.24
              nb_secteur
              31.99
              nb_critère
              45.21
              nb_theme_raison
              -137.79
              type_contratCDI
              -44.44
    type_contratFreelance, portage salarial
              538.12
              rejoindre_puNon
              -180.53
              rejoindre_puOui
              -330.17

```

Start: AIC=3723.85

salaire_max ~ 1

	Df	Sum of Sq	RSS	AIC
+ lieu	2	63062633	411887295	3691.1
+ nb_exp	1	45900047	429049881	3699.6
+ type_contrat	2	17839562	457110366	3718.0
+ nb_theme_raison	1	10507107	464442821	3720.1
+ genre	2	8964261	465985667	3722.9
+ rejoindre_pu	2	8806710	466143218	3723.0
<none>			474949928	3723.8
+ nb_critère	1	2793486	472156442	3724.3
+ consul_offre_pu	1	423325	474526603	3725.6
+ nb_secteur	1	273777	474676152	3725.7


```
+ metier          11    7525848 467424080 3741.7
```

Step: AIC=3691.09

salaire_max ~ lieu

	Df	Sum of Sq	RSS	AIC
+ nb_exp	1	52118266	359769029	3658.2
+ type_contrat	2	19538711	392348584	3682.6
+ genre	2	15071356	396815939	3685.5
+ nb_theme_raison	1	11715677	400171618	3685.6
+ rejoindre_pu	2	9759102	402128194	3688.9
+ nb_critère	1	4460171	407427124	3690.3
<none>			411887295	3691.1
+ nb_secteur	1	268647	411618648	3692.9
+ consul_offre_pu	1	20	411887275	3693.1
+ metier	11	12786806	399100489	3705.0
- lieu	2	63062633	474949928	3723.8

Step: AIC=3658.19

salaire_max ~ lieu + nb_exp

	Df	Sum of Sq	RSS	AIC
+ genre	2	14515796	345253233	3651.6
+ type_contrat	2	12789804	346979225	3652.8
+ nb_theme_raison	1	5844570	353924459	3656.0
+ nb_critère	1	5628498	354140531	3656.1
+ rejoindre_pu	2	6780739	352988290	3657.3
<none>			359769029	3658.2
+ nb_secteur	1	883305	358885724	3659.6
+ consul_offre_pu	1	97318	359671711	3660.1
+ metier	11	14782641	344986389	3669.4
- nb_exp	1	52118266	411887295	3691.1
- lieu	2	69280852	429049881	3699.6

Step: AIC=3651.56

salaire_max ~ lieu + nb_exp + genre

	Df	Sum of Sq	RSS	AIC
+ type_contrat	2	13027778	332225455	3645.6
+ nb_theme_raison	1	5440721	339812512	3649.5
+ nb_critère	1	5242810	340010423	3649.6
+ rejoindre_pu	2	7122930	338130303	3650.2
<none>			345253233	3651.6

+ nb_secteur	1	436436	344816797	3653.2
+ consul_offre_pu	1	82080	345171153	3653.5
- genre	2	14515796	359769029	3658.2
+ metier	11	9872228	335381005	3666.1
- nb_exp	1	51562706	396815939	3685.5
- lieu	2	74905535	420158768	3698.2

Step: AIC=3645.64

salaire_max ~ lieu + nb_exp + genre + type_contrat

	Df	Sum of Sq	RSS	AIC
+ rejoindre_pu	2	6366639	325858816	3644.6
+ nb_theme_raison	1	3568395	328657059	3644.9
+ nb_critere	1	3016000	329209455	3645.3
<none>			332225455	3645.6
+ nb_secteur	1	698850	331526604	3647.1
+ consul_offre_pu	1	32231	332193224	3647.6
- type_contrat	2	13027778	345253233	3651.6
- genre	2	14753770	346979225	3652.8
+ metier	11	8983438	323242017	3660.6
- nb_exp	1	45990682	378216137	3677.1
- lieu	2	75716561	407942016	3694.6

Step: AIC=3644.65

salaire_max ~ lieu + nb_exp + genre + type_contrat + rejoindre_pu

	Df	Sum of Sq	RSS	AIC
+ nb_theme_raison	1	2920181	322938635	3644.3
<none>			325858816	3644.6
+ nb_critere	1	2462083	323396733	3644.7
+ nb_secteur	1	1397592	324461224	3645.5
- rejoindre_pu	2	6366639	332225455	3645.6
+ consul_offre_pu	1	181893	325676923	3646.5
- type_contrat	2	12271487	338130303	3650.2
- genre	2	15567628	341426445	3652.7
+ metier	11	8444608	317414208	3659.9
- nb_exp	1	44892402	370751218	3675.9
- lieu	2	77183940	403042756	3695.5

Step: AIC=3644.32

salaire_max ~ lieu + nb_exp + genre + type_contrat + rejoindre_pu +
nb_theme_raison

	Df	Sum of Sq	RSS	AIC
+ nb_critère	1	3668859	319269776	3643.4
+ nb_secteur	1	2580527	320358108	3644.3
<none>			322938635	3644.3
- nb_thème_raison	1	2920181	325858816	3644.6
- rejoindre_pu	2	5718424	328657059	3644.9
+ consul_offre_pu	1	203654	322734981	3646.2
- type_contrat	2	10672947	333611582	3648.7
- genre	2	15325930	338264565	3652.3
+ métier	11	9509089	313429547	3658.6
- nb_exp	1	41421376	364360012	3673.5
- lieu	2	77268278	400206913	3695.7

Step: AIC=3643.38

salaire_max ~ lieu + nb_exp + genre + type_contrat + rejoindre_pu +
nb_thème_raison + nb_critère

	Df	Sum of Sq	RSS	AIC
+ nb_secteur	1	2484259	316785517	3643.4
<none>			319269776	3643.4
- rejoindre_pu	2	5026331	324296107	3643.4
- nb_critère	1	3668859	322938635	3644.3
- nb_thème_raison	1	4126957	323396733	3644.7
+ consul_offre_pu	1	223701	319046075	3645.2
- type_contrat	2	8325326	327595102	3646.0
- genre	2	15249481	334519257	3651.4
+ métier	11	8392586	310877191	3658.5
- nb_exp	1	42445462	361715238	3673.6
- lieu	2	78697337	397967113	3696.2

Step: AIC=3643.36

salaire_max ~ lieu + nb_exp + genre + type_contrat + rejoindre_pu +
nb_thème_raison + nb_critère + nb_secteur

	Df	Sum of Sq	RSS	AIC
<none>			316785517	3643.4
- nb_secteur	1	2484259	319269776	3643.4
- rejoindre_pu	2	5755191	322540708	3644.0
- nb_critère	1	3572591	320358108	3644.3
+ consul_offre_pu	1	70115	316715402	3645.3
- nb_thème_raison	1	5411248	322196765	3645.7
- type_contrat	2	8463498	325249015	3646.2
- genre	2	14414337	331199854	3650.8

+ metier	11	7449131	309336386	3659.2
- nb_exp	1	42915590	359701107	3674.1
- lieu	2	78756301	395541818	3696.6

Call:

```
lm(formula = salaire_max ~ lieu + nb_exp + genre + type_contrat +
    rejoindre_pu + nb_theme_raison + nb_critère + nb_secteur,
    data = jeu_entrainement)
```

Coefficients:

	(Intercept)	1863.60
	lieuEn outre-mer	-10.78
	lieuEn région parisienne	1148.13
	nb_exp	56.33
	genreUn homme	937.84
	genreUne femme	506.24
	type_contratCDI	-44.44
type_contratFreelance, portage salarial		538.12
	rejoindre_puNon	-180.53
	rejoindre_puOui	-330.17
	nb_theme_raison	-137.79
	nb_critère	45.21
	nb_secteur	31.99

Analysis of Variance Table

Response: salaire_max

Df	Sum Sq	Mean Sq	F value	Pr(>F)
----	--------	---------	---------	--------

```

nb_exp      1  45900047 45900047 34.5733 1.414e-08 ***
lieu        2  69280852 34640426 26.0922 5.954e-11 ***
genre       2  14515796 7257898  5.4669 0.004784 **
nb_secteur  1    436436  436436  0.3287 0.566957
nb_critère  1    5169115 5169115  3.8935 0.049654 *
nb_theme_raison 1  8530066 8530066  6.4251 0.011908 *
metier      11  8063644  733059  0.5522 0.865857
type_contrat 2  8227827 4113913  3.0987 0.046971 *
consul_offre_pu 1    5674    5674  0.0043 0.947932
rejoindre_pu 2   5486053 2743027  2.0661 0.128990
Residuals   233 309334418 1327616
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

Une fois le meilleur modèle sélectionner, on l'estime.

salaire_max ~ lieu + nb_exp + genre + type_contrat + nb_secteur

Call:

```
lm(formula = salaire_max ~ lieu + nb_exp + genre + type_contrat +
    nb_secteur, data = jeu_entrainement)
```

Residuals:

Min	1Q	Median	3Q	Max
-2596.2	-666.3	-173.2	596.0	6016.1

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1748.925	488.892	3.577	0.000417
lieuEn outre-mer	-99.398	590.270	-0.168	0.866410
lieuEn région parisienne	1118.412	149.646	7.474	1.32e-12
nb_exp	58.135	9.837	5.910	1.12e-08
genreUn homme	794.115	401.539	1.978	0.049068
genreUne femme	319.760	422.955	0.756	0.450356
type_contratCDI	15.404	243.787	0.063	0.949668
type_contratFreelance, portage salarial	721.497	314.082	2.297	0.022440
nb_secteur	16.332	22.542	0.724	0.469445

(Intercept)	***
lieuEn outre-mer	
lieuEn région parisienne	***
nb_exp	***

```

genreUn homme          *
genreUne femme
type_contratCDI
type_contratFreelance, portage salarial *
nb_secteur
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

```

Residual standard error: 1154 on 249 degrees of freedom
Multiple R-squared:  0.302, Adjusted R-squared:  0.2795
F-statistic: 13.47 on 8 and 249 DF,  p-value: 3.582e-16

```

on test le modèle sur le jeu test

Comme pour le salaire_min, on calcul les résidus, c'est à dire les écarts entre les vraies valeurs et les valeurs prédites. On calcul aussi un indicateur de la qualité de la prédiction, le RMSE.

```
[1] -107.1655
```

```
[1] "RMSE : "
```

```
[1] 1098.317
```

En moyenne, l'écart entre les valeurs prédites et les vraies valeurs est de - 146,79€. Cependant, le RMSE est important (1098.317) donc grosse écart entre les valeurs prédites et réelles. Ce qui signifie concrètement que le modèle se trompe en moyenne de 1100€, ce qui est énorme.

La méthode de régression n'est pas très bonne mais généralisons la tout de même pour la comparer aux autres!

Régression sur le jeu entier

```

Call:
lm(formula = salaire_max ~ lieu + nb_exp + genre + type_contrat +
    nb_secteur, data = base_na)

```

```

Residuals:
    Min       1Q   Median       3Q      Max
-2568.5  -671.4  -162.9   513.6  6064.7

```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	2023.971	374.234	5.408	1.14e-07
lieuEn outre-mer	-203.709	512.592	-0.397	0.6913
lieuEn région parisienne	1102.306	120.500	9.148	< 2e-16
nb_exp	54.564	7.874	6.930	1.87e-11
genreUn homme	343.318	301.367	1.139	0.2554
genreUne femme	-120.715	318.969	-0.378	0.7053
type_contratCDI	165.719	201.356	0.823	0.4110
type_contratFreelance, portage salarial	657.492	258.764	2.541	0.0115
nb_secteur	27.143	18.611	1.458	0.1456

(Intercept)	***
lieuEn outre-mer	
lieuEn région parisienne	***
nb_exp	***
genreUn homme	
genreUne femme	
type_contratCDI	
type_contratFreelance, portage salarial *	
nb_secteur	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1129 on 372 degrees of freedom

(67 observations effacées parce que manquantes)



Multiple R-squared: 0.2836, Adjusted R-squared: 0.2682

F-statistic: 18.41 on 8 and 372 DF, p-value: < 2.2e-16

Remplacement des valeurs manquantes dans la colonne salaire max.

8.3.2 Deuxième méthode : médiane sur le genre et le nombre d'expérience

La deuxième méthode est la même que précédemment lorsque nous avons remplacer les NA par la médiane en fonction du genre et du nombre d'année d'expérience.



Graphiquement, on observe bien que les hommes déclarent un salaire plus élevé que les femmes. C'est encore plus vrai lorsque le nombre d'année d'expérience augmente.

Vérification qu'il n'y ait plus de NA.


```
[1] "Vérification de la présence des valeurs manquantes : "
```

```
[1] 0
```

Plus de valeurs manquantes

8.3.3 Troisième méthode avec le package {mice}

```
iter imp variable
1 1 consul_offre_pu souhait_2 souhait_3 salaire_min salaire_max
1 2 consul_offre_pu souhait_2 souhait_3 salaire_min salaire_max
1 3 consul_offre_pu souhait_2 souhait_3 salaire_min salaire_max
1 4 consul_offre_pu souhait_2 souhait_3 salaire_min salaire_max
1 5 consul_offre_pu souhait_2 souhait_3 salaire_min salaire_max
2 1 consul_offre_pu souhait_2 souhait_3 salaire_min salaire_max
2 2 consul_offre_pu souhait_2 souhait_3 salaire_min salaire_max
2 3 consul_offre_pu souhait_2 souhait_3 salaire_min salaire_max
2 4 consul_offre_pu souhait_2 souhait_3 salaire_min salaire_max
2 5 consul_offre_pu souhait_2 souhait_3 salaire_min salaire_max
3 1 consul_offre_pu souhait_2 souhait_3 salaire_min salaire_max
3 2 consul_offre_pu souhait_2 souhait_3 salaire_min salaire_max
3 3 consul_offre_pu souhait_2 souhait_3 salaire_min salaire_max
3 4 consul_offre_pu souhait_2 souhait_3 salaire_min salaire_max
3 5 consul_offre_pu souhait_2 souhait_3 salaire_min salaire_max
4 1 consul_offre_pu souhait_2 souhait_3 salaire_min salaire_max
4 2 consul_offre_pu souhait_2 souhait_3 salaire_min salaire_max
4 3 consul_offre_pu souhait_2 souhait_3 salaire_min salaire_max
4 4 consul_offre_pu souhait_2 souhait_3 salaire_min salaire_max
4 5 consul_offre_pu souhait_2 souhait_3 salaire_min salaire_max
5 1 consul_offre_pu souhait_2 souhait_3 salaire_min salaire_max
5 2 consul_offre_pu souhait_2 souhait_3 salaire_min salaire_max
5 3 consul_offre_pu souhait_2 souhait_3 salaire_min salaire_max
5 4 consul_offre_pu souhait_2 souhait_3 salaire_min salaire_max
5 5 consul_offre_pu souhait_2 souhait_3 salaire_min salaire_max
```

Liste des meilleurs méthodes selon le package {mice}

```
base_impute$method
```

```

secteur
""
consul_offre_pu
"logreg"
rejoindre_pu
""
raison
""
souhait_1
""
souhait_2
"polyreg"
souhait_3
"logreg"
souhait_4
""
type_contrat
""
lieu
""
salaire_min
"pmm"
salaire_max
"pmm"
critere
""
genre
""
metier
""
nb_exp
""
nb_secteur
""
Écologie
""
Éducation nationale
""
Enseignement supérieur et recherche
""
nb_critère
""
Avoir des horaires de travail flexibles

```

```

"""
Être libre d'installer les logiciels dont j'ai besoin sur mon poste de travail
"""
    Pouvoir travailler 1-2 jours par semaine en télétravail
    """
        nb_theme_raison
        """
            Servir l'intérêt général
            """
                Donner du sens à mon travail
                """
                    Avoir un impact sur le quotidien
                    """
                        exp_cat
                        """

```

L'algorithme du package mice nous recommande d'utiliser la même méthode pour `salaire_min` et `salaire_max`. La méthode PMM autrement dit prédictive mean matching.



La PMM va :

- Prédire le salaire manquant en fonction de l'âge, de l'expérience, etc.
- Trouver des personnes avec des salaires prédits proches.
- Prendre un salaire réel parmi ces personnes pour remplacer la valeur manquante.

```

#|echo: false
plot(base_impute)

```



On remplace les NA par les valeurs imputées par la méthode PMM.

```
base_mice <- complete(base_impute, 3)
```

8.4 Tableau de comparaison des différentes méthodes

L'objectif de cette partie est de comparer les différentes méthodes d'imputation que nous avons mise en place. Sachant que nous avons supprimé manuellement nous données, nous avons sous le coude les vraies valeurs correspondant aux valeurs manquantes. Nous avons comparé dans un tableau les valeurs imputées aux vraies valeurs et calculé les écarts entre les ces dernières, c'est à dire les résultats.

Pour rappel, les trois méthodes utilisées sont les suivantes :

- Régression linéaire
- Médiane sur le genre et le nombre d'année d'expérience
- Predictive mean matching (PMM) donnée par le package {mice}

8.4.1 Comparaison des différentes méthodes pour le salaire min

	valeur_réelle	valeur_régression	valeur_median
1	1400	2198.022	2100
2	4800	3941.242	3000
3	4000	4516.240	3500
4	2500	2533.438	2900
5	1450	2150.106	3500

	valeur_mice	ecart_reg	ecart_mice	ecart_med
1	1800	-798.02207	-400	-700
2	4000	858.75803	800	1800
3	3500	-516.24029	500	500
4	2750	-33.43776	-250	-400
5	2000	-700.10554	-550	-2050

8.4.2 Comparaison des différentes méthodes pour le salaire max

	valeur_réelle	valeur_régression	valeur_median
1	2600	2805.180	3500
2	1600	2229.810	2900
3	2500	2995.557	3500
4	3000	3727.679	3500
5	5000	3771.309	2725

	valeur_mice	ecart_reg	ecart_mice	ecart_med
1	2300	-205.1796	300	-900
2	2400	-629.8102	-800	-1300

3	2500	-495.5566	0	-1000
4	3000	-727.6793	0	-500
5	5000	1228.6911	0	2275

8.5 Calcul des écarts moyen

L'objectif est, à partir, du tableau de comparaison des méthodes calculer l'écart moyen entre les valeurs réelles et les valeurs estimés par les différentes méthodes d'imputation. Plus l'écart sera faible meilleure la méthode sera.

Salaire max

[1] 222.0149

[1] 23.32836

[1] -44.49527

salaire min

[1] 133.4627

[1] 22.31343

[1] 104.7002

On voit dans les deux cas que la méthode proposé par mice est la meilleure. La méthode d'imputation par la régression est la plus mauvaise des trois.

Pour le salaire max, la méthode d'imputation par la médiane en fonction du genre et du nombre d'année d'expérience est une bonne alternative avec un écart moyen plutôt proche de la réalité.

Il faut bien prendre en compte que nous parlons de salaire donc les écarts sont en euros (€). Par exemple, un écart moyen de 100 correspond à une erreur de prédiction moyenne de 100€ sur le vrai salaire déclaré.

9 Valeurs manquantes sur les variables souhaits

Nombre de valeurs manquantes pour les 4 variables souhait

```
[1] "valeurs manquantes : souhait_1"
```

```
[1] 0
```

```
[1] "valeurs manquantes :souhait_2"
```

```
[1] 142
```

```
[1] "valeurs manquantes :souhait_3"
```

```
[1] 255
```

```
[1] "valeurs manquantes :souhaité_4"
```

```
[1] 336
```

Les variables souhait sont une construction ne notre part pour voir les 4 premiers souhaits des individus concernant l'échelle dans laquelle il souhaite intégrer un service public. Certains individus ont répondu en ne mettant uniquement qu'un souhait sur quatre possible, on a donc des valeurs manquantes sur ces variables.

Comme l'ordre des souhaits n'a pas d'importance et dépend simplement du fait qu'un individu est coché une ou plusieurs cases en fonction de ces préférence, on ne peut pas remplacer ces valeurs de manière efficace et satisfaisante.

Dans le questionnaire, les réponses à la question "dans quelle service souhaitez vous travailler?" sont organisés dans l'ordre suivant : Au sein d'un ministère, Au sein d'une région, Au sein d'un département, Au sein d'une commune.

Si un individu coche une seule case, par exemple "au sein d'une région", dans {souhait_1}, on aura la réponse "au sein d'une région" et des valeurs manquantes dans les autres variables souhaits.

Si un individu coche plusieurs case alors les réponses apparaîtront dans les différentes variables "souhait" en fonction de l'ordre des réponses du questionnaire donc si l'individu coche "au sein d'un ministère" puis "au sein d'une commune" alors dans {souhait_1}, on aura "au sein d'un ministère" et dans {souhait_2} "au sein d'une commune", indépendamment du fait qu'il

préfère peut être travailler dans une commune plutôt que dans un ministère pourtant travailler dans un ministère sera automatiquement dans {soudhait_1} si la réponse est coché.

Nous avons donc le choix entre supprimer la données ou la conserver. Nous avons décidé de garder la données pour garder de l'information supplémentaire. Cependant, c'est variables ne pourront pas être utilisé pour des analyses poussées.

10 Conclusion

Pour les variables quantitatives, la méthode d'imputation la plus performante fut celle proposée par le package {mice}, qui sélectionne automatiquement la méthode d'imputation la plus adaptée. Dans notre cas, la méthode retenue est le PMM (Predictive Mean Matching).

Concernant les variables qualitatives, l'imputation la plus efficiente repose sur les tendances observées lors de notre analyse descriptive.

En conclusion, nous avons pu imputer de manière satisfaisante l'ensemble de nos données manquantes, ce qui nous permettra par la suite de réaliser des analyses plus approfondies.