

TECHNIQUE DE PRÉVISIONS & CONJONCTURE

Prévision du prix du brocoli sur un horizon temporel de 12 mois à l'aide de variables explicatives

BOUSCAUD Jules

Table des matières

Introduction	3
Analyse préliminaire	4
Présentation des données.....	4
Détection des points atypiques	8
Vérification de la stationnarité des différentes séries.....	10
Statistique descriptive sur la série des prix du brocoli	11
Sélection des variables	12
Prévision sur un horizon temporel à 12 mois	14
Représentation graphique des prévisions	14
Comparaison des prévisions et qualité de prévision	16
Test de prévision.....	18
Conclusion.....	19
Annexe	20

Introduction

En 1990, le président américain George H.W. Bush lors d'un discours, a prononcé les paroles suivantes : « Je n'aime pas les brocolis. Et je ne les ai pas aimés depuis que je suis petit et que ma mère me forçait à en manger. Je suis le Président des États-Unis et je ne vais plus manger de brocoli ! ». Ces paroles ont eu un véritable retentissement politique, impactant directement le marché du brocoli et ses prix. Dans ce dossier, nous allons étudier le prix du brocoli sur la période de 2000 à 2020. Pour terminer cette petite anecdote, contrairement à ce que l'on peut penser, la côte du brocoli ne s'est pas effondré, au contraire, cette polémique a paradoxalement dynamisé les ventes de brocoli.

L'objectif de ce dossier n'est pas de comprendre les moindres méandres du marché du brocoli mais plutôt axé sur une analyse de série temporelle pour faire des prédictions de très court terme. Pour essayer d'affiner les prévisions, nous allons utiliser différentes autres séries temporelles qui sont potentiellement susceptible d'impacter le prix du brocoli.

Concrètement, la problématique de ce projet se matérialise sous la question suivante : « Dans quelle mesure l'intégration de variables climatiques et économiques permet-elle d'améliorer la prévision du prix du brocoli à un horizon de 12 mois ? »

Le dossier va se décomposer en deux grandes parties, une première faisant office d'analyse préliminaire dans laquelle nous verrons les caractéristiques des séries étudiées, les différents points atypiques qui marquent la série des prix du brocoli. La stationnarité des séries sera également étudiée dans cette partie ainsi que les statistiques descriptives. Une deuxième partie plutôt technique s'axera autour de la sélection des variables réellement impactantes et dans laquelle nous ferons nos prévisions sur 12 mois. Dans cette même partie, nous regarderons la qualité de prévision avant de finir sur une conclusion récapitulant l'ensemble des résultats.


Analyse préliminaire

L'analyse préliminaire de nos séries est primordiale pour comprendre leurs comportements. Elle permet de préparer les séries pour une étude plus poussée dans l'objectif de faire les prévisions les plus précises possibles. Pour cela, il faut comprendre la nature des données, leurs fréquences, s'il existe des points susceptibles d'influencer les prévisions. Stationnariser les séries est également une étape clé pour pouvoir faire de la prévision. Il faudra donc traiter les séries qui ne sont pas stationnaires.

Présentation des données

La série principale de notre étude est la série du prix d'un pound¹ de brocoli. Elle retrace l'historique du prix du brocoli sur 20 ans de janvier 2000 à fin décembre 2020 avec une fréquence mensuelle. Elle est disponible sur le site de la FRED².

Graphique 1 : Série du prix d'un pound de brocoli



Cette série n'est pas marquée par une quelconque saisonnalité et, à première vue, n'est pas stationnaire. On a une légère tendance haussière dans le temps avec quelques pics qui représentent probablement des prix atypiques. Il conviendra de s'en assurer par la suite.

Pour tenter d'améliorer les prévisions du prix du pound de brocoli, nous avons sélectionné 4 autres séries de nature climatique et économique.


¹ Représente environ 453,59 gramme

² Federal Reserve Economic Data

La première, le prix du carburant mesurée en dollars par gallons. La série du carburant peut être une bonne série explicative pour la série du prix du brocoli, en effet, intuitivement nous pouvons nous dire qu'une variation du prix du carburant pourrait avoir un impact indirect sur le prix du brocoli que ce soit dans le processus de production ou de transport.

Cette série est initialement à fréquence hebdomadaire mais par souci de cohérence, il a fallu modifier la fréquence pour la mensualiser. Pour cela, le dernier prix enregistré dans le mois correspond au prix de début de mois. On obtient donc la série ci-dessous :

Graphique 2 : Série prix du carburant aux USA :




Source : FRED

La série ne présente aucune saisonnalité ni tendance apparente pourtant, elle n'est pas stationnaire.

La deuxième série explicative économique est la série « engrais » de l'indice des prix à la production par industrie pour la fabrication des pesticides, engrais et autres produits chimiques à destinée agricole. Cette série présente sur le site de la FRED est indexé sur le mois de décembre 1984 en base 100. Elle est à fréquence mensuelle.

Comme pour la série du carburant, une variation de l'indice des prix de la production d'engrais peut être responsable d'une variation du prix du brocoli, en effet, dans les cultures de brocoli américaine de nombreux traitements sont appliqués sur les champs pour maximiser le rendement. Une variation du prix de production de l'engrais entraînerait alors une variation indirecte du prix du brocoli.

Graphique 3 : Série indice des prix à la production de l'engrais et pesticides




Source : FRED

Graphiquement, la série ne semble pas contenir de composante saisonnière ni de tendance apparente claire. Par précaution, nous la stationnariserons avant de faire les prévisions.

Les deux dernières séries explicatives sont des séries climatiques qui représentent respectivement l'indice de sécheresse de Palmer³ qui est compris entre -10 et 10 et le cumul de précipitation en Inches. Ces deux séries proviennent du site de la NCEI⁴ et concerne l'Etat de Californie qui est le principal Etat producteur de brocoli avec l'Arizona. Elles sont toutes les deux à fréquence mensuelle sur la même période que les autres c'est-à-dire de janvier 2000 à fin décembre 2020.


Graphique 4 : Série indice de sécheresse de Palmer pour l'Etat de Californie



³ PDSI (Palmer Drought Severity Index)

⁴ National Centers for environmental Information

Graphique 5 : Série des précipitations dans l'Etat de Californie



La série de l'indice de sécheresse n'est pas marquée par une composante saisonnière contrairement à la série des précipitations où l'on retrouve une saisonnalité très marquée. On ne va pas stationnariser ces séries car on risquerait de perdre toutes l'informations pertinente pour nos prévisions. L'intérêt est de voir si une fracture dans la saisonnalité dans les précipitations impacte le prix du brocoli.

Détection des points atypiques

Maintenant que nous avons vu les différentes séries qui vont être utilisées dans ce dossier, regardons s'il existe des observations dites atypiques qui influenceraient le comportement de la série. Le tableau ci-dessous récapitule les différents points atypiques mis en avant par la méthode de détection des points atypiques.

Tableau 1 : Récapitulatif des points atypiques de la série de prix d'un pound de brocoli

Type	Période	Indice	Coefficient	Statistique t
AO	12	2000:12	0.485	6.696
TC	25	2002:01	0.408	4.743
AO	26	2002:02	0.417	5.631
TC	85	2007:01	0.409	4.846
TC	132	2010:12	0.299	3.510
TC	157	2013:01	0.451	5.352

Parmi les sept outliers identifiés par la méthode de détection automatique, trois sont particulièrement significatifs.

Le mois de décembre 2000 a été marqué par une période de gel importante en Californie et en Arizona qui sont les principaux états producteurs de brocolis aux USA⁵. Cette période a perturbé les récoltes et a fait grimper le prix du pound de brocoli. Ce choc a été ponctuel, les prix sont revenus à la normale à la fin de cet événement climatique particulier.

Encore une fois, des températures particulièrement basses ont provoqué des gelées importantes en Californie et en Arizona en hiver 2002, ce qui a de nouveau perturbé la récolte des légumes d'hiver. Cette pénurie s'est répercutée sur le prix de ces légumes comme le brocoli à la fin de l'hiver. Cela correspond également à un choc brutal et temporaire.

En janvier/février 2002, il y a une séquence composée d'un choc transitoire suivi d'un choc ponctuel (AO). Économiquement, il s'agit davantage d'un choc transitoire car l'effet a légèrement persisté à très court terme. L'outlier effects le montre très bien également, en effet, la signature graphique du choc est très similaire à celle d'un choc transitoire.

⁵ Sur le site de l'U.S Department of Agriculture, le rapport annuel sur les légumes communique des informations sur la production, l'utilisation, la valeur et le prix des différents légumes produits aux États-Unis.

Pour finir, le troisième point correspond encore une fois à de mauvaises conditions climatiques. Le prix du brocoli a atteint son plus haut historique notamment à cause d'une mauvaise récolte en Californie, en Arizona et au Mexique qui est le principal exportateur de brocolis des USA. Cette réduction de l'offre de brocoli sur le marché a causé une augmentation du prix de manière transitoire avant de revenir à la normale par la suite avec la reprise des importations et les récoltes printanières aux USA. L'aspect ponctuel ou/et transitoire de ces chocs est appuyé par l'outlier effect .

La fonction « tso » identifie un ARIMA(1,1,0) comme le processus qui correspond le mieux à la série corrigée sans les points influents détectés. La série est différenciée à l'ordre 1 ce qui indique la présence d'une tendance dans le temps. En effet, si on regarde la série du prix des brocolis, on voit très clairement la présence d'une tendance positive. Donc la série n'est pas stationnaire en niveau d'où la nécessité de la différencier. Le coefficient de la série corrigée est estimé à -0,29, ce qui traduit une légère correction des prix après chaque choc.


A partir de maintenant, nous allons travailler avec la série corrigée, c'est-à-dire sans la présence des outliers détectés précédemment.

Vérification de la stationnarité des différentes séries


Maintenant, regardons si nos différentes séries sont stationnaires. A priori, les séries sur le prix du brocoli, du carburant et sur l'indice des prix de l'engrais ne sont pas stationnaires. Pour corriger cela, il faut procéder à une transformation logarithmique puis à une différenciation première pour avoir les séries des rendements ou en taux de croissance.

$$\Delta \text{Log}(Y_t) = \log(Y_t) - \log(Y_{t-1})$$


Graphique 6 : série stationnarisée du prix du brocoli



Graphique 7 : série stationnarisée du prix du carburant



Graphique 8 : série stationnarisée de l'indice de l'engrais



Les deux autres séries sur l'indice de sécheresse de Palmer et sur la quantité de précipitation en Californie n'ont pas besoin d'être stationnarisées, en effet, la première étant un indice, par construction la série est pré-stationnarisée. L'étude de cette série est censée nous apporter de l'information sur la l'état du choc pour chaque mois, si la série est différenciée, cela signifierait que l'on regarderait si le sol est plus ou moins sec par rapport au mois dernier, ce qui n'a pas de sens dans notre étude.

En ce qui concerne la série des précipitations, elle n'a pas de tendance en effet, la quantité de pluie tombée dans le mois ne dépend pas de la quantité du mois passé. Différencier la série reviendrait à comparer la quantité de pluie tombée par rapport au mois précédents or ce qui est réellement intéressante c'est s'il a beaucoup plus ou pas dans le mois.

Statistique descriptive sur la série des prix du brocoli

Avant de nous lancer dans une analyse plus poussée. Intéressons-nous, en premier lieu, à la série corrigée et stationnarisée du prix du brocoli, soit à la variation du prix du brocoli. Le tableau ci-dessous regroupe les principales statistiques descriptives. L'objectif de ces statistiques est de comprendre le comportement de notre série notamment sur sa distribution.

Tableau 2 : Statistiques descriptives série de prix du pound de brocoli corrigé

Statistique	Valeur
Nombre d'observations	239.0000
Moyenne	0.0019
Médiane	0.0025
Écart-type	0.0647
Variance	0.0042
Minimum	-0.2081
Maximum	0.1759
Étendue	0.3840
Q1 (25%)	-0.0388
Q3 (75%)	0.0453
Intervalle interquartile (IQR)	0.0841
Skewness (asymétrie)	-0.1541
Kurtosis (aplatissement)	3.2702
Kurtosis excès	0.2702

La série log-différenciée du prix du brocoli présente une moyenne quasi-nulle (0.0019) confirmant la stationnarité de la série après transformation. La médiane légèrement supérieure (0.0025) couplée à un skewness faiblement négatif (-0.154) indique que la distribution est très légèrement tirée vers la gauche, suggérant que les chocs baissiers tendent à être marginalement plus prononcés que les chocs haussiers — comportement cohérent avec la nature des prix agricoles. La volatilité est notable avec un écart-type de 6.47%, des extremums atteignant -0.208 et $+0.176$, bien que l'IQR (0.084) révèle que la majorité des variations restent contenues dans un intervalle étroit, les valeurs extrêmes demeurant des événements ponctuels. Enfin, un kurtosis excès proche de zéro (0.270) montre que la distribution de la série est proche d'une distribution normale.

Sélection des variables

Dans notre étude, nous cherchons à améliorer les prévisions du prix du brocoli grâce à des variables pouvant impacter la production de brocoli. Ce sont les séries explicatives que nous voyons jusqu'à présent (prix du carburant, précipitation, PDSI, indice des prix de l'engrais).

Parmi ces quatre séries, il est fort probable que certaines n'apportent aucune information supplémentaire afin d'améliorer la capacité de prévision du prix du brocoli. C'est pour cela que nous allons utiliser une approche par sélection automatique de variable.

La première méthode « BestSubSet » soit traduit littéralement, la méthode du meilleur sous-ensemble préconise de ne garder qu'un modèle ne contenant que les variables « précipitation » et « carburant ». Ce modèle est celui qui maximise la qualité d'ajustement avec un R^2 ajusté de 0.0054. Si on s'intéresse davantage au critère d'information (BIC, Cp de Mallow) alors le modèle qui minimise ces deux critères ne garde que la variable « carburant » avec respectivement un BIC de 9.1 et un Cp de 1.6.

Ainsi, deux des trois indicateurs suggèrent de garder le modèle contenant uniquement la variable « carburant ». Regardons maintenant ce que nous propose la méthode GETS qui est une méthode permettant d'obtenir à la fois un modèle bien spécifié et parcimonieux.

La méthode GETS ne parvient pas à spécifier le meilleur modèle car le test de Ljung-Box ARCH(1) indique qu'il y a de l'hétéroscédasticité, les erreurs ne sont pas constantes dans le temps. En présence d'une volatilité des erreurs la méthode n'a pas réussi à réduire le modèle.

À partir des résultats généraux du modèle⁶, nous parvenons tout de même à dégager un « meilleur modèle », en effet, le coefficient de la composante AR(1) est très significatif (au seuil de 1%). Le coefficient devant la variable « carburant » est lui aussi significatif mais à un seuil de 10%. Ainsi, la méthode GETS, nous donne comme meilleur modèle, un modèle ARX(1) avec la variable « carburant » si nous élargissons le seuil d'erreur à 10% sinon un modèle AR(1) sans variables explicatives si on réduit le seuil⁷

Pour conclure cette partie sur la sélection de variables pertinentes pour expliquer le prix du brocoli, les deux méthodes étudiées convergent vers des résultats très similaires, en effet, il semblerait que le meilleur modèle à étudier contiendrait une composante AR(1) et pas de variables explicatives. Cependant, pour la suite de l'étude, nous allons tout de même conserver un modèle ARX(1) avec la variable « carburant » comme variable explicative.

Le tableau ci-dessous récapitule tous les coefficients pour chaque modèle défini par chacun des deux méthodes de sélection de variables vu précédemment ainsi que le meilleur modèle sans l'ajout de variables explicatives.

⁶ Un modèle ARX(3) avec les 5 variables explicatives.

⁷ Si on contraint la méthode à ne pas tenir compte des tests de Ljung-Box, le modèle final donné par la méthode GETS est un AR(1)

Tableau 3: Récapitulatif des coefficients pour chaque modèles

	ARX(3)	ARIMA(2,0,1)	OLS
AR(1)	-0.323 ***	0.535	-
AR(2)	-	0.201	-
MA(1)	-	0.003	-
Carburant	-0.1215876	-	-0.110
Engrais	-	-	-
Précipitation	-0.001	-	-0.003
PDSI	-	-	-
AIC	-619.1873	-661.610	-626.941
R ²	0.11612	-	0.014

Si on compare un peu les différents modèles en se basant sur l'AIC, le modèle qui semble avoir été le meilleur statistiquement est le modèle ARIMA(2,0,1), en effet, c'est celui qui minimise ce critère d'information. Les variables explicatives n'étant pas ou très peu significatives⁸ n'apportent de réelle plus-value à l'ajustement du modèle, au contraire, elles l'alourdissent davantage en le rendant moins parcimonieux.


⁸ Seule la variable « carburant » est significative au seuil de 10% dans le modèle ARX(3)

Prévision sur un horizon temporel à 12 mois

Maintenant que nous avons pu sélectionner plusieurs modèles susceptibles de prédire le prix du brocoli, essayons de faire des prévisions sur un horizon temporel de 12 mois. Pour cela, nous avons coupé notre jeu de données en deux sous-échantillons, l'un pour entraîner le modèle et l'autre pour le tester. L'idée est ensuite de comparer les différentes prévisions avec les données réelles de la série.


Représentation graphique des prévisions

Graphique 9 : prévision sur 12 mois avec le modèle ARX(1) avec la variable « carburant »




Sur le graphique ci-dessus, nous voyons une stagnation du taux de croissance du prix du brocoli prédit autour de 0 qui correspond quasiment à la moyenne historique (0,019), ce qui semble particulièrement mauvais au vu de la volatilité historique du taux de croissance. L'intervalle de confiance est également particulièrement large $\pm 0,12$, ce qui économiquement, se traduit par le fait que le modèle peut dans 95% des cas prédire des prix futurs dans cette tranche de prix. Ce vaste intervalle peut s'expliquer par le fait que la variable explicative « carburant » n'est pas significative et ajoute de la variance au modèle.

Graphique 10 : prévision sur 12 mois avec un modèle ARIMA(2,0,1)



Sur ce graphique, on constate des prévisions très similaires à celles du modèle précédent AR(1) avec la variable « carburant ». En effet, les prévisions du taux de croissance du prix du brocoli stagnent autour de 0 avec un intervalle de confiance au seuil de 95% qui est également très large. La seule différence est le petit pic négatif au début de la prévision probablement causé par l'ajout d'une composante AR(2).

Graphique 11 : Prévision à 12 mois avec un modèle OLS




Les prévisions faites avec ce modèle ne sont pas dictées par les dynamiques temporelles de la série, en effet, le modèle ne tient pas compte des observations passées mais seulement des variables explicatives (ici, « carburant » et « précipitation »). Graphiquement, cela s'illustre par des prévisions qui fluctuent davantage que les deux autres modèles, même si le taux de croissance du prix du brocoli est toujours autour de 0. Cela est dû au fait que le taux de croissance réagit uniquement aux variations du rendement du carburant et au cumul de précipitation.

Comparaison des prévisions et qualité de prévision

Maintenant que nous avons effectué les prévisions pour nos trois modèles différents comparons simultanément les prévisions de ces modèles et regardons leur qualité de prévision. Pour cela, nous allons calculer le MSE et le R^2_{OOS} pour chaque modèle et les comparer avec celles d'une prévision dite naïve c'est-à-dire une marche aléatoire $y_t = y_{t-1} + \varepsilon_t$.

Graphique 12 : Comparaison des différentes prévisions avec la série observée



Sur ce graphique, la similitude entre les prévisions faites par les différents modèles est vraiment frappante. Elles convergent toutes vers 0 et restent très plates sur l'horizon de prévision. La moyenne historique étant très proche de 0, il n'est pas surprenant de voir les prévisions converger vers cette valeur, en effet, la mémoire de ces modèles est très courte et s'estompe petit à petit. Ces méthodes servent à faire des prévisions à très court terme (à 1 mois).

En observant la série observée, nous remarquons qu'elle est très volatile, avec des variations mensuelles du prix du brocoli allant de 5% à -10%. Aucun des trois modèles étudiés ne parvient à capter cette volatilité, ce qui signifie qu'il existe d'autres composantes que celles étudiées qui expliquent le prix du brocoli.

Maintenant, nous allons nous intéresser à la qualité de prévision de chaque modèle en calculant divers indicateurs comme le MSE et le R^2_{OOS} puis en le comparant avec une marche aléatoire pour savoir si nos modèles font mieux que le hasard.


Tableau 4 : Récapitulatif des tests de Diebold-Mariano

Modèle	MSE	R ² OOS
Naïf	0.006412	0.000000
ARX(1)	0.001806	0.718424
ARIMA(2,0,1)	0.001825	0.715343
OLS	0.001640	0.744300

Pour les trois modèles, le R²OOS est supérieur à 0, ce qui signifie que les trois modèles sont meilleurs que le modèle naïf. Le R²OOS d'environ 0,72 indique que les modèles expliquent 72% de la variance out-of-sample par rapport au modèle naïf. Cela peut paraître étonnant au regard de la comparaison graphique mais cohérent avec le fait que le modèle naïf n'est pas nécessairement un bon modèle de référence pour la série étudiée notamment dû à la volatilité.

Si nous regardons maintenant le MSE, le modèle OLS a un MSE très légèrement inférieur aux deux autres modèles, ce qui signifierait que les prévisions seraient plus proches des vraies valeurs que pour les autres modèles.

Graphique 12: Erreur de prévision cumulée au carré (CSPE)



Le CSPE confirme que les trois modèles linéaires dominent largement le modèle naïf sur l'ensemble de l'horizon, mais restent très proches entre eux. L'OLS ressort marginalement meilleur en fin de période. Ce graphique illustre également que les erreurs s'accumulent de façon relativement régulière pour les trois modèles, sans choc majeur, contrairement au naïf qui subit de plein fouet la forte volatilité de décembre 2019.

Test de prévision

Cependant avant d'affirmer que le modèle OLS fait les meilleures prévisions, il faut tester statistiquement si les modèles sont significativement meilleurs que le modèle naïf. Pour cela nous allons utiliser le test de Diebold-Mariano. Nous allons d'abord comparer et tester les différents modèles vus avec le modèle naïf puis enfin entre eux pour voir si un modèle se dégage des autres par sa qualité, ce qui ne sera probablement pas le cas au vu de la similitude de nos modèles entre eux.

Tableau 5 : Test de Diebold-Mariano

Comparaison	Statistique DM	p-valeur
ARX(1) vs Naïf	-3.3493	0.0032
ARIMA(2,0,1) vs Naïf	-3.1252	0.0048
OLS vs Naïf	-3.2086	0.0042
ARX(1) vs ARIMA(2,0,1)	-0.1614	0.8747
ARX(1) vs OLS	1.1396	0.2786
ARIMA(2,0,1) vs OLS	1.2871	0.2245

Les résultats exhibés dans ce tableau montrent très clairement que les trois modèles étudiés sont significativement meilleurs que le modèle naïf de référence, en effet, le DM test est significatif au seuil de 1% pour les trois premières lignes du tableau. Cependant, aucun modèle ne se distingue des autres par sa qualité ce qui vient confirmer le graphique CSPE qui montrait que les erreurs cumulées au carré étaient marginalement les mêmes. En conclusion, nos trois modèles sont meilleurs que le benchmark mais aucun ne se révèle meilleur que les autres donc le modèle OLS n'est statistiquement pas meilleur que le modèle ARX(1) ou le modèle ARIMA(2,0,1).

Conclusion

Au terme de cette étude, il ressort que le prix du brocoli suit une tendance haussière sur la période 2000-2020, ponctuée de chocs transitoires majoritairement d'origine climatique — gelées hivernales en Californie et en Arizona, sécheresses au Mexique — qui perturbent ponctuellement l'offre avant un retour à la normale. Ces chocs, bien qu'identifiables a posteriori, constituent précisément ce qui rend la série difficile à prévoir.

Les méthodes de sélection de variables ont convergé vers un résultat relativement décevant : parmi les quatre séries explicatives retenues, seule la variable « carburant » apporte une contribution marginalement significative à l'explication du prix du brocoli, et uniquement au seuil de 10 %. Les deux méthodes utilisées — BestSubSet et GETS — s'accordent sur l'idée qu'un modèle parcimonieux avec une composante AR(1) constitue la meilleure spécification, les variables exogènes n'améliorant que très faiblement la qualité d'ajustement.

Les prévisions réalisées sur un horizon de 12 mois avec les trois modèles retenus — ARX(1), ARIMA(2,0,1) et OLS — sont remarquablement similaires. Elles convergent toutes vers 0, valeur proche de la moyenne historique de la série log-différenciée, sans parvenir à reproduire la volatilité observée. Néanmoins, les indicateurs de qualité de prévision nuancent ce constat : les trois modèles affichent un R^2_{OOS} d'environ 0,72, ce qui signifie qu'ils surpassent largement le modèle naïf de référence. Le test de Diebold-Mariano confirme cette supériorité de manière statistiquement significative au seuil de 1 %, tout en établissant qu'aucun des trois modèles ne se distingue significativement des autres.

Plusieurs limites méritent d'être soulevées. En premier lieu, les transformations appliquées aux séries logarithme et différenciation première — si elles sont nécessaires pour satisfaire les conditions de stationnarité — peuvent avoir affaibli les relations économiques existantes en niveaux. Il est en effet probable que la transmission du prix du carburant vers le prix du brocoli opère avec un délai de plusieurs mois, ce que les modèles actuels ne capturent pas faute d'intégrer des termes retardés sur les variables exogènes.

En second lieu, les variables explicatives retenues ne semblent pas être les déterminants directs du prix du brocoli. Les vrais facteurs explicatifs (rendements agronomiques, surfaces cultivées, conditions météorologiques locales précises, décisions d'importation) sont soit non disponibles à fréquence mensuelle, soit tout simplement non modélisables par des approches linéaires. La faible corrélation entre les variables explicatives et la série cible, visible dans la matrice de corrélation, en est la traduction directe.

Par ailleurs, les modèles linéaires utilisés sont, par construction, inadaptés à la prévision sur un horizon de 12 mois pour une série aussi volatile. Leur mémoire s'estompe rapidement et leurs prévisions convergent mécaniquement vers la moyenne inconditionnelle, ce qui les rend plus pertinents sur un horizon d'un à deux mois. Des approches à volatilité conditionnelle de type GARCH permettraient de mieux modéliser l'hétéroscédasticité détectée dans les résidus, tandis que des méthodes non linéaires ou à apprentissage automatique pourraient davantage capter les dynamiques complexes qui gouvernent ce marché agricole.

Bibliographie

(s.d.). Récupéré sur Sécheresse:
<https://droughtmonitor.unl.edu/DmData/DataDownload/ComprehensiveStatistics.aspx>

(s.d.). Récupéré sur esmis.nal.usda.gov: <https://esmis.nal.usda.gov/publication/vegetables-annual-summary>

FRED. (s.d.). Récupéré sur FRED: <https://fred.stlouisfed.org/series/APU0000712412>

FRED. (s.d.). Récupéré sur INDICE PRIX ENGRAIS:
<https://fred.stlouisfed.org/series/PCU32533253>

FRED. (s.d.). Récupéré sur PRIX CARBURANT: <https://fred.stlouisfed.org/series/GASDESW>

Pluie. (s.d.). Récupéré sur NOAA: <https://www.ncei.noaa.gov/access/monitoring/climate-at-a-glance/statewide/time-series>

Annexe

0- Librairie & package utilisés

```
library(tidyverse)
library(tsoutliers)
# Pour la lecture des data
library(readr)
library(readxl)

# Pour le tableau
library(knitr)
library(kableExtra)

# Pour les statistiques
library(moments)


# prévision
library(RJDemetra)

# Sélection de variable
library(leaps)
library(gets)

# Timeseries
library(tseries)
library(TSA)
library(forecast)
```


1- Détection points atypiques

Graphique : série originale vs ajustée & outlier effects




2- Sélection de variable


Graphique : modèle maximisant le R2-ajusté



Graphique : modèle maximisant le Cp de Mallow



Graphique : modèle maximisant le BIC



Sortie code : méthode de sélection : méthode BestSubSet

Subset selection object

Call: regsubsets.formula(prixbroco ~ ., data = data_corrige, nbest = 1,
method = "exhaustive")

4 Variables (and intercept)

	Forced in	Forced out
carburant	FALSE	FALSE
engrais	FALSE	FALSE
PDSI	FALSE	FALSE
precipitation	FALSE	FALSE

v

1 subsets of each size up to 4

Selection Algorithm: exhaustive

carburant engrais PDSI precipitation

```
1 ( 1) "*" " " " " " "
2 ( 1) "*" " " " " "*"
3 ( 1) "*" "*" " " "*"
4 ( 1) "*" "*" "*" "*"
```

Sortie code : méthode de sélection : méthode GETS

GUM mean equation:

	reg.no.	keep	coef	std.error	t-stat	p-value
mconst	1	0	0.0082433	0.0065362	1.2612	0.20853
ar1	2	0	-0.3361904	0.0660861	-5.0872	7.588e-07 ***
ar2	3	0	-0.0818070	0.0695879	-1.1756	0.24098
ar3	4	0	-0.0582345	0.0661144	-0.8808	0.37935
carburant	5	0	-0.1434558	0.0798078	-1.7975	0.07358 .
engrais	6	0	0.1210363	0.1524870	0.7937	0.42817
PDSI	7	0	0.0010796	0.0016644	0.6487	0.51720
precipitation	8	0	-0.0014931	0.0021607	-0.6910	0.49025

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Diagnostics:

	Chi-sq	df	p-value
Ljung-Box AR(4)	2.8491	4	0.5833789
Ljung-Box ARCH(1)	7.5786	1	0.0059065

Messages:

- GUM does not pass one or more diagnostic checks

Sortie de code modèle OLS avec « carburant » et « précipitation »

Call:

```
lm(formula = as.formula(paste("prixbroco ~", paste(best_vars,
collapse = " + "))), data = data_corrige)
```

Residuals:

Min	1Q	Median	3Q	Max
-0.216153	-0.040885	0.000817	0.043366	0.164116

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	v
(Intercept)	0.006688	0.005551	1.205	0.229	
carburant	-0.109814	0.081751	-1.343	0.180	
precipitation	-0.002528	0.002072	-1.220	0.224	

Residual standard error: 0.06451 on 236 degrees of freedom

Multiple R-squared: 0.01375, Adjusted R-squared: 0.005389

F-statistic: 1.645 on 2 and 236 DF, p-value: 0.1953

(Intercept)	carburant	precipitation
0.006688013	-0.109813697	-0.002528365
[1]	-626.9413	

Sortie de code modèle ARX(1) avec « carburant »

Date: Sun Apr 26 11:07:22 2026

Dependent var.: train\$prixbroco

Method: Ordinary Least Squares (OLS)

Variance-Covariance: Ordinary

No. of observations (mean eq.): 226

Sample: 2 to 227

Mean equation: v

	coef	std.error	t-stat	p-value
mconst	0.0043961	0.0040740	1.0791	0.2817
ar1	-0.3252122	0.0620449	-5.2416	3.687e-07 ***
mxreg	-0.1217061	0.0777905	-1.5645	0.1191

Signif. codes:

```
0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Diagnostics and fit:

```
Chi-sq df p-value
Ljung-Box AR(2) 1.0245 2 0.5991
Ljung-Box ARCH(1) 6.5821 1 0.0103 * v
```

Signif. codes:

```
0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
SE of regression 0.06109
R-squared 0.11612
Log-lik.(n=226) 312.59364
```

Sortie de code modèle ARIMA(2,0,1)

Series: data_corrige\$prixbroco
ARIMA(2,0,1) with non-zero mean

Coefficients:

```
ar1 ar2 ma1 mean v
0.5355 0.2011 -0.9508 0.0026
s.e. 0.0752 0.0713 0.0351 0.0008
```

```
sigma^2 = 0.003575: log likelihood = 335.81
AIC=-661.61 AICc=-661.35 BIC=-644.23
```