

Master 1 – Économétrie et statistiques,
parcours économétrie appliquée

Auteur : Jules Bouscaud

Prévision de la fréquentation touristiques en France à un horizon de court terme

Encadrant : Oliver Darne

4 juin 2026

Remerciement

Je tiens tout d'abord à remercier mon entourage : famille, amis et proches pour leur soutien tout au long de la rédaction de ce mémoire. Ils m'ont encouragé à persévérer alors que l'envie s'amenuisait petit à petit. Je souhaite également remercier mon encadrant M. Darne pour avoir répondu à mes nombreuses interrogations et de m'avoir aiguillé dans la rédaction de ce présent mémoire.

Résumé

Cette étude a pour objectif de déterminer le meilleur modèle de prévision les plus performants pour anticiper la fréquentation touristique en France à court terme, mesurée par le nombre de nuitées en hôtellerie sur la période 2011-2025. Elle répond à deux questions : Quel modèle permet de prévoir efficacement la fréquentation touristique en France à court terme ? Dans quelle mesure l'intégration de variables conjoncturelles, compétitives et comportementales permet-elle d'améliorer la qualité de ces prévisions ? Sept modèles ont été estimés, répartis en deux groupes : des modèles saisonniers (SARIMA, ETS, ADAM ETS ARIMA, SARIMAX) et des modèles sur la tendance appliqués à la série corrigée des variations saisonnières (SARIMA, ARIMAX, RLM). Après traitement des valeurs manquantes par lissage de Kalman et désaisonnalisation par la méthode X13-ARIMA-SEATS, les prévisions de chaque modèle sont évaluées sur l'année 2025 grâce à des indicateurs de qualité de prévision (RMSE, MAE, MASE, MAPE) et au test statistique (Diebold-Mariano). Les résultats montrent que les modèles de prévision saisonniers SARIMA et SARIMAX surpassent le modèle naïf saisonnier. Cependant, aucun modèle sur la tendance ne parvient à faire mieux que les prévisions du modèle naïf simple. L'intégration de variables exogènes (Covid, Prix relatif Lags 2 et Google Trends) améliore les indicateurs de qualité sans que cette amélioration soit statistiquement significative.

Mots-clés : Prévision touristique, fréquentation hôtelière, séries temporelles, évaluation des prévisions, R

Abstract

The objective of this study is to identify the most effective forecasting model for predicting short-term tourist demand in France, as measured by the number of hotel room nights for the period 2011–2025. It addresses two questions: Which model can effectively forecast short-term tourist demand in France? To what extent does the inclusion of economic, competitive, and behavioral variables improve the quality of these forecasts? Seven models were estimated, divided into two groups: seasonal models (SARIMA, ETS, ADAM ETS ARIMA, SARIMAX) and trend models applied to the seasonally adjusted series (SARIMA, ARIMAX, RLM). After handling missing values via Kalman smoothing and seasonality adjustment using the X13-ARIMA-SEATS method, the forecasts of each model are evaluated for the year 2025 using forecast quality indicators (RMSE, MAE, MASE, MAPE) and the Diebold-Mariano statistical test. The results show that the SARIMA and SARIMAX seasonal forecasting models

outperform the naive seasonal model. However, no trend model manages to outperform the forecasts of the simple naive model. The inclusion of exogenous variables (COVID, Relative Price Lags 2, and Google Trends) improves the quality indicators, though this improvement is not statistically significant.

Keywords: Tourism forecasting, hotel occupancy, time series, forecast evaluation, R

Sommaire

Remerciement.....	2
Résumé.....	3
Sommaire	5
Sigles	6
Introduction	8
La demande touristique en France : mesure et potentiels déterminants.....	14
Méthodologie de la prévision du nombre de nuitées en hôtellerie.....	23
Analyse empirique de la fréquentation touristique : estimation et prévision.....	39
Conclusion et limites	64
Bibliographie.....	67
Annexes	69
Table des matières	93

Sigles

ACF : Autocorrelation Function (Fonction d'autocorrélation)
ADF : Augmented Dickey-Fuller (Test augmenté de Dickey-Fuller)
ADAM : Augmented Dynamic Adaptive Model
AHTC : Autres Hébergements Touristiques Collectifs
AIC : Akaike Information Criterion (Critère d'information d'Akaike)
AICc : Akaike Information Criterion corrected (Critère d'Akaike corrigé)
AR : Autorégressif
ARDL : Autoregressive Distributed Lag
ARIMA : Autoregressive Integrated Moving Average
ARIMAX : Autoregressive Integrated Moving Average with eXogenous variables
ARMA : Autoregressive Moving Average
BCE : Banque Centrale Européenne
CCF : Cross-Correlation Function (Fonction de corrélation croisée)
CSPE : Cumulative Squared Prediction Errors (Erreurs de prévision cumulées au carré)
CVS : Correction des Variations Saisonnières
DOM : Départements d'Outre-Mer
ES : Exponential Smoothing (Lissage exponentiel)
ETS : Error, Trend, Season
IA : Intelligence Artificielle
IPCH : Indice des Prix à la Consommation Harmonisé
IQR : Interquartile Range (Intervalle interquartile)
INSEE : Institut National de la Statistique et des Études Économiques
KPSS : Kwiatkowski–Phillips–Schmidt–Shin (Test de stationnarité)
MA : Moving Average (Moyenne mobile)
MAE : Mean Absolute Error (Erreur absolue moyenne)
MAPE : Mean Absolute Percentage Error (Erreur absolue moyenne en pourcentage)
MASE : Mean Absolute Scaled Error (Erreur absolue moyenne normalisée)
MCO : Moindres Carrés Ordinaires
MIDAS : Mixed Data Sampling
PACF : Partial Autocorrelation Function (Fonction d'autocorrélation partielle)
PIB : Produit Intérieur Brut
 R^2 : Coefficient de détermination

R^2 OOS : R^2 Out-Of-Sample (Coefficient de détermination hors échantillon)

RLM : Régression Linéaire Multiple

RMSE : Root Mean Square Error (Racine de l'erreur quadratique moyenne)

RNA : Réseau de Neurones Artificiels

SARIMA : Seasonal Autoregressive Integrated Moving Average

SARIMAX : Seasonal Autoregressive Integrated Moving Average with eXogenous variables

SR : Static Regression (Régression statique)

USD/EUR : Dollar américain / Euro (taux de change)

VAR : Vecteur Autorégressif

Introduction

Alors que la fréquentation touristique atteignait un sommet historique en 2019, avec 446,6 millions de nuitées dans les hébergements collectifs, la pandémie de COVID-19 a réduit drastiquement le tourisme français en faisant chuter ce chiffre à 258,2 millions de nuitées en 2020 (INSEE, 2025), ce qui représente une diminution sans précédent de 42,18% par rapport à 2019. Si la reprise progressive des activités touristiques en France a permis d'atteindre dès 2023, un niveau supérieur à celui d'avant-crise, la période de pandémie mondiale n'a pas été sans conséquence sur les comportements touristiques et la manière de penser le tourisme. Les Jeux Olympiques de Paris 2024 très attendus par les pouvoirs publics et les professionnels du secteur pour relancer la fréquentation dans les hébergements collectifs, n'ont pas eu les effets escomptés. Alors qu'habituellement la fréquentation hôtelière francilienne concentre environ 27% de la fréquentation hôtelière nationale, elle a enregistré une baisse de 9,2% par rapport à 2023 (INSEE, 2024). Ce paradoxe met en évidence la complexité de prévoir la fréquentation touristique dans les hébergements collectifs alors même que le tourisme en France est en pleine mutation. L'essor des plateformes de location d'hébergement et les changements de comportements touristiques complexifient la capacité à produire des prévisions fiables, dans un secteur qui représente 3,8% du PIB français et 7,4% de l'emploi¹ en 2022, selon l'INSEE. Ces chiffres montrent l'importance de l'enjeu économique du secteur touristique français. Ainsi, la prévision de la fréquentation touristique constitue un outil essentiel tant pour les professionnels du secteur que pour les pouvoirs publics : elle permet d'anticiper les fluctuations de la demande, d'adapter l'offre et d'orienter les décisions d'investissement.

Avant d'entrer dans le cœur du sujet, il convient de le définir précisément et de fixer ses limites. Pour cela, il est nécessaire de définir certains termes pour ne pas se perdre en cours de chemin. La fréquentation touristique² correspond à la demande touristique³ effectivement réalisée et mesurable. La fréquence touristique est utilisée dans cette étude pour matérialiser la demande touristique au sens économique du terme. Lorsque nous ferons référence à la demande touristique, il faudra garder en tête que nous intéressons à la fréquentation touristique en particulier. Elle est mesurée sous la forme du nombre de nuitées effectuées dans des hôtels. Ainsi si une personne séjourne 5 jours sur un territoire et dort dans un hôtel, 5 nuitées seront

¹ Soit 1,5 million d'emplois salariés (INSEE, 2025)

² Définition provenant de la documentation de l'enquête de fréquentation dans les hébergements touristiques de l'INSEE.

³ L'intention de consommer des biens et services touristiques


comptabilisées. Nous étudierons la fréquentation touristique en France (métropolitaine et départements d'outre-mer) de manière mensuelle de janvier 2011 à décembre 2025. Comme le nom du sujet l'indique, nous allons faire des prévisions afin de déterminer le modèle qui prévoit le mieux la fréquentation touristique en France. Cependant, il convient de définir l'horizon de prévision que nous nous sommes fixés. Nous allons faire des prévisions à court terme c'est-à-dire à un horizon de prévision de douze mois après la dernière date connue. Maintenant que les principaux termes du sujet sont définis, regardons ce que dit la littérature sur ce sujet.

Aujourd'hui, la littérature sur le sujet est multiple, entre 1960 et 2018 plus de six cents études sur la prévision de la demande touristique⁴ ont été publiées. Les trois auteurs de cet étude (Song et alii., 2019), exerçant à l'Université Polytechnique de Hong-Kong ont effectué un important travail dans lequel ils ont passé en revue toute la littérature sur le sujet. Dans leur papier, 211 articles ont été sélectionnés comme étant des articles pionniers ou majeurs dans la recherche sur la prévision touristique. Dans cette étude, nous nous baserons en grande partie sur les résultats de ce papier notamment pour le choix des modèles à tester. En effet, grâce à ces précieux travaux, une liste exhaustive des différentes méthodes de prévisions a été dressée afin de faire le point sur ces techniques et voir si l'une ou plusieurs d'entre elles se distinguent réellement des autres par leur(s) efficacité(s). Les auteurs font la distinction entre 4 grands groupes de méthodes de prévisions de la demande touristique : Les modèles de séries temporelles, les modèles économétriques, les modèles d'intelligences artificielles (IA) et les modèles de jugement. « Les modèles de séries temporelles prévoient la demande touristique en se basant sur ses schémas historiques. Ces modèles tentent d'identifier les tendances, les pentes et les cycles parmi les données de séries temporelles » (Song et alii., 2019). Parmi ces méthodes de séries temporelles, on retrouve tous les modèles autorégressifs (AR), de moyenne mobile (MA) ainsi que les méthodes de lissages exponentiels (ES). « Les modèles économétriques se concentrent plutôt sur l'établissement de la structure de la causalité, ou sur la détermination de l'impact des différentes variables explicatives sur la demande future. » (Song et alii., 2019). Dans cette catégorie, on retrouve les modèles de régression multiple (RLM), des modèles incluant une dynamique temporelle et des variables explicatives (ARX, ARIMAX) mais aussi des modèles vectoriels autorégressifs (VAR). « Les modèles basés sur l'IA sont capables d'expliquer des données non linéaires sans connaissance préalable des relations entre les variables d'entrée et de sortie. » (Song et alii., 2019). Parmi les principaux modèles basés sur

⁴ A review of research on tourism demand forecasting Launching the Annals of Tourism Research (Song, Qui, Jinah, 2019)

l'IA, on retrouve des modèles de réseau de neurones artificiels (RNA) les plus fréquemment utilisés et divers modèles empruntés aux sciences physiques et chimique ou/ et à la biologie. Pour finir les « modèles de jugement sont conçues pour fournir une description complète et définitive des développements futurs en utilisant l'expérience et l'intuition accumulées par des experts individuels ou des groupes de personnes. » (Song et alii., 2019). Parmi ces méthodes, la méthode Delphi est la plus connue et reconnue pour ses prévisions à long terme. Ce premier aperçu ne dresse en aucun cas une liste exhaustive des modèles de chaque méthode mais uniquement les plus célèbres et les plus utilisés dans la littérature. Dans cette étude, nous nous concentrerons uniquement sur les méthodes de séries temporelles et économétriques ; les modèles d'AI et de jugement seront donc écartés. Le schéma ci-dessous réalisé par les trois auteurs précédemment cités récapitule tous les modèles de manière exhaustive qui ont servi à prévoir la demande touristique au cours de ces dernières décennies.

Figure 1 : Schéma récapitulatif des méthodes quantitatives de séries temporelles et économétriques



Source : Song et alii., 2019

Les modèles sont classés en fonction de s'ils sont statique ou dynamique et de s'ils contiennent une ou plusieurs équations. Nous ne verrons que les modèles contenant une seule équation statistique c'est-à-dire ceux qui se situent dans la partie rougeâtre du schéma.

Les travaux de Box et Jenkins⁵ publiés dans les années 1970 ont introduit les méthodes autorégressives à moyenne mobile intégrée (ARIMA) qui ont permis une nette avancée des techniques de prévisions et ont servi de base pour nombre de travaux sur une multitude de sujet incluant les recherches sur le tourisme. Ces méthodes ont suscité un grand intérêt dans la communauté académique et ont été très largement exploitées pour prédire la demande touristique. L'article « *Forecasting Tourist Arrivals In Greece And The Impact Of macroeconomics Shoks From The Countries Of Tourists'Origin* » (Gounopoulos, 2011) montre pour le cas de la Grèce qu'un ARIMA(1,1) surperforme les méthodes de lissage exponentiel dans la prévision de court terme (1 an) de la demande touristique.

« *The Tourism Forecasting Competition* » (Athanasopoulos et alii., 2011) publié dans la revue *International Journal of Forecasting* constitue une contribution majeure à la recherche sur le sujet. Les auteurs ont testé différents modèles de prévision de séries temporelles univariées et multivariées ainsi que des modèles économétriques sur un échantillon de plus de 1000 séries temporelles uniquement touristiques à fréquence annuelle, trimestrielle et mensuelle. Leur étude se démarque des précédents notamment par l'utilisation de variables explicatives. Cette étude a permis de montrer que les modèles purement basés sur les séries temporelles produisaient des prévisions plus précises que les modèles avec variables explicatives. Cette conclusion est importante pour notre étude, il conviendra d'analyser si les résultats, pour le cas du nombre de nuitées dans les hôtels en France sont similaires à ceux trouvés par Athanasopoulos.

En ce qui concerne le cas d'étude de la demande touristique en France, peu d'étude ont été publiées ces deux dernières décennies. Nous pouvons citer les travaux de (Botti et alii., 2006) dans lequel les auteurs proposent une analyse économétrique de la demande touristique en France et dans 4 autres pays. Ce papier reste proche du thème de cette étude mais s'écarte toutefois de la problématique de prévision pure de la demande touristique.

Plusieurs autres articles intéressants et en lien direct avec la prévision de la demande touristique notamment par l'intégration d'indicateurs de recherche via Google Trends montrent des éléments très intéressants qui vont nous servir de référence tout du long de cette étude. Dans leur article « *Forecasting tourist arrivals : Google Trends meets mixed-frequency data* (Havranek & Zeynalov, 2019), les auteurs montrent que les données issues de Google Trends améliorent de manière significative les prévisions par rapport à un modèle sans ces données. Ils montrent

⁵ Time Series Analysis : Forecasting and Control (Box & Jenkins, 1970)

également qu'un modèle MIDAS combinant des données issues de Google Trends à fréquence hebdomadaire et mensuelle à 2 mois surpasse les prévisions des modèles utilisant des données de Google Trends à fréquence mensuelle et les modèles sans données Google Trends. Ces résultats sont importants dans la mesure où nous nous attendons à trouver une amélioration significative des prévisions avec l'intégration de données Google Trends. Les études suivantes : « *Forecasting tourism arrivals with an online search engine data : A study of the Balearic Islands* » (Rodríguez, 2017) et « *Short-term forecasting of Japanese tourist inflow to South Korea using Google Trend data* » (Park et alii., 2017) démontrent les mêmes conclusions. Les modèles améliorés par Google Trends donnent de meilleures prévisions que les modèles standards de séries temporelles particulièrement pour des prévisions de court terme.

Pour finir cette revue de littérature sur la prévision de la demande touristique, plus récemment plusieurs articles ont été publiés dont « *Progress in tourism demand research : Theory and empirics* » (Song et alii., 2023), qui est en quelque sorte la suite de leurs travaux dans lequel les auteurs examinent de manière exhaustive les derniers papiers sur la demande touristique et « *Hotel demand forecasting: a comprehensive literature review* » (Huang et Zheng, 2023) dans *Tourism Review* qui s'intéresse spécifiquement aux articles sur le sujet de la prévision de la demande hôtelière. Cet article en particulier présente de fortes similitudes avec l'objet de notre étude. Cette synthèse met surtout en avant une forte utilisation de modèles de séries temporelles et basés sur IA pour prévoir la demande hôtelière dans la recherche.

Bien que la littérature sur la prévision touristique soit abondante, ce travail n'ambitionne pas d'apporter des innovations théoriques inédites. Toutefois, il propose de réexaminer, sous un angle nouveau, des techniques ayant largement fait leurs preuves, en les appliquant spécifiquement au contexte de la fréquentation touristique en France. Par ailleurs, la demande touristique a rarement été appréhendée sous l'angle du nombre de nuitées hôtelières. C'est précisément dans cette approche que ce mémoire se distingue, apportant ainsi une valeur ajoutée aux études existantes.

L'objectif de ce travail est d'évaluer différents modèles de séries temporelles et économétriques, en intégrant des variables conjoncturelles, compétitives et comportementales⁶ afin prévoir le nombre de nuitées dans les hôtels français et de comparer leur qualité de prévision. Cet objectif se formalise à travers la question de recherche : Quel modèle permet de prévoir efficacement la fréquentation touristique en France à court terme ? Dans quelle mesure l'intégration de

⁶ Variables construites à l'aide des données issues de Google Trends

variables conjoncturelles, compétitives et comportementales permet-elle d'améliorer la qualité de ces prévisions ?

Pour répondre à cette problématique, notre analyse s'articulera en deux parties. La première sera consacrée à la présentation des données utilisées ainsi qu'à la méthodologie de construction des différents modèles. La seconde, sera dédiée à la discussion des principaux résultats en comparant leur qualité de prévision. Enfin, la conclusion exposera les apports et les limites de ce travail.

1. La demande touristique en France : mesure et potentiels déterminants

Cette première partie pose les fondements conceptuels de l'étude. Elle est consacrée à la présentation et à la justification des données utilisées pour répondre à la problématique. Dans un premier temps, nous définirons notre variable principale : le nombre de nuitées en hôtellerie et nous justifierons pourquoi nous l'utilisons pour mesurer la fréquentation touristique. Dans un second temps, nous présenterons les variables exogènes que nous avons retenues comme x déterminants potentiels de la fréquentation touristique. Nous les avons regroupés en trois types de variables : conjoncturelles, compétitives et comportementales. Pour chacune d'elle, nous détaillerons le processus de construction et les effets attendus sur la fréquentation touristique.

1.1. Les nuitées hôtelières comme indicateur de la fréquentation touristique

Pour comprendre et prédire la demande touristique en France, nous avons choisi de nous appuyer sur une enquête de l'INSEE, « *L'enquête sur la fréquentation dans l'hôtellerie* » qui a initialement pour « objectif l'observation conjoncturelle de la fréquentation dans l'hôtellerie de tourisme et l'étude de la structure de la clientèle, notamment de son origine géographique. » (INSEE, 2026). À partir de 2019, « *L'enquête mensuelle de fréquentation dans les hébergements collectifs de tourisme* » a succédé à celle sur la fréquentation dans l'hôtellerie pour regrouper les enquêtes qui étaient alors séparées pour chaque type d'hébergement collectifs (hôtel, camping et AHTC) afin de simplifier les opérations. L'enquête est diffusée chaque mois pour le mois précédent. En 2026, l'enquête est réalisée sur un échantillon national de 8 400 hôtels sur un total de 16 900 hôtels dans la France entière⁷, qui repose sur un plan de sondage aléatoire et stratifié (INSEE, 2026). L'une des données principales recueillie dans cette enquête est le nombre de nuitées en hôtellerie⁸. Cette variable constitue ainsi notre mesure de référence de la demande touristique en France.

Dans une grande partie de la littérature sur le sujet, « La demande touristique internationale est mesurée en termes d'arrivées touristiques, de dépenses touristiques ou de durée de séjour »


⁷ Département d'outre-mer inclus

⁸ Cf définition dans l'introduction p.6

(Song et alii., 2019). Ces mesures sont cependant le plus souvent disponibles à fréquence trimestrielle ou annuelle, ce qui limite leur utilisation dans un cadre de prévision à court terme. En effet, des données à fréquence mensuelle offrent un plus grand nombre d'observations permettant ainsi d'améliorer la robustesse des résultats et des prévisions. Elles permettent également de mettre en avant la saisonnalité très marquée dans le secteur touristique. De même, nous nous intéressons à la demande touristique pour la France ce qui inclut les touristes internationaux et les touristes résidents sur le territoire.

Cependant, l'analyse de la demande touristique par le prisme du nombre de nuitées en hôtellerie occulte une partie de la fréquentation touristique réelle. En effet, les nuitées réalisées dans d'autres hébergements marchands (campings, villages vacances, plateformes de type Airbnb) ainsi que dans des hébergements non-marchands (famille, résidence secondaire) ne sont pas captées par cette mesure. En 2025, cette part de nuitée non captée représentait environ 84% du nombre de nuitées totales enregistrées sur le territoire français (INSEE, 2025). À ce jour, il n'existe pas de mesure complète sur une période suffisamment vaste pour inclure cette part dans l'analyse de la fréquentation touristique. Ainsi, le nombre de nuitées en hôtellerie est une mesure disponible, fiable et qui reflète la demande touristique pour la France en agrégeant la demande domestique et internationale.

Figure 2– Nombre de nuitées en hôtellerie (en millier), janvier 2011- décembre 2025



Source : INSEE, Enquête mensuelle de fréquentation dans les hébergements collectifs de tourisme

Nous remarquons sur ce graphique qu'il manque certaines valeurs sur la période du covid-19, en effet, les données pour le mois de janvier, février et mars 2020 sont manquantes. Il nous

faudra procéder à une imputation des ces valeurs avant d'analyser cette série. Nous verrons plus tard la méthode sélectionnée pour imputer ces valeurs manquantes.

1.2. Les potentiels déterminants de la demande touristique

Dans l'objectif de faire les prévisions les plus précises possibles, nous avons décidé d'intégrer des variables exogènes à la demande touristique, c'est-à-dire susceptibles d'influencer la demande touristique sans que celle-ci ne les affecte en retour.

Nous avons décidé de choisir un ensemble de cinq variables explicatives : le taux de change entre le dollar et l'euro⁹, l'indicateur de confiance des ménages, la consommation des ménages en bien (en volume), le prix relatif de la France comme destination par rapport aux autres pays de la zone euro et une variable regroupant les recherches triées par mots-clés issues de Google Trends. Ce choix a été grandement influencé par la littérature existante sur le sujet de la prévision de la demande touristique à l'aide de modèles incluant des variables explicatives. Ces études mettent en évidence que seulement quelques variables améliorent de manière significative la prévision de la demande touristique. C'est le cas pour le taux de change, le revenu du pays d'origine, le prix des produits touristiques dans les destinations par rapport à ceux d'origine (c'est-à-dire le prix relatif) et les prix des produits touristiques dans les destinations concurrentes (c'est-à-dire le prix de substitution) (Song et alii., 2019). Bien que certaines de nos variables ne soient pas identiques à celle listées dans l'étude de Song, l'idée est de s'approcher de celles-ci avec des variables proxy dont les effets sur la demande touristique sont théoriquement comparables. La consommation des ménages en biens en volume reflète leur pouvoir d'achat donc de manière indirecte le revenu. De plus, d'après l'INSEE, 53% des nuitées en hôtellerie sont effectuées par des résidents. Ce constat renforce l'intérêt d'utiliser une telle variable. Nous cherchons également à tester de nouvelles hypothèses en intégrant d'autres déterminants comme l'indicateur de confiance des ménages, variable peu mobilisée dans la littérature sur le tourisme.

Parmi les variables sélectionnées¹⁰ nous pouvons les classer selon trois catégories. Les variables conjoncturelles qui reflètent l'état de l'activité économique à court terme et réagissent à ses fluctuations cycliques. Les variables de compétitivité mesurent l'attractivité relative d'une destination touristique par rapport aux destinations concurrentes ou aux pays d'origine des

⁹ Ou taux de change USD/EUR

¹⁰ Représentation graphique dans l'Annexe 1

touristes. Enfin les variables de comportement qui captent les intentions et les attitudes des agents économiques, indépendamment des indicateurs macroéconomiques traditionnels. Notre objectif est donc de voir si ces variables apportent une réelle plus-value sur les prévisions de la demande touristique.

1.2.1. Les variables de conjoncture

Dans la catégorie des variables de conjonctures, nous retrouvons la variable sur la consommation des ménages en biens. Cette variable est exprimée en volumes aux prix de l'année précédente, c'est-à-dire qu'elle reflète la quantité réelle consommée par les ménages, corrigée de l'effet-prix¹¹. Produite par l'INSEE, elle permet de mesurer le montant mensuel total consommé par les ménages dans les différents types de biens en unité monétaire (en milliards d'euros). Par exemple, en décembre 2025, les ménages ont consommé à hauteur de 46,253 milliards d'euros. Il convient, cependant, de préciser que seuls les ménages résidant en France Métropolitaine sont pris en compte dans le calcul de ce montant. Cette variable constitue en quelque sorte un indicateur du revenu des ménages : une hausse de la consommation en volume traduit une amélioration du pouvoir d'achat réel disponible. Dans la mesure où le tourisme constitue un bien normal, voire supérieur, une hausse de la consommation reflétant une hausse du pouvoir d'achat réel, devrait se traduire par une augmentation de la demande de nuitées hôtelières. L'étude du pouvoir d'achat est particulièrement intéressante dans le contexte de la demande touristique, d'autant qu'en 2025, 53% des nuitées en hôtellerie en France sont réalisées par des résidents (INSEE, 2025), ce qui fait des fluctuations du pouvoir d'achat domestique au travers de la consommation des ménages un déterminant potentiel majeur de la fréquentation hôtelière.

Toujours dans cette même catégorie, nous avons la variable sur l'indicateur de confiance des ménages issue d'une enquête mensuelle de conjoncture auprès des ménages réalisée par l'INSEE sous l'impulsion de la Commission Européenne. « Cette enquête [...] a pour objectif de recueillir, mois par mois, des informations sur le comportement des ménages, ainsi que sur les anticipations en matière de consommation et d'épargne. [...] À partir de cette enquête, un diagnostic conjoncturel et des prévisions à court terme de consommation des ménages est établi. » (INSEE, 2026). Elle est calculée par analyse factorielle à partir de 8 soldes d'opinion.

¹¹ La distinction entre valeur et volume est fondamentale : la mesure en valeur (ou nominale) reflète les montants aux prix courants sans correction de l'inflation, tandis que la mesure en volume (ou réelle) est déflatée afin de s'affranchir des effets prix et de ne refléter que les variations de quantités effectivement consommées.

Cette variable est également intéressante dans notre étude car elle tient compte des anticipations¹² des ménages. Prenons un exemple : si les ménages sont pessimistes sur le futur, ils vont épargner davantage pour se prémunir des risques éventuels liés à une mauvaise perception de la conjoncture¹³. Selon la comptabilité nationale, tout ce qui est épargné se fait au détriment de la consommation¹⁴. Donc une baisse de l'indicateur de confiance se traduirait in fine par une baisse du tourisme et donc du nombre de nuitées hôtelières. Ainsi, cette variable peut également être un déterminant potentiel de la demande touristique complémentaire à la consommation des ménages.

1.2.2. Les variables de compétitivité

Intéressons-nous maintenant aux variables de compétitivités. Le taux de change USD/EUR correspond au nombre de dollars nécessaires pour acquérir un euro. Le taux de change USD/EUR est publié chaque jour ouvré par la BCE. La série étudiée correspond au taux de change USD/EUR mensuel moyen¹⁵. L'utilisation du taux de change pour comprendre la demande touristique est documentée par certains auteurs (Song et alii., 2008), en effet, il est identifié comme un déterminant significatif de la demande touristique internationale. Si le taux de change augmente alors il y a une appréciation de l'euro, ce qui rend la France plus chère comme destination touristique pour les Américains et pour les touristes dont la devise est le dollar ou indexée sur celui-ci, ce qui se traduit par moins de nuitées en hôtellerie. Nous avons un effet qui joue négativement sur la demande. L'autre effet attendu d'une appréciation de l'euro est une fuite des résidents français vers les destinations utilisant le dollar, en effet, ces destinations deviennent moins chères. Nous avons donc aussi un effet de substitution des destinations étrangères au détriment du tourisme local. Cependant, comme nous travaillons avec le nombre de nuitées en hôtellerie sans faire de distinction entre les résidents et les non-résidents, l'effet du taux de change risque d'être plus ambigu sur le nombre de nuitées, bien que la part de résidents soit légèrement supérieure (53%) à celle des touristes internationaux.

La deuxième variable de cette catégorie, le prix relatif de la France par rapport à la Zone euro est construite comme le rapport entre l'Indice des Prix à la Consommation Harmonisé de la France (IPCH France) sur celui de la Zone euro (IPCH Zone euro).

¹² C'est une estimation des valeurs futures d'une variable économique par les agents économiques.

¹³ Voir Keynes (1936), *The General Theory of Employment, Interest and Money*, sur les motifs de l'épargne.

¹⁴ Le revenu disponible (R) peut être soit consommé (C) soit épargné (S) d'où la relation $R = C + S$

¹⁵ Une moyenne est faite sur l'ensemble des taux de référence journaliers au cours du mois considéré.

$$Prix\ relatif = \frac{IPCH\ France}{IPCH\ Zone\ euro}$$

Ces deux variables sont issues d'Eurostat et sont des indices en base 100 = 2025. Ainsi, cette variable permet de mesurer l'attractivité-prix de la France comme destination touristique par rapport aux autres destinations touristiques de la zone euro. De fait, une hausse du prix relatif de la France par rapport à la Zone euro provoquerait une baisse de l'attractivité-prix de la France au profit des autres destinations de la zone euro, ce qui induirait in fine une baisse du nombre de nuitées en hôtellerie. L'utilisation de variables similaires¹⁶ est également documentée dans la littérature et, tout comme le taux de change, elles sont identifiées comme déterminants significatifs de la demande touristique.

1.2.3. La variable comportementale

Pour finir, nous allons voir comment nous avons construit notre variable comportementale grâce aux données de Google Trends. Avant de présenter notre indicateur, il convient de rappeler brièvement le mode de construction des données issues de Google Trends. Google nous donne la définition suivante : « Les résultats reflètent la proportion de recherches portant sur un mot clé donné dans une région et pour une période spécifique, par rapport à la région où le taux d'utilisation de ce mot clé est le plus élevé (valeur de 100). Ainsi, une valeur de 50 signifie que le mot clé a été utilisé moitié moins souvent dans la région concernée, et une valeur de 0 signifie que les données pour ce mot clé sont insuffisantes. ».

Nous avons donc créé plusieurs indicateurs regroupant différents mots clés liés à notre variable cible c'est-à-dire le nombre de nuitées en hôtellerie. Nous avons au préalable sélectionné deux paramètres importants : la période qui s'étend de janvier 2011 à décembre 2025 pour correspondre à celle de notre variable cible, et la catégorie voyage pour capter uniquement les recherches liées au tourisme. Ensuite, nous avons essayé plusieurs combinaisons mots clés en nous appuyant sur différents travaux existants relatifs à la prévision de la demande touristique avec Google Trends. (Mikulić et alii., 2025) ont conclu dans leur étude que pour prédire la demande générale pour une destination, il est important de dresser une liste des langues pertinentes afin de sélectionner les mots-clés de départ dans ces langues. C'est pourquoi nous avons d'abord eu l'idée de capter les recherches avec les mots-clés « Hôtel France » traduit

¹⁶ Certaines variables « prix relatif » sont construites comme un rapport entre l'IPC du pays étudié et celui du pays d'origine indexé sur le taux de change pertinent (Athanasopoulos et alii., 2011)

dans les langues des principaux pays d'origine des touristes qui voyagent en France (les Français, Anglais, Allemands et Espagnols) afin d'éviter un biais lié à la langue¹⁷. Ces premiers résultats présentent une saisonnalité commune¹⁸ avec le nombre de nuitées en hôtellerie synonyme d'un signal bien capté, avec un léger décalage (voir Annexe 2) et une divergence après la période du Covid 19 surtout au niveau de la tendance. Cependant, nous remarquons une différence d'amplitude assez marquée entre nos deux séries, l'amplitude de l'indicateur Google Trends étant sensiblement inférieure à celle des nuitées. Plusieurs études utilisent des mots clés qui reflètent les différentes étapes de planification d'un voyage (hébergements, destination, déplacement ...) pour capter le nombre d'arrivée touristique dans un pays (Yang et alii., 2022) et (Rodríguez, 2017) notamment « fly », « travel », « vacation » et le nom du pays en question. En s'inspirant de ces études, nous avons construit notre indicateur en utilisant des mots clés plus spécifiques à notre variable cible (Booking France, Nuits hotel France, Réservation vacances France, hotel France ...) puis nous avons affiné nos recherches en sélectionnant des termes plus spécifiques à l'hôtellerie. Cependant, à la différence de notre premier indicateur basé sur la traduction du mot clé « Hotel France » en diverses langues, nous avons fait le choix pour celui-ci d'utiliser majoritairement la langue française, cela peut se justifier par le fait qu'une majorité de touristes sont des résidents. Nous avons également fait varier le paramètre géographique en testant deux configurations « Dans tous les pays » qui capte les recherches faites partout dans le monde et « En France » qui lui capte uniquement les recherches faites en France. Ainsi, nous avons retenu un indicateur qui agrège les cinq groupes de mots clés suivant : « Booking France », « Nuit Hotel France », « Reservation hotel France », « Hotel France », « Chambre hotel », toujours dans la catégorie voyage et dans la zone géographique de la France uniquement, pour la même raison que la recherche en langue française.


Une remarque importante est à mentionner. L'orthographe des mots-clés est importante dans Google Trends et un changement peut engendrer des résultats différents. Par exemple, un indicateur basé sur le mot clé « hotel » sans accent circonflexe engendre des résultats bien différents de celui avec le mot clé « hôtel ». Dans notre combinaison de mots clés, nous avons fait le choix de choisir d'écrire le mot « hotel » sans accent circonflexe car nous sommes partis

¹⁷ Une requête faite en allemand, par exemple pour le mot « hôtel » ne sera pas captée par l'indicateur pour ce même mot écrit en français.

¹⁸ Pour pouvoir comparer les deux séries, initialement dans des unités différentes, il a fallu normaliser le nombre de nuitées en hôtellerie via la formule suivante : $x_{norm} = \frac{x - \min(x)}{\max(x) - \min(x)} * 100$. La série du nombre de nuitées en hôtellerie est maintenant exprimé entre 0 et 100 .

de l'hypothèse que la majorité des recherches sont faites sur smartphone et que les utilisateurs ne prennent pas nécessairement le temps de correctement orthographier leurs recherches.

Figure 3 : Graphique comparaison indicateur Google Trends et nombre de nuitées en hôtellerie



Source : Auteurs

Nous remarquons graphiquement, une très forte similitude entre les deux courbes avec une saisonnalité commune et une amplitude quasiment identique. Nous constatons également que l'indicateur diffère du nombre de nuitées en hôtellerie notamment sur le début de période du Covid 19. La tendance de l'indicateur Google Trends est décroissante dans le temps, mais cette décroissance s'accroît davantage après la pandémie, ce qui suggère une perte d'efficacité de l'indicateur. Cette perte d'efficacité a été documentée (Yang et alii., 2022) et (Llewellyn et alii., 2023). Ces deux études mettent en avant l'instabilité de l'indicateur pendant la période du Covid 19, en montrant que les comportements ont changé, réduisant la pertinence de l'indicateur et également en montrant que les combinaisons optimales de mots-clés changent au cours du temps et peuvent ne plus être valables dans le futur.

Pour conclure sur cette partie concernant nos différentes variables, nous avons pris soin de regrouper dans un tableau synthétique les principales informations sur chaque variable.

Tableau 1 : Récapitulatif des variables utilisées dans cette étude


	Nombre de nuitées en hôtellerie en France	Taux de change USD/EUR	Indicateur de confiance des ménages	Consommation des ménages en biens	Prix relatif de la France par rapport aux destinations de la zone euro	Indicateur Google Trends
Unité	En milliers de nuitées	En dollars par euro	Indice base 100 = moyenne 1987-2024	En milliards d'euros	Indice base 100 = 2025	Nombre de recherche
Source	INSEE – Enquête sur la fréquentation touristique	Eurostat	INSEE- Enquête mensuelle de conjoncture auprès de ménage	INSEE	BCE	Google Trends
Construction	–	–	–	–	Rapport entre l'IPCH France et l'IPCH zone euro	Regroupement de mots-clés
Fréquence	Mensuelle	Mensuelle	Mensuelle	Mensuelle	Mensuelle	Mensuelle
Période	Janv-2011 – Déc 2025	Janv-2011 – Déc 2025	Janv-2011 – Déc 2025	Janv-2011 – Déc 2025	Janv-2011 – Déc 2025	Janv-2011 – Déc 2025
Zone géographique	France	Monde	France	France	Europe	Monde
Effet attendu	–	↗ taux de change => ↘ nuitées	↗ confiance => ↗ nuitées	↗ conso => ↗ nuitées	↗ prix relatif => ↘ nuitées	↗ indicateur Google => ↗ nuitées

Source : Auteurs

2. Méthodologie de la prévision du nombre de nuitées en hôtellerie

Dans cette seconde partie, l'objectif va être de justifier l'intégralité des modèles de prévisions utilisés dans cette étude pour la prévision du nombre de nuitées en hôtellerie. Comme nous l'avons introduit précédemment, nous allons utiliser deux catégories de modèles, les modèles en séries temporelles et les modèles économétriques n'ayant qu'une unique équation (cf. Figure.0). Le choix de se restreindre uniquement à ces deux catégories est en partie conditionné par la littérature. Song et alii. (2019) ont étudié 211 études parmi les plus influentes sur le sujet de la prévision de la demande touristique. À partir de cette revue, ils recensent les modèles mobilisés, leur fréquence d'utilisation et leur taux de citation comme modèle le plus performant, selon les périodes. Ils ont synthétisé cela dans le schéma ci-dessous.

Figure 4 : Schéma - Tendance dans la littérature sur la prévision de la demande touristique



Source : Song et alii. (2019)

À gauche le nombre d'utilisation de chaque modèle et à droite le nombre de fois où le modèle est considéré comme meilleur.

« Depuis 2010, les séries temporelles avancées et les modèles économétriques dominent la littérature de prévision de la demande touristique » (Song et alii.,2019). Bien que la littérature actuelle se concentre de plus en plus à des modèles basés sur l'IA, nous n'allons pas aborder cette catégorie de modèles pour nous concentrer exclusivement sur les deux catégories citées.

Ensuite, il convient de faire la différence entre les « prévisions saisonnières » et les « prévisions sur la tendance ». Les prévisions saisonnières sont effectuées à l'aide de modèles utilisant une série saisonnière, dans notre cas, c'est la série brute du nombre de nuitées en hôtellerie, par conséquent, les prévisions vont reproduire les fluctuations saisonnières des années précédentes. Alors que les prévisions sur la tendance, elles, sont faites à partir de modèle utilisant une série corrigée des variations saisonnières (CVS) permettant de nous intéresser au niveau conjoncturel du nombre de nuitées en hôtellerie sans tenir compte des variations saisonnières présentes dans ce secteur. Cette distinction est importante, car en l'état, nous ne pouvons pas comparer les deux types de prévision, l'une et l'autre étant par définition différentes. Cependant, il est tout à fait possible de comparer les différents modèles de prévisions au sein même de chacun de ces deux catégories de prévisions. Mais avant de comparer nos modèles entre eux, il faut les spécifier correctement pour que les résultats d'estimation puissent capter les caractéristiques des séries étudiées. Il est donc nécessaire de tenir compte du Covid 19, des différents effets retardés entre le nombre de nuitées en hôtellerie et les variables exogènes pour obtenir des résultats optimaux et non biaisés. Il nous faudra, pour finir, définir au préalable les indicateurs qui nous serviront à juger la qualité de prévision de chaque modèle pour les comparer entre eux afin d'établir le meilleur.

Ainsi, nous présenterons dans un premier temps, les modèles de prévision saisonniers et sur la tendance puis nous aborderons le processus d'estimation des modèles. Enfin, nous traiterons du processus d'évaluation et de comparaison des prévisions.

2.1. Les modèles de prévision saisonniers

Comme nous l'avons rapidement défini précédemment, les modèles de prévision saisonniers sont estimés sur la série brute du nombre de nuitées en hôtellerie. Ce type de prévisions saisonnières est très importantes notamment pour les professionnels du secteur touristique pour qui il est impératif d'avoir une estimation de la demande touristique future. L'enjeu est d'anticiper les pics de fréquentation afin d'adapter leurs offres, gérer leurs tarifications et maximiser leur chiffre d'affaires. Les modèles étudiés possèdent un nombre de spécification

importante, nous allons donc présenter de manière synthétique les modèles généraux utilisés sans rentrer dans les détails de la spécification retenue. Nous y reviendrons dans la partie suivante. Ainsi, nous présenterons les modèles SARIMA, ETS, ADAM ETS et un modèle multivarié SARIMAX.

2.1.1. Le modèle SARIMA

Le modèle SARIMA est une extension de l'approche de Box-Jenkins (1970) : ARIMA¹⁹ qui permet de prendre en compte la structure saisonnière de la série. Ainsi, pour des données à fréquence mensuelle comme les nôtres, la valeur du mois de janvier 2026 dépendra des valeurs de janvier 2025, de janvier 2024 et ainsi de suite. Un modèle SARIMA s'écrit de la manière suivante :

$$SARIMA(p, d, q)(P, D, Q)_s$$

Pour la partie de gauche, p correspond à l'ordre de la composante régressive, d à l'ordre d'intégration et q à l'ordre de la composante moyenne mobile. Pour la partie de droite : P correspond à l'ordre de la composante régressive, D à l'ordre d'intégration et Q à l'ordre de la composante moyenne mobile. Enfin s correspond à la longueur du cycle saisonnier (par exemple, 12 mois).

Ces approches SARIMA ont de nombreux avantages qui les rendent intéressantes pour faire de la prévision. Elles sont simples à mettre en place et facilement interprétables. De plus, depuis 1968, les modèles de type (S)AR(I)MA ont été utilisés à 76 reprises et sont ressortis 27 fois comme étant les meilleurs (Voir -Figure 4 : Schéma - Tendance dans la littérature sur la prévision de la demande touristique), ce qui montre que ces modèles sont reconnus pour leur efficacité.

Cependant, plusieurs limites sont à prendre en considération, en effet, ces approches peuvent engendrer des prévisions peu fiables notamment à cause d'une mauvaise prise en compte des relations non linéaires. La présence de rupture structurelle comme la crise du Covid 19, constitue une autre limite susceptible de biaiser l'estimation des paramètres. Ces approches sont également extrêmement sensibles à la spécification donnée. Une mauvaise spécification engendre très souvent de mauvais résultats.

Les prévisions sont faites en extrapolant la structure autorégressive et saisonnière identifiée. Pour un horizon de prévision à 12 mois, le modèle prédit une première valeur à partir des valeurs

¹⁹ Le modèle est présenté plus en détail dans la sous-partie suivante sur les modèles de prévisions sur la tendance

et des erreurs passées observées et itère ce principe jusqu'à l'horizon souhaité. À partir du deuxième horizon de prévision, les valeurs futures inconnues sont progressivement remplacées par les valeurs prédites sur lesquelles sont calculées les nouvelles prévisions. Cependant, ce mécanisme de prévision accumule l'erreur de prévision. Au fur et à mesure que l'horizon de prévision augmente il engendre un élargissement de l'intervalle de prévision dégradant la qualité des prévisions.

2.1.2. Le lissage exponentiel avancée – l'approche ETS

Les méthodes de lissage exponentiel constituent une alternative aux modèles de séries temporelles classiques vus précédemment. Ces méthodes accordent moins d'importance aux observations à mesure qu'elles deviennent anciennes en attribuant une pondération décroissante.

L'approche ETS (Error, Trend, Season) est introduite pour la première fois par Hyndman et alii (2002). Inspirée de la méthode saisonnière de Holt -Winters (1960), ETS est une généralisation des méthodes de lissage exponentiel avec une représentation sous forme d'espace d'états. Chaque composante peut prendre trois états différents : Absence (N), Additive (A) et multiplicative (M). Un paramètre d'amortissement (damped) peut également s'appliquer à la composante de tendance afin d'atténuer sa progression à long terme. Les modèles ETS couvrent une multitude de configurations différentes. Par exemple, un modèle ETS(A,A,A) désigne un modèle avec des erreurs additives, une tendance additive et une saisonnalité additive.

La représentation sous forme d'espace d'état permet trois avantages majeurs qui ont orienté la décision d'utiliser ce modèle. Elle permet de calculer analytiquement les intervalles de prévisions, permettant de quantifier l'incertitude liée aux prévisions. Son équivalence formelle avec les modèles (S)ARIMA permet également une comparaison directe entre ces deux catégories de modèles. Si nous reprenons notre exemple, un modèle ETS(A,A,A) est équivalent à un modèle SARIMA(0,1,1)(0,1,1)_s avec s la fréquence de la saisonnalité. Enfin, le modèle détermine lui-même la spécification optimale en minimisant l'AIC. Ces avantages constituent un intérêt pour l'utilisation de modèles ETS pour faire de la prévision.

Cependant, il est nécessaire que la structure de la série étudiée soit stable dans le temps. De même, les différentes ruptures structurelles peuvent dégrader les performances du modèle et de ses prévisions. Il sera donc nécessaire de prendre en compte la crise du Covid 19 pour ne pas biaiser les résultats.

Pour la prévision le modèle met à jour récursivement ses composantes à chaque nouvelle observation, les valeurs futures étant générées par extrapolation de ces composantes jusqu'à l'horizon souhaité. Comme pour les approches précédentes, ce mécanisme itératif entraîne une accumulation progressive des erreurs de prévision. Toutefois, la représentation sous forme d'espace d'états permet de mieux quantifier cette incertitude croissante à travers le calcul analytique des intervalles de prévision.

2.1.3. Les modèles ADAM : une généralisation des approches ETS et ARIMA

Le modèle ADAM (Augmented Dynamic Adaptive Model) proposé par Svetunkov (2022) unifie et généralise les modèles ETS et ARIMA vus précédemment sous la forme d'espace d'états. En combinant ces deux approches, l'un des principaux atouts de ce nouveau modèle est de couvrir une multitude de configurations différentes.

Un modèle ADAM ETS – ARIMA, lui s'écrit de cette manière,

$$ADAM\ ETS(A, M, N) + ARIMA(p, d, q)$$

En reprenant les notations des modèles (S)ARIMA et ETS.

Contrairement aux méthodes de lissage, l'approche ADAM ne suppose pas la normalité des erreurs et autorise des distributions alternatives mieux adaptées aux résidus. De même, l'approche ADAM permet d'identifier les observations atypiques (outliers), ce qui permet l'étude de séries contenant des ruptures structurelles comme la crise du Covid, tout en gérant les éventuelles valeurs manquantes. L'ensemble de ces caractéristiques en font une approche très flexible et complète intéressante pour faire de la prévision à court terme. De plus, cette approche est encore relativement récente dans la littérature et peu documentée notamment sur le thème de la prévision de la demande touristique. Ainsi, son utilisation vient ajouter une plus-value à notre étude.

Bien que sa grande flexibilité lui permette de s'adapter aux données, elle constitue également une limite importante. En effet, le nombre élevé de paramètres peut conduire à un phénomène de surparamétrisation qui peut grandement complexifier l'interprétation des coefficients du modèle. La combinaison avec d'autres modèles accentue ce phénomène de surparamétrisation, en plus de rendre l'identification des coefficients difficile et une certaine redondance, cela peut engendrer des problèmes de convergence à cause de la lourdeur du modèle.

Pour prévoir les valeurs futures, le processus itératif reste le même. Le modèle génère à chaque horizon de prévision une nouvelle valeur qui sera utilisée pour prédire la valeur suivante. La différence notable réside toutefois dans la robustesse de l'intervalle de prévision grâce à l'explicitation de la loi de distribution des résidus supposée gaussienne dans les approches précédentes. L'accumulation des erreurs de prévisions reste l'une des principales faiblesses de cette approche.

2.1.4. SARIMAX : une approche saisonnière multivariée

Jusqu'à présent, nous avons vu seulement des approches en séries temporelles univariées incluant seulement la dynamique passée comme moyen de faire des prévisions. Maintenant, nous allons nous intéresser à une approche multivariée SARIMAX incluant cette fois-ci des variables exogènes qui sont de potentiels déterminants du nombre de nuitées en hôtellerie. Tout comme les modèles (S)AR(I)MA, le SARIMAX a été utilisé plus d'une vingtaine de fois ces soixante dernières années pour la prévision de la demande touristique et ressorti très souvent comme le modèle le plus performant (voir Figure 4 : Schéma - Tendance dans la littérature sur la prévision de la demande touristique). Il se définit quasiment comme un SARIMA et cumule les avantages de ce dernier. Toutefois, il se différencie en intégrant des variables exogènes.

$$SARIMA(p, d, q)(P, D, Q)_s + \text{variables exogènes}$$

Cependant, pour que le modèle ait un intérêt, il faut que les variables exogènes respectent un certain nombre de conditions. En effet, pour intégrer des variables, elles doivent être strictement exogènes. Il est également impératif que les données soient de même fréquence et sur la même période. Pour finir, il est recommandé que les variables exogènes soient saisonnières si la variable cible l'est. Toutes ces conditions garantissent que les résultats ne soient pas biaisés.

Le SARIMAX en plus de supporter les limites liées à la dynamique temporelle, doit supporter les limites liées aux variables exogènes. En effet, il est d'autant plus nécessaire de bien spécifier le modèle aussi bien dans le choix des ordres que dans le choix des variables afin d'éviter un phénomène de surparamétrisation. L'ajout de variables complexifie également davantage le modèle le rendant plus difficilement interprétable.

Pour la prévision, il est nécessaire d'avoir les valeurs futures des variables exogènes, ce qui implique de faire des prévisions pour les variables exogènes. Nous avons pu voir à plusieurs reprises que les erreurs de prévisions s'accumulent au fur et à mesure que l'horizon de prévision

augmente. Les erreurs de prévisions des variables explicatives viennent s'ajouter aux erreurs de prévisions du nombre de nuitées en hôtellerie ce qui amplifie ce phénomène.

Son approche multivariée en fait un modèle intéressant, en effet, elle nous permettra de répondre à la seconde partie de notre problématique : « Est-ce que l'ajout de variables exogènes améliore la qualité de prévision de la fréquentation touristique ? », en servant de point de comparaison avec les approches univariées.

Toutes les approches vues jusqu'à présent prennent en compte la saisonnalité du nombre de nuitées en hôtellerie. Les prévisions issues de ces approches constituent le premier « groupe » des prévisions saisonnières. Les prévisions issues de chaque modèle de ce groupe pourront être comparées ensemble afin de déterminer l'approche qui offre la meilleure qualité de prévision. La sous-partie suivante s'intéresse aux modèles de prévision sur la tendance, qui constitue le deuxième groupe de prévision.

2.2. Les modèles de prévision sur la tendance

Dans cette sous-partie, les modèles de prévision sont estimés sur la série du nombre de nuitées en hôtellerie corrigée des variations saisonnières. L'objectif de ces modèles est de faire des prévisions sur la tendance afin d'étudier la conjoncture indépendamment des pics saisonniers, ce qui a pour avantage d'identifier la dynamique structurelle du nombre de nuitées en hôtellerie. Pour les décideurs politiques et les différents acteurs institutionnels comme l'Etat et la Banque de France, il est plus important de connaître les prévisions sur la tendance pour évaluer la dynamique touristique de la France mais aussi pour intégrer le tourisme dans les analyses conjoncturelles. Ainsi, faire des prévisions sur la tendance revient à se poser la question : Est-ce que le nombre de nuitées en hôtellerie va augmenter ou diminuer dans les mois à venir ? Comme pour la sous-partie précédente, nous nous concentrerons sur l'aspect général des modèles et nous reviendrons sur les spécifications retenues par la suite. Ainsi, nous présenterons successivement un modèle univarié ARIMA suivi de plusieurs modèles multivariés (RLM, ARIMAX).

2.2.1. Le modèle ARIMA

Nous avons présenté rapidement dans la première sous-partie l'approche ARIMA de Box-Jenkins et son extension saisonnière SARIMA. Nous n'allons pas apporter plus d'information sur ce modèle étant donné que la seule différence avec le modèle SARIMA présenté concerne la série sur laquelle nous l'avons estimé. En effet, comme nous nous intéressons cette fois-ci aux modèles de prévision sur série CVS, le modèle étudié ne prend plus en compte la composante saisonnière. Il s'écrit de la manière suivante :

$$ARIMA(p, d, q)$$

Avec p : l'ordre de la composante autorégressive (AR) ; d : l'ordre d'intégration de la série et q : l'ordre de la composante moyenne mobile (MA).

Pour que le modèle soit pertinent et ne produise pas de résultats biaisés, il est important que la série finale soit stationnaire²⁰. En pratique, le modèle détecte automatiquement l'ordre d'intégration de la série mais nous devrions rester prudent et vérifier statistiquement à l'aide de tests que la série est bien stationnaire.

Pour la prévision le principe est similaire, les valeurs futures sont prévues grâce à la structure autorégressive identifiée par le modèle ARIMA. Par conséquent, les risques associés demeurent les mêmes : accumulation des erreurs de prévision, biais dans les résultats en présence de rupture structurelle.

Bien que cette approche soit basique, lors de notre présentation du SARIMA, nous avons mentionné une utilisation massive des modèles de type (S)AR(I)MA. Cela renforce l'intérêt d'estimer un tel modèle. De même, comme nous nous intéressons aux prévisions sur la série CVS, il est également intéressant de voir si cette approche permet une bonne estimation. Par la suite, nous allons étudier principalement des modèles multivariés sur la série CVS, ainsi l'utilisation d'une approche univariée va nous servir de point de comparaison avec ces modèles.

²⁰ Une série est stationnaire lorsque ces propriétés statistiques (moyenne, variance, autocorrélation) restent stables dans le temps

2.2.2. Le modèle ARIMAX

L'approche ARIMAX permet d'inclure des variables exogènes potentiellement déterminantes de notre variable cible : le nombre de nuitées en hôtellerie. Nous avons vu dans la sous-partie précédente une approche similaire (SARIMAX) qui incluait également des variables exogènes. La différence entre ces approches réside dans le traitement de la composante saisonnière. Dans cette nouvelle approche ARIMAX, la série de référence est corrigée des variations saisonnières (CVS).

Le modèle ARIMAX prend en compte toutes les composantes d'un ARIMA classique. Il s'écrit comme suit :

$$ARIMA(p, d, q) + X_i$$

Avec X_i le vecteur contenant les variables exogènes

Cependant, pour ajouter des variables exogènes, il faut également respecter des conditions plus ou moins strictes pour assurer la fiabilité et la qualité des résultats très similaire à celle que nous avons déjà vues. En effet, il faut que les variables soient encore une fois strictement exogènes. Il est également nécessaire que la fréquence et la période de ces variables soient identiques à notre variable cible. De même, notre série étant désaisonnalisée, il est préférable que les variables exogènes soient elles aussi désaisonnalisées ou non saisonnières afin de capter uniquement les informations liées à la composante tendance-cycle.

Les avantages et les limites de ces modèles, sont tout aussi similaires au SARIMAX. Le principal avantage de ces modèles réside dans l'ajout de variables exogènes permettant d'apporter une source d'information supplémentaire susceptible d'améliorer la qualité des prévisions sur la tendance.

Pour la prévision, il est nécessaire d'avoir les données pour les variables exogènes jusqu'à l'horizon de prévision souhaité. Dans le cas contraire, il faudra également faire des prévisions pour les variables exogènes qui serviront ensuite à produire celles de notre variable cible. Le risque d'accumulation des erreurs de prévision est accentué par l'ajout de ces variables supplémentaires.

2.2.3. Le modèle de régression linéaire multiple (RLM)

Jusqu'à présent, nous n'avons abordé que des modèles incluant une dynamique temporelle. Maintenant, nous allons nous intéresser à un dernier modèle cette fois-ci purement économétrique. Cette nouvelle approche cherche à déterminer l'existence de liens causaux entre le nombre de nuitées en hôtellerie et les différents déterminants évoqués dans la première partie. Ce modèle basé sur la méthode des moindres carrés ordinaires est intéressant pour étudier les relations entre la variable cible et les potentiels déterminants sans tenir compte de la dynamique temporelle.

Derrière, ce modèle se cache un certain nombre d'hypothèses à respecter pour ne pas avoir de régression fallacieuse²¹ (linéarité, exogénéité, homoscedasticité, multicollinéarité, absence d'autocorrélation). Malgré les inconvénients de ce modèle, il est interprétable et facilement compréhensible, ce qui en fait un modèle de référence très utilisé dans la littérature sur le sujet. Sur la totalité des études sur la période 1968 – 2018 par Song et alii. (2019), 46 modèles de régression statique (SR) ont été utilisés (voir Figure 4 : Schéma - Tendances dans la littérature sur la prévision de la demande touristique).

Le modèle se matérialise sous l'équation simplifiée suivante :

$$\text{Nombre de nuitées en hôtellerie} = \text{variables exogènes} + \varepsilon$$

Avec ε le terme d'erreur

Pour la prévision, tout comme les approches multivariées vues précédemment, il est nécessaire d'avoir les valeurs futures des variables exogènes jusqu'à l'horizon de prévision pour pouvoir faire des prévisions sur la variable cible. Contrairement, à ces dernières, chaque prévision est indépendante des précédentes, évitant le processus d'accumulation des erreurs.

L'intérêt de réaliser un tel modèle est de pouvoir avoir un point de comparaison entre des modèles intégrant une dynamique temporelle et un modèle statique causal. Bien que la littérature ait souvent attribué une meilleure performance de prévision pour les modèles en série temporelle, il est intéressant de voir si ce constat est toujours d'actualité dans notre étude.

²¹ Une régression fallacieuse permet met en avant une relation statistique significative sans pour autant avoir que cette relation soit causale au sens économique du terme.

2.3. Méthodologie d'évaluation et comparaison des prévisions

Les deux sous-parties précédentes ont établi une liste de modèles de prévision répartis en deux groupes : les modèles de prévision saisonniers et les modèles de prévisions sur la tendance. Pour répondre de façon concrète à notre problématique et déterminer les meilleurs modèles de prévision, il est indispensable d'avoir un point de comparaison, un modèle de référence minimal dont l'objectif est de déterminer si les modèles de prévision produisent des prévisions supérieures à celui-ci. Cependant, pour pouvoir comparer les modèles entre eux, il est nécessaire d'avoir recours à des indicateurs qui jugent la qualité de la prévision d'un modèle donné. Ainsi, nous aborderons la manière dont les modèles naïfs sont définis puis nous présenterons les indicateurs de qualité de prévision que nous avons retenus et enfin nous décrirons le processus de prévision et de comparaison.

2.3.1. Le modèle de référence : le modèle naïf

Un modèle naïf est un modèle simple qui a seulement pour objectif de servir de référence dans la comparaison des prévisions. L'utilisation de modèles naïfs comme référence est largement documentée dans la littérature sur la prévision. Comme nous avons deux groupes de prévision, il convient de définir un modèle naïf pour chacun de ces groupes.

Le modèle naïf simple va nous servir de référence pour les modèles de prévision sur la tendance. Nous pouvons le définir grâce à l'équation suivante :

$$\hat{Y}_{t+h|t} = Y_t$$

Avec h l'horizon temporel et t le temps.

Pour le groupe des modèles de prévision saisonniers, le modèle naïf tient compte de la saisonnalité. Il se définit comme suit :

$$\hat{Y}_{t+h|t} = Y_{t+h-s}$$

Avec s la saisonnalité.

Le modèle naïf saisonnier aussi appelé modèle « Snaïf » produit des prévisions à l'aide de la dernière observation de la saison correspondante. Par exemple, une prévision naïve pour le mois

de janvier de l'année N serait produite en reconduisant la valeur du mois de janvier de l'année N-1.

Dans les deux cas, un modèle de prévision n'est jugé pertinent que s'il surpasse son modèle naïf de référence. En effet, il est incohérent de conserver un modèle qui produit des prévisions de qualité inférieure à une simple reconduction de la dernière observation passée.

2.3.2. Les indicateurs de qualité de prévision

Chaque modèle va produire des prévisions, pour déterminer la qualité de prévision de chacun d'eux, il nous faudra définir un ensemble d'indicateurs. Ces indicateurs aussi appelés « fonctions de perte » quantifient l'écart entre les prévisions effectuées et les valeurs réellement observées. Dans la pratique ces indicateurs sont calculés sur l'échantillon de test²² qui contient uniquement les 12 dernières observations de notre échantillon total. Il existe différents indicateurs ayant chacun leurs caractéristiques propres et leur façon de minimiser cet écart. Nous allons lister les principaux indicateurs utilisés dans notre étude.

Le MAPE (Mean Absolute Pourcentage Error) est un indicateur qui s'exprime en pourcentage l'erreur moyenne de prévision. Il est facilement interprétable et compréhensible, ce qui en fait un indicateur de choix. Plus le pourcentage d'erreur est faible, meilleures sont les prévisions du modèle. A l'inverse, plus le pourcentage est élevé, plus les prévisions sont mauvaises.

Cependant, il ne faut pas que le nombre de nuitées soit égal à 0. Cela impliquerait une division par 0, ce qui est mathématiquement impossible, rendant l'utilisation du MAPE inutile. De plus, le MAPE ne tient pas compte réellement de la saisonnalité, en effet, si le modèle se trompe de 10 nuitées sur 100 réelles en période basse, le pourcentage d'erreur sera le même que si le modèle se trompe de 100 nuitées sur 1000 réelles en période de haute saison. En réalité, la deuxième erreur est davantage problématique pour les professionnels du secteur. Il pénalise également plus lourdement les prévisions trop hautes que les prévisions trop basses, ce qui créer une asymétrie de pénalité.

Le MASE (Mean Absolute Scaled Error) proposé par Hyndman et alii. (2006), est quant à lui, un indicateur qui permet de comparer directement le modèle avec le modèle naïf défini précédemment. Il s'interprète également très facilement : si le MASE < 1 alors le modèle choisi fait moins d'erreurs que le modèle naïf, il est bon pour faire de la prévision. Si le MASE > 1

²² Nous avons décomposé notre échantillon total en deux sous-échantillon : entraînement et test

alors le modèle naïf fait moins d'erreurs que le modèle choisi, dans ce cas autant utiliser le modèle naïf pour faire de la prévision. Plus le MASE est proche de 0, moins le modèle fait d'erreur, meilleur il est. A l'inverse, si MASE est égale à un alors le modèle fait autant d'erreur que le modèle naïf.

Le MASE possède trois propriétés qui le rendent très intéressant à exploiter, en effet, il s'adapte à la saisonnalité de la série. Par conséquent, il ne définit pas le modèle naïf de la même manière en fonction de la saisonnalité. Il est indépendant de l'échelle utilisée par les modèles bien que cette propriété n'ait pas trop d'importance dans notre cas étant donné la nature agrégée de nos données, cela reste une propriété intéressante. Enfin, il est beaucoup plus stable mathématiquement ce qui le rend davantage robuste.

Le RMSE (Root Mean Square Error) est un indicateur qui effectue la moyenne des écarts entre les prévisions du modèle et la réalité tout en pénalisant davantage les grosses erreurs de prévisions. Le RMSE s'exprime dans la même unité que la variable étudiée, dans notre cas, en nombre de nuitées. Pour regarder si le modèle possède une bonne qualité de prévision, il faut comparer le RMSE à la moyenne de la série : plus le RMSE est faible par rapport à la moyenne plus le pourcentage d'erreur est faible.

Cependant, le RMSE est strictement dépendant de l'échelle des données. Il n'est pas pertinent de comparer deux RMSE calculé à partir de séries qui n'ont pas la même échelle mais ce n'est pas un problème pour nous car l'échelle de nos données ne varie pas d'un modèle à l'autre. De plus, le RMSE ne permet pas de savoir si le modèle sous-estime ou surestime le nombre de nuitées.

Enfin, le MAE (Mean Absolute Error) est un indicateur qui traite toutes les erreurs de la même manière et de façon proportionnelle. Le MAE s'exprime également dans l'unité de la série étudiée (en nombre de nuitées). Il s'interprète comme l'erreur moyenne du nombre de nuitées. Un MAE de 100 signifie qu'en moyenne, le modèle se trompe de 100 nuitées par mois. Il est donc facilement compréhensible pour les personnes non-initiées aux statistiques. À l'inverse du RMSE, le MAE est robuste aux valeurs aberrantes. Ainsi, il permet de donner une image de la performance moyenne du modèle.

Cependant, comme le RMSE, le MAE ne permet pas de connaître le sens de l'erreur, c'est-à-dire si le modèle a surestimé ou sous-estimé le nombre de nuitées dans ces prévisions. Il est également sensible à l'échelle de la série, mais encore une fois ce problème ne se pose pas dans notre cas.

Ainsi, chaque indicateur de qualité de prévision possède des caractéristiques différentes qui les rendent plus ou moins unique. Il n'existe pas d'indicateur qui surpasse les autres, mais certains sont plus utilisés que d'autres car plus stable mathématique ou plus interprétable. Nous verrons dans la suite après quels seront les indicateurs de références en fonction des groupes de prévision que nous avons constitués.

2.3.3. Processus d'estimation de chaque modèle

Afin de trouver la meilleure spécification possible pour faire de la prévision, il est recommandé d'utiliser certaines méthodes de sélection (variables, meilleur modèle), de prendre en compte certains éléments pouvant biaiser les résultats (Covid 19), d'inclure ou non des retards sur nos variables exogènes. Ainsi, avant d'analyser les résultats d'estimation des différents modèles retenus, nous allons présenter de manière synthétique tout le travail de recherche qui a été réalisé pour arriver à la meilleure spécification pour chaque modèle.

Pour commencer, la gestion de la crise du Covid 19 est un élément essentiel à absolument prendre en considération dans l'estimation de nos modèles. Pour la plupart des modèles, nous avons introduit une variable binaire qui prend 1 lorsque la date t se situe dans la période retenue et 0 sinon. Seul le modèle ETS ne tient pas compte de cette variable car il n'est pas possible d'inclure de variables exogènes. Nous avons retenu une période qui s'étend du 1^{er} janvier 2020 au 1^{er} juillet 2021. Cette période couvre les plus gros pics de la crise, bien que les effets ont continué après cette date avec le Pass sanitaire. Le seul but de cette variable est d'isoler le choc lié au Covid 19 afin que le modèle estime ses coefficients sur le « comportement » normal de la série. Toutefois, il est possible que les composantes du modèle capturent de manière endogène l'effet du Covid 19 réduisant l'intérêt d'utiliser ce type de variable.

Chaque modèle de série temporelle ((S)AR(I)MA, ETS, ADAM) possède une fonction²³ de sélection automatique des paramètres pour garder les spécifications qui permettent de capter au mieux les caractéristiques de la série étudiée. Cependant, pour les modèles multivariés en série temporelle incluant des variables exogènes, ces fonctions ne permettent pas de sélectionner les meilleures variables. Ainsi, nous avons effectué une méthode de sélection manuelle pour ne garder que les variables qui contribuent de manière significative au modèle. Pour le modèle statique de régressions linéaires multiples (RLM), il existe plusieurs méthodes pour

²³ Ces fonctions et les packages associés sont répertoriés dans le tableau

sélectionner les variables qui contribuent le plus au modèle. Nous avons utilisé la méthode du « BestSubset » traduit littéralement du meilleur échantillon, qui permet de conserver les variables qui permettent de minimiser des critères (AIC, CP de Mallows).

Enfin, nous avons également voulu tester l'intégration de retards (*Lags*) sur les variables exogènes pour déterminer une éventuelle relation décalée entre ces variables et le nombre de nuitées en hôtellerie. En effet, il semble réaliste qu'une augmentation du prix relatif de la France par rapport à la zone euro au mois t ne puisse pas affecter de manière instantanée le nombre de nuitées, mais plutôt sur le mois d'après ou celui encore après. L'introduction de retard permet également de donner un pouvoir prédictif au modèle, en effet, nous connaissons les valeurs des variables retardées pour faire de la prévision. Ainsi, lorsque nous produirons des prévisions, nous aurons des données observées sur lesquelles nous reposer, ce qui nous permettra d'atténuer la propagation du risque d'accumulation d'erreur que nous avons déjà présenté.

Ainsi, lors de l'estimation des meilleurs modèles, nous avons pris en compte toutes ces possibilités pour obtenir les modèles les plus optimales pour faire de la prévision à court terme.

2.3.4. Processus d'évaluation et de comparaison des modèles

Maintenant que nous avons correctement défini tous les éléments pour comparer la qualité de prévision de chaque modèle. Nous allons aborder comment nous allons procéder pour comparer efficacement et avec les bons indicateurs les prévisions de chaque groupe.

Bien que nous l'ayons dit à plusieurs reprises, il faut bien garder en tête que les prévisions des deux groupes ne sont pas comparables entre eux, les prévisions du premier intègrent la saisonnalité de la série, ce qui n'est pas le cas des prévisions du second. Ainsi, nous allons faire des comparaisons intra-groupes, c'est-à-dire que nous allons comparer les modèles au sein de chaque groupe. En plus de cette première distinction, nous allons effectuer plusieurs comparaisons différentes au sein de chaque groupe.

Nous allons tout d'abord, comparer les prévisions du modèle naïf avec les prévisions de chaque modèle pour les deux groupes. Cette première comparaison, nous permettra de connaître la pertinence des modèles de prévision. Pour ce faire, nous utiliserons un test statistique de Diebold-Mariano (1995) dont l'objectif est de comparer les prévisions du modèle choisi à un modèle de référence (benchmark), ici, le modèle naïf afin de déterminer la pertinence du modèle

à être utilisé. Il permet d'évaluer statistiquement l'écart de performance entre les modèles naïfs et le modèle choisi.

Ensuite, nous comparerons les modèles entre eux au sein de chaque groupe : les modèles saisonniers entre eux et les modèles sur la tendance entre eux, afin de déterminer si un modèle se dégage des autres. La dernière comparaison se fait entre les modèles univariés et multivariés afin de pouvoir répondre sur la pertinence d'utiliser des variables exogènes pour améliorer la prévision.

Pour les modèles de prévision saisonniers, l'indicateur de qualité principal auquel nous nous fierons sera le RMSE, car il permet de prendre en compte les gros écarts de prévision pénalisant fortement les prévisions qui ne tiennent pas correctement compte de la saisonnalité.

Pour les modèles de prévision sur la tendance, le MAE est le candidat naturel, étant donné que la série CVS est plus lisse, il va capter l'écart moyen entre les prévisions et les valeurs réelles sans avoir besoin de pénaliser les grands écarts. Les autres indicateurs MAPE et MASE, nous serviront d'indicateur de contrôle dont l'objectif est de donner une analyse complémentaire aux deux indicateurs principaux afin de valider et de nuancer les résultats et le classement des modèles.

Pour conclure brièvement cette partie, nous avons reparté les modèles de prévision en deux groupes distincts selon la nature de la série étudiée : les modèles de prévision saisonniers (SARIMA, ETS, ADAM, SARIMAX) et les modèles de prévision sur la tendance (ARIMA, ARIMAX, RLM) permettant de répondre à des objectifs économiques distincts et ne pouvant pas être comparés directement entre eux. Chacun de ces modèles est estimé en tenant compte de la crise du Covid, des effets retardés entre le nombre de nuitées et les variables exogènes afin d'obtenir les modèles les mieux spécifiés possible pour la prévision. Enfin, la méthodologie d'évaluation et de comparaison des prévisions reposant sur des comparaisons avec des modèles naïfs, des indicateurs de qualité de prévision et des tests statistiques garantit une comparaison rigoureuse. La partie suivante mobilise ce cadre méthodologique pour estimer les modèles, produire les prévisions et évaluer leur qualité empiriquement.

3. Analyse empirique de la fréquentation touristique : estimation et prévision

Jusqu'à présent, nous nous sommes contentés de simplement décrire nos objectifs, quels moyens nous avons mis en œuvre pour les atteindre, comment et avec quelles données. Maintenant, nous allons nous focaliser sur la partie centrale de ce projet, l'analyse des résultats en sortant du cadre théorique pour rentrer dans le cadre empirique.

Cette partie tend à remplir plusieurs objectifs qui ont pour but de répondre la problématique : « Quel modèle permet de prévoir efficacement la fréquentation touristique en France à court terme ? ». Le premier objectif, est de comprendre nos données au travers de l'analyse exploratoire. Il est important et non négligeable de comprendre les caractéristiques de la série que nous étudions avant d'essayer de faire des prévisions. Une série mal analysée implique très souvent de mauvaises prévisions. Le deuxième objectif est d'exhiber les résultats intermédiaires sur l'estimation des différents modèles afin d'avoir un premier aperçu sur la qualité de ces derniers. Si les modèles étudiés résument de manière satisfaisante la série de données alors il y a de forte chance que les prévisions faites à partir de celui-ci soient de bonne qualité également. Pour finir, le dernier objectif va être de comparer les prévisions avec un modèle naïf en fonction de chaque groupe que nous avons établie afin de déterminer le ou les meilleur(s) modèle(s) de prévision pour le nombre de nuitées en hôtellerie.

Le plan de cette partie se présente en trois sous-parties dans lesquelles nous allons atteindre les trois objectifs fixés. Ainsi, dans un premier temps, nous allons mener une analyse exploratoire sur nos données puis dans un second temps, nous allons commenter les résultats d'estimation de chaque modèle présenté. Enfin pour finir, nous allons comparer la qualité de chaque modèle de prévision.

Avant d'étudier les différents modèles utilisés, il est important de mentionner que l'ensemble des estimations et spécifications effectuées dans cette partie ont été réalisées sous le langage de programmation R. Ainsi, toutes les fonctions et packages mentionnés ont été développés et utilisés sur R.

3.1. Pré-traitement et analyse exploratoire

Dans cette sous-partie, nous avons mis en évidence les principaux résultats relevant de l'analyse exploratoire de nos données : statistiques descriptives, études des outliers²⁴, études de la stationnarité et de la saisonnalité des séries étudiées, toujours dans le but de comprendre nos données avant de faire des prévisions dessus. Toutes ces étapes permettent également de donner du crédit à notre travail ; une mauvaise analyse exploratoire peut compromettre l'efficacité des approches. Par exemple, une série qui n'est pas correctement corrigée des outliers peut biaiser les résultats du test de stationnarité qui peut à son tour provoquer une mauvaise spécification du modèle étudié et donc faire de mauvaises prévisions. Cet exemple montre rapidement l'importance de cette sous-partie bien qu'elle ne réponde pas directement à notre problématique.

3.1.1. Imputation des valeurs manquantes et statistiques descriptives

Initialement, notre série du nombre de nuitées en hôtellerie produite par l'INSEE, comportait trois valeurs manquantes correspondant aux dates du mois de janvier, février et mars de l'année 2020, donc au début de la période du Covid 19 en France. Nous avons donc imputé ces données manquantes à l'aide de la méthode d'imputation de Kalman Smoothing (Kalman, 1960) propre aux séries temporelles. Cette méthode est reconnue scientifiquement pour être extrêmement rigoureuse. Une fois les données correctement imputées (voir Graphique -Annexe 3), nous pouvons commencer à étudier les statistiques descriptives de notre série. Le tableau ci-dessous récapitule l'ensemble des statistiques descriptives importantes calculées sur la série nouvellement imputée du nombre de nuitées en hôtellerie.

Tableau 2 : Statistiques descriptives sur la série du nombre de nuitées en hôtellerie

Statistiques	Valeur
Nombre d'observation	180.00
Moyenne	16476.02
Médiane	16743.00
Écart-type	5074.78

²⁴ Observations atypiques caractérisées par des valeurs aberrantes mais plausible économiquement

Variance	25753417.11
Minimum	721.00
Maximum	25549.00
Q1 (25%)	13179.25
Q3 (75%)	20067.75
Intervalle interquartile (IQR)	6888.50
Skewness (asymétrie)	-0.60
Kurtosis (aplatissement)	0.45

Source : Auteur

Le tableau de statistiques descriptives nous donne une multitude d'information intéressante qui nous renseigne sur les caractéristiques de la série. L'activité hôtelière moyenne se situe aux alentours de 16 500 milliers de nuitées sur la période. La médiane est très proche de cette moyenne synonyme d'une distribution équilibrée. La série est également marquée par une forte volatilité (~ 5000 nuitées) notamment à cause de la présence de saisonnalité. Le minimum de 720 milliers de nuitées est très éloigné de la moyenne, ce qui indique clairement la présence d'un choc (en l'occurrence la période du Covid 19). Le skewness et le kurtosis indiquent une distribution quasi normale légèrement asymétrique sur la gauche (négative) dû à la présence de quelques valeurs basses.

3.1.2. Analyse des outliers

Les statistiques descriptives ont permis de mettre en évidence la présence d'un choc sûrement lié à la période du Covid 19 qui affecté le comportement de la série. L'étude des outliers va nous permettre d'aller plus loin et d'identifier toutes les dates pour lesquelles le nombre de nuitées est soit très faible soit très élevé. Le tableau ci-dessous récapitule les principaux outliers détectés par la méthode X13-ARIMA-SEATS²⁵.

Tableau 3 : Récapitulatif des outliers détectés

²⁵ Via la fonction x13() du package {RjDemetra}

Date	Type d'effet	Estimate	Std. Error	Date	Type d'effet	Estimate	Std. Error
Mobile	Effet mobile (Pâques)	1033.5	89.03	08-2020	Additif ponctuel	2449.5	286.68
05-2013	Additif ponctuel	870.6	249.78	11-2020	Changement temporaire	-1805.7	298.75
03-2015	Additif ponctuel	-932.3	248.45	01-2021	Changement de niveau	1585.4	331.93
11-2015	Changement temporaire	-977.3	257.79	03-2021	Changement temporaire	-2879.3	293.90
08-2016	Additif ponctuel	-894.8	248.34	04-2021	Changement temporaire	-4232.8	312.68
05-2017	Additif ponctuel	-779.8	249.73	07-2021	Changement de niveau	5149.2	348.97
05-2019	Additif ponctuel	-1211.8	277.38	09-2021	Additif ponctuel	-1058.9	255.61
01-2020	Additif ponctuel	-3464.8	331.92	12-2021	Changement temporaire	-983.3	293.07
02-2020	Changement de niveau	-23751.0	714.58	01-2022	Additif ponctuel	-2209.6	296.75
02-2020	Changement temporaire	15595.0	691.23	07-2022	Changement temporaire	2042.2	290.74
04-2020	Additif ponctuel	-1991.4	346.13	09-2023	Additif ponctuel	912.3	253.50
06-2020	Changement de niveau	3443.9	425.54	07-2024	Additif ponctuel	-1379.7	253.13

Source : Auteur

En analysant les différents outliers détectés, nous remarquons que la grande majorité se situe dans la période du Covid 19 et Post-Covid. En effet, les différentes mesures de lutte contre la pandémie ont entraîné des confinements massifs de la population à l'échelle mondiale ce qui a freiné considérablement le tourisme international. La France n'y a pas échappé, ce qui s'est retranscrit par des baisses brutales du nombre de nuitées en hôtellerie. Malgré la fin progressive des mesures de lutte contre la pandémie en France et les phases de confinement et de déconfinement, la fréquentation touristique matérialisée par le nombre de nuitées en hôtellerie a eu du mal à retrouver son niveau d'avant crise. C'est seulement en 2023 que le nombre de nuitées dépasse enfin le précédent record établi pendant l'été 2019.

D'autres outliers ont une date pouvant correspondre à des épisodes de terrorismes qui ont eu lieu sur le territoire français (Charlie Hebdo – janvier 2015, Bataclan – novembre 2015). Les conditions climatiques sont un autre facteur à prendre en compte pour expliquer ce genre de chocs ponctuels. En effet, une météo plus ou moins favorable peut influencer les comportements de réservation, notamment en mai, avec la succession de jours fériés et en septembre.


Pour finir, la baisse de fréquentation de juillet 2024 correspond à la date de Jeux Olympique de Paris 2024, causé par un effet d'éviction du tourisme habituel a eu lieu ainsi que par un effet substitution du logement : les locations entre particuliers de courte durée étant préférées aux hôtels.

3.1.3. Saisonnalité et stationnarité

Nous avons évoqué à plusieurs reprises dans les parties précédentes, le caractère saisonnier du nombre de nuitées en hôtellerie sur la période étudiée. Bien qu'il soit nettement visible sur le graphique corrigé des valeurs manquantes (voir Annexe 3), les tests statistiques de Webel-Ollech et seasonal dummies²⁶ ont confirmé de manière empirique le caractère saisonnier de notre série (Résultats -Annexe 4). Nous avons également effectué les mêmes tests de détection de la saisonnalité sur les variables exogènes de notre étude (Résultats – Annexe 7).

Pour désaisonnaliser l'ensemble de nos variables, nous avons utilisé deux méthodes de désaisonnalisation : X13-ARIMA-SEATS et TRAMO-SEATS, reconnues par les différents instituts de statistiques nationaux et banques centrales dès qu'il s'agit de corriger les variations saisonnières d'une série. Ces deux méthodes détectent la présence des outliers et des effets de calendriers permettant une correction optimale de la saisonnalité. Nous avons choisi de conserver la correction proposée par la méthode X13-ARIMA-SEATS, celle-ci battant en tout point la correction proposée par la méthode TRAMO-SEATS notamment sur la présence de résidus saisonniers après désaisonnalisation (Résultats - Annexe 5 et Annexe 6). Le graphique suivant montre la série corrigée des variations saisonnières du nombre de nuitées en hôtellerie que nous utiliserons pour faire nos prévisions sur la tendance.

Figure 5 : Graphique du nombre de nuitées en hôtellerie (CVS)



Source : Auteur

²⁶ Ces deux tests permettent de tester l'hypothèse nulle d'absence de saisonnalité.

Nous constatons que la tendance du nombre de nuitées en hôtellerie est légèrement en hausse depuis 2011. Cependant, nous constatons une grosse chute de nuitées dans la période du Covid 19 qu'il conviendra de traiter avec la plus grande attention pour ne pas biaiser nos résultats.

Enfin, Nous avons fait le choix de désaisonnaliser les variables exogènes saisonnières²⁷ avec la méthode X13-ARIMA-SEATS, afin de préserver une certaine continuité dans les méthodes utilisées.

Lors de la présentation méthodologique, nous avons vu que certains modèles requièrent des prérequis stricts avant de pouvoir être estimés. C'est le cas de la stationnarité. En effet, pour les modèles de type ARIMA et leurs extensions, il est nécessaire que la série étudiée soit stationnaire. Bien qu'elles intègrent un paramètre d'intégration automatique, nous avons tout de même vérifié la stationnarité de notre série du nombre de nuitées en hôtellerie corrigée des variations saisonnières et des différentes variables exogènes (CVS) en amont. Pour ce faire, nous avons effectué deux tests statistiques complémentaires : le test augmenté de Dickey-Fuller (ADF)²⁸ et le test KPSS, permettant respectivement de tester l'absence et la présence de stationnarité. Certaines séries sont théoriquement stationnaire par construction, c'est notamment le cas pour la série sur la confiance qui est un indice ainsi que pour l'indicateur Google Trends (CVS). Cependant, la rigueur économétrique, nous impose de toutes les tester. Dans le cas précis, où l'une d'elle est déterminée comme non-stationnaire, nous ferons le choix de suivre les résultats des tests et de différencier la série afin de la rendre stationnaire.

Enfin, certaines variables doivent être transformées avant d'être ajoutées dans un modèle. En effet, la consommation des ménages, le prix relatif et le taux de change doivent être transformés en logarithme afin d'étudier respectivement le taux de croissance de la consommation et l'élasticité-prix. Elle permet entre autres de mieux mesurer la sensibilité de la demande touristique par rapport aux variations de la consommation, du prix relatif ou du taux de change, en plus de stabiliser la variance. Ces transformations rendent également l'interprétation des coefficients des différents modèles plus pertinente et économiquement plus intéressante. Le tableau ci-dessous contient toutes les caractéristiques (saisonnalité, stationnarité et transformation logarithmique) des différentes séries de cette étude.

²⁷ La représentation graphique des séries CVS est disponible dans l'Annexe 8

²⁸ La crise du Covid 19 a été prise en compte lors du test grâce à une interpolation linéaire afin d'éviter l'obtention de résultats biaisés

Tableau 4 : Récapitulatif des tests de détection de la saisonnalité et de stationnarité

Séries	Nuitées en hôtellerie	Consommation des ménages en biens	Confiance des ménages	Taux de change USD/EUR	Prix relatif de la France par rapport à la zone euro	Indicateur Google Trends
Nom de la variable	nuitee	conso	confiance	taux_dollar_euro	prix_relatif	google_trends
Saisonnalité (sur série brute)	Oui	Non	Non	Non	Oui	Oui
Stationnarité (sur série CVS)	Oui	Non	Non	Non	Non	Non
Transformation logarithmique	Non	Oui	Non	Oui	Oui	Non
Résultats annexes	Annexe 3 Annexe 4 Annexe 14	Annexe 7 Annexe 9Annexe 9	Annexe 7 Annexe 10	Annexe 7 Annexe 11	Annexe 7 Annexe 12	Annexe 7 Annexe 13

Source : Auteur

En regardant les résultats du tableau, nous remarquons qu'il est nécessaire de différencier à l'ordre 1²⁹ toutes les variables exogènes de notre base de données. Après avoir effectué les étapes de désaisonnalisation, de transformation, et de différenciation³⁰ (voir graphiques - Annexe 15) , nous avons vérifié la stationnarité avec à nouveau un test de Dickey-Fuller. Les résultats de ces tests (voir Annexe 16), nous confirment la stationnarité de toutes nos séries. Nous pourrions donc inclure sans problèmes nos différentes variables dans nos modèles multivariés.


3.1.4. Corrélation

Intéressons-nous maintenant aux liens qui peuvent exister entre l'ensemble de nos variables. La matrice de corrélation de Spearman est plus adaptée en raison de la présence de chocs (Covid 19).

²⁹ La différenciation à l'ordre 1 consiste à faire le calcul suivant : $Y_t - Y_{t-1}$

³⁰ Il se peut que les deux tests ne soient pas validés en même temps dans ce cas, nous avons choisi de considérer la série comme non-stationnaire

Figure 6 : Matrice de corrélation de Spearman



Source : Auteur

Les coefficients de la matrice de corrélation sont tous très faibles et proche de 0, suggérant une absence de lien entre nos différentes variables. La matrice des p-value associée à ces relations (voir Annexe 16 – Test de stationnarité (ADF) sur les variables exogènes après transformation et différenciation – sortie de code R

Variable	Statistique	P-value	Stationnarité
conso	-11.08	0.01	Stationnaire
prix_relatif_cvs	-5.09	0.01	Stationnaire
confiance	-5.06	0.01	Stationnaire
google_trends_cvs	-8.12	0.01	Stationnaire
taux_dollar_euro	-5.01	0.01	Stationnaire

Source : Auteur

Annexe 17) montre l'existence de liens statistiquement significatifs entre le nombre de nuitées en hôtellerie et la confiance des ménages (confiance) et également avec le prix relatif de la France par rapport à la zone euro (prix_relatif_cvs). Cependant, les faibles corrélations calculées n'excluent pas la présence de relation non-linéaire ou décalés dans le temps de nos variables exogènes avec le nombre de nuitées en hôtellerie.

L'analyse exploratoire nous a apporté plusieurs éléments intéressants, nous permettant d'avoir une meilleure compréhension de notre variable cible et des variables exogènes. Les différents tests statistiques effectués, nous ont mis en avant les différentes caractéristiques de chaque série afin d'effectuer toutes les transformations et corrections nécessaires pour estimer les modèles en introduisant le moins de biais possible. Enfin, l'étude de corrélation nous donne un premier aperçu de la contribution potentielle des variables exogènes pour améliorer la prévision. Maintenant que nous avons posé les bases empiriques de notre étude, nous pouvons commencer à estimer les modèles de prévision que nous avons défini dans la partie précédente.

3.2. Estimation des modèles de prévision

L'objectif de cette sous-partie est de mettre en lumière les résultats d'estimation des différents modèles que nous avons listé dans la deuxième partie de ce mémoire. L'estimation de modèle est primordiale pour faire de la prévision. Sans une compréhension du comportement passée de la série étudiée, il est impossible de faire de la prévision.

Dans une grande majorité des cas, les modèles ayant une grande qualité d'estimation sont ceux qui produisent les meilleures prévisions. Il est donc pertinent d'analyser les résultats d'estimations pour déterminer, si le modèle est pertinent car il est possible qu'un modèle, malgré sa validation théorique ne capte pas correctement le comportement de la série étudiée, ce qui le rend inutile pour faire de la prévision. Mais également, si l'évaluation de l'estimation des modèles permet de dégager les modèles qui ont une meilleure qualité d'estimation. Ainsi, il sera intéressant de regarder la continuité des résultats trouvés dans cette sous-partie avec ceux qui viendront dans la partie suivante.

L'idée principale de cette sous-partie est de comparer les modèles entre eux et déterminer ceux qui ont la meilleure qualité d'ajustement, nous allons utiliser des critères d'informations comme l'AIC, le R^2 . Nous allons découper cette sous-partie en deux afin de traiter distinctement les deux groupes de modèles que nous avons défini plus tôt.

3.2.1. Estimation des modèles de prévision saisonniers

Pour chaque modèle que nous avons estimé sur la série saisonnière du nombre de nuitées en hôtellerie. Dans le tableau suivant nous avons regroupé les résultats principaux des différents modèles estimés³¹.

Tableau 5 : Estimation des différents modèles de prévision saisonniers

Modèle	SARIMA	ETS	ADAM ETS ARIMA	SARIMAX
Spécification	(1,0,2)(2,1,0) ₁₂	(A,N,A)	ETS(A,N,A) + ARIMA(1,0,0)	SARIMA(2,0,0)(2,1,0) ₁₂
Coefficients	AR(1) : 0,77 *** MA(1) : 0,35 *** MA(2) : 0,32 *** SAR(1) : -0,41 *** SAR(2) : -0,29 *** Covid_dummy : -2026, 41 **	$\alpha = 0,99$ $\gamma = 1e-04$	$\alpha = 0,26^{***}$ $\gamma = 0,02$ $\phi_1 = 0,85^{***}$ Covid_dummy = -2214,32***	AR(1) : 1,10 *** AR(2) : -0,23 *** SAR(1) : -0,52 *** SAR(2) : -0, 32*** Covid_dummy : -1853* Prix relatif (Lag 2) : -96317, 53** Google_trends : 72,54 ***
Variables	covid_dummy	—	covid_dummy	covid_dummy Prix relatif (Lag 2) Google_trends
AIC	2902.81	3514.68	3054.24	2846.12
AICc	2903.51	3517.60	3054.89	2847.04
Bruit blanc	OUI	NON	NON	OUI
Fonction et package	auto.arima() {forecast}	ets() {forecast}	adam() {smooth}	auto.arima() {forecast}
Intérêt du modèle	OUI	NON	OUI/NON	OUI
Annexe	Annexe 19	Annexe 20	Annexe 21	Annexe 22

Seuil de significativité : 10% : *, 5% : **, 1% : ***

Source : Auteur

Ce tableau récapitule toutes les informations les plus pertinents résultats de l'estimation de chaque modèle. Le premier constat que nous pouvons faire concerne le modèle ETS. Si nous nous intéressons de plus près aux coefficients, nous remarquons une anomalie, en effet, le

³¹ Les résultats complets sous la forme de sortie de code sont disponibles en annexe (voir

coefficient α est égal à 0,99. Ce coefficient correspond au paramètre de lissage, autrement dit, c'est le paramètre de mémoire du modèle. Plus α est proche de 1, moins le modèle de mémoire, ainsi, lorsqu'il est égal à 1 ou très proche, le modèle n'a quasiment pas de mémoire, c'est-à-dire qu'il utilise la dernière valeur observée : le mois passé, pour prédire le mois suivant. Concrètement, la valeur de coefficient montre que le modèle ETS n'a pas réussi à capter correctement la saisonnalité de la série. Ainsi, il y a de très forte chance que ce modèle produise des prévisions similaires voire inférieure au modèle naïf saisonnier.

Le constat suivant concerne la variable binaire qui permet de tenir compte du Covid 19 dans les estimations : la variable `covid_dummy`. Les coefficients associés à cette variable sont à minima significatifs au seuil de 10%. De plus, le seul modèle qui ne permet pas de prendre en compte de manière exogène de la crise du Covid 19, est le modèle ETS. Il ne parvient pas à la capter de manière endogène. Ce double constat montre l'importance d'inclure cette variable dans l'estimation de nos modèles.

Si nous nous intéressons maintenant à l'approche multivariée, le modèle SARIMAX, nous remarquons que les deux variables exogènes saisonnières détectées (voir Tableau 4) c'est-à-dire le prix relatif de la France par rapport à la zone euro et l'indicateur Google Trends permettent d'expliquer significativement le nombre de nuitées en hôtellerie (brute). À noter que la variable du prix relatif de la France est retardée de deux niveaux. Le *cross correlation function* (CCF) a montré l'existence d'une relation entre le prix relatif et le nombre de nuitées maximale au retard 2 (voir Annexe 18). Si nous prenons un exemple simple, le prix relatif du mois de janvier de l'année N permettrait d'expliquer le nombre de nuitées du mois de mars de cette même année N. La valeur et le signe du coefficient associé à cette variable peuvent être interprétés. Le modèle étant correctement spécifié, nous pouvons interpréter la valeur et le signe du coefficient associé à cette valeur. Une hausse du prix relatif affecte négativement le nombre de nuitées en hôtellerie deux mois plus tard. Ce résultat est parfaitement cohérent et correspond à l'effet attendu de cette variable sur le nombre de nuitée. L'indicateur Google Trends quant à lui, n'est pas retardé. Il affecte positivement de manière instantanée le nombre de nuitées en hôtellerie. La composante temporelle capture les caractéristiques de la série du nombre de nuitées en hôtellerie avec deux coefficients AR qui capte la dynamique des deux derniers mois. Le premier est positif et le deuxième est quant à lui négatif, ce qui montre que le modèle corrige à la hausse le nombre de nuitées par rapport au dernier mois et à la baisse par rapport à l'avant dernier mois. La composante saisonnière intègre une différenciation dont l'objectif est de stabiliser la

saisonnalité, ainsi que deux coefficients SAR(1, 2) négatifs afin de corriger l'estimation par rapport aux deux dernières saisons.

Les spécifications du modèle ADAM ETS ARIMA sont cohérentes par rapport aux caractéristiques de notre série. La composante ETS renvoie une absence de tendance, ainsi que des erreurs et une saisonnalité additive qui capturent correctement les pics saisonniers réguliers et la stabilité du nombre de nuitées dans le temps. Le paramètre alpha ($\alpha = 0,26$) montre un lissage lent du niveau tout à fait cohérent avec le comportement de notre série. Le coefficient gamma (γ) non-significatif montre que la saisonnalité est capturée par le modèle mais que cette dernière reste quasiment fixe, ce qui correspond parfaitement aux pics saisonniers qui se reproduisent chaque année. Quant à elle, la variable *covid_dummy* remplit parfaitement son rôle en isolant le choc lié à la crise du Covid 19 permettant ainsi de stabiliser le modèle. C'est peut-être en partie à cause de l'isolation de la crise que le coefficient devant gamma n'est pas significatif. Enfin, la composante ARIMA(1,0,0) sur les erreurs et le coefficient phi1 ($\phi_1 = 0,85$) associé montrent une forte autocorrélation mensuelle des résidus. Globalement, le modèle est correctement spécifié avec un nombre de paramètres acceptable afin d'éviter le surparamétrage.

Les spécifications du modèle SARIMA semble cohérentes avec les caractéristiques de la série. Les composantes AR(1) et MA(1, 2) capturent la dynamique mensuelle à court terme de manière très significative. La différenciation saisonnière ($D = 1$) stabilise la composante saisonnière dans le temps. Les composantes SAR(1,2) dont les coefficients sont négatifs permettent d'apporter des corrections par rapport aux valeurs des années précédentes. Enfin, la variable *covid_dummy* continue de remplir son rôle en isolant efficacement le choc du Covid 19.

Deux des quatre modèles estimés ont des résidus qui sont des bruits blancs. Le bruit blanc est composé des résidus du modèle qui ne peuvent pas être déterminés. Il ne doit pas contenir de structure prévisible le cas contraire signifierait que notre modèle est mal spécifié. Pour confirmer la présence de bruit blanc, nous avons regardé les graphiques d'autocorrélation et d'autocorrélation partielles des résidus (ACF et PACF) afin d'avoir une première idée visuelle puis nous avons effectué un test de Ljung-Box pour avoir une confirmation statistique.

Figure 7 – Tableau résultats du test de Ljung-Box (modèles de prévisions saisonniers)

Modèle	Stat	P-value
SARIMA	20,81	0,64
ETS	0,64	3,76 ^e -06
ADAM ETS ARIMA	44,63	0,00
SARIMAX	24,09	0,45

Source : Auteur

Ainsi, nous pouvons déjà conclure que deux de nos quatre modèles sont correctement spécifiés et n'ont plus de structure prévisible dans leurs résidus. Cependant, le modèle ADAM ETS ARIMA bien que comportant encore un peu de bruit, a une spécification cohérente avec les caractéristiques de la série étudiée probablement due à l'intégration de la composante ETS qui ne permet pas de capter toute la saisonnalité à cause du Covid 19, malgré l'ajout d'une variable binaire exogène.

Enfin pour savoir lequel de nos trois modèles de prévision saisonniers est le meilleur, comparons l'AIC et l'AICc³² de chaque modèle. Ces deux critères très similaires tiennent compte de la qualité d'ajustement du modèle et de la simplicité de celui-ci. Le modèle qui minimise le mieux l'AIC est considéré comme le meilleur modèle. Dans notre cas, l'approche SARIMAX est le modèle qui a l'AIC et l'AICc les plus faibles suivie par le SARIMA et le modèle ADAM ETS ARIMA. Cependant, il faut bien garder en tête que le modèle qui a la meilleure qualité d'estimation n'est pas nécessairement celui qui produira les meilleures prévisions même s'il y a de grande chance.

Pour conclure sur les résultats d'estimation des modèles de prévision saisonniers, le modèle SARIMAX apparaît comme le modèle avec la meilleure qualité d'ajustement suivi par le SARIMA et les modèles ADAM ETS ARIMA. Le modèle ETS est très mal spécifié et très bruyant. Le modèle ADAM ETS ARIMA, lui sera conservé pour faire de la prévision. Nous verrons par la suite si les prévisions de ces modèles sont de bonne qualité.

³² L'AICc est une version corrigée du critère AIC conçu pour éviter le surapprentissage.

3.2.2. Estimations des modèles de prévision sur la série CVS

Comme précédemment, nous allons commenter les résultats d'estimations des modèles de prévision sur la tendance. Ces modèles sont estimés sur le nombre de nuitées en hôtellerie corrigée des variations saisonnières. Nous avons également récapitulé tous les principaux résultats liés à l'estimation de nos modèles dans un tableau.

Tableau 6 : Estimation des modèles de prévision sur la tendance

Modèle	SARIMA	ARIMAX	RLM
Spécification	(1,1,3)(0,0,1) ₁₂	(2,1,1)	–
Coefficients	AR(1) : 0,80*** MA(1) : -0,49*** MA(2) : -0,24*** MA(3) : -0,26 SAR(1) : 0,31*** Covid : -1716,51***	AR(1) : 1,09*** AR(2) : -0,50*** MA(1) : -0,58*** Google Trends : 25,24*** Prix relatif Lag 2 -57786,56***	Constante : 17 478,83 Prix relatif Lag 9 : -144 107** Covid : -9572,14*** Google trends : 60,24*** Consommation : -7192,18**
Variables	Covid	Google Trends Prix relatif Lag 2	Prix relatif Lag 9 Covid Google Trends Consommation
AIC	2975,96	2834,68	2953,76
AICc	2976,62	2834,82	–
R² ajusté	–	–	0,83
Bruit blanc	OUI	OUI	–
Fonction et package	<i>auto.arima</i> <i>{forecast}</i>	<i>Arima</i> <i>{forecast}</i>	<i>lm</i> <i>{stats}</i>
Intérêt du modèle	OUI	OUI	OUI <i>F-stat : 273,76 ***</i>
Annexe	<i>Annexe 25</i>	<i>Annexe 26</i>	<i>Annexe 27</i>

Source : Auteur

Si nous commentons les éléments clés de ce tableau, plusieurs résultats importants se dessinent. Contrairement à ce que nous avons annoncé dans la sous-partie consacrée aux modèles de prévision sur la tendance, le modèle retenu pour la série CVS n'est pas un ARIMA simple mais un SARIMA, en raison de la présence de résidus saisonniers issus d'une désaisonnalisation incomplète. En effet, la méthode X13-ARIMA-SEATS n'a pas réussi à désaisonnaliser correctement la période Post-Covid 19 ce qui a laissé des résidus saisonniers. Par conséquent, lors de la recherche automatique la fonction *auto.arima* a convergé vers un modèle saisonnier avec un SMA(1) pour corriger ce résidu. L'autre information principale est la différenciation première ($d = 1$). Nous constatons que malgré un test de Dickey-Fuller confirmant la stationnarité de la série CVS du nombre de nuitées en hôtellerie (voir Tableau 4 et Annexe 14), le modèle suggère une différenciation première pour rendre stationnaire la série. Cette différenciation et les coefficients AR(1) et MA(1, 2, 3) indiquent que le modèle utilise l'information contenue dans le mois précédent pour prévoir la valeur à la date t . Finalement, le modèle a une légère mémoire saisonnière dont le but est de corriger la valeur présente par l'erreur du mois $t-12$ mais n'exploite pas directement le niveau de ce même mois. La variable Covid joue encore un rôle essentiel dans l'isolement de l'effet de la crise du Covid 19 malgré la correction des outliers effectuée par la méthode X13-ARIMA-SEATS. Sa significativité montre que le modèle seul n'a pas réussi à absorber entièrement les effets de la crise.

Les résultats du modèle ARIMAX sont également très intéressants. Nous retrouvons une différenciation première ($d = 1$) comme le modèle SARIMA précédent afin de rendre stationnaire la série et d'étudier uniquement les variations de la tendance. Le nombre de nuitées en hôtellerie s'interprète maintenant comme un taux de variation du nombre de nuitées. Les coefficients AR(1, 2) et MA(1) montrent qu'il y a une forte relation entre la valeur en t et les valeurs en $t-1$ et $t-2$, c'est-à-dire des deux derniers mois. Les deux variables exogènes significatives, viennent ajouter de l'information supplémentaire dans le modèle. Comme le prix relatif a subi une transformation logarithmique l'interprétation de ce coefficient change par rapport au prix relatif brut non corrigé des variations saisonnières. De plus, cette variable est retardée de deux mois (Lags 2). Nous pouvons donc faire l'interprétation suivante : Une hausse de la variation du prix relatif de la France par rapport à la zone euro retardée de deux mois entraîne une diminution de la variation du nombre de nuitées en hôtellerie. Ce résultat est attendu et correspond à l'effet décrit dans la présentation des variables exogènes : si le prix de la France augmente par rapport aux destinations de la zone euro, les touristes vont se tourner vers des destinations moins chères. Nous pouvons en faire de même avec la variable Google

Trends : une hausse de la variation de l'indicateur entraîne une augmentation de la variation du nombre de nuitées en hôtellerie. L'effet correspond à celui que nous avons précédemment décrit. Enfin, l'absence de la variable Covid montre que le modèle isole de manière endogène les chocs liés à la crise du Covid 19.

Les deux modèles précédents contiennent tous les deux des bruits blancs mis en avant par les ACF et PACF (voir Annexe 28), ainsi que par le test de Ljung-Box. Le tableau récapitule les résultats de ce test.

Tableau 7 : Tableau résultats du test de Ljung-Box (modèles de prévision sur la tendance)

Modèle	Stat	P-value
SARIMA	32,48	0,11**
ARIMAX	34,158	0,08***

Source : Auteur

La présence de bruit blanc vient confirmer qu'aucune structure prévisible n'est contenu dans les résidus. Nos deux modèles sont donc correctement spécifiés et capturent bien toutes les caractéristiques de la série du nombre de nuitées en hôtellerie CVS.

Le dernier modèle estimé est bien différent de tout ce que nous avons pu voir jusqu'à présent. En effet, ce dernier est purement économétrique et n'inclut aucune dynamique temporelle dans son estimation. Ce modèle s'occupe de déterminer l'existence de relation causale entre le nombre de nuitées en hôtellerie et les variables exogènes. Les variables présentes dans ce modèle ont été sélectionnées à l'aide de la méthode « bestsubset ». La méthode a finalement retenu quatre variables parmi un échantillon de dix variables dont certaines retardées après l'étude des CCF (voir Annexe 24). Le prix relatif retardé de neuf mois a un effet attendu économiquement. Si le prix relatif entre la France et la zone euro d'il y a neuf mois augmente par rapport au mois dernier, alors le nombre de nuitées en hôtellerie va être affecté très négativement neuf mois plus tard. L'intégration de 9 retards sur la variation du prix relatif peut sembler incohérente mais si nous nous plaçons dans une optique de planification et d'organisation de vacances, prévoir ces vacances neuf mois avant est cohérent.

Le fait d'être dans la période du Covid 19 entraîne une chute du nombre de nuitées en hôtellerie, toutes choses égales par ailleurs. Quant à la variable sur la consommation en bien des ménages l'effets est, à première vue, contre-intuitif, mais il peut s'expliquer économiquement. Les résultats montrent qu'une variation de la consommation entraîne une diminution du nombre de nuitées en hôtellerie. L'objectif initial de cette variable était de s'en servir comme d'un

indicateur du niveau de revenu des ménages : Une hausse de la consommation sous-entend une hausse du revenu sous-jacente. Or, dans le modèle la consommation agit comme substitut de du nombre de nuitées en hôtellerie. Autrement dit, les ménages font un arbitrage entre consommer des biens ou consommer du tourisme (nuitées en hôtellerie). L'effet négatif prend alors tout son sens. La variable Google Trends a un faible effet positif très cohérent. Elle permet de capter l'effet instantané de l'indicateur Google Trends que nous avons construit à l'aide de la fréquence de recherche de certains mots-clés sur le nombre de nuitées. Une hausse de l'indicateur Google entraine une hausse du nombre de nuitées en hôtellerie. Pour finir la constante est relativement proche de la moyenne historique du nombre de nuitées sur la période, ce qui signifie que si hypothétiquement toutes nos variables sont nulles, le nombre de nuitées en hôtellerie serait aux alentours de 17 500 milliers de nuitées. Cela montre que le modèle est plutôt bien centré sur les données ce qui renforce sa pertinence. Enfin, le modèle explique 83% de l'information contenue dans les données ce qui est très bon indicateur de la qualité d'ajustement du modèle. L'intérêt d'interpréter un tel modèle est confirmé par la statistique de Fisher significative au seuil de 1%.

Enfin, si on compare naïvement l'AIC de nos trois modèles : l'ARIMAX ressort comme le plus parcimonieux, suivi par le RLM et le SARIMA. Cependant, cette comparaison n'est pas tout à fait juste car la série CVS du nombre de nuitées en hôtellerie n'a pas été différenciée dans le modèle RLM. Cela signifie que la série sur laquelle les modèles sont estimés, est différentes pour le SARIMA et ARIMAX et pour le RLM.

Finalement, les résultats des trois modèles de prévision sur la tendance montrent une bonne spécification. Il est donc intéressant de les estimer pour faire de la prévision. Bien que les trois modèles ne soient pas tout à fait comparables en l'état, le modèle ARIMAX semble le modèle avec la meilleure qualité d'estimation.

Pour conclure cette sous-partie, nous avons estimé sept modèles différents regroupés en deux catégories : les modèles de prévisions saisonniers et les modèles de prévision sur la tendance. Dans la première catégorie les modèles SARIMA et SARIMAX se distinguent par leur qualité d'estimation et leur pertinence alors que les modèles ETS et ADAM ETS ARIMA peinent à capter les caractéristiques saisonnières de la série. Enfin, dans la deuxième catégorie, les modèles SARIMA, ARIMAX et RLM se sont remarqués par leur bonne qualité d'estimation. Ainsi, cinq des sept modèles estimés sont prêts pour faire de la prévision.

3.3. Prédiction et comparaison


Pour terminer l'analyse de nos résultats, nous allons nous intéresser aux résultats des prévisions. Les valeurs en tant que telles ne nous intéressent pas. Cependant, elles vont nous aider à comparer les différentes prévisions entre elles et avec les valeurs réellement observées. Pour rappel, les prévisions sont faites sur une partie de l'échantillon appelée « échantillon de test » qui contient uniquement la dernière année de données, c'est-à-dire l'année 2025.

Dans cette sous-partie, nous allons dans un premier temps comparer les modèles de prévision par rapport au modèle naïf de référence³³ puis dans un second temps, nous évaluerons la qualité des prévisions de chacun de ces modèles toujours en nous référant au modèle naïf, enfin, nous finirons par vérifier à l'aide de test statistique la pertinence des modèles pour faire de la prévision.

3.3.1. Comparaison des prévisions

Chaque modèle va produire des prévisions différentes même s'ils appartiennent au même groupe de modèle de prévision. Pour avoir un premier aperçu de la qualité des prévisions, il est indispensable de comparer les prévisions de chaque modèle avec les valeurs qui sont réellement observées ainsi qu'avec le modèle naïf correspondant. Ce modèle naïf qu'il soit simple ou saisonnier nous servira de référence pour valider les prévisions des modèles.

Figure 8 – Graphique comparaison des prévisions saisonnières




Source : Auteur

³³ Toujours en veillant à faire la distinction entre les deux groupes de modèle de prévision

Ce graphique met en évidence les différentes prévisions produites par les modèles saisonniers. La courbe noire correspond à la série observée. Quant à elle, la courbe rose, représente la prévision naïve, c'est-à-dire une simple reconduction des valeurs de l'année 2024. Les trois autres courbes représentent les prévisions produites par les modèles que nous avons précédemment estimés.

Si nous regardons le graphique, nous constatons que toutes les courbes sont très proches les unes des autres. Cela montre que globalement tous nos modèles de prévision saisonniers produisent des prévisions cohérentes et proche de la réalité. Si nous regardons maintenant plus attentivement, nous remarquons que la courbe rouge représentant les prévisions du modèle ADAM ETS ARIMA se situe légèrement en dessous de la courbe noire des valeurs observées et de la courbe rose du modèle naïf saisonnier. Il sous-estime le nombre de nuitées en hôtellerie. Ce résultat n'est pas étonnant, rappelons-nous que l'estimation du modèle ADAM ETS ARIMA avait laissé des résidus bruyants. Ces résidus peuvent être l'une des causes de cette sous-estimation. Enfin, pour les courbes des autres modèles, il est difficile de distinguer clairement une nette différence, il faudra les comparer à l'aide d'indicateurs et de tests statistiques.

Figure 9 – Graphique comparaison des prévisions sur la tendance



Source : Auteur

Maintenant, si nous nous intéressons au graphique de comparaison des prévisions produites par le deuxième groupe de modèle de prévision sur la tendance. Le constat global est très différent du premier groupe. En effet, les courbes de prévision ont des allures très différentes les unes des autres. De plus, elles sont toutes en dessous de la courbe noire représentant les valeurs observées. Les trois modèles de prévision sous-estiment fortement le nombre de nuitées en

hôtellerie. Cela peut s'expliquer par la difficulté pour les modèles linéaires ((S)ARIMA, RLM) d'absorber les chocs structurels comme la crise du Covid 19 malgré la présence de variable exogène pour isoler ce choc.

Finalement, le modèle qui se rapproche le plus de la série initiale est le modèle naïf simple qui reconduit uniquement la dernière valeur en mémoire, c'est-à-dire celle du dernier mois (2024-11-01). Ce constat alarmant est un premier indicateur de la mauvaise qualité des prévisions de nos modèles sur la tendance.

Les deux graphiques de comparaison des prévisions pour les deux groupes de modèle de prévision ont permis de constater plusieurs éléments intéressants, nous donnant ainsi un premier aperçu de la qualité des prévisions. Pour les prévisions saisonnières, il est difficile de savoir lequel possède la meilleure qualité de prévision malgré un léger décrochage du modèle ADAM ETS ARIMA. Alors que pour les prévisions sur la tendance aucun modèle n'a l'air de surpasser le modèle naïf. Cependant, l'interprétation graphique n'est pas suffisante conclure, il nous faut donc étudier la qualité des prévisions à l'aide d'indicateurs et de tests statistiques pour arriver à une conclusion satisfaisante.

3.3.2. Evaluation des prévisions

Comme nous l'avons rapidement abordé, il est nécessaire de montrer empiriquement quel modèle de prévision possède la meilleure qualité de prévision. Pour cela, nous allons utiliser les indicateurs que nous avons préalablement défini dans le processus d'évaluation et de comparaison des prévisions dans la partie deuxième partie de ce mémoire. Nous allons également comparer les modèles de chaque groupe avec le modèle naïf correspondant pour déterminer la plus-value de faire des prévisions avec de tels modèles. Les tableaux qui vont suivre récapitulent l'ensemble de ces indicateurs.

Tableau 8 – Indicateurs de qualité des modèles de prévision saisonniers

Modèle	R ² OOS	RMSE	MAPE	MAE	MASE
Naïf saisonnier	0,00	908,29	3,83	728,25	0,34
SARIMA	0,64	544,03	2,60	449,61	0,21
ADAM ETS ARIMA	-0,94	1266,24	6,58	1135,13	0,52
SARIMAX	0,73	467,01	2,10	329,67	0,15

Source : Auteur

Commençons par interpréter le R^2 OOS (Out-Of-Sample). Cet indicateur permet de calculer la variance (information) en dehors de l'échantillon d'entraînement, expliquée par le modèle par rapport au modèle naïf. C'est le modèle de référence. Le modèle SARIMAX est celui qui explique le plus de variance par rapport à un modèle naïf avec 73% de variance expliquée. Le R^2 OOS du modèle ADAM ETS ARIMA est lui négatif, ce qui signifie que le modèle naïf explique plus de variance que ce modèle. Maintenant, intéressons-nous au RMSE. Cet indicateur permet de tenir compte des gros écarts de prévision et de les pénaliser davantage. Le modèle naïf saisonnier se trompe en moyenne de 900 milliers de nuitées. Ce nombre est énorme mais il faut bien garder en tête que l'unité est exprimée en milliers de nuitées et que la moyenne de nuitées sur la période (de 2011 à 2025) est d'environ 16 500 nuitées. Une fois les proportions en tête, ce chiffre représente un faible taux d'erreur. C'est d'ailleurs ce qui est confirmé par le MAPE qui indique un pourcentage d'erreur de 3,83%, ce qui est très correct pour un modèle de prévision. Finalement, deux modèles font mieux que le modèle naïf saisonnier : le SARIMA et le SARIMAX avec un RMSE et MAPE respectivement plus faible. Seul le modèle ADAM ETS ARIMA est moins bon que le modèle naïf avec des performances nettement moins bonnes que les autres modèles.

Tableau 9 – Indicateurs de qualité des modèles de prévision sur la tendance

Modèle	R^2 OOS	MAE	RMSE	MASE
Naïf saisonnier	0,00	304,67	369,74	0,43
SARIMA	-91,20	3056,09	3550,45	4,39
ARIMAX	-1,858	591,53	625,08	0,85
RLM	-4,43	792,07	861,66	1,13


Source : Auteur

Encore une fois, le constat est très différent pour le deuxième groupe de modèle. En regardant, le R^2 OOS, nous remarquons qu'aucun modèle ne fait mieux que le modèle naïf simple, confirmant notre intuition de départ. Le modèle ARIMAX reste le modèle le moins mauvais des trois, alors que le modèle SARIMA au contraire est de loin le plus mauvais. L'étude du MAE le confirme avec une erreur absolue moyenne autour 304 milliers de nuitées (en moins si nous nous référons à la position de la courbe bleu par rapport à la courbe noire - Figure 9). L'ARIMAX a quasiment un MAE doublé par rapport à celui du modèle naïf. Le MAE du SARIMA explose avec une erreur absolue moyenne de plus de 3036 milliers de nuitées soit dix fois plus que le modèle naïf. Nous pouvons affirmer sans mal que ce modèle souffre d'une très mauvaise qualité de prévision. L'étude du MASE n'apporte pas de contradiction et vient

seulement préciser le constat fait à partir de l'étude du MAE. Si maintenant, nous comparons rapidement le RMSE et le MAE deux erreurs moyennes, nous remarquons une similitude à moins 100 unités près sauf pour le modèle SARIMA où le RMSE a explosé. Cela signifie que ce modèle a fait de grosses erreurs de prévision qui ont été fortement pénalisées par l'indicateur, contrairement aux autres modèles.

Regardons à présent, les erreurs cumulées au carré (CSPE) pour les deux groupes de modèle de prévision. Les deux graphiques matérialisent l'évolution de cette erreur sur l'horizon de prévision de douze mois.


Figure 10 – Graphique erreurs de prévision cumulées carré (CSPE) sur les modèles de prévision saisonniers



Source : Auteurs

Sur ce premier graphique, nous pouvons apercevoir sans mal que les modèles SARIMA et SARIMAX cumulent moins les erreurs de prévision sur l'horizon de douze mois que les modèles ADAM ETS ARIMA et naïf saisonnier, confirmant leur supériorité pour faire de la prévision. Enfin le modèle ADAM ETS ARIMA voit son erreur cumulée augmenter très rapidement surtout à la fin de l'horizon de prévision là où le modèle naïf saisonnier stabilise davantage la sienne. Ce graphique ne fait que renforcer le constat établi après l'étude des indicateurs de qualité de prévision.

Figure 11 - Graphique erreurs de prévision cumulées carré (CSPE) sur les modèles de prévision sur la tendance



Source : Auteur

Sur ce graphique, nous pouvons voir que les erreurs de prévision cumulée au carré pour les modèles ARIMAX, RLM et naïf simple, augmentent très faiblement sans réel décrochage. Cependant, le modèle naïf reste le modèle qui accumule le moins d'erreur de prévision sur l'horizon. Au contraire, le modèle SARIMA est le modèle qui accumule le plus d'erreur de prévision, confirmant sa mauvaise spécification pour faire de la prévision.

Ces tableaux et graphiques sont extrêmement informatifs et nous ont permis de constater une nette différence dans la qualité des prévisions entre le premier groupe constitué de modèle de prévision saisonnier et le deuxième groupe constitué de modèle de prévision sur la tendance. Les modèles saisonniers produisent des prévisions de très bonne qualité avec une erreur moyenne faible dépassant pour deux des trois, les prévisions du modèle naïf saisonnier. À l'inverse, les modèles de prévision sur la tendance ne se distinguent pas par leur qualité de prévision : aucun ne produit des prévisions surpassant le modèle naïf simple.

3.3.3. Pertinence des modèles de prévisions

Pour finir, nous allons tester de manière statistique la pertinence des modèles de prévision par rapport à leur modèle naïf de référence. Pour cela, nous allons utiliser un test de Diebold-Mariano dont l'objectif est de tester si un modèle est significativement meilleur que le modèle de référence. Nous avons également décidé d'utiliser ce test pour comparer la significativité

des modèles entre eux afin de déterminer si un modèle en particulier se dégage des autres. Les tableaux suivants récapitulent les résultats de ces tests pour nos deux groupes de modèles de prévisions.

Tableau 10 – Résultats du test de Diebold-Mariano sur les modèles de prévision saisonniers

Comparaison	Statistique	P-value
SARIMA vs Naïf saisonnier	-2,21	0,02 **
ADAM ETS ARIMA vs Naïf saisonnier	25 ,67	1,00
SARIMAX vs Naïf saisonnier	-1,93	0,03**
SARIMAX vs SARIMA	-0,65	0,52
SARIMAX vs ADAM ETS ARIMA	-25,75	0,00 ***
SARIMA vs ADAM ETS ARIMA	-25,69	0,00 ***

Source : Auteur

Ce tableau compare les modèles entre eux pour déterminer de manière statistique le meilleur modèle³⁴. Le résultat intéressant concerne le modèle ADAM ETS ARIMA. En effet, ce dernier n'est significativement pas meilleur que le modèle naïf saisonnier. Les deux autres modèles : SARIMA et SARIMAX le surpassent également. Il est maintenant clair que ce modèle n'est pas pertinent pour faire de la prévision. Si nous nous intéressons à la comparaison entre les deux autres modèles avec le modèle naïf saisonniers, nous constatons qu'ils sont tous les deux significativement meilleur que ce dernier. Ce résultat est attendu après avoir étudié les indicateurs de qualité de prévision. Enfin si nous comparons le SARIMAX et le SARIMA ensemble aucun ne semble se distinguer de l'autre. Le test conclut donc que le SARIMAX et le SARIMA sont les deux modèles de prévision saisonnier pertinent pour prévoir le nombre de nuitées en hôtellerie.

Si nous effectuons le même travail pour le deuxième groupe de prévision, nous obtenons le tableau suivant.

³⁴ Si la p-value est inférieure à 0,05 alors le modèle 1 est meilleur que le modèle 2 (au seuil de 5%)

Tableau 11– Résultats du test de Diebold-Mariano sur les modèles de prévision sur la tendance

Comparaison	Statistique	P-value
SARIMA vs Naïf simple	5,72	0,99
ARIMAX vs Naïf simple	6,64	1,00
RLM vs Naïf simple	4,83	0,99
ARIMAX vs SARIMA	-5,12	0,00 ***
ARIMAX vs RLM	-3,51	0,00 ***
SARIMA vs RLM	-3,86	0,00 ***

Source : Auteur

Les résultats du test confirme le constat établi précédemment. Aucun modèle de prévision ne surpasse significativement le modèle de prévision naïf simple. Si nous regardons la comparaison entre modèles (hors naïf), la modèle ARIMAX se distingue des autres. En effet, sur le graphique des CSPE, le modèle ARIMAX est celui qui cumule le moins d'erreur de prévision au carré après le modèle naïf simple. Cependant, son infériorité par rapport au modèle naïf simple le rend impertinent pour faire de la prévision au même titre que les deux autres (SARIMA et RLM).

Le test de Diebold-Mariona nous a permis de tester statistiquement la qualité des prévisions de nos différents modèles. Pour les modèles de prévision saisonniers, SARIMA et SARIMAX ont tous les deux un intérêt à être utiliser pour la prévision. Pour les modèles de prévision sur la tendance, aucun ne surpassent le modèle naïf simple. Par conséquent, ils n'ont aucun intérêt à être utiliser pour la prévision.

L'ensemble des comparaisons : graphiques, indicateurs de qualité de prévision et tests arrivent à la même conclusion. Les modèles de prévision saisonniers ont une qualité de prévision nettement supérieure aux modèles de prévision sur la tendance surpassant le modèle naïf saisonnier. Ce qui n'est pas le cas des modèles de prévisions sur la tendance pour les prévisions sont inférieures au modèle naïf simple.

Cette partie fondamentale a permis de mettre en avant les différents résultats empiriques de notre étude. Les caractéristiques propres de chaque série ont été identifiées. Le nombre de nuitées en hôtellerie est une série fortement saisonnière avec une très faible tendance. L'estimation des modèles en deux groupes a permis de tenir compte de ces deux caractéristiques pour produire les meilleures prévisions possibles. Pour le premier groupe de modèles, les modèles : le SARIMA et le SARIMAX se sont également révélés comme ceux avec la meilleure

qualité de prévision. Le modèle ADAM ETS ARIMA malgré des prévisions proche de la réalité ne fait pas mieux que le modèle naïf saisonnier. Le modèle ETS a été écarté pour la prévision à cause de sa mauvaise spécification.

Pour les modèles du deuxième groupe, bien qu'a priori, leurs estimations ne soient pas de mauvaises qualités, la qualité des prévisions ne surpassent pas celle du modèle naïf simple, marquant l'échec de nos modèles pour la prévision. Ainsi, seuls les modèles saisonniers SARIMA et SARIMAX sont pertinents pour faire de la prévision.

Conclusion et limites

Cette étude visait à répondre à un double objectif : Quel modèle permet de prévoir efficacement la fréquentation touristique en France à court terme ? Dans quelle mesure l'intégration de variables conjoncturelles, compétitives et comportementales permet-elle d'améliorer la qualité de ces prévisions ? Pour y répondre nous avons utilisé le nombre de nuitées en hôtellerie sur la période 2011 – 2025, pour matérialiser la fréquentation touristique en France. Deux groupes de modèles ont été estimés : le premier ciblant la prévision saisonnière du nombre de nuitées (SARIMA, SARIMAX, ADAM ETS ARIMA), le second cherchant à prévoir l'évolution tendancielle de la série corrigée des variations saisonnières du nombre de nuitées en hôtellerie ((S)ARIMA, ARIMAX, RLM). Voici les résultats marquants de cette étude :

Les modèles SARIMA et SARIMAX surpassent significativement le modèle naïf saisonnier démontrant leur pertinence pour prévoir le nombre de nuitées en hôtellerie. Plusieurs variables exogènes ressortent comme des facteurs significatifs de la fréquentation touristique. C'est le cas des variables : Covid, Google Trends, Prix relatif (Lags 2). Elles permettent de capter l'intention de voyage et de nuitées sur le territoire français ainsi que la compétitivité-prix. Cependant, bien que le SARIMAX surpasse légèrement le SARIMA sur tous les indicateurs (RMSE, MAE, MAPE, MASE), la différence n'est pas statistiquement significative. L'autre résultat marquant montre l'absence de modèle de prévision sur la tendance capable de surpasser le modèle naïf simple montrant l'échec des prévisions conjoncturelles. Ces résultats encourageants doivent être nuancés au regard des limites de cette étude.

De notre étude ressortent plusieurs limites importantes. La première limite concerne la matérialisation de la fréquentation touristique par le nombre de nuitées en hôtellerie. Bien que notre étude s'axe majoritairement sur la partie économétrique, l'objectif principal est de prévoir la fréquentation touristique. Cependant, le nombre de nuitées ne permet malheureusement pas de prendre en compte la totalité des nuitées effectuées à des fins touristiques sur le territoire occultant les nuitées dans d'autres établissements collectifs comme les campings mais aussi dans les hébergements particuliers.

La seconde limite concerne les données utilisées, en effet, les données récupérées étaient incomplètes et ont dû être complétées via un algorithme d'imputation de valeurs manquantes introduisant du biais pouvant influencer les estimations. Ensuite, nos données contenaient la crise du Covid 19 qui a profondément altéré la structure de ces dernières rendant les estimations très instables. Enfin, la méthode de désaisonnalisation utilisée n'a pas réussi à corriger toutes les variations saisonnières laissant des résidus qui ont influencé nos estimations.

La dernière limite repose sur le besoin d'avoir les données à l'horizon temporel voulu pour faire des prévisions à l'aide de modèle multivarié comme le SARIMAX. Nous nous sommes concentrés uniquement sur les prévisions dans un échantillon test et non pas hors échantillon. Les prévisions hors échantillon nécessite de prévoir également les valeurs pour les variables exogènes intégrées dans le modèle accumulant les erreurs de prévision.

Ainsi, nous recommandons aux professionnels hôteliers d'utiliser un modèle SARIMA pour anticiper fidèlement la saisonnalité du nombre de nuitées tout en évitant la complexité liée à un modèle SARIMAX. Cependant, il est primordial de garder une variable exogène Covid tant que la période de la crise se trouve dans les données estimées afin d'obtenir des résultats optimaux.

Il serait également intéressant de poursuivre cette étude en intégrant de nouveaux modèles basés davantage sur l'IA mais aussi basés sur des approches économétriques plus complexe. Combiner les prévisions de différentes approches (forecast combination) peut également s'avérer être une approche à explorer.

D'autres perspectives plus générales peuvent également envisagées pour améliorer ce travail notamment en élargissant la variable cible, en affinant la période du Covid 19 en déterminant de manière plus rigoureuse la période à prendre en compte. L'intégration de déterminants plus corrélés au nombre de nuitées en hôtellerie peut également être une piste à envisager.

Ainsi, cette étude vient apporter sa pierre à l'édifice en contribuant à la littérature sur la demande touristique en France et ouvrant la voie à d'autres travaux plus approfondis sur ce sujet stratégique.

Bibliographie

Athanasopoulos, G., Hyndman, R. J., Song, H., & Wu, D. C. (2011). The tourism forecasting competition. *International Journal of Forecasting*, 27(3), 822-844. <https://doi.org/10.1016/j.ijforecast.2010.04.009>

Botti, L., Peypoch, N., Randriamboarison, R., & Solonandrasana, B. (2006). An Econometric Model of Tourism Demand in France. *Tourismos*, 2.

Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time Series Analysis : Forecasting and Control*. John Wiley & Sons.

En décembre 2025, la confiance des ménages repart légèrement à la hausse—Informations rapides—2 | Insee. (s. d.). <https://www.insee.fr/fr/statistiques/8720764#documentation>

Enquête de fréquentation dans l'hôtellerie | Insee. (s. d.). <https://www.insee.fr/fr/metadonnees/source/serie/s1242>

Havranek, T., & Zeynalov, A. (2019). Forecasting tourist arrivals : Google Trends meets mixed-frequency data. *Tourism Economics*, 27, 135481661987958. <https://doi.org/10.1177/1354816619879584>

Havranek, T., & Zeynalov, A. (2021). Forecasting tourist arrivals : Google Trends meets mixed-frequency data. *Tourism Economics*, 27(1), 129-148. <https://doi.org/10.1177/1354816619879584>

L'essentiel sur... Le tourisme | Insee. (s. d.). <https://www.insee.fr/fr/statistiques/7653005>

Llewellyn, M., Ross, G., & Ryan-Saha, J. (2023). COVID-era forecasting : Google trends and window and model averaging. *Annals of Tourism Research*, 103, 103660. <https://doi.org/10.1016/j.annals.2023.103660>

Mikulić, J., & Baumgärtner, R. M. (2025). Google Trends and Baidu index data in tourism demand forecasting : A critical assessment of recent applications. *Tourism Management*, 110, 105164. <https://doi.org/10.1016/j.tourman.2025.105164>

Park, S., Lee, J., & Song, W. (2017). Short-term forecasting of Japanese tourist inflow to South Korea using Google trends data. *Journal of Travel and Tourism Marketing*, 34(3), 357-368. <https://doi.org/10.1080/10548408.2016.1170651>

Poids du tourisme dans l'économie française | Atout France. (2025, mai 15). <https://www.atout-france.fr/fr/informations/poids-du-tourisme-dans-leconomie-francaise>

Saison touristique d'été 2024—Insee Focus—335. (s. d.). https://www.insee.fr/fr/statistiques/8261969#figure2_radio2

Song, H., Qiu, R., & Park, J. (2023). Progress in tourism demand research : Theory and empirics. *Tourism Management*, 94, 104655. <https://doi.org/10.1016/j.tourman.2022.104655>

Song, H., Qiu, R. T. R., & Park, J. (2019). A review of research on tourism demand forecasting : Launching the *Annals of Tourism Research* Curated Collection on tourism demand forecasting. *Annals of Tourism Research*, 75, 338-362. <https://doi.org/10.1016/j.annals.2018.12.001>

Tourisme—Une fréquentation touristique en hausse | Insee. (s. d.). <https://www.insee.fr/fr/statistiques/8354627#documentation>

Universitat de les Illes Balears(España), & García Rodríguez, Ó. (2017). Forecasting tourism arrivals with an online search engine data : A study of the Balearic Islands. *Pasos. Revista de Turismo y Patrimonio Cultural*, 15(4), 943-958. <https://doi.org/10.25145/j.pasos.2017.15.064>




Yang, Y., Fan, Y., Jiang, L., & Liu, X. (2022). Search query and tourism forecasting during the pandemic : When and where can digital footprints be helpful as predictors? *Annals of Tourism Research*, 93, 103365. <https://doi.org/10.1016/j.annals.2022.103365>

Annexes


Annexe 1 - Graphique – Variables explicatives	71
Annexe 2 - Comparaison des différents indicateurs Google Trends testés	72
Annexe 3 – Graphique :série du nombre de nuitées en hôtellerie corrigée des valeurs manquantes.....	73
Annexe 4 - Tableau de résultat – test de Webel-Ollech et Seasonal Dummies	73
Annexe 5 - Résultat de la désaisonnalisation de la série des nuitées en hôtellerie via la méthode TRAMO-SEATS - Sortie de code R	74
Annexe 6 - Résultat de la désaisonnalisation de la série des nuitées en hôtellerie via la méthode X13-ARIMA-SEATS – sortie de code R	75
Annexe 7 – Tableau test de saisonnalité des variables explicatives	76
Annexe 8 – Graphiques variables explicatives CVS.....	76
Annexe 9 – Test de stationnarité (ADF & KPSS) : consommation des ménages en biens – volume – Sortie de code R	77
Annexe 10 - Test de stationnarité (ADF & KPSS) : confiance des ménages - Sortie de code R	78
Annexe 11 - Test de stationnarité (ADF & KPSS) : Taux de change USD/EUR - Sortie de code R	79
Annexe 12 - Test de stationnarité (ADF & KPSS) : Prix relatif de la France par rapport à la zone euro (CVS) - Sortie de code R	80
Annexe 13 - Test de stationnarité (ADF & KPSS) : indicateur Google Trends (CVS) - Sortie de code R.....	81
Annexe 14 – Test de stationnarité (ADF & KPSS) : Nombre de nuitées en hôtellerie (CVS) – sortie de code R	82
Annexe 15 – Graphiques variables après différenciation et transformation	83
Annexe 16 – Test de stationnarité (ADF) sur les variables exogènes après transformation et différenciation – sortie de code R.....	85
Annexe 17 – Matrice de P-value des corrélations entre les variables	85
Annexe 18 – CCF entre le prix relatif de la France par rapport à la zone euro et le nombre de nuitées en hôtellerie (brute).....	85
Annexe 19 – Résultat d’estimation du SARIMA	86
Annexe 20 – Résultat d’estimation ETS	86
Annexe 21 – Résultat d’estimation du modèle ADAM ETS ARIMA	87

Annexe 22 – Résultat d’estimation du modèle SARIMAX	87
Annexe 23 – ACF et PACF : modèle de prévision saisonniers	88
Annexe 24 – CCF variables exogènes avec le nombre de nuitées	89
Annexe 25 – Résultat d’estimation ARIMA	90
Annexe 26 – Résultat d’estimation ARIMAX	90
Annexe 27 – Résultat d’estimation RLM.....	90
Annexe 28 – ACF et PACF : modèles de prévision sur la tendance	91
Annexe 29 – Graphique prévisions saisonnières.....	91
Annexe 30 - Graphique prévisions sur la tendance	92

Annexe 1 - Graphique – Variables explicatives




Prix relatif de l'attractivité-prix de la France par rapport aux autres destinations de la zone euro



Source : Eurostat

Indicateur Google Trends


Mots clés : Booking France, Nuit Hotel France, Reservation hotel France, Hotel France, Chambre hotel



Source : Eurostat


Annexe 2 - Comparaison des différents indicateurs Google Trends testés

Comparaison Google Trends vs Nuitées hôtelières



Source : Auteur

Annexe 3 – Graphique :série du nombre de nuitées en hôtellerie corrigée des valeurs manquantes



Source : Auteur, INSEE

Annexe 4 - Tableau de résultat – test de Webel-Ollech et Seasonal Dummies

Test de saisonnalité			
Webel-Ollech		Seasonal Dummies	
stat	p-value	stat	p-value
1	0, 0, 0	63.29	0.00

Source : Auteur

Annexe 5 - Résultat de la désaisonnalisation de la série des nuitées en hôtellerie via la méthode TRAMO-SEATS - Sortie de code R

<u>RegARIMA</u> $y = \text{regression model} + \text{arima}(3, 1, 0, 0, 1, 1)$ Model: RegARIMA - TRAMO/SEATS Estimation span: from 1-2011 to 12-2025 Log-transformation: no Regression model: no mean, no trading days effect, no leap year effect, Easter effect, outliers(2) Coefficients: ARIMA: Estimate Std. Error T-stat Pr(> t) Phi(1) -0.50301 0.07728 -6.509 8.47e-10 *** Phi(2) 0.10443 0.08701 1.200 0.23172 Phi(3) 0.24376 0.07741 3.149 0.00194 ** BTheta(1) -0.89184 0.04995 -17.855 < 2e-16 *** --- Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1 Regression model: Estimate Std. Error T-stat Pr(> t) Easter [6] 1096.9 170.4 6.438 1.23e-09 *** AO (6-2019) 1882.3 536.7 3.507 0.000582 *** AO (9-2020) -2084.5 537.2 -3.880 0.000150 *** --- Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1 Residual standard error: 1026 on 159 degrees of freedom Log likelihood = -1404, aic = 2825, aicc = 2826, bic(corrected for length) = 14.08 <u>Decomposition</u> Model AR: $1 - 1.103819 B + 0.506040 B^2$ D: $1 - B - B^{12} + B^{13}$ MA: $1 - 0.590780 B - 0.911317 B^{12} + 0.538387 B^{13}$ SA AR: $1 - 1.103819 B + 0.506040 B^2$ D: $1 - 2.000000 B + B^2$ MA: $1 - 1.583545 B + 0.587147 B^2 - 0.000482 B^3 + 0.000034 B^4$ Innovation variance: 0.9193092 Trend D: $1 - 2.000000 B + B^2$ MA: $1 + 0.007707 B - 0.992293 B^2$ Innovation variance: 0.2379145	Seasonal D: $1 + B + B^2 + B^3 + B^4 + B^5 + B^6 + B^7 + B^8 + B^9 + B^{10} + B^{11}$ MA: $1 + 2.411720 B + 3.306856 B^2 + 3.481382 B^3 + 3.048939 B^4 + 2.317684 B^5 + 1.572669 B^6 + 0.951102 B^7 + 0.543277 B^8 + 0.256814 B^9 + 0.159231 B^{10} - 0.017900 B^{11}$ Innovation variance: 0.00344708 Transitory AR: $1 - 1.103819 B + 0.506040 B^2$ MA: $1 + 1.389895 B + 1.000000 B^2$ Innovation variance: 0.07874711 Irregular Innovation variance: 0.08052807 <u>Diagnostics</u> Relative contribution of the components to the stationary portion of the variance in the original series, after the removal of the long term trend Trend computed by Hodrick-Prescott filter (cycle length = 8.0 years) <table> <tr><th colspan="2">Component</th></tr> <tr><td>Cycle</td><td>21.093</td></tr> <tr><td>Seasonal</td><td>64.788</td></tr> <tr><td>Irregular</td><td>4.604</td></tr> <tr><td>TD & Hol.</td><td>0.192</td></tr> <tr><td>Others</td><td>0.192</td></tr> <tr><td>Total</td><td>90.870</td></tr> </table> Combined test in the entire series Non parametric tests for stable seasonality <table> <tr><th colspan="2">Pvalue</th></tr> <tr><td>Kruskal-Wallis test</td><td>0</td></tr> <tr><td>Test for the presence of seasonality assuming stability</td><td>0</td></tr> <tr><td>Evolutionary seasonality test</td><td>0</td></tr> </table> Identifiable seasonality present Residual seasonality tests <table> <tr><th colspan="2">Pvalue</th></tr> <tr><td>qs test on sa</td><td>0.017</td></tr> <tr><td>qs test on i</td><td>0.002</td></tr> <tr><td>f-test on sa (seasonal dummies)</td><td>1.000</td></tr> <tr><td>f-test on i (seasonal dummies)</td><td>1.000</td></tr> <tr><td>Residual seasonality (entire series)</td><td>1.000</td></tr> <tr><td>Residual seasonality (last 3 years)</td><td>0.000</td></tr> <tr><td>f-test on sa (td)</td><td>0.435</td></tr> <tr><td>f-test on i (td)</td><td>0.417</td></tr> </table>	Component		Cycle	21.093	Seasonal	64.788	Irregular	4.604	TD & Hol.	0.192	Others	0.192	Total	90.870	Pvalue		Kruskal-Wallis test	0	Test for the presence of seasonality assuming stability	0	Evolutionary seasonality test	0	Pvalue		qs test on sa	0.017	qs test on i	0.002	f-test on sa (seasonal dummies)	1.000	f-test on i (seasonal dummies)	1.000	Residual seasonality (entire series)	1.000	Residual seasonality (last 3 years)	0.000	f-test on sa (td)	0.435	f-test on i (td)	0.417
Component																																									
Cycle	21.093																																								
Seasonal	64.788																																								
Irregular	4.604																																								
TD & Hol.	0.192																																								
Others	0.192																																								
Total	90.870																																								
Pvalue																																									
Kruskal-Wallis test	0																																								
Test for the presence of seasonality assuming stability	0																																								
Evolutionary seasonality test	0																																								
Pvalue																																									
qs test on sa	0.017																																								
qs test on i	0.002																																								
f-test on sa (seasonal dummies)	1.000																																								
f-test on i (seasonal dummies)	1.000																																								
Residual seasonality (entire series)	1.000																																								
Residual seasonality (last 3 years)	0.000																																								
f-test on sa (td)	0.435																																								
f-test on i (td)	0.417																																								

Annexe 6 - Résultat de la désaisonnalisation de la série des nuitées en hôtellerie via la méthode
X13-ARIMA-SEATS – sortie de code R

RegARIMA <i>y = regression model + arima (1, 1, 0, 1, 1, 1)</i> Log-transformation: no Coefficients: Estimate Std. Error Phi(1) 0.6227 0.069 BPhi(1) -0.6259 0.089 BTheta(1) -0.8821 0.063 Estimate Std. Error Easter [8] 1033.5 89.03 LS (7-2020) 9130.4 380.61 AO (8-2020) 2449.5 286.68 LS (1-2021) 1585.4 331.93 LS (7-2021) 5149.2 348.97 LS (2-2020) -23751.0 714.58 TC (2-2020) 15595.0 691.23 AO (1-2020) -3464.8 331.92 TC (4-2021) -4232.8 312.68 LS (6-2020) 3443.9 425.54 TC (3-2021) -2879.3 293.90 AO (1-2022) -2209.6 296.75 AO (4-2020) -1991.4 346.13 TC (11-2020) -1805.7 298.75 TC (7-2022) 2042.2 290.74 AO (7-2024) -1379.7 253.13 AO (5-2019) -1211.8 277.38 AO (9-2021) -1058.9 255.61 TC (11-2015) -977.3 257.79 AO (3-2015) -932.3 248.45 AO (5-2013) 870.6 249.78 AO (8-2016) -894.8 248.34 AO (9-2023) 912.3 253.50 TC (12-2021) -983.3 293.07 AO (5-2017) -779.8 249.73 Residual standard error: 349.5 on 138 degrees of freedom Log likelihood = -1218, aic = 2493 aicc = 2506, bic(corrected for length) = 12.57 Decomposition Monitoring and Quality Assessment Statistics: M stats M(1) 0.013 M(2) 0.010 M(3) 0.977 M(4) 0.988 M(5) 0.795 M(6) 0.103	M(7) 0.043 M(8) 0.105 M(9) 0.066 M(10) 0.138 M(11) 0.131 Q 0.307 Q-M2 0.344 Final filters: Seasonal filter: 3x5 Trend filter: 13 terms Henderson moving average Diagnostics Relative contribution of the components to the stationary portion of the variance in the original series, after the removal of the long term trend Trend computed by Hodrick-Prescott filter (cycle length = 8.0 years) <table><tr><th>Component</th><th></th></tr><tr><td>Cycle</td><td>0.507</td></tr><tr><td>Seasonal</td><td>47.197</td></tr><tr><td>Irregular</td><td>0.146</td></tr><tr><td>TD & Hol.</td><td>0.111</td></tr><tr><td>Others</td><td>50.593</td></tr><tr><td>Total</td><td>98.554</td></tr></table> Combined test in the entire series Non parametric tests for stable seasonality <table><tr><th></th><th>Pvalue</th></tr><tr><td>Kruskall-Wallis test</td><td>0.000</td></tr><tr><td>Test for the presence of seasonality assuming stability</td><td>0.000</td></tr><tr><td>Evolutionary seasonality test</td><td>0.798</td></tr></table> Identifiable seasonality present Residual seasonality tests <table><tr><th></th><th>Pvalue</th></tr><tr><td>qs test on sa</td><td>0.013</td></tr><tr><td>qs test on i</td><td>0.020</td></tr><tr><td>f-test on sa (seasonal dummies)</td><td>0.999</td></tr><tr><td>f-test on i (seasonal dummies)</td><td>0.990</td></tr><tr><td>Residual seasonality (entire series)</td><td>0.998</td></tr><tr><td>Residual seasonality (last 3 years)</td><td>0.881</td></tr><tr><td>f-test on sa (td)</td><td>0.355</td></tr><tr><td>f-test on i (td)</td><td>0.457</td></tr></table>	Component		Cycle	0.507	Seasonal	47.197	Irregular	0.146	TD & Hol.	0.111	Others	50.593	Total	98.554		Pvalue	Kruskall-Wallis test	0.000	Test for the presence of seasonality assuming stability	0.000	Evolutionary seasonality test	0.798		Pvalue	qs test on sa	0.013	qs test on i	0.020	f-test on sa (seasonal dummies)	0.999	f-test on i (seasonal dummies)	0.990	Residual seasonality (entire series)	0.998	Residual seasonality (last 3 years)	0.881	f-test on sa (td)	0.355	f-test on i (td)	0.457
Component																																									
Cycle	0.507																																								
Seasonal	47.197																																								
Irregular	0.146																																								
TD & Hol.	0.111																																								
Others	50.593																																								
Total	98.554																																								
	Pvalue																																								
Kruskall-Wallis test	0.000																																								
Test for the presence of seasonality assuming stability	0.000																																								
Evolutionary seasonality test	0.798																																								
	Pvalue																																								
qs test on sa	0.013																																								
qs test on i	0.020																																								
f-test on sa (seasonal dummies)	0.999																																								
f-test on i (seasonal dummies)	0.990																																								
Residual seasonality (entire series)	0.998																																								
Residual seasonality (last 3 years)	0.881																																								
f-test on sa (td)	0.355																																								
f-test on i (td)	0.457																																								



Source : Auteur

Annexe 7 – Tableau test de saisonnalité des variables explicatives

	Webel-Ollech		Seasonal Dummies		
	stat	p-value	stat	p-value	
Consommation des ménages en biens	0	1, 1, 0.99	0.53	0.88	NS
Confiance des ménages	0	1, 0.14, 0.29	1.68	0.08	NS
Taux de change USD/EUR	0	1, 1, 0.32	1.21	0.28	NS
Prix relatif de la France	1	0, 0, 0	42.13	0.00	S
Indicateur Google	1	0, 0, 0	37.12	0.00	S

(NS : non saisonnière ; S : saisonnière), Source : Auteur

Annexe 8 – Graphiques variables explicatives CVS



Source : Auteur

Annexe 9 – Test de stationnarité (ADF & KPSS) : consommation des ménages en biens – volume – Sortie de code R

<pre>##### # Augmented Dickey-Fuller Test Unit Root Test # ##### Test regression drift Call: lm(formula = z.diff ~ z.lag.1 + 1 + z.diff.lag) Residuals: Min 1Q Median 3Q Max -11.0059 -0.5353 0.0077 0.5157 6.6942 Coefficients: Estimate Std. Error t value Pr(> t) (Intercept) 24.73651 3.61411 6.844 1.24e-10 *** z.lag.1 -0.52963 0.07733 -6.849 1.21e-10 *** z.diff.lag 0.01265 0.07560 0.167 0.867 --- Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1 Residual standard error: 1.534 on 175 degrees of freedom Multiple R-squared: 0.2616, Adjusted R-squared: 0.2531 F-statistic: 30.99 on 2 and 175 DF, p-value: 3.007e-12 Value of test-statistic is: -6.8491 23.4556 Critical values for test statistics: 1pct 5pct 10pct tau2 -3.46 -2.88 -2.57 phi1 6.52 4.63 3.81</pre>	<pre>##### # KPSS Unit Root Test # ##### Test is of type: mu with 4 lags. Value of test-statistic is: 0.6609 Critical value for a significance level of: 10pct 5pct 2.5pct 1pct critical values 0.347 0.463 0.574 0.739 ##### # KPSS Unit Root Test # ##### Test is of type: tau with 4 lags. Value of test-statistic is: 0.3566 Critical value for a significance level of: 10pct 5pct 2.5pct 1pct critical values 0.119 0.146 0.176 0.216</pre>
---	--

Source : Auteur

Annexe 10 - Test de stationnarité (ADF & KPSS) : confiance des ménages - Sortie de code R

<pre>##### # Augmented Dickey-Fuller Test Unit Root Test # ##### Test regression drift Call: lm(formula = z.diff ~ z.lag.1 + 1 + z.diff.lag) Residuals: Min 1Q Median 3Q Max -10.4299 -1.5000 0.1508 1.3641 6.7024 Coefficients: Estimate Std. Error t value Pr(> t) (Intercept) 5.46104 2.44078 2.237 0.0265 * z.lag.1 -0.05884 0.02620 -2.246 0.0260 * z.diff.lag -0.01466 0.07566 -0.194 0.8466 --- Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1 Residual standard error: 2.398 on 175 degrees of freedom Multiple R-squared: 0.02993, Adjusted R-squared: 0.01885 F-statistic: 2.7 on 2 and 175 DF, p-value: 0.07 Value of test-statistic is: -2.246 2.5229 Critical values for test statistics: 1pct 5pct 10pct tau2 -3.46 -2.88 -2.57 phi1 6.52 4.63 3.81</pre>	<pre>##### # KPSS Unit Root Test # ##### Test is of type: mu with 4 lags. Value of test-statistic is: 0.6056 Critical value for a significance level of: 10pct 5pct 2.5pct 1pct critical values 0.347 0.463 0.574 0.739 ##### # KPSS Unit Root Test # ##### Test is of type: tau with 4 lags. Value of test-statistic is: 0.5945 Critical value for a significance level of: 10pct 5pct 2.5pct 1pct critical values 0.119 0.146 0.176 0.216</pre>
---	--

Source : Auteur

Annexe 11 - Test de stationnarité (ADF & KPSS) : Taux de change USD/EUR - Sortie de code R

<pre>##### # Augmented Dickey-Fuller Test Unit Root Test # ##### Test regression drift Call: lm(formula = z.diff ~ z.lag.1 + 1 + z.diff.lag) Residuals: Min 1Q Median 3Q Max -0.064137 -0.011513 -0.001666 0.012019 0.044879 Coefficients: Estimate Std. Error t value Pr(> t) (Intercept) 0.03506 0.01599 2.192 0.0297 * z.lag.1 -0.03048 0.01354 -2.251 0.0257 * z.diff.lag 0.30811 0.07095 4.343 2.38e-05 *** --- Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1 Residual standard error: 0.01944 on 175 degrees of freedom Multiple R-squared: 0.1151, Adjusted R-squared: 0.105 F-statistic: 11.39 on 2 and 175 DF, p-value: 2.247e-05 Value of test-statistic is: -2.2507 2.6789 Critical values for test statistics: 1pct 5pct 10pct tau2 -3.46 -2.88 -2.57 phi1 6.52 4.63 3.81</pre>	<pre>##### # KPSS Unit Root Test # ##### Test is of type: mu with 4 lags. Value of test-statistic is: 2.1272 Critical value for a significance level of: 10pct 5pct 2.5pct 1pct critical values 0.347 0.463 0.574 0.739 ##### # KPSS Unit Root Test # ##### Test is of type: tau with 4 lags. Value of test-statistic is: 0.3289 Critical value for a significance level of: 10pct 5pct 2.5pct 1pct critical values 0.119 0.146 0.176 0.216</pre>
---	--

Source : Auteur

Annexe 12 - Test de stationnarité (ADF & KPSS) : Prix relatif de la France par rapport à la zone euro (CVS) - Sortie de code R

<pre>##### # Augmented Dickey-Fuller Test Unit Root Test # ##### Test regression none Call: lm(formula = z.diff ~ z.lag.1 - 1 + z.diff.lag) Residuals: Min 1Q Median 3Q Max -0.0068213 -0.0007874 0.0000117 0.0008651 0.0061853 Coefficients: Estimate Std. Error t value Pr(> t) z.lag.1 -0.0002120 0.0001195 -1.775 0.0776. z.diff.lag 0.1544232 0.0744874 2.073 0.0396 * --- Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1 Residual standard error: 0.00162 on 176 degrees of freedom Multiple R-squared: 0.04743, Adjusted R-squared: 0.03661 F-statistic: 4.382 on 2 and 176 DF, p-value: 0.01389 Value of test-statistic is: -1.775 Critical values for test statistics: 1pct 5pct 10pct tau1 -2.58 -1.95 -1.62</pre>	<pre>##### # KPSS Unit Root Test # ##### Test is of type: mu with 4 lags. Value of test-statistic is: 2.3898 Critical value for a significance level of: 10pct 5pct 2.5pct 1pct critical values 0.347 0.463 0.574 0.739 ##### # KPSS Unit Root Test # ##### Test is of type: tau with 4 lags. Value of test-statistic is: 0.5835 Critical value for a significance level of: 10pct 5pct 2.5pct 1pct critical values 0.119 0.146 0.176 0.216</pre>
--	--

Source : Auteur

Annexe 13 - Test de stationnarité (ADF & KPSS) : indicateur Google Trends (CVS) - Sortie de code R

<pre>##### # Augmented Dickey-Fuller Test Unit Root Test # ##### Test regression trend Call: lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag) Residuals: Min 1Q Median 3Q Max -37.751 -2.129 -0.039 2.601 19.409 Coefficients: Estimate Std. Error t value Pr(> t) (Intercept) 25.79018 4.16853 6.187 4.26e-09 *** z.lag.1 -0.38063 0.06023 -6.320 2.13e-09 *** tt -0.05309 0.01149 -4.621 7.40e-06 *** z.diff.lag 0.16454 0.07459 2.206 0.0287 * --- Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1 Residual standard error: 5.472 on 174 degrees of freedom Multiple R-squared: 0.1872, Adjusted R-squared: 0.1732 F-statistic: 13.36 on 3 and 174 DF, p-value: 6.903e-08 Value of test-statistic is: -6.3196 13.3379 19.9745 Critical values for test statistics: 1pct 5pct 10pct tau3 -3.99 -3.43 -3.13 phi2 6.22 4.75 4.07 phi3 8.43 6.49 5.47</pre>	<pre>##### # KPSS Unit Root Test # ##### Test is of type: mu with 4 lags. Value of test-statistic is: 2.4885 Critical value for a significance level of: 10pct 5pct 2.5pct 1pct critical values 0.347 0.463 0.574 0.739 ##### # KPSS Unit Root Test # ##### Test is of type: tau with 4 lags. Value of test-statistic is: 0.3763 Critical value for a significance level of: 10pct 5pct 2.5pct 1pct critical values 0.119 0.146 0.176 0.216</pre>
--	--

Source : Auteur


Annexe 14 – Test de stationnarité (ADF & KPSS) : Nombre de nuitées en hôtellerie (CVS) –
sortie de code R

<pre>##### # Augmented Dickey-Fuller Test Unit Root Test # ##### Test regression drift Call: lm(formula = z.diff ~ z.lag.1 + 1 + z.diff.lag) Residuals: Min 1Q Median 3Q Max -4246.2 -312.8 88.1 459.0 4574.1 Coefficients: Estimate Std. Error t value Pr(> t) (Intercept) 1565.28594 409.94311 3.818 0.000186 *** z.lag.1 -0.09464 0.02444 -3.873 0.000152 *** z.diff.lag 0.45547 0.06743 6.755 2.04e-10 *** --- Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1 Residual standard error: 1064 on 175 degrees of freedom Multiple R-squared: 0.2318, Adjusted R-squared: 0.223 F-statistic: 26.41 on 2 and 175 DF, p-value: 9.507e-11 Value of test-statistic is: -3.873 7.505 Critical values for test statistics: 1pct 5pct 10pct tau2 -3.46 -2.88 -2.57 phi1 6.52 4.63 3.81</pre>	<pre>##### # KPSS Unit Root Test # ##### Test is of type: mu with 4 lags. Value of test-statistic is: 0.2472 Critical value for a significance level of: 10pct 5pct 2.5pct 1pct critical values 0.347 0.463 0.574 0.739 ##### # KPSS Unit Root Test # ##### Test is of type: tau with 4 lags. Value of test-statistic is: 0.2197 Critical value for a significance level of: 10pct 5pct 2.5pct 1pct critical values 0.119 0.146 0.176 0.216</pre>
--	--


Source : Auteur

Annexe 15 – Graphiques variables après différenciation et transformation

Confiance des ménages (log & stationnaire)




Consommation des ménages en biens (stationnaire)




Taux de change USD/EUR (log & stationnaire)



Indicateur Google Trends (stationnaire)



Prix relatif de la France (log & stationnaire)



Source : auteur

Annexe 16 – Test de stationnarité (ADF) sur les variables exogènes après transformation et différenciation – sortie de code R

Variable	Statistique	P-value	Stationnarité
conso	-11.08	0.01	Stationnaire
prix_relatif_cvs	-5.09	0.01	Stationnaire
confiance	-5.06	0.01	Stationnaire
google_trends_cvs	-8.12	0.01	Stationnaire
taux_dollar_euro	-5.01	0.01	Stationnaire


Source : Auteur

Annexe 17 – Matrice de P-value des corrélations entre les variables

	<i>Conso</i>	<i>prix_relatif_cvs</i>	<i>taux_dollar_euro</i>	<i>confiance</i>	<i>google_trends_cvs</i>	<i>nuitee</i>
<i>conso</i>	0.000	0.084	0.018	0.173	0.294	-0.062
<i>prix_relatif_cvs</i>	0.084	0.000	0.061	0.006	-0.016	-0.024
<i>taux_dollar_euro</i>	0.018	0.061	0.000	0.044	0.032	-0.084
<i>confiance</i>	0.173	0.006	0.044	0.000	0.311	0.020
<i>google_trends_cvs</i>	0.294	-0.016	0.032	0.311	0.000	0.083
<i>nuitee</i>	-0.062	-0.024	-0.084	0.020	0.083	0.000

Source : Auteur

Annexe 18 – CCF entre le prix relatif de la France par rapport à la zone euro et le nombre de nuitées en hôtellerie (brute)



Source : Auteur

Annexe 19 – Résultat d'estimation du SARIMA

```
Series: data_ts_cvs[, "nuitee_brute"]
Regression with ARIMA(1,0,2)(2,1,0)[12] errors

Coefficients:
      ar1    ma1    ma2    sar1    sar2    xreg
      0.7758 0.3538 0.3245 -0.4173 -0.2974 -2026.4108
s.e. 0.0730 0.0810 0.1004 0.0769 0.0728 928.9702

sigma^2 = 1725815: log likelihood = -1444.41
AIC=2902.81 AICc=2903.51 BIC=2924.68

Training set error measures:
      ME  RMSE  MAE  MPE  MAPE  MASE
Training set 20.81755 1246.288 827.1931 -4.217664 9.807965 0.4092718
      ACF1
Training set 0.006912948
```

Source : Auteur

Annexe 20 – Résultat d'estimation ETS

```
ETS(A,N,A)

Call:
ets(y = data_ts_cvs[, "nuitee_brute"])

Smoothing parameters:
alpha = 0.9999
gamma = 1e-04

Initial states:
l = 17089.3614
s = -3135.426 -3616.168 600.7489 2859.746 7412.82 5858.041
      2497.142 701.1057 -1179.624 -2515.807 -4434.663 -5047.916

sigma: 1240.999

      AIC  AICc  BIC
3514.680 3517.607 3562.574

Training set error measures:
      ME  RMSE  MAE  MPE  MAPE  MASE
Training set 10.43955 1191.761 801.5466 -4.104947 10.01385 0.3965826
      ACF1
Training set 0.2896313
```

Source : Auteur

Annexe 21 – Résultat d'estimation du modèle ADAM ETS ARIMA

Model estimated using adam() function: ETSX(ANA)+ARIMA(1,0,0)

Response variable: nuitée_brute

Distribution used in the estimation: Normal

Loss function type: likelihood; Loss function value: 1523.393

Coefficients:

Error standard deviation: 1159.324

Sample size: 180

Number of estimated parameters: 5

Number of degrees of freedom: 175

Information criteria:

AIC	AICc	BIC	BICc
3056.786	3057.131	3072.751	3073.646

	Estimate <dbl>	Std. Error <dbl>	Lower 2.5% <dbl>	Upper 97.5% <dbl>	<chr>
alpha		0.2629	0.0890	0.0872	0.4384
gamma		0.0296	0.0197	0.0000	0.0685
phi1[1]		0.8592	0.0619	0.7370	0.9814
Covid_Dummy		-2214.3239	259.8957	-2727.2574	-1701.5834

Source : Auteur

Annexe 22 – Résultat d'estimation du modèle SARIMAX

Series: Y_clean

Regression with ARIMA(2,0,0)(2,1,0)[12] errors

Coefficients:

ar1	ar2	sar1	sar2	Covid	Prix_Lag2	google_trends
1.1079	-0.2398	-0.5202	-0.3251	-1853.601	-96317.53	72.5403
s.e. 0.1020	0.0908	0.0791	0.0721	1001.020	43144.73	13.6075

$\sigma^2 = 1493581$; log likelihood = -1415.06

AIC=2846.12 AICc=2847.04 BIC=2871.01

Training set error measures:


ME	RMSE	MAE	MPE	MAPE	MASE
Training set -5.876773	1155.056	782.1026	-3.468725	8.683886	0.3829906

ACF1

Training set -0.0004494974


Source : Auteur

Annexe 23 – ACF et PACF : modèle de prévision saisonniers



Source : Auteur

Annexe 24 – CCF variables exogènes avec le nombre de nuitées



Source : Auteur

Annexe 25 – Résultat d'estimation ARIMA

```
Series: data_ts_diff[, "nuitee"]
Regression with ARIMA(1,1,3)(0,0,1)[12] errors

Coefficients:
      ar1    ma1    ma2    ma3    sma1    xreg
      0.8008 -0.4962 -0.2420 -0.2618 0.3186 -1716.517
s.e. 0.0618 0.0792 0.0972 0.0940 0.0693 730.461

sigma^2 = 999071: log likelihood = -1480.98
AIC=2975.96 AICc=2976.62 BIC=2998.23

Training set error measures:
      ME    RMSE    MAE    MPE    MAPE    MASE    ACF1
Training set -4.073367 979.7966 608.6607 -12.09493 16.31992 0.308305 0.01303964
```

Source : Auteur

Annexe 26 – Résultat d'estimation ARIMAX

```
Series: Y_clean
Series: Y
Regression with ARIMA(2,1,1) errors

Coefficients:
      ar1    ar2    ma1 Google Prix_Lag2
      1.0961 -0.5022 -0.5879 25.2469 -57786.56
s.e. 0.1463 0.0733 0.1630 7.4914 26768.96

sigma^2 = 1076542: log likelihood = -1411.15
AIC=2834.3 AICc=2834.82 BIC=2853.08

Training set error measures:
      ME    RMSE    MAE    MPE    MAPE    MASE    ACF1
Training set 11.56751 1019.091 659.2709 -107.5236 112.6887 0.3184586 0.004025472
```

Source : Auteur

Annexe 27 – Résultat d'estimation RLM

```
Call:
lm(formula = as.formula(paste("Y ~", paste(best_vars, collapse = " + "))),
   data = df_selection)

Residuals:
      Min       1Q   Median       3Q      Max
-6207.8 -555.9   76.7   679.8  6938.7

Coefficients:
      Estimate Std. Error t value Pr(>|t|)
(Intercept)  17478.83    122.53 142.645 < 2e-16 ***
Prix_Lag9   -144107.58   70828.66  -2.035 0.04349 *
Covid       -9572.47    363.29 -26.350 < 2e-16 ***
Google        60.24     22.38  2.692 0.00784 **
Conso       -7192.18    3072.94  -2.340 0.02045 *
---

```


Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1486 on 165 degrees of freedom
Multiple R-squared: 0.8145, Adjusted R-squared: 0.81
F-statistic: 181.1 on 4 and 165 DF, p-value: < 2.2e-16

[1] 2972.638


Source : Auteur

Annexe 28 – ACF et PACF : modèles de prévision sur la tendance






Source : Auteur

Annexe 29 – Graphique prévisions saisonnières



Source : Auteur

Annexe 30 - Graphique prévisions sur la tendance



Source : Auteur

Liste des packages R utilisés

- tidyverse
- readxl
- readr
- knitr
- kableExtra
- scales
- moments
- zoo
- tseries
- gets
- urca
- TSA
- seastests
- seasonal
- RJDemetra
- forecast
- smooth
- tsoutliers
- leaps

Table des figures

Figure 1 : Schéma récapitulatif des méthodes quantitatives de séries temporelles et économétriques.....	10
Figure 2– Nombre de nuitées en hôtellerie (en millier), janvier 2011- décembre 2025	15
Figure 3 : Graphique comparaison indicateur Google Trends et nombre de nuitées en hôtellerie	21
Figure 4 : Schéma - Tendence dans la littérature sur la prévision de la demande touristique..	23
Figure 5 : Graphique du nombre de nuitées en hôtellerie (CVS).....	43
Figure 6 : Matrice de corrélation de Spearman	46
Figure 7 – Tableau résultats du test de Ljung-Box (modèles de prévisions saisonniers).....	51
Figure 8 – Graphique comparaison des prévisions saisonnières	56
Figure 9 – Graphique comparaison des prévisions sur la tendance	57
Figure 10 – Graphique erreurs de prévision cumulées carré (CSPE) sur les modèles de prévision saisonniers	60
Figure 11 - Graphique erreurs de prévision cumulées carré (CSPE) sur les modèles de prévision sur la tendance	61

Table des tableaux

Tableau 1 : Récapitulatif des variables utilisées dans cette étude	22
Tableau 2 : Statistiques descriptives sur la série du nombre de nuitées en hôtellerie	40
Tableau 3 : Récapitulatif des outliers détectés	41
Tableau 4 : Récapitulatif des tests de détection de la saisonnalité et de stationnarité.....	45
Tableau 5 : Estimation des différents modèles de prévision saisonniers	48
Tableau 6 : Estimation des modèles de prévision sur la tendance.....	52
Tableau 7 : Tableau résultats du test de Ljung-Box (modèles de prévision sur la tendance)...	54
Tableau 8 – Indicateurs de qualité des modèles de prévision saisonniers.....	58
Tableau 9 – Indicateurs de qualité des modèles de prévision sur la tendance.....	59
Tableau 10 – Résultats du test de Diebold-Mariano sur les modèles de prévision saisonniers	62
Tableau 11– Résultats du test de Diebold-Mariano sur les modèles de prévision sur la tendance	63

Table des matières

Remerciement.....	2
Résumé	3
Sommaire	5
Sigles	6
Introduction	8
1. La demande touristique en France : mesure et potentiels déterminants.....	14
1.1. Les nuitées hôtelières comme indicateur de la fréquentation touristique	14
1.2. Les potentiels déterminants de la demande touristique.....	16
1.2.1. Les variables de conjoncture	17
1.2.2. Les variables de compétitivité.....	18
1.2.3. La variable comportementale	19
2. Méthodologie de la prévision du nombre de nuitées en hôtellerie.....	23
2.1. Les modèles de prévision saisonniers	24
2.1.1. Le modèle SARIMA	25

2.1.2.	Le lissage exponentiel avancée – l’approche ETS	26
2.1.3.	Les modèles ADAM : une généralisation des approches ETS et ARIMA.....	27
2.1.4.	SARIMAX : une approche saisonnière multivariée.....	28
2.2.	Les modèles de prévision sur la tendance	29
2.2.1.	Le modèle ARIMA.....	30
2.2.2.	Le modèle ARIMAX.....	31
2.2.3.	Le modèle de régression linéaire multiple (RLM)	32
2.3.	Méthodologie d'évaluation et comparaison des prévisions	33
2.3.1.	Le modèle de référence : le modèle naïf	33
2.3.2.	Les indicateurs de qualité de prévision	34
2.3.3.	Processus d'estimation de chaque modèle	36
2.3.4.	Processus d'évaluation et de comparaison des modèles	37
3.	Analyse empirique de la fréquentation touristique : estimation et prévision.....	39
3.1.	Pré-traitement et analyse exploratoire.....	40
3.1.1.	Imputation des valeurs manquantes et statistiques descriptives.....	40
3.1.2.	Analyse des outliers	41
3.1.3.	Saisonnalité et stationnarité.....	43
3.1.4.	Corrélation.....	45
3.2.	Estimation des modèles de prévision	47
3.2.1.	Estimation des modèles de prévision saisonniers	48
3.2.2.	Estimations des modèles de prévision sur la série CVS.....	52
3.3.	Prévision et comparaison	56
3.3.1.	Comparaison des prévisions.....	56
3.3.2.	Evaluation des prévisions.....	58
3.3.3.	Pertinence des modèles de prévisions	61
	Conclusion et limites	64
	Bibliographie.....	67

Annexes	69
Table des figures.....	93
Table des tableaux	94
Table des matières	94