

Note de synthèse

Prévision de la fréquentation touristique en France, à court terme

Résumé

L'objectif de cette étude est d'explorer la prévision de la fréquentation touristique en France à court terme en utilisant le nombre de nuitées en hôtellerie de 2011 à 2025. Parmi les modèles estimés deux modèles se sont avérés être de bonne qualité pour faire de la prévision : les modèles SARIMA et SARIMAX, tous deux surpassant le modèle de référence (naïf) saisonnier. L'intégration de variables explicatives améliore les indicateurs de qualité sans pour autant améliorer la qualité des prévisions de manière significative.

Mots-clés : Prévision touristique, fréquentation hôtelière, séries temporelles, évaluation des prévisions, R

Problématique et cadre de l'étude

En 2022, la part du tourisme s'élevait à 3,8% du PIB français. Cette part non-négligeable du PIB fait du tourisme un secteur stratégique de l'économie française. La récente crise du Covid 19 a eu des effets considérables sur le tourisme. Le nombre de nuitées en hôtellerie a chuté de 42,18% en 2020. Dans certains territoires, le tourisme constitue le principal moteur de l'activité économique, rendant ces régions particulièrement vulnérables aux chocs. Dans ce contexte, la capacité à anticiper et à prévoir la fréquentation touristique à court terme (12 mois) devient un enjeu majeur pour les acteurs du secteur.

Cette étude vise plus particulièrement à répondre à deux questions : Quel modèle permet de prévoir efficacement la fréquentation touristique en France à court terme ? Dans quelle mesure l'intégration de variables conjoncturelles, compétitives et comportementales permet-elle d'améliorer la qualité de ces prévisions ? L'enjeu est donc double : à la fois académique, pour


faire avancer la recherche sur ce terrain, et à la fois opérationnel, pour aider les professionnels du secteur hôtelier à anticiper leur activité.

Le sujet de la prévision de la demande touristique est largement documenté. Song et alii. (2019) proposent une revue exhaustive de la littérature sur le sujet, qui a servi de pilier théorique et empirique pour cette étude. Si la littérature est abondante sur le sujet, peu d'études portent sur la fréquentation hôtelière en France à fréquence mensuelle.

Données utilisées

Dans cette étude, la fréquentation touristique est mesurée par le nombre de nuitées en hôtellerie en France (métropolitaine et départements d'outre-mer). Cette série de données est produite par l'INSEE grâce aux résultats d'une enquête mensuelle sur la fréquentation des hébergements collectifs de tourisme et couvre la période 2011-2025.

Graphique du nombre de nuitées en hôtellerie en France entre 2011 et 2025 (en milliers de nuitées) – Imputées des valeurs manquantes



Source : INSEE

Ces données présentent un fort caractère saisonnier régulier, visible par la répétition annuelle des pics estivaux. Les effets de la crise du Covid 19 sont identifiables sur la période janvier 2020 - début 2022 avec une chute brutale du nombre de nuitées en hôtellerie. Pour éviter des effets indésirables liés à cette crise, une variable a été intégrée aux modèles estimés. D'autres variables : indicateurs Google Trends, Prix relatif France/zone euro retardé de 2 mois ont également été introduites pour essayer d'améliorer la qualité de prévision.

Méthodologie

Le modèle SARIMA utilisé dans cette étude est un modèle de série temporelle qui prédit les valeurs futures à partir des valeurs passées tout en tenant compte de pics saisonniers annuels. Le modèle SARIMAX est une extension du modèle SARIMA permettant l'intégration de variables explicatives (Covid, Google Trends, Prix relatif France/zone euro ...) dans l'estimation du modèle dans l'objectif d'améliorer les prévisions. En plus des deux modèles principaux sept autres modèles ont été estimés et répartis en deux groupes distincts : l'un contenant des modèles saisonniers et l'autre contenant des modèles estimés sur la série corrigée des variations saisonnières pour prévoir la conjoncture. Les modèles sont entraînés sur la période 2011-2024 puis évalués sur l'année 2025 à l'aide d'indicateurs de qualité de prévision (RMSE, MAE) qui mesurent l'erreur moyenne du modèle par rapport aux valeurs réellement observées. Enfin chaque modèle est comparé à un modèle de référence simple: le modèle naïf pour déterminer la pertinence du modèle à faire des prévisions.

Résultats de l'étude

Les résultats de l'étude ont montré que pour le groupe des prévisions saisonnières, les modèles SARIMA et SARIMAX surpassent le modèle naïf saisonnier produisant ainsi des prévisions plus efficaces qu'une reconduction de la saisonnalité passée. Pour le groupe des prévisions sur la tendance (évolution du nombre de nuitées sans les pics saisonniers), aucun modèle estimé ne surpasse une simple reconduction de la valeur du mois dernier produite par le modèle naïf simple.

Tableau : Résultats des indicateurs de qualité de prévision, exprimé en milliers de nuitées


	Modèle	RMSE	MAE
Modèles saisonniers	Naïf saisonnier	908,29	728,25
	SARIMA	544,03	449,61
	SARIMAX	467,01	329,67
Modèles tendanciels	Naïf simple	369,74	304,67

Source : Auteur

Le modèle SARIMA réduit l'erreur moyenne du modèle naïf saisonnier de près de 40% et de 27% pour le SARIMAX. Quant au modèle naïf simple, il se trompe, en moyenne, d'environ 304 milliers de nuitées par rapport aux données réellement observées.

L'intégration de variables explicatives dans le modèle SARIMAX a permis d'améliorer les indicateurs de qualité de prévision (moins d'erreurs par rapport au modèle SARIMA) sans pour autant se distinguer statistiquement de l'approche SARIMA plus légère, sans variables explicatives.

Graphique – comparaison des prévisions sur l'année 2025



Source : Auteur

Conclusion

Les résultats recommandent l'utilisation d'un modèle SARIMA pour les professionnels du secteur hôtelier souhaitant anticiper la saisonnalité à douze mois du nombre de nuitées, ce dernier étant plus léger à estimer. Pour les autres acteurs du secteur qui s'intéressent à l'évolution du nombre de nuitées, il est recommandé d'utiliser un simple modèle naïf reconduisant la dernière valeur connue en attendant que d'autres modèles plus performants voient le jour. Il est également conseillé de garder la variable Covid pour les modèles qui incluraient la période du Covid 19 dans leurs données afin d'isoler l'effet de cette crise sur l'estimation des résultats. Cette étude peut être approfondie en estimant des approches plus contemporaines comme les modèles basés sur l'IA notamment.

Bibliographie

Song, H., Qiu, R. T. R., & Park, J. (2019). A review of research on tourism demand forecasting : Launching the *Annals of Tourism Research* Curated Collection on tourism demand forecasting. *Annals of Tourism Research*, 75, 338-362. <https://doi.org/10.1016/j.annals.2018.12.001>