


Projet d'économétrie linéaire

**Quels facteurs expliquent les disparités départementales du taux
d'accidents mortels sur les routes de France ?**



Ikram Abouzayd - Jules Bouscaud – Emma Loquet

M1 – ECAP 2025/2026

IAE Nantes

Table des matières

Résumé	2
Introduction	3
Modélisation de l'étude et définition des variables	5
A) Présentation des variables	5
B) Modélisation de l'étude	15
Analyse descriptive	18
A) Analyse descriptive univariée	18
B) Analyse descriptives bivariée (quantitative – quantitative)	27
Analyse économétrique	33
A) Estimation naïve d'un premier modèle	33
B) Méthode d'auto-sélection et estimation du modèle autosélectionné	34
C) Construction d'un modèle final	37
D) Estimation du « meilleur modèle »	44
E) Interprétation des coefficients du modèle	45
Prévision	47
Discussion	49
A) Comparaison de nos résultats avec la littérature	49
B) Les limites de notre analyse	51
Conclusion	53
Annexe	55
Bibliographie	74
Index	77

Résumé

La sécurité routière est un sujet qui revient inlassablement chaque année et le bilan est lourd : environ 3000 sont mortes sur les routes françaises au cours de ces cinq dernières années. Il devient impératif pour les pouvoirs publics d'agir et de mettre des moyens en œuvre pour diminuer ce chiffre. Nous sommes partis du constat qu'il existait une grande disparité entre les départements concernant le nombre d'accidents de la route mortels. Il est clair qu'une majorité des accidents sont causés par le comportement des individus, mais ce seul comportement ne peut pas expliquer cette forte disparité entre les départements. Il doit exister des facteurs intrinsèques aux départements concernant la structure du réseau routier, les conditions météorologiques, la démographie ou encore la topographie qui sont susceptibles d'expliquer

Dans cette analyse, nous avons cherché à identifier, à l'échelle départementale, les facteurs explicatifs du taux de mortalité lié aux accidents de la route à l'aide de la méthode des moindres carrés ordinaires. Pour ce faire, nous nous sommes appuyés sur des données récentes et avons veillé à maintenir une méthodologie rigoureuse tout au long de nos analyses, afin d'obtenir des résultats aussi pertinents et fiables que possible. L'objectif est d'apporter aux décideurs des éléments de compréhension sur la nature de ces disparités, afin qu'ils puissent mettre en œuvre des politiques publiques adaptées.

Introduction

En 2023, un accident sur dix entraînait au moins une victime sur les routes de France. Derrière ce chiffre se cache toutefois une forte disparité entre les différents départements de France métropolitaine. En effet, alors que certains départements présentent un taux d'accidents mortels très faible, avoisinant les 0,3%, d'autres sont de véritables exceptions avec un taux de mortalité par accident supérieur à 30%.

Un certain nombre de mesures ont été prises par le gouvernement pour tenter de diminuer le nombre de tués sur les routes. En 2018, le décret n° 2018-487 du 15 juin 2018 a abaissé la vitesse maximale autorisée de 90 km/h à 80 km/h sur environ 400 000 km de routes¹ en France métropolitaine. Cette mesure visait à diminuer le nombre de décès sur les routes en agissant sur la vitesse des automobilistes. Peu de temps après la mise en place de ce décret, la loi d'orientation des mobilités (LOM) de décembre 2019, a été adoptée. Cette loi a permis d'assouplir le décret n° 2018-487, laissant le choix aux présidents de conseils départementaux ainsi qu'à certains maires de repasser certaines portions de routes à 90 km/h sous certaines conditions et après avis consultatif de la commission départementale de la sécurité routière (CDSR).

Cependant, cette loi s'est heurtée à la forte hétérogénéité des différents départements, ce qui a conduit à un effet mitigé quant à son impact réel sur le taux de mortalité par accident. D'un côté, la Sécurité routière² a affirmé que cette mesure avait permis de sauver environ 350 vies. De l'autre côté, la Ligue de défense des conducteurs conteste ces résultats. Elle affirme grâce aux données de l'Observatoire National Interministériel de la Sécurité Routière (ONISR), dans un article³ sorti en septembre 2021, que « pour 49% des départements métropolitain, la mortalité routière reste identique ou s'est aggravée après son instauration ».

Par conséquent, il devient primordial de comprendre quels sont les facteurs intrinsèques aux départements qui influencent le taux d'accidents mortels. Dans notre étude, nous nous sommes focalisés sur des facteurs démographiques, géographiques ou encore naturels propres

¹ Principalement sur les routes bidirectionnelles sans séparateur central

² Dans son rapport du juillet 2020

³ [Dans 49 % des départements, la mortalité routière a stagné ou augmenté après l'instauration du 80 km/h - Ligue de défense des conducteurs](#)

à chaque département, susceptibles d'expliquer le taux de mortalité par accident. Nous nous sommes alors interrogés sur la question suivante :

Quels facteurs expliquent les disparités départementales du taux d'accidents mortels sur les routes de France ?

Notre étude vise à comprendre et expliquer le taux d'accidents mortels à l'échelle départementale, en mobilisant un ensemble de variables susceptibles d'agir sur le taux de mortalité par accident. Alors que nombreuses recherches s'intéressent à ce phénomène en privilégiant une approche individuelle des accidents, peu d'études s'intéressent à un niveau agrégé à l'échelle départementale, les rares études existantes proposent plutôt une analyse descriptive. Notre étude distingue par son approche territoriale et par son approche explicative.

Il est difficile pour les pouvoirs publics de mettre en place des mesures à l'échelle individuelle. Par exemple, il est impossible d'interdire concrètement à autrui de consommer de l'alcool en grande quantité et de prendre le volant par la suite, même si la loi française interdit la conduite au-delà d'un certain taux d'alcool dans le sang. Les seuls leviers d'action qu'ont les pouvoirs publics pour agir à cette échelle sont la sensibilisation via des campagnes de préventions, ou un renforcement des contrôles. Bien qu'il serait très intéressant de mesurer l'impact concret de ces mesures, il n'empêche que le taux de mortalité par accident reste très élevé en France.

Notre travail a une portée différente et pourrait aider les pouvoirs publics à mettre en place des mesures au niveau départemental en fonction des caractéristiques du département afin de pouvoir agir de manière efficace sur le taux de mortalité par accident.

Notre étude suivra une progression claire et précise qui se veut la plus accessible possible. Nous commencerons par présenter quelques éléments de méthodologie afin d'expliquer la construction de notre base de données. Nous proposerons ensuite une analyse descriptive des variables pour mieux appréhender nos données. La partie centrale sera consacrée à l'analyse économétrique de notre modèle. Enfin, nous conclurons en confrontant nos résultats aux principaux chiffres issus de la littérature et en discutant des limites de notre recherche.

Modélisation de l'étude et définition des variables

Pour répondre à cette problématique, nous avons décidé de concentrer notre analyse uniquement sur les accidents survenus durant l'année 2023, soit un total de 54 822 accidents. Cette décision s'explique par plusieurs raisons. Tout d'abord, pour des raisons pratiques de disponibilité des données, car les données plus récentes ne sont pas toujours disponibles. Ensuite, pour des raisons de pertinence, en effet, entre 2020 et 2022, notamment à cause des confinements de la population liés à la COVID-19, le trafic routier était anormal, ce qui en fait des années spéciales, qui auraient pu compliquer ou biaiser nos résultats. Nous aurions pu également choisir des données plus anciennes mais il nous a paru plus pertinent d'étudier des données plus récentes.

A)Présentation des variables

1. Variable d'intérêt : le taux de mortalité par accident⁴

En 2023, en France, les accidents de la route représentaient 0,5% de l'ensemble des décès⁵. Bien que cette proportion puisse paraître faible au premier abord, c'est en réalité une part non négligeable de la mortalité nationale, qui représente 3 398 décès. Nous avons donc voulu déterminer quels étaient les différents facteurs qui pouvaient impacter cette proportion, et plus particulièrement analyser les différences observées entre départements. Autrement dit, notre objectif est de comprendre pourquoi certains départements ont un taux de mortalité lié aux accidents de la route plus élevé que d'autres ?

Durant nos recherches, nous n'avons pas réussi à trouver de base de données permettant d'obtenir directement les différents taux de mortalité liés à la sécurité routière par département. Cependant, nous avons réussi à récupérer sur le site data.gouv.fr plusieurs bases de données recensant l'ensemble des accidents corporels de la circulation routière survenus entre 2005 et 2023. Plus précisément, les accidents recensés impliquent au moins une victime, un véhicule, et sont survenus sur une voie ouverte à la circulation publique. L'ensemble de ces données, en particulier les données relatives à la gravité des blessures et à la localisation de l'accident, nous

⁴ Au long de cette étude, il est possible que nous fassions référence à cette variable en la nommant différemment « taux d'accidents mortels », « mortalité routière »

⁵ cf [bilans annuels - ONISR](#) & INSEE, *Bilan démographique de 2023*

ont alors permis de construire notre propre base de données et donc notre variable d'intérêt « *taux_mortalité* ».

D'autre part, nous avons fait le choix d'exclure de notre analyse l'ensemble des accidents impliquant des piétons. En effet, ce type d'accidents survient majoritairement là où la présence de piétons est importante : en ville, dans les villages, les lotissements, à proximité des habitations ou des commerces. Il est rare d'observer un accident impliquant un piéton sur l'autoroute ou les grands axes routiers. Ces accidents se concentrent donc essentiellement dans des zones où la vitesse des véhicules est modérée et réglementée. Plusieurs situations peuvent expliquer ces accidents. Dans un premier cas, un piéton traverse la chaussée de manière totalement imprévisible et est percuté par un véhicule. L'origine de l'accident relève alors principalement du comportement individuel dangereux du piéton, ou d'un malheureux hasard. Dans un deuxième cas, c'est le conducteur qui perd le contrôle de son véhicule et heurte un piéton. L'accident peut alors être lié à un comportement dangereux du conducteur ou à des facteurs propres au territoire, comme les infrastructures ou encore l'état des routes, bien qu'en théorie, ces cas soient moins fréquents, puisque la circulation en présence de piétons se fait généralement à vitesse réduite. La première situation ne dépend en aucun cas des caractéristiques du département, tandis que la seconde peut y être liée de manière limitée. Nous avons donc estimé que les accidents impliquant des piétons étaient globalement moins sensibles aux caractéristiques du département. Il paraît ainsi pertinent d'exclure ces accidents de notre analyse.

Néanmoins, il est important de noter que même parmi les accidents n'incluant pas de piétons, certains ne sont pas causés ou influencés par des caractéristiques propres au département. Nous reviendrons toutefois sur ces limites et les discussions qu'elles soulèvent ultérieurement.

Parmi les bases récupérées, nous nous sommes d'abord intéressés à la base qui concerne les usagers. Dans cette dernière, on retrouve pour chaque usager impliqué dans un accident, l'identifiant de l'accident, de l'usager, du véhicule, mais aussi la place occupée dans le véhicule par l'usager au moment de l'accident, la catégorie de l'usager (conducteur, passager ou piéton), la gravité de ses blessures, son sexe, son année de naissance, le motif de déplacement au moment de l'accident, l'utilisation et la présence ou non de l'équipement de sécurité. Pour les piétons, la base précise également leur action, leur localisation et s'ils étaient accompagnés. A partir de cette base, et à l'aide du logiciel R Studio, nous avons pu récupérer l'ensemble des accidents n'incluant pas les piétons, et parmi eux, l'ensemble des accidents mortels. Un accident

est considéré comme mortel si au moins un usager impliqué dans l'accident est décédé des faits de l'accident, sur le coup ou dans les trente jours qui suivent. Ensuite, nous nous sommes intéressés à la base qui concerne les caractéristiques de l'accident. Elle décrit les circonstances générales de l'accident, on y retrouve les différentes informations relatives à la date, au type de collision, aux conditions atmosphériques et à la localisation de l'accident. Grâce à celle-ci, nous avons pu associer chaque numéro d'identification, et donc chaque accident, au département dans lequel il a eu lieu.

Par la suite, ces informations nous ont permis d'agréger l'ensemble des accidents par département en créant deux variables : le nombre d'accidents mortels survenus dans chaque département en 2023, et le nombre total d'accidents enregistrés dans celui-ci la même année. Enfin, nous avons pu calculer le taux de mortalité des accidents par département en divisant le nombre d'accidents mortels par le nombre total d'accidents survenus dans ce département en 2023. C'est ainsi que nous avons obtenu notre variable d'intérêt : « *taux_mortalité* ».

Pour finir, nous avons pris la décision de ne pas inclure dans notre analyse les départements d'outre-mer. En effet, pour un certain nombre de variables explicatives, il s'est avéré difficile de trouver des données fiables ou mesurées de la même manière que celles des territoires de France métropolitaine. Ainsi, pour l'ensemble des variables de notre analyse, que ce soit pour la variable d'intérêt ou les variables explicatives, chaque observation correspond à un département de France métropolitaine.

2. Variables explicatives

Nous avons cherché à identifier les différents facteurs susceptibles d'influencer le taux de mortalité des accidents de la route dans chaque département français.

- **Cumul de pluie**

La pluie est un facteur météorologique qui influence directement les conditions de conduite, le comportement des conducteurs et, par conséquent, la sécurité routière. En effet, lorsqu'il pleut, l'adhérence des pneus sur la chaussée diminue, ce qui la rend plus glissante. Les usagers peuvent alors perdre plus facilement le contrôle de leur véhicule. La distance de freinage s'allonge, tandis que les virages, les freinages brusques ainsi que les manœuvres précipitées deviennent alors beaucoup plus risqués. Par ailleurs, la pluie réduit considérablement la

visibilité des conducteurs, notamment la nuit, avec le reflet des phares sur la chaussée humide. Le champ de vision est également restreint et les autres usagers deviennent moins visibles. Avec la pluie, il est d'autant plus difficile pour les conducteurs d'évaluer correctement la vitesse et les distances, entraînant souvent une mauvaise perception de ces éléments essentiels à la conduite.

L'ensemble de ces conditions défavorables augmente les risques de sorties de route et de collisions, souvent plus violentes que par temps sec. C'est pourquoi nous avons considéré que la quantité de pluie tombée dans chaque département serait susceptible d'avoir un réel impact sur le taux de mortalité liés aux accidents de la route. Une pluviométrie importante pourrait ainsi avoir un effet positif, et donc augmenter le taux de mortalité routière.

Nous avons alors recherché des données sur la pluviométrie, c'est-à-dire la mesure de la quantité de pluie tombée, de chaque département français au cours de l'année 2023. En général, les précipitations sont mesurées en volume d'eau tombé au sol rapporté à une unité de surface : le litre par mètre carré. Autrement dit, 1 millimètre de pluie représente 1 litre d'eau par mètre carré, en supposant une répartition homogène des [précipitations](#) sur cette surface.

Nous avons pu récupérer sur le site infoclimat.fr, le cumul de pluie, exprimé en millimètre, entre le 1er janvier et le 31 décembre 2023 pour l'entièreté des départements de France métropolitaine. Ces données ont été rassemblées manuellement, afin de constituer une base regroupant l'ensemble de ces valeurs, que nous avons pu utiliser par la suite dans notre modèle à travers la variable « *pluie* ».

- **Parts d'âges**

Selon l'Observatoire national interministériel de la Sécurité routière, l'ONISR⁶, les accidents de la route sont la 1ère cause de mortalité chez les 18-25 ans. Les conducteurs novices, c'est-à-dire qui ont obtenu leur permis il y a moins de deux ans, sont impliqués dans 24% des accidents mortels. Ils ont 4 fois plus de risque d'être impliqués dans un accident mortel que le reste de la population. En effet, on observe un risque élevé chez les conducteurs novices : le manque d'expérience se révèle être un facteur de risque car le nombre de conducteurs novices impliqués dans les accidents mortels est d'autant plus élevé que la durée de détention du permis est faible. Cependant, l'expérience n'est pas le seul facteur de risque observé chez les 15-25

⁶ Conseils aux conducteurs – [Sécurité routière](#)

ans, la jeunesse l'est aussi. On peut supposer que les jeunes sont moins averses aux risques, et ont donc des comportements plus dangereux sur la route.

L'alcool, la vitesse, les stupéfiants, la fatigue et le téléphone au volant sont les principales causes d'accidents de la route chez les jeunes. 39% des jeunes reconnaissent qu'ils leur arrivent de dépasser les limitations de vitesse contre 27% pour l'ensemble la population. Or la vitesse est un facteur qui a un impact non négligeable sur la gravité des accidents de la route. Elle réduit le champ de vision, augmente les risques de perte de contrôle du véhicule et surtout augmente la violence de l'impact en cas de collision. Les jeunes ont aussi plus tendance à prendre le volant après avoir consommé de l'alcool ou des stupéfiants. 1 jeune sur 5 reconnaît avoir déjà pris le volant au-dessus du seuil d'alcoolémie ou après avoir fumé du cannabis. Une consommation d'alcool ou de stupéfiants diminue de manière importante l'attention et la concentration. Le temps de réaction diminue, il devient plus difficile d'évaluer la vitesse, les distances et les situations dangereuses. Elle peut aussi rendre difficile le maintien de la trajectoire et entraîner une surconfiance (conduite plus rapide, dépassements dangereux, moins de respect des règles...), ce qui rend la conduite dangereuse. De plus, 38% des 18-25 ans reconnaissent envoyer des SMS en conduisant. L'utilisation du téléphone au volant est un autre comportement très dangereux sur la route. Le risque d'accident est multiplié par 3 lors d'une conversation téléphonique et par 23 si l'on écrit un SMS au volant. Lorsqu'on utilise un téléphone, notre attention est obligatoirement déviée, nos yeux quittent la route, ce qui diminue notre vigilance, notre capacité à anticiper des situations dangereuses et peut entraîner une perte de contrôle du véhicule.

L'ensemble de ces statistiques soulignent parfaitement la pertinence et l'importance d'intégrer dans notre modèle une variable qui retranscrit la proportion de jeunes dans un département. Cependant, les jeunes ne sont pas la seule tranche d'âge sensible. En effet deux autres tranches d'âge nous ont particulièrement intéressé : les enfants et les seniors.

Les enfants, dû à leur jeune âge, sont une population fragile. Ce sont des individus particulièrement vulnérables au risque routier. Leur corps est encore en développement, ce qui rend les conséquences d'un choc plus graves que chez un adulte.

Les seniors sont une population particulièrement touchée par les accidents de la route. En 2023, 887 personnes âgées de 65 ans ou plus ont été tuées sur la route en France métropolitaine. Cela représente 28% des personnes tuées sur la route, alors qu'ils ne représentent que 21% de la population totale. L'âge peut en effet avoir un impact sur la conduite.

Les capacités visuelles, auditives ou motrices peuvent être réduites, ce qui peut diminuer la réactivité face à une situation dangereuse et avoir de lourdes conséquences.

Ainsi, un département avec une population jeune, qui adopte des comportements à risque, ou une population sensible comme les enfants et les seniors, pourrait connaître davantage d'accidents graves. La part que représente chaque classe d'âge dans un département est donc pertinente à intégrer dans notre analyse et serait donc susceptible d'avoir un impact sur le taux de mortalité routière dans ce département.

A partir de la base « Estimation de population par département, sexe et âge quinquennal - Années 1975 à 2023 » que nous avons obtenu sur le site de l'INSEE, l'Institut national de la statistique et des études économiques, nous avons pu récupérer une estimation du nombre de personnes dans chaque département par tranches d'âges de 5 ans. Nous avons ensuite agrégé ces données afin de créer 5 classes d'âge intéressantes pour notre analyse tout en conservant une étendue assez similaire entre les classes. Nous avons décidé de créer les classes suivantes : 0 à 14 ans, qui représentent le nombre d'enfants, 15 à 24 ans, qui représente le nombre de jeunes, 25 à 44 ans, 45 à 64 ans et 65 ans et plus, qui représente le nombre de seniors. Pour mener à bien notre analyse, et ne pas faire d'erreur d'interprétation, nous ne pouvions pas conserver ces variables telles quelles. En effet, on aurait alors un effet de taille : il serait évident qu'un petit département, comme le Territoire de Belfort par exemple, ait une population plus réduite, ce qui ne signifie pas que la part de jeunes ou de personnes âgées est nécessairement plus faible dans ce département que dans un autre. C'est pourquoi nous avons décidé de calculer des proportions de classes d'âge. Nous avons divisé chaque estimation de la population d'un département par classe d'âge par le nombre total de population estimée dans ce département. Ces calculs nous ont permis d'obtenir nos variables « part_0_14 », « part_15_24 », « part_25_44 », « part_45_64 » et « part_65_plus ».

- **Type de route**

En 2023, 59% des personnes tuées sur la route ont été tuées sur des routes hors agglomérations, 32% en agglomération et 9% sur l'autoroute. Nous nous sommes demandé si le type de route sur lequel a eu lieu un accident pouvait avoir une influence sur la gravité de cet accident, et donc si les différents types de routes dont est composé le département a un impact sur le taux de mortalité routière. En effet, on pourrait imaginer qu'un accident ayant lieu sur une autoroute aurait une gravité plus importante qu'un accident ayant lieu en ville en raison de

la vitesse de la circulation qui est beaucoup plus élevée. Néanmoins, il existe plus de croisements dangereux en agglomération que sur autoroute où il ne s'agit que de dépassements et d'insertions. Il serait donc intéressant d'inclure dans notre analyse des variables qui résument si un département est composé de plus d'autoroutes, de routes nationales ou encore départementales qu'un autre. On sait qu'une différence pourrait être observée puisque dans certains départements comme le Finistère ou le Morbihan par exemple, il n'y a aucune autoroute.

Sur le site de l'INSEE, nous avons pu obtenir des informations concernant la composition du réseau routier français en 2023. La base de données récupérée nous indique le nombre de kilomètres d'autoroutes, de routes nationales et de routes départementales et communales dans chaque département. Comme pour les classes d'âge, pour éviter un effet de taille liée à la superficie du département, nous avons dû transformer nos variables. Nous avons décidé de diviser les kilomètres de routes par la superficie du département en kilomètres carrés (km²), afin d'obtenir nos variables « Auto_dens », « Nat_dens » et « Dep_dens ». Par exemple, si Dep_dens = 3, cela signifie qu'il y a 3 kilomètres de routes départementales et communales par kilomètres carrés dans ce département.

- **Parc automobile**

Le parc automobile désigne l'ensemble des véhicules immatriculés et en circulation dans un pays ou un territoire à une date donnée. Au 1er janvier 2023, le parc automobile français était composé de 38.9 millions de voitures particulières, de 6.4 millions de véhicules utilitaires légers, 620 000 poids lourds et 94 000 autobus et autocars en circulation. Les autobus et autocars représentent une seule catégorie de véhicules : les transports en commun collectif de personnes (TCP). Nous avons supposé qu'il serait intéressant d'inclure dans notre modèle des variables qui représentaient le parc automobile de chaque département. En effet, certaines questions quant à la composition de ce parc peuvent se poser. Par exemple, une proportion accrue de poids lourds pourrait-elle avoir un impact positif sur le taux de mortalité des accidents de la route dans ce département ?

Nous avons pu récupérer le nombre de véhicules immatriculés et en circulation dans chaque département sur le site statistiques.developpement-durable.gouv.fr. Afin d'éviter un biais lié à la taille du département, nous avons dû transformer les données récupérées, comme nous l'avons fait pour les variables Classes d'âges et Type de routes. Nous avons donc divisé

le nombre de voitures particulières, de véhicules utilitaires légers, de poids lourds, et de TCP par la superficie du département. Nous avons alors obtenu nos variables « *taux_voiture* », « *taux_utilitaire* », « *taux_camion* » et « *taux_transport* » qui représentent le nombre de voitures particulières, de véhicules utilitaires légers, de poids lourds, et de TCP par kilomètres carrés dans chaque département de France métropolitaine.

- **Heure d'ensoleillement**

L'ensoleillement, autrement dit la luminosité, est une variable qui a un impact direct sur les conditions de conduite. Sur la route, la nuit tue plus que le jour. En effet, le risque d'avoir un accident mortel à la tombée de la nuit est sept fois supérieur au risque en journée. Lorsqu'il fait sombre ou même totalement nuit, la visibilité du conducteur se retrouve réduite. Il est plus difficile d'anticiper, de voir un obstacle ou un danger arriver. On peut alors supposer qu'un nombre d'heures d'ensoleillement plus élevé dans un département pourrait avoir un effet négatif sur le taux de mortalité des accidents de la route dans ce département : plus il fait jour, moins le taux de mortalité serait élevé.

Afin d'obtenir des données sur le temps d'ensoleillement par département en France, et de créer notre variable « *heure_soleil* », nous nous sommes appuyés sur un article de *L'internaute* recensant le nombre d'heures d'ensoleillement par département. Cet article utilise les estimations issues des bulletins climatiques libres d'accès de Météo France, dont les valeurs sont mesurées par plus d'une centaine de stations météo réparties en France métropolitaine.

- **Différence d'altitude**

La France est un pays qui présente une grande diversité de reliefs et de paysages : littoraux, forêts, plaines ou encore massifs montagneux. Il existe donc des différences topographiques, c'est-à-dire relative à la représentation de la forme et du relief d'un terrain sur un plan, entre chaque département. Certains territoires sont assez plats tandis que d'autres ont un fort dénivelé. Dans ces départements, les routes sont souvent plus pentues et plus sinueuses. En montagne, certains croisements peuvent être difficiles, voire dangereux, en raison du manque de visibilité liés aux nombreux virages. On peut alors supposer qu'un département caractérisé par une forte variation d'altitude pourrait avoir un taux de mortalité routière plus élevé.

Afin de créer une variable qui pourrait rendre compte des différences de dénivelé entre les départements, nous avons recueilli des données sur les points d'altitudes les plus hauts et les plus bas de chacun d'entre eux. Nous avons ensuite calculé l'écart entre ces deux valeurs pour obtenir notre variable "diff_alt", qui correspond à la différence d'altitude de chaque département.

- **Nombre de lits à l'hôpital**

La mortalité d'un accident ne dépend pas uniquement de l'impact ou des quelques minutes qui suivent le choc. En effet, comme dit précédemment, un accident est considéré comme mortel si au moins un usager impliqué dans l'accident est décédé des faits de l'accident, sur le coup ou dans les trente jours qui suivent. Les heures et jours qui suivent un accident sont donc déterminantes. L'état d'un blessé grave peut dépendre de la rapidité de sa prise en charge par les secours, puis lors de son arrivée à l'hôpital. L'hôpital est un lieu qui malheureusement, est souvent très convoité... Le nombre de lits disponibles et en état d'accueillir des patients est souvent limité. Plus le service est surchargé, moins de lits sont disponibles et plus la prise en charge de nouveaux patients peut être longue. Lors d'un accident de la route, si un individu est gravement blessé, chaque heure qui passe peut être déterminante. On peut alors supposer que plus le nombre de lits disponibles à l'hôpital est élevé, plus le taux de mortalité routière est faible. Le nombre de lits disponibles aurait un effet négatif sur notre variable d'intérêt.

Grâce à la Direction de la recherche, des études, de l'évaluation et des statistiques (DREES), et à leurs travaux sur la statistique publique de la santé et de la solidarité, nous avons pu récupérer des données sur les établissements de santé français en 2023. Nous avons trouvé une base rendant compte des capacités d'accueil des hôpitaux, et en particulier de la densité de lits d'hospitalisation complète par département en 2023. Nous l'avons alors utilisé afin de créer notre variable « Nb_lit », qui correspond au nombre de lits d'hospitalisation pour 100 000 habitants du département. Ici, le problème de l'effet de taille est également évité car le nombre de lits est rapporté à la même unité pour tous les départements.

- **Part d'hommes**

En 2023, 78% des individus tués sur les routes étaient des hommes. Cette statistique illustre une différence très importante entre la mortalité routière des hommes et des femmes. Les hommes auraient tendance à adopter plus de comportements à risque que les femmes. De plus, la part d'hommes est sur-représentée dans les métiers routiers (transporteurs, taxis...), qui, par définition, sont plus exposés au risque d'accident. Il paraît donc pertinent de supposer que la part d'homme dans un département aurait un effet positif sur le taux de mortalité routière : plus la part d'hommes dans un département est grande, plus le taux de mortalité routière est élevé.

Grâce à l'INSEE, nous avons pu obtenir une estimation du nombre d'hommes et de femmes dans chaque département français au 1er janvier 2023. Il nous a alors suffi de diviser le nombre d'hommes par la population totale du département afin d'obtenir une part et donc de supprimer un potentiel biais lié à l'effet de taille. C'est ainsi que nous avons construit notre variable « part_homme ».

- **Part forêts**

En France, la superficie totale des forêts représente 17 600 000 hectares, soit 32% du territoire français. Les forêts étant des lieux où la biodiversité est développée, il n'est pas rare d'apercevoir des animaux, et notamment à la tombée du jour ou durant la nuit. Les animaux sauvages sont les responsables de nombreux accidents de la route. A l'approche de l'hiver, le risque de rencontrer des animaux sur la route augmente. La rencontre avec certains animaux comme les sangliers ou les cerfs peut s'avérer très dangereuse, et peut provoquer des accidents assez graves. Nous avons donc supposé qu'inclure une variable qui rend compte de la part de forêt dans chaque département serait pertinente. Un département avec une surface de forêt importante pourrait avoir un taux de mortalité routière plus importante.


Nous avons pu obtenir sur le site de l'Observatoire des forêts françaises la superficie forestière de chaque département. Afin de neutraliser l'effet de taille liée à la superficie des départements, nous avons décidé de transformer les données récupérées, comme pour un certain nombre de nos variables précédentes. Nous avons divisé la superficie forestière de chaque département par sa superficie totale afin d'obtenir notre variable « pct_foret », qui correspond alors à la part du territoire qui est couvert par la forêt.

B) Modélisation de l'étude

En somme, notre analyse économétrique se portera sur un ensemble de 19 variables, composé d'une variable d'intérêt, le taux de mortalité des accidents de la route, et de 18 variables explicatives. L'ensemble de ces variables sont des variables quantitatives. Nous n'avons aucune variable qualitative.

Afin d'avoir une vue d'ensemble des variables du modèle, le schéma et le tableau ci-dessous résument l'ensemble des variables prises en considération dans notre analyse.

Figure 1 : Schéma présentant le modèle



Source : Auteurs

Tableau 1 : Récapitulatif de l'ensemble des variables

Variable	Nom correspondant sur R	Effet attendu sur la variable d'intérêt
Taux de mortalité routière	« taux_mortalité »	/
Cumul de pluie sur l'année 2023	« Pluie »	Positif
Part des 0-14 ans	« part_0_14 »	Positif
Part des 15-24 ans	« part_15_24 »	Positif
Part des 25-44 ans	« part_25_44 »	Aucun effet particulier attendu
Part des 45-64 ans	« part_45_64 »	Aucun effet particulier attendu
Part des 65 ans et plus	« part_65_plus »	Positif
Nombre de kilomètres d'autoroutes par km ²	« Auto_dens »	Positif
Nombre de kilomètres de routes nationales par km ²	« Nat_dens »	Aucun effet particulier attendu
Nombre de kilomètres de routes départementales et communales par km ²	« Dep_dens »	Aucun effet particulier attendu
Nombre de voitures particulières par km ²	« taux_voiture »	Aucun effet particulier attendu

Nombre de véhicules utilitaires légers par km2	« taux_utilitaire »	Aucun effet particulier attendu
Nombre de poids lourds par km2	« taux_camion »	Positif
Nombre de transports en commun collectif de personnes par km2	« taux_transport »	Aucun effet particulier attendu
Nombre d'heures d'ensoleillement	« heure_soleil »	Négatif
Différence de dénivelé	« diff_alt »	Positif
Nombre de lits disponibles dans les hôpitaux	« Nb_lit »	Négatif
Part d'hommes	« part_homme »	Positif
Part de forêt	« pct_foret »	Positif

Sources : Auteurs

Analyse descriptive

A) Analyse descriptive univariée

1. Statistiques descriptives

Avant d'interpréter les résultats du modèle économétrique, il est essentiel d'examiner les principales caractéristiques statistiques des variables utilisées. Le tableau ci-dessous présente pour chacune d'elles la moyenne, la médiane, les valeurs extrêmes et l'écart-type, permettant ainsi de décrire leur distribution et la variabilité entre départements.

Tableau statistique 1 :

Variable	Moyenne	Médiane	Minimum	Maximum	Ecart_type
Taux_mortalite	0,1	0,09	0,004	0,33	0,06
Nat_dens	0,02	0,02	0	0,11	0,02
Auto_dens	0,03	0,02	0	0,25	0,04
Dep_dens	2,54	2,04	0,383	30,83	3,31
Pluie	926,88	857,05	403,2	1685,8	243
Part_homme	48,57	48,62	46,931	50,05	0,53
Diff_alt	1012,93	511	102	4558	1054,06
Heure_soleil	2068,06	1997	1657	3010	302,55
Nb_lit	565,57	560,5	351	971	111,7
Pct_foret	0,34	0,31	0,003	1	0,19
Taux_voiture	219,47	54,43	10,017	5360,27	741,85
Taux_camion	3	0,93	0,213	71,58	9,58
Taux_transport	1,4	0,1	0,019	84,02	9,13
Taux_utilitaire	33,21	9,37	2,465	781,58	108,75
Part_0_14	0,16	0,16	0,128	0,22	0,02
Part_15_24	0,11	0,11	0,085	0,14	0,01
Part_25_44	0,22	0,22	0,179	0,32	0,03
Part_45_64	0,26	0,26	0,231	0,28	0,01
Part_65_plus	0,24	0,24	0,128	0,32	0,04

Source : Auteurs

L'analyse du tableau statistique fait apparaître un premier groupe de variables dont la distribution est fortement asymétrique : les moyennes sont nettement supérieures aux médianes, les valeurs maximales très élevées et les écarts-types importants. Ces écarts-types importants confirment que la dispersion autour de la moyenne est très forte, ce qui traduit une hétérogénéité marquée entre les départements. Ce profil témoigne de la présence de quelques territoires atypiques dont les valeurs extrêmes étirent la distribution vers le haut.

C'est notamment le cas des variables liées aux réseaux routiers. Par exemple, pour « *Dep_dens* », la médiane est très faible alors que certaines valeurs sont bien plus élevées. L'écart-type important confirme cette forte dispersion : la majorité des départements disposent d'un réseau départemental assez limité, tandis que quelques territoires, souvent plus urbanisés, présentent des niveaux de densité beaucoup plus importants. On retrouve une tendance similaire pour « *Nat_dens* » et « *Auto_dens* », même si leur dispersion est légèrement moins marquée, ce qui traduit une hétérogénéité toujours présente mais un peu plus modérée.

La variable « *diff_alt* » présente également une asymétrie marquée. Alors que la médiane reste relativement modérée, la valeur maximale dépasse 4500 mètres, ce qui indique un écart important entre les différents départements. L'écart-type, extrêmement élevé, confirme cette forte dispersion et indique qu'un petit nombre de départements de montagne influence la distribution. Cette configuration met en évidence une topographie très contrastée entre régions de plaine et territoires situés en altitude, tels que les massifs alpins ou pyrénéens.

Les variables liées au trafic, comme « *taux_voiture* », « *taux_camion* », « *taux_transport* » ou « *taux_utilitaire* », présentent-elles aussi une forte asymétrie. Les valeurs maximales sont très éloignées des valeurs centrales et les écarts-types élevés confirment que certains départements concentrent des volumes de circulation nettement supérieurs à la moyenne. Ce profil correspond souvent à des zones avec des infrastructures logistiques importantes ou situées sur des axes de transit majeurs.

À côté de ces variables fortement asymétriques, certaines variables présentent une asymétrie plus modérée. C'est le cas de la pluviométrie : la moyenne est un peu plus élevée que la médiane, ce qui suggère que quelques départements très pluvieux tirent la distribution vers le haut, mais sans créer de forts déséquilibres. L'écart-type, relativement faible, confirme que la majorité des départements se situent dans une zone climatique assez similaire. Le nombre de lits hospitaliers et les heures d'ensoleillement suivent le même principe : leur distribution est légèrement décalée, mais elles ne présentent pas de valeurs extrêmes. Ces variables traduisent donc des différences régionales réelles, mais qui restent modérées.

Enfin, plusieurs variables se caractérisent par une distribution quasi symétrique et faiblement dispersée. Le taux de mortalité en fait partie : la moyenne et la médiane sont proches et l'écart-type faible indique une répartition relativement homogène entre les départements. Les variables démographiques adoptent le même profil : la part d'hommes et la part des différentes tranches d'âge sont distribuées de manière resserrée autour de leurs valeurs centrales, sans


asymétrie notable. La faible dispersion indique que les structures de population varient peu d'un département à l'autre.







Dans l'ensemble, la lecture du tableau statistique nous indique que la base de données est structurée autour de trois dynamiques principales : des variables fortement asymétriques liées notamment aux infrastructures, au trafic ou à la topographie, qui reflètent l'existence de départements aux caractéristiques particulières; des variables modérément asymétriques, qui traduisent des contrastes régionaux marqués mais sans valeurs extrêmes ; et des variables symétriques et homogènes qui décrivent des caractéristiques largement partagées par l'ensemble du territoire.


2. Visualisation des distributions

Afin de compléter l'analyse descriptive présentée précédemment, nous avons eu recours à différents outils de visualisation graphique. Ceux-ci permettent de mieux appréhender la distribution des variables quantitatives de notre jeu de données et d'illustrer certains éléments déjà mis en évidence dans le tableau statistique.

Dans un premier temps, nous avons représenté les distributions d'histogrammes.








Source : Auteurs


Les histogrammes confirment visuellement les contrastes déjà suggérés par les statistiques descriptives. Certaines variables présentent une distribution très resserrée autour d'une valeur centrale, tandis que d'autres s'étendent sur un intervalle beaucoup plus large. Ce premier aperçu graphique permet ainsi d'identifier rapidement les caractéristiques du territoire où les départements se ressemblent, et celles où ils diffèrent fortement.

Dans un second temps, nous avons utilisé des boîtes à moustaches, autrement appelés boxplots, afin d'obtenir une représentation plus synthétique de la dispersion des données et de repérer clairement les valeurs extrêmes. Contrairement aux histogrammes, qui décrivent l'ensemble de la distribution, les boxplots mettent en avant la médiane, l'écart interquartile et les observations atypiques. Ils offrent ainsi une lecture complémentaire et cohérente avec les tendances déjà mises en évidence dans le premier tableau statistique.




Différence d'altitude

Distribution de l'altitude




Distribution de l'ensoleillement




Lits hospitaliers

Distribution du nombre de lits




Distribution du % de forêt




Pluviométrie

Distribution de la pluie




Distribution de la part d'hommes




Taux voitures

Distribution du taux de voitures




Taux camions

Distribution du taux de camions




Taux transport

Distribution des véhicules de transport





Taux utilitaires

Distribution des utilitaires



Part 65+ ans





Source : Auteurs

Les boxplots mettent d'abord en évidence un ensemble de variables présentant de nombreux outliers⁷. C'est particulièrement visible pour les variables liées aux infrastructures routières et au trafic : malgré une médiane faible, de nombreux points extrêmes apparaissent au-delà des moustaches. Cette configuration traduit une distribution étirée, où la majorité des départements se concentrent dans la partie basse de l'échelle tandis qu'une minorité affiche des valeurs très élevées.

Un schéma similaire apparaît pour certaines variables environnementales telles que la pluviométrie ou la différence d'altitude : les boîtes sont plus larges et la fréquence des outliers confirme une hétérogénéité entre les départements, souvent liée à des disparités géographiques marquées.

À l'inverse, un second groupe de variables se caractérise par l'absence quasi totale d'outliers et par une dispersion limitée. C'est le cas des variables démographiques par exemple, le boxplot est resserré, la médiane est centrale et les moustaches restent courtes, ce qui confirme une variabilité faible à l'échelle nationale.

⁷ Valeurs aberrantes

3. Traitement des atypiques

Les différents boxplots ont mis en évidence plusieurs observations susceptibles de constituer des valeurs atypiques. Afin de déterminer si ces valeurs reflétaient de véritables anomalies ou simplement des situations particulières mais cohérentes avec la diversité des départements, nous avons appliqué des tests statistiques adaptés : le test de Rosner ou ESD lorsque plusieurs observations semblaient potentiellement atypiques, et le test de Grubbs lorsqu'un seul point était isolé.

Le tableau ci-dessous synthétise les résultats des tests de détection des valeurs extrêmes en distinguant les valeurs suspectes repérées visuellement et celles effectivement confirmées par les tests statistiques. ([Annexe 2](#))

Variables	Test utilisé	Nombre d'observations suspectes (visuel)	Nombre d'outliers confirmés	Départements concernés
Taux de mortalité	Rosner	5	2	91, 22
Nat_dens	Rosner	3	2	95, 93
Auto_dens	Rosner	3	3	93, 94, 95
Dep_dens	Rosner	5	4	93, 94, 95, 76
Diff_alt	Rosner	7	0	—
Part_homme	Rosner	3	0	—
Pluie	Grubbs	1	0 (p-value = 0,13)	—
heure_soleil	ESD	11	0	—
Nb_lit	Rosner	4	1	5
pct_foret	Grubbs	1	1 (p-value = 0.04)	93
Taux_voiture	ESD	>10	10	76 93 94 95 96 49 22 4 15 5
Taux_camion	ESD	>10	7	94 76 93 95 96 22 56
Taux_transport	ESD	>10	10	76 93 56 4 53 3 18 37 90 22
Taux_utilitaire	ESD	>10	10	76 93 94 95 49 22 53 56 4 59
part_0_14	Rosner	2	0	—
part_15_24	—	0	—	—
part_25_44	Grubbs	1	1 (p-value = 0.009)	76
part_45_64	—	0	—	—
part_65_plus	—	0	—	—

Ce tableau montre que les valeurs atypiques se concentrent principalement dans quelques départements, en particulier les départements 93, 94 et 95, qui reviennent dans la majorité des tests. Situés en Île-de-France, ces territoires se distinguent par une forte urbanisation et des niveaux d'équipement, de trafic et de densité particulièrement élevés par rapport à ceux du reste du pays. D'autres départements tels que le 91, le 92 ou encore le 5, apparaissent plus ponctuellement, de manière beaucoup moins systématique.


La présence répétée de ces départements parmi les outliers ne traduit donc pas une erreur de mesure : elle reflète simplement des situations locales très spécifiques, déjà observées dans l'analyse descriptive. Pour cette raison, même lorsque certaines valeurs sont confirmées comme atypiques, nous avons choisi de les conserver. Elles apportent une information réelle sur les contrastes territoriaux et restent importantes pour comprendre les différences de mortalité routière entre départements. La suppression de l'une de ces valeurs atypiques aurait entraîné une trop grande perte d'information et ainsi aurait réduit la puissance statistique de notre futur modèle.




B) Analyse descriptives bivariée (quantitative – quantitative)


1. Nuage de points

Après avoir décrit individuellement chaque variable, nous examinons maintenant les relations bivariées entre le taux de mortalité et certaines variables explicatives. Cette étape permet d'identifier d'éventuelles associations linéaires, de repérer une dispersion marquée ou au contraire resserrée, et d'évaluer visuellement la pertinence de certaines variables avant la modélisation.

Nous avons ainsi réalisé des nuages de points pour les variables quantitatives jugées les plus informatives lors de l'analyse descriptive : l'intensité des réseaux routiers (national, autoroutier et départemental), la pluviométrie et la différence d'altitude.







Les trois variables décrivant l'intensité du réseau routier montrent une relation globalement décroissante : lorsque les infrastructures sont plus développées, le taux de mortalité a tendance à être légèrement plus faible. La pente reste faible, mais les graphiques suggèrent tout de même qu'un réseau routier plus dense pourrait être associé à de meilleures conditions de circulation. Cette interprétation visuelle doit toutefois être nuancée. Les nuages de points montrent en effet une forte concentration des départements autour de faibles niveaux d'intensité, tandis que seuls quelques départements très équipés se situent sur les valeurs les plus élevées. La présence de ces observations plus isolées, déjà identifiées comme outliers dans l'analyse des valeurs extrêmes, contribue à étirer la droite de régression vers le bas, sans pour autant refléter une relation uniforme. Certains départements affichent par exemple un réseau autoroutier ou départemental dense tout en conservant un niveau de mortalité relativement élevé, ce qui souligne que l'effet des infrastructures n'est ni automatique ni homogène.

La pluviométrie présente quant à elle une relation légèrement croissante. Les départements recevant davantage de pluie semblent afficher un taux de mortalité légèrement plus élevé, ce qui est cohérent avec l'idée que des conditions de circulation dégradées peuvent augmenter le risque d'accidents mortels. Toutefois, les graphiques montrent également une dispersion particulièrement importante, que l'on retrouve sur tout l'axe de la pluviométrie : certains départements très pluvieux présentent des mortalités faibles, et inversement.

Enfin, la différence d'altitude ne révèle aucune relation apparente avec le taux de mortalité. Le nuage de points est très dispersé, sans orientation identifiable, et la droite de régression est quasiment horizontale. Les départements présentant de fortes amplitudes altitudinales, souvent situés dans des zones montagneuses, ne se distinguent pas des autres en

termes de mortalité. Cette absence de lien visuel montre que la topographie, prise globalement, ne semble pas influencer directement, ou très peu, la mortalité routière à l'échelle départementale.

2. Matrice de corrélation

La matrice de corrélation permet de mettre en évidence les relations entre les différentes variables explicatives. L'objectif de l'étude des corrélations est d'identifier les associations fortes afin d'éviter d'intégrer simultanément des variables trop corrélées entre elles dans un même modèle, ce qui pourrait entraîner des problèmes de multicollinéarité et fausser l'interprétation des résultats.


Cependant, il existe plusieurs méthodes pour étudier la corrélation entre nos différentes variables. La plus connue est la méthode du coefficient de corrélation de Pearson qui étudie la relation linéaire entre deux variables. Pour que ce coefficient puisse être correctement interprété, il est nécessaire que les variables suivent une loi normale.

Nous avons effectué un test de Shapiro-Wilk pour vérifier la normalité de nos variables (voir [annexe 1](#)). A l'exception de 3 variables: la part d'homme, la part des 0-14 ans et la part de 65 ans et plus, toutes les autres ne suivent pas une loi normale, par conséquent, nous ne pouvons pas utiliser un coefficient de corrélation de Pearson.

Comme la majorité de nos variables ne suivent pas une loi normale, nous avons choisi d'utiliser le coefficient de corrélation de Spearman pour étudier les relations entre elles. Tout comme le coefficient de corrélation de Pearson, Spearman permet de mesurer la relation entre deux variables. La différence essentielle qu'il se base sur les rangs des valeurs, il peut donc être utilisée même lorsque les variables ne suivent pas une loi normale ou que la relation n'est pas linéaire. De plus, Spearman est très peu sensible aux outliers, ce qui en fait un choix pertinent au vu de la présence de valeurs atypiques (cf partie outliers)

Nous avons représenté graphiquement la matrice de corrélation pour faciliter sa compréhension. L'intensité des corrélations est représentée grâce à une échelle de couleur (du bleu pour les corrélations négatives au rouge pour les corrélations positives)

Matrice de corrélation



Source : Auteurs

On constate un très grand nombre de corrélation entre nos variables explicatives avec le coefficient de corrélation de Spearman. En effet, les variables du type de route (Auto_dens et Dep_dens) sont très corrélées avec les parts d'âge et avec les variables du parc automobile (taux_voiture, taux_camion ...). Les variables du parc automobile sont également très corrélées entre elles, par construction⁸. Même chose pour les parts d'âge qui, par construction, sont très corrélées entre elles. La variables Densité est également fortement corrélée à plusieurs autres variables notamment les parts d'âge, les variables du type de route et du parc auto. La variables « *diff_alt* », dans une moindre mesure, est corrélée au pourcentage de forêt (pct_foret) et au nombre d'heure d'ensoleillement (heure_soleil).

⁸ La somme de tous les véhicules vaut 1

Ainsi, l'étude des corrélations est primordiale pour analyser et comprendre les relations entre nos variables. Elle permet d'identifier les liens les plus significatifs et de préparer le terrain pour un travail d'estimation économétrique plus fiable et pertinent.

Analyse économétrique

Nous allons dès à présent aborder la partie portant sur l'analyse économétrique du taux de mortalité par accident. Pour cela, nous allons détailler de façon claire et concise, comment nous sommes parvenus au meilleur modèle à estimer. Un bon modèle économétrique basé sur la méthode des moindres carrés ordinaires (MCO) doit respecter un certain nombre d'hypothèses pour être fiable et pertinent à interpréter. En pratique, le meilleur moyen de vérifier ces hypothèses est d'effectuer des tests statistiques.

A) Estimation naïve d'un premier modèle

Dans un premier temps, nous avons réalisé une estimation naïve en intégrant dans notre modèle toutes les variables explicatives que nous avons à disposition. Nous supposons également que ces variables sont exogènes (nous y reviendrons plus tard).

Cependant, comme nous avons pu le constater dans la matrice de corrélation (cf. matrice corrélation), il existe de fortes corrélations entre les variables constituant le type de route, les parts d'âge ainsi que les variables constituant le parc auto. Nous avons également détecté une forte corrélation entre la différence d'altitude, le pourcentage de forêt et le nombre d'heures d'ensoleillement. Or, la théorie économétrique indique de ne pas intégrer dans un même modèle deux variables corrélées⁹ entre elles. Ainsi, avant même d'estimer ce modèle, un premier obstacle se met en travers de notre chemin.

taux_mortalité = part 0-14 ans + part 15-24 ans + part 25-44 ans + part 45-64 ans + part 65 ans et plus + part d'homme + Pluie + heure d'ensoleillement + différence d'altitude + densité de départementale + densité d'autoroutes + densité de nationale + Densité + densité de forêt + nombre de lit d'urgence + taux de camion + taux de voiture + taux de transport + taux d'utilitaire¹⁰

Faisons abstraction, pour le moment, de ce problème de corrélations, et regardons ce que nous suggèrent les méthodes d'autosélection des variables (stepwise regression).

⁹ Calcul de la multicolinéarité (voir [annexe 5](#))

¹⁰ Nous avons tout de même estimé ce modèle (voir [annexe 4](#))

B) Méthode d'auto-sélection et estimation du modèle autosélectionné

L'objectif de ces méthodes est de ne garder uniquement les variables les plus significatives en excluant celles qui ne contribuent pas ou peu au modèle.

Nous avons donc essayé d'appliquer ces méthodes afin de déterminer quel modèle économétrique serait le plus pertinent à analyser en gardant un compromis entre précision et simplicité. Il existe trois méthodes de sélection automatiques des variables: la méthode ascendante qui ajoute progressivement les variables significatives au modèle (forward); la méthode descendante (backward) qui à l'inverse retire les variables les moins significatives de manière progressive et la méthode mixte (both) combinant les deux précédentes.

Comme ces méthodes reposent sur des logiques de sélection fondamentalement différentes, il est courant que les résultats ne soient pas convergents. En effet, dans notre cas voici les résultats obtenus (voir [annexe 6](#)):

Méthode Forward

taux mortalité = part 25-44 ans + part d'homme + Pluie + heure d'ensoleillement
+ différence d'altitude

(tableau 2)

Méthode Backward

taux mortalité = part 15-24 ans + part 25-44 ans + part 45_64 + part d'homme + Pluie
+ heure d'ensoleillement + différence d'altitude

(tableau 3)

Méthode Both

taux mortalité = part 25-44 ans + part d'homme + Pluie + heure d'ensoleillement
+ différence d'altitude

(tableau 4) Source : Auteurs

Les méthodes ascendante et mixte convergent vers le même modèle. Quant à la méthode descendante, elle nous propose un modèle quasiment identique à celui obtenu avec les deux autres méthodes, à la différence de 2 variables explicatives supplémentaires: la part 15-24 ans et la part 45-64 ans. Ces deux variables étant très corrélées entre elles, nous savons d’ores et déjà que nous ne pourrions pas retenir ce modèle. Toutefois, rappelons que nous faisons pour le moment abstraction de la question des corrélations.

Le choix du “meilleur” modèle à estimer nous revient donc. Étant donné que deux des trois méthodes convergent vers un même modèle, nous allons retenir ce dernier et l’estimer.

Après avoir estimé ce modèle à l’aide d’une MCO, il est nécessaire de contrôler si celui-ci vérifie les hypothèses inhérentes à ce type d’estimation (homoscédasticité des erreurs, normalité des résidus, indépendance des résidus, exogénéité des variables explicatives) via des tests statistiques.

Estimation modèle après sélection automatique des variables


	Coef
constante	-1.033 *
part_25_44	0.859 ***
part_homme	0.025*
Pluie	0.000062**
diff_alt	0.000012*
heure_soleil	0.000030
R ²	0.351
R ² ajusté	0.315
F-statistique	9.737 (p-value < 1.852e-07)
*** : 0,001 ** : 0,01 * : 0,5 . : 0,1	

(tableau 5) (voir [annexe 7](#)) Source : Auteurs

Le modèle estimé après la sélection automatique des variables est significatif au seuil de 5%, ce qui indique qu'il existe bien un intérêt à étudier ce modèle. Le R^2 et le R^2 ajusté associés sont relativement faibles pour un modèle estimé à partir de la méthode des MCO. Cependant, il est important de mettre en perspective ce résultat. Le R^2 permet de mesurer la part de la variance expliquée par le modèle, en d'autres termes, il permet de savoir quel pourcentage d'information le modèle est capable d'expliquer. Notre sujet d'étude étant un sujet relativement complexe relevant d'une part naturellement aléatoire, il n'est pas surprenant ni dérangeant d'obtenir un R^2 faible. Par ailleurs, nous allons toujours préférer regarder le R^2 ajusté car il permet de prendre en compte le nombre de variables explicatives introduites dans le modèle tout en évitant que la qualité du modèle ne soit gonflée par l'ajout de variables explicatives supplémentaires.

Malgré l'intérêt du modèle à être estimé par la MCO, celui-ci ne satisfait pas l'ensemble des hypothèses¹¹, en particulier celle de normalité des résidus.

Graphique 1 : normalité des résidus



Source : Auteurs- *explication graphique: plus les points se confondent avec la ligne rouge, plus les résidus suivent une loi normale*

Graphiquement, on observe une rupture dans le comportement des résidus à partir du point d'abscisse 1, ce qui confirme le non-respect de l'hypothèse de normalité des résidus. Le

¹¹ L'ensemble des tests ont été réalisé en [annexe 8](#)

non-respect de cette hypothèse peut entraîner des biais dans les tests de significativité, et donc conduire à une mauvaise interprétation des coefficients du modèle.

Intéressons-nous maintenant plus en détail les corrélations. Dans le modèle que nous venons d'estimer, la méthode de sélection automatique des variables a introduit simultanément deux variables corrélées entre elles : la différence d'altitude et le nombre d'heures d'ensoleillement.

En effet, ces méthodes ne sont pas conçues pour détecter les problèmes de corrélation ou de multicollinéarité. En revenant aux résultats obtenus dans le (tableau IV.4), on constate très clairement que le coefficient associé à la variable "différence d'altitude" est significatif au seuil de 5%. À première vue, la différence d'altitude semble donc expliquer le taux de mortalité par accident puisqu'elle ressort comme statistiquement significative. Cependant, ce résultat est trompeur: il s'agit d'un effet de confusion. Autrement dit, on croit à tort qu'il existe un lien direct (causal) entre la différence d'altitude et le taux de mortalité, alors que cette relation apparente s'explique en réalité par la présence de la variable représentant le nombre d'heures d'ensoleillement qui est fortement corrélée à la différence d'altitude. La différence d'altitude ne fait que refléter indirectement l'effet de cette dernière variable.

Pour conclure, la non-normalité des résidus combinée à la présence d'une forte corrélation entre deux variables du modèle, nous pousse à revoir notre modèle. Nous ne retiendrons donc pas le modèle proposé par les méthodes d'auto-sélection des variables (forward et both) afin d'éviter de faire des conclusions erronées.

C) Construction d'un modèle final

En partant du modèle précédent, nous avons cherché à construire un modèle explicatif fonctionnel respectant les différentes hypothèses de la MCO.

Le premier problème identifié concernait la non-normalité des résidus. Pour remédier à ce problème, nous avons décidé d'appliquer une transformation logarithmique sur la variable d'intérêt (le taux de mortalité par accident). Nous allons désormais estimer le logarithme du taux de mortalité sur nos variables explicatives. Schématiquement, on pourrait représenter notre nouveau modèle ainsi :

log(taux de mortalité) ← expliqué par ←variables explicatives (pluie, type de route, parc auto...)

Le deuxième problème rencontré dans le modèle précédent était la présence de corrélation entre certaines variables explicatives, l'idée est donc de ne pas introduire dans ce nouveau modèle deux variables corrélées entre elles.

Pour cela, nous avons de nouveau utilisé les méthodes d'auto-sélection des variables (stepwise), comme précédemment, à la différence que la variable taux de mortalité ait été transformée en « log(taux_mortalité) ». De plus, afin d'éviter que ces méthodes nous proposent un modèle avec des variables corrélées, nous avons supprimé toutes les variables susceptibles de présenter une corrélation avec une autre variable (principalement les variables sur le parc auto et les parts d'âge)¹².

Voici les résultats:

Méthode Forward

$$\log(\text{taux mortalité}) = \text{part d'homme} + \text{Pluie} + \text{différence d'altitude} + \text{densité de départementale} + \text{densité d'autoroutes} + \text{Densité}$$

(tableau 6)

Méthode Backward

$$\log(\text{taux mortalité}) = \text{part d'homme} + \text{Pluie} + \text{différence d'altitude} + \text{densité de départementale} + \text{densité d'autoroutes}$$

(tableau 7)

Méthode Both

$$\log(\text{taux mortalité}) = \text{part d'homme} + \text{Pluie} + \text{différence d'altitude} + \text{densité de départementale} + \text{densité d'autoroutes}$$

(tableau 8) Source: Auteurs

¹² Nous avons estimé un modèle intermédiaire afin d'exécuté les méthodes d'auto-sélection comme précédemment (voir [annexe 10](#))

La densité¹³ (note de bas de page : préciser que c'est une variable qui a permis la construction d'autres variables, pas vraiment une variable explicative) étant corrélée avec plusieurs autres variables du modèle, il n'est pas pertinent de l'inclure dans le modèle même si la méthode de sélection forward l'a gardée. Les trois méthodes aboutissent donc à un unique modèle qui est le suivant:

$$\log(\text{taux mortalité}) = \text{part d'homme} + \text{Pluie} + \text{différence d'altitude} + \text{densité de départementale} + \text{densité d'autoroutes}$$

Nous allons donc estimer ce modèle afin de déterminer s'il est pertinent pour expliquer les variations du taux de mortalité par accident sur le territoire français.

Estimation du modèle log après sélection automatique des variables

	Coef
constante	-8,88 .
Pluie	0.00048 *
part_homme	0.135 *
Auto_dens	-8.20 ***
diff_alt	0.000095 *
Dep_dens	-0.111 ***
R ²	0.647
R ² ajusté	0.6274
F-statistique	33 (p-value < 2.2e-16)
*** : 0,001 ** : 0,01 * : 0,5 . : 0,1	

(tableau 9) ([annexe 11](#)) Source: Auteurs


¹³ Nous n'avons pas défini la variable « Densité » dans la partie présentation des variables. Nous l'avons construit en divisant la population de chaque département par la superficie en km², étant donnée sa forte colinéarité avec les autres variables, elle ne sera pas pertinente dans notre analyse.

La statistique du test de Fisher nous indique que le modèle est pertinent à analyser : il existe au moins un coefficient significativement différent de 0, c'est-à-dire qu'au moins une des variables explicatives présente dans le modèle a un impact sur la variable d'intérêt. Le R^2 et le R^2 ajusté sont très bons, en effet, ils sont respectivement de 0,647 et de 0,6274.

Le modèle permettrait donc d'expliquer environ 63% de la variabilité du taux de mortalité. Ce résultat est très élevé pour un phénomène aussi difficilement prévisible que le taux de mortalité des accidents de la route.

Cependant, si le modèle ne vérifie pas les hypothèses nécessaires à la validité des MCO, il n'est pas pertinent de s'y attarder davantage. Vérifions donc s'il satisfait ces conditions. (détails en [annexe 12](#))

Graphique 2 : normalité des résidus



Source: Auteurs

Graphiquement, on observe une légère rupture dans le comportement des résidus au point d'abscisse -2. Cela nous laisse penser que les résidus pourraient ne pas suivre une loi normale. Pour confirmer cette hypothèse, nous avons effectué un test de Shapiro-Wilk. La statistique associée à ce test nous a permis de valider l'hypothèse de normalité des résidus. Nous pouvons donc nous fier sans problème aux tests de Student et au test de Fisher. (voir annexe test Shapiro)

Par ailleurs, la moyenne des résidus du modèle tend vers 0. Nous avons vérifié ce point en réalisant un test de Student sur les résidus, qui nous a confirmé que les résidus sont bien centrés autour de zéro, vérifiant ainsi l'hypothèse d'espérance nulle des résidus.


Notre modèle satisfait également l'hypothèse d'absence d'autocorrélation des erreurs. En effet, nos données sont en coupe transversale et les individus sont indépendants, les erreurs ont donc très peu de risque d'être corrélées entre elles. Nous avons tout de même vérifié cette hypothèse à l'aide d'un test de Durbin-Watson. (annexe)

La forme fonctionnelle du modèle est également correctement spécifiée, cela signifie que la relation entre les variables explicatives et la variable d'intérêt reflète au mieux la réalité économique et statistique étudiée.

Le modèle passe sans difficulté le test de Breusch-Pagan permettant de vérifier l'hypothèse d'homoscédasticité des résidus. (voir annexe)

De plus, notre modèle ne présente pas de problème de multicolinéarité. Nous avons effectué un test VIF (Variance Inflation Factor) afin de vérifier l'absence de multicolinéarité parfaite. (voir annexe)

Graphique 3 : différence entre les erreurs et les valeurs prédites



Source : Auteurs

Graphiquement, nous ne distinguons aucune tendance entre les résidus et les valeurs ajustées ce qui confirme la validité des hypothèses concernant l'homoscédasticité des résidus ainsi que la spécification de la forme fonctionnelle. Le modèle est par conséquent un modèle linéaire.

La dernière hypothèse relative à la méthode des MCO est l'absence d'endogénéité des variables explicatives. Lorsque nous avons modélisé notre étude, nous nous sommes rapidement aperçu que certaines informations intéressantes susceptibles d'expliquer le taux de mortalité par accident peuvent être manquantes pour diverses raisons (informations non observables ou non mesurables), comme la vitesse ou le taux d'alcoolémie du conducteur. Nous reviendrons sur ces limites ultérieurement. Ce constat soulève naturellement la question de l'endogénéité : manque-t-il des variables qui seraient liées à la fois à nos variables explicatives et à notre variable d'intérêt, le taux de mortalité ? Le taux de mortalité pourrait-il lui-même influencer certaines variables explicatives du modèle ?

Pour répondre à ces questions, il faudrait dans un premier temps identifier des variables dites instrumentales, qui soient corrélées avec la variable supposée endogène mais non corrélée avec les résidus, puis dans un second temps, effectuer des tests tels que le test de Weak-instrument, Sargan et Wu-Hausman, afin de déterminer si la variable supposée endogène l'est réellement et étudier la qualité de l'instrument.


Dans notre étude, les variables explicatives retenues sont, par nature, exogènes. En effet, elles sont pour la plupart indépendantes du taux de mortalité par accident, en particulier les variables climatiques (le cumul de pluie, le nombre d'heures d'ensoleillement, la différence d'altitude...) ou démographiques (la part d'homme, les différentes parts d'âge).

Cependant, il existe un risque potentiel d'endogénéité sur les variables liées au type de route et au parc automobile. Ces deux types de variables pourraient être impactées par des politiques publiques comme par exemple, une mesure visant à interdire la circulation de véhicules faisant un certain poids sur certains types de routes (routes départementales, communales). Toutefois, nous avons pris la décision d'exclure cette possibilité : d'une part, il n'existe à ce jour aucune politique mise en place ayant réussi à influencer considérablement le taux de mortalité par accidents, et d'autre part, il serait difficile de trouver des instruments cohérents pour ces variables. Ainsi, toutes les variables incluses dans notre modèle sont supposées exogènes.

Notre modèle respecte donc l'ensemble des hypothèses qui sont nécessaires à la réalisation d'une régression avec la méthode des MCO. Nous pouvons donc, en principe, nous fier aux résultats sortis par notre logiciel de programmation R.

Cependant, malgré la validation de toutes les hypothèses, nous devons impérativement réaliser des tests dit ex-post, c'est-à-dire effectués après l'estimation, pour vérifier qu'il n'existe pas d'observations (ici, des départements) qui peuvent influencer les résultats de notre modèle. Pour cela, nous avons représenté graphiquement les distances de Cooks.

Graphique 4 : distance de Cooks



Source : Auteurs

Sur le graphique, on observe que le point d'abscisse 76 présente une distance de Cooks particulièrement élevée (supérieure à 4). En théorie, une observation est dite influente si elle dépasse le seuil critique de 1, ce qui est ici le cas de notre observation. Il est donc pertinent de l'exclure du modèle et de procéder à une nouvelle estimation.

D) Estimation du « meilleur modèle »


Estimation du modèle log sans l'observation influente

E)	Coef
constante	-9,1719 .
Pluie	0.0005 *
part_homme	0.1422
Auto_dens	-5.3748 .
diff_alt	0.0001 *
Dep_dens	-0.1887**
R ²	0.5755
R ² ajusté	0.5517
F-statistique	24.13 (p-value < 2.2e-16)
*** : 0,001 ** : 0,01 * : 0,5 . : 0,1	

(tableau 10) ([annexe 13](#)) source: Auteur

Pour être le plus rigoureux possible, il est important, voire indispensable, après avoir réestimé notre nouveau modèle de réitérer l'ensemble des tests effectués précédemment afin de vérifier la validité de toutes les hypothèses. Nous avons donc de nouveau réalisé l'ensemble des tests (voir [annexe 14](#)). Nous avons également représenté une nouvelle fois les distances de Cooks.

Graphique 5 : distance de Cooks



Source : Auteur

Nous constatons très clairement qu'il n'existe plus d'observations susceptibles d'influencer notre régression, toutes les observations sont très loin du seuil critique de 1. Nous avons donc enfin identifié le meilleur modèle à estimer.

En conclusion, après avoir vérifié toutes les hypothèses inhérentes à la réalisation d'une MCO, ainsi que la présence d'observations pouvant influencer la régression, nous avons enfin trouver le meilleur modèle à estimer pour expliquer de manière pertinente, à la fois statistiquement et économiquement, le taux de mortalité par accident.

E) Interprétation des coefficients du modèle

Tout au long de cette partie, nous nous sommes préoccupés de la construction ainsi que de la validation théorique et pratique de notre modèle. Maintenant que celui-ci respecte l'ensemble des hypothèses requises, nous pouvons interpréter les coefficients sans craindre un quelconque biais qui viendrait en modifier le signe ou la valeur. Cependant, avant de se lancer dans toute interprétation, nous devons nous assurer de la significativité des coefficients. Pour cela, nous devons nous référer aux symboles à côté de chacun d'entre eux, qui sont donnés par le test de Student. (cf tableau 10)

Les variables « Pluie », « diff_alt » et « Dep_dens » sont significatives au seuil de 5%. La variable « Auto_dens », est-elle significative au seuil de 10%. Quant à la variable « part_homme », elle n'est pas significative, cela signifie que le coefficient n'impacte pas le taux d'accidents mortels de manière assez significative pour en tirer une quelconque conclusion. On remarque également que la constante (intercept) est significative au seuil de 10%. Ici, elle n'est cependant pas interprétable et a uniquement un but pratique pour l'estimation des autres coefficients. En effet, en réalité dans notre modèle, certaines variables comme le nombre de kilomètres de routes départementales et communales par km² ou encore le cumul de pluie ne peuvent pas être égales à 0, ce qui empêche l'interprétation de cette constante.

Nous pouvons alors maintenant interpréter les coefficients associés aux variable « Pluie », « diff_alt », « Dep_dens » et « Auto_dens ». Notre modèle étant un modèle de la forme log-linéaire, puisque nous avons transformé précédemment notre variable d'intérêt en logarithme, il est nécessaire d'être prudent car les coefficients ne doivent pas être interprétés directement comme des variations. Dans un modèle log-linéaire, les coefficients mesurent en réalité une augmentation ou une diminution en pourcentage de notre variable d'intérêt. Pour

obtenir une interprétation correcte, les coefficients doivent être transformés, en passant notamment par la fonction exponentielle.

Toujours à partir du *tableau 10*, nous pouvons alors affirmer les phrases suivantes en interprétant les coefficients. Lorsqu'un département reçoit un millimètre de pluie supplémentaire par an, le taux de mortalité routière augmente en moyenne de 0.05%, toutes choses égales par ailleurs. De même, lorsqu'un département présente une différence d'altitude d'un mètre supplémentaire, le taux de mortalité routière augmente en moyenne de 0.01% toutes choses égales par ailleurs.


A l'inverse, lorsqu'un département gagne un kilomètre d'autoroute par kilomètre carré (km^2), le taux de mortalité diminue en moyenne de 99,5 %, toutes choses égales par ailleurs. Cette valeur est extrêmement élevée, mais cela s'explique par le fait qu'un kilomètre en plus par km^2 représente en réalité une transformation massive et quasi-irréaliste du réseau routier. Dans notre échantillon, toutes les valeurs observées sont inférieures à 0.3 kilomètre par km^2 , ce qui rend compte qu'une telle augmentation est pratiquement impossible. Enfin, lorsqu'un département gagne un kilomètre de routes départementales et communales par km^2 , le taux de mortalité diminue en moyenne de 17.2 %. toutes choses égales par ailleurs.

Pour résumer, il apparaît que les caractéristiques géographiques et météorologiques des départements comme le cumul de pluie ou la différence d'altitude ont un effet positif mais modéré sur le taux de mortalité des accidents de la route. Au contraire, la structure du réseau routier a quant à lui un important effet négatif sur le taux de mortalité routière. Toutefois, il est important de rester prudent avec cette interprétation car l'unité de mesure utilisée est peu intuitive et difficile à interpréter directement. Enfin, la part d'hommes dans un département n'a pas d'effet significatif sur le taux de mortalité routière.

Prévision

Même si l'objectif principal de notre travail est de trouver une explication au taux de mortalité par accident, il peut être intéressant de regarder si notre modèle est pertinent pour faire de la prévision. Pour cela, nous avons fait un graphique qui compare les valeurs prédites aux valeurs réelles. L'objectif étant de déterminer la qualité du pouvoir prédictif de notre modèle.

Graphique 6 : comparaison entre valeurs observées et valeurs prédites



Source : Auteurs

En abscisse, nous retrouvons les valeurs prédites par notre modèle pour le taux de mortalité (initialement en logarithme, mais on applique une fonction exponentielle afin d'obtenir des valeurs positives) et en ordonnée les valeurs observées. La droite rouge correspond aux points sur lesquels les valeurs prédites sont égales aux valeurs observées. Plus un point est loin, plus la différence entre sa valeur prédite et sa valeur observée est grande.

Pour être sûr que notre modèle à une bonne qualité prédictive, nous avons calculé le MSE (la moyenne des carrés des erreurs) et le RMSE (l'erreur quadratique moyen) (voir [annexe 15](#)). L'un sert à calculer l'autre. En d'autres termes, en calculant ces indicateurs, nous cherchons à mesurer la qualité de la prédiction du modèle en mesurant la différence entre les valeurs réelles et les valeurs prédites. Plus le RMSE est proche de 0, plus le modèle à une bonne qualité de prédiction.

Le RMSE de notre modèle est égale à 0,052, cela signifie que l'erreur moyenne de prédiction du modèle est d'environ 0,052 point de pourcentage. Concrètement, la valeur prédite pour le taux de mortalité par accident d'un quelconque département sera en moyenne de 0,05 point de pourcentage autour de la vraie valeur. Donc si un département à un taux de mortalité par accident de 3%, le modèle prédit un taux de mortalité en moyenne autour de 2,95% - 3,05%.

Ainsi, ces résultats mettent en exergue, la capacité de notre modèle à expliquer de manière fiable le taux de mortalité par accident de la route, un objet d'étude pourtant complexe.


Discussion

A) Comparaison de nos résultats avec la littérature

Chaque année, l'ONISR publie son bilan annuel sur la sécurité routière, dans lequel on retrouve toutes sortes de statistiques que nous avons déjà utilisées à plusieurs reprises pour introduire nos propos. Ces données vont maintenant nous servir de point de comparaison avec les résultats clés que nous avons obtenus. Toutefois, il reste difficile de comparer ces résultats car ils ne sont pas présentés sous la même forme.

Dans ce rapport, on nous indique que 9% des accidents mortels ont eu lieu sur une autoroute. Proportionnellement, le taux de mortalité des accidents qui ont lieu sur autoroute est bien plus faible que celui observé sur les routes hors agglomérations. Dans notre modèle, nous avons montré qu'une plus grande densité d'autoroute est associée à une baisse significative du taux de mortalité routière. Cette statistique va donc dans le même sens que notre analyse : cela nous indique que les autoroutes, proportionnellement à leur trafic, sont en réalité le type de route le plus sûr.

Graphique 7 : taux de mortalité par type de route




Source: ONISR données définitives jusqu'en 2023 - (en jaune: autoroute, en vert: hors aggro, en gris aggro)

Le rapport met également en avant la part prépondérante d'hommes tués lors d'accidents de la route. En effet, plus de 78% des décès sont des hommes. Pourtant dans notre analyse, la part d'homme d'un département n'apparaît pas comme un facteur explicatif du taux d'accidents mortels. Autrement dit, on ne peut pas affirmer qu'un département avec une part d'homme plus importante qu'un autre ait un taux d'accidents mortels plus important. Cela peut être en partie

dû à une homogénéité de cette variable entre les différents départements, qui peut limiter sa capacité à expliquer les différences de taux de mortalité.

Graphique 8 : taux de mortalité par sexe



Source: *ONISR données définitives jusqu'en 2023- (en rose: Femme, en bleu: Homme)*

Dans une autre étude de l'ONISR, nous pouvons lire que dans les départements vallonnés ou de montagne, la proportion de routes principales (départementales et nationales) est assez faible, mais que ce sont les seules où il est possible d'atteindre la vitesse maximale autorisée, ce qui en fait des axes particulièrement dangereux. Dans notre analyse, nous avons obtenu un effet significatif de la différence d'altitude sur le taux de mortalité par accident. On observe donc une correspondance entre les résultats de notre travail et les chiffres mis en avant par cette étude.

Bien sûr, il est nécessaire de prendre du recul et de bien garder en mémoire que ce n'est pas parce qu'une variable est associée à un fort taux de mortalité qu'elle en est la cause. Ceci nous rappelle qu'il ne faut pas confondre corrélation et causalité. Un facteur peut être lié à un autre mais n'en est pas forcément la cause.

B) Les limites de notre analyse

Bien que notre modèle respecte toutes les hypothèses requises pour la méthode des MCO et produise des résultats globalement cohérents, il possède, comme tout modèle, un certain nombre de limites.

Dans un premier temps, notre modèle présente certaines limites méthodologiques. L'un des principaux problèmes que nous avons rencontré est le problème de multicollinéarité entre nos variables explicatives. Dès les premières analyses descriptives, nous avons observé de fortes corrélations entre plusieurs de nos variables, ce qui nous a posé problème pour l'estimation de notre modèle avec la méthode des MCO. En effet, on ne peut pas introduire deux variables corrélées dans le même modèle. Cette situation nous a amené à supprimer certaines variables du modèle, ce qui peut réduire la précision du modèle pour évaluer l'impact de chaque variables sur le taux de mortalité des accidents de la route. En effet, certaines n'ont pas pu être introduites dans le modèle final car elles étaient trop corrélées avec les autres.

De plus, il est possible que notre modèle rencontre un problème de sur-ajustement. En effet, notre modèle possède un R^2 et R^2 ajusté élevé, ce qui peut sembler trop élevé au vu de notre problématique. Ce R^2 élevé n'est pas nécessairement synonyme d'un excellent modèle. En effet, derrière ce chiffre peut se cacher un surajustement du modèle, c'est-à-dire que celui-ci comporte peut être trop de variables explicatives ou qu'il est trop complexe. Autrement dit, le modèle peut être pertinent pour expliquer le taux de mortalité par rapport à nos données mais risque de ne pas être reproductible pour les données d'une autre année.

Notre modèle ne rencontre pas seulement des limites méthodologiques, mais aussi des limites liées à notre unité d'observation et donc aux données utilisées. En effet, nous avons étudié le taux de mortalité routière au niveau départemental. Ce choix d'unité d'observation nous a contraint dans le choix et l'intégration de variables explicatives. Ainsi, avec cette unité d'observation, nous n'avons pu inclure aucune variable individuelle, qui sont pourtant déterminantes dans la gravité d'un accident. On peut citer par exemple la vitesse, le taux d'alcoolémie du conducteur ou encore le port de la ceinture de sécurité.

La vitesse est l'une des variables les plus importantes que nous n'avons pas pu inclure dans notre modèle. En effet, elle n'existe pas au niveau départemental, et reste une variable très difficile voire impossible à mesurer avec précision : comment faire pour mesurer la vitesse exacte d'un véhicule lors du choc ? Cependant, elle est déterminante, car plus la vitesse est

élevée, plus l'impact sera violent. Par exemple, un choc à "seulement" 50km/h équivaut à une chute de trois étages, et à cette vitesse, la distance d'arrêt est de 28 mètres.”.

Une autre variable déterminante que nous n'avons pas pu introduire dans notre modèle concerne le comportement du conducteur : la consommation d'alcool ou de drogues. Selon la [sécurité-routière.gouv](http://securite-routiere.gouv.fr), près de 30% des accidents mortels sont dus à une consommation excessive d'alcool. C'est l'une des premières causes de mortalité routière. Cependant, cette variable ne peut pas être incluse dans notre modèle puisque nos observations sont des départements et non des individus.

Ainsi, notre modèle risque de ne pas expliquer une part importante du taux de mortalité routière, à cause des variables manquantes que nous n'avons pas pu inclure, qu'il s'agisse de variables impossibles à mesurer ou de variables non disponibles à l'échelle départementale

Conclusion

Dans cette analyse, nous avons cherché à identifier quelles étaient les différentes variables expliquant le taux de mortalité des accidents de la route au niveau départemental. Partant d'un modèle initial avec 18 variables explicatives, nous avons abouti à un modèle contenant 5 variables explicatives dont 4 se sont révélées significatives.

Les analyses menées tout au long de cette étude nous ont indiquées que les écarts de mortalité routière entre départements ne relèvent pas du hasard. Ils s'expliquent par des caractéristiques propres à chaque territoire, qui influencent les conditions de circulation et l'exposition aux situations à risque.

Les premières statistiques ont d'abord montré une forte diversité entre départements pour un certain nombre de variables comme la pluviométrie, la différence d'altitude, les infrastructures routières ou la structure du trafic. A l'inverse, certaines variables comme les caractéristiques démographiques se sont révélées assez homogènes d'un département à l'autre.

La régression linéaire a mis en évidence le fait que seules certaines caractéristiques territoriales ont un effet significatif dans les différences de taux de mortalité routière. La pluviométrie ainsi que la différence d'altitude exercent un effet positif significatif sur notre variable d'intérêt, indiquant qu'une hausse des précipitations ou une hausse de la différence d'altitude est associée à un niveau de mortalité routière plus élevé. À l'inverse, deux variables liées aux infrastructures routières montrent un effet significatif négatif : une hausse de la densité d'autoroutes ou de la densité de routes départementales est associée à une diminution du taux de mortalité. En revanche, d'autres variables qui pouvaient sembler pertinentes, comme la structure démographique, ne présentent pas d'effet significatif, ce qui indique qu'ils ne contribuent pas directement aux variations de taux de mortalité routière observées entre départements.

Ensuite, la partie prévision nous a confirmé la cohérence de notre modèle : les valeurs estimées se rapprochent globalement des taux de mortalités observées. Même si certains éléments échappent à notre analyse, le modèle parvient à rendre compte des principales différences entre départements.

Finalement, ces résultats montrent que les politiques de sécurité routière gagneraient à être adaptées aux réalités propres à chaque département : renforcer la prévention dans les zones fortement exposées aux aléas météorologiques, limiter la vitesse dans les zones avec de fort

dénivelés ou encore cibler plus spécifiquement les territoires où plusieurs facteurs de risque se cumulent.

Bien que les résultats montrent qu'une augmentation de la densité d'infrastructure routière permet de diminuer le taux d'accidents mortels, il est très coûteux de construire plus de routes.

Il faut néanmoins prendre en considération que notre modèle se heurte à des limites méthodologiques et économiques, qui limitent son pouvoir explicatif et sa pertinence. La mortalité routière est un sujet complexe, qui dépend de très nombreux facteurs parfois non mesurables ou qui ne dépendent pas directement des caractéristiques intrinsèques des départements.

Annexe

Annexe 1 – test de Shapiro sur les variables du modèle

Variable: taux_transport

Results of Hypothesis Test

Alternative Hypothesis:

Test Name:	Shapiro-Wilk normality test
Data:	get(var)
Test Statistic:	W = 0.1297393
P-value:	3.111481e-21

Variable: taux_utilitaire

Results of Hypothesis Test

Alternative Hypothesis:

Test Name:	Shapiro-Wilk normality test
Data:	get(var)
Test Statistic:	W = 0.2554889
P-value:	7.782073e-20

Variable: taux_voiture

Results of Hypothesis Test

Alternative Hypothesis:

Test Name:	Shapiro-Wilk normality test
Data:	get(var)
Test Statistic:	W = 0.261237
P-value:	9.103205e-20

Variable: taux_camion

Results of Hypothesis Test

Alternative Hypothesis:

Test Name:	Shapiro-Wilk normality test
Data:	get(var)
Test Statistic:	W = 0.2624601
P-value:	9.413189e-20

Variable: diff_alt

Results of Hypothesis Test

Alternative Hypothesis:

Test Name:	Shapiro-Wilk normality test
Data:	get(var)
Test Statistic:	W = 0.7880693
P-value:	1.92928e-10

Variable: Pluie	
<u>Results of Hypothesis Test</u>	
Alternative Hypothesis:	
Test Name:	Shapiro-Wilk normality test
Data:	get(var)
Test Statistic:	W = 0.961993
P-value:	0.007026058
Variable: Auto_dens	
<u>Results of Hypothesis Test</u>	
Alternative Hypothesis:	
Test Name:	Shapiro-Wilk normality test
Data:	get(var)
Test Statistic:	W = 0.5222479
P-value:	3.853155e-16
Variable: Dep_dens	
<u>Results of Hypothesis Test</u>	
Alternative Hypothesis:	
Test Name:	Shapiro-Wilk normality test
Data:	get(var)
Test Statistic:	W = 0.3117996
P-value:	3.769251e-19
Variable: Nat_dens	
<u>Results of Hypothesis Test</u>	
Alternative Hypothesis:	
Test Name:	Shapiro-Wilk normality test
Data:	get(var)
Test Statistic:	W = 0.7624313
P-value:	3.697726e-11
Variable: part_0_14	
<u>Results of Hypothesis Test</u>	
Alternative Hypothesis:	
Test Name:	Shapiro-Wilk normality test
Data:	get(var)
Test Statistic:	W = 0.9781902
P-value:	0.1099906

Variable: part_15_24

Results of Hypothesis Test

Alternative Hypothesis:

Test Name: Shapiro-Wilk normality test

Data: get(var)

Test Statistic: $W = 0.9523619$

P-value: 0.001559018

Variable: part_25_44

Results of Hypothesis Test

Alternative Hypothesis:

Test Name: Shapiro-Wilk normality test

Data: get(var)

Test Statistic: $W = 0.9467791$

P-value: 0.0006844189

Variable: part_45_64

Results of Hypothesis Test

Alternative Hypothesis:

Test Name: Shapiro-Wilk normality test

Data: get(var)

Test Statistic: $W = 0.9684558$

P-value: 0.02050665

Variable: part_65_plus

Results of Hypothesis Test

Alternative Hypothesis:

Test Name: Shapiro-Wilk normality test

Data: get(var)

Test Statistic: $W = 0.981786$

P-value: 0.2038958

Variable: part_homme

Results of Hypothesis Test

Alternative Hypothesis:

Test Name:	Shapiro-Wilk normality test
Data:	get(var)
Test Statistic:	W = 0.9841345
P-value:	0.3007503

Variable: Nb_lit

Results of Hypothesis Test

Alternative Hypothesis:

Test Name:	Shapiro-Wilk normality test
Data:	get(var)
Test Statistic:	W = 0.948385
P-value:	0.0008641965

Variable: pct_foret

Results of Hypothesis Test

Alternative Hypothesis:

Test Name:	Shapiro-Wilk normality test
Data:	get(var)
Test Statistic:	W = 0.9160717
P-value:	1.280404e-05

Variable: heure_soleil

Results of Hypothesis Test

Alternative Hypothesis:

Test Name:	Shapiro-Wilk normality test
Data:	get(var)
Test Statistic:	W = 0.7947613
P-value:	3.034542e-10

Annexe 2 - Outliers / valeurs atypiques

Diff_al

\$all.stats

	i	Mean.i	SD.i	Value	Obs.Num	R.i+1	lambda.i+1	Outlier
1	0	1012.9271	1054.0604	4558	75	3.363254	3.370097	FALSE
2	1	975.6105	993.8603	3954	39	2.996789	3.366490	FALSE
3	2	943.9255	949.7261	3643	74	2.841950	3.362836	FALSE

Heure_soleil

No. Outliers <int>	Test Stat. <dbl>	Critical Val. <dbl>
1	3.113356	3.370097
2	3.082329	3.366490
3	3.167975	3.362836
4	3.544931	3.359136
5	3.610426	3.355387
6	3.740822	3.351588
7	3.570384	3.347738
8	3.567406	3.343836
9	3.714893	3.339880
10	3.959945	3.335869

Nat_dens

\$all.stats

	i	Mean.i	SD.i	Value	Obs.Num	R.i+1	lambda.i+1	Outlier
1	0	0.01886506	0.01834607	0.11428571	95	5.201151	3.370097	TRUE
2	1	0.01786063	0.01556523	0.10820046	93	5.803951	3.366490	TRUE
3	2	0.01689957	0.01249769	0.05384346	79	2.956059	3.362836	FALSE
4	3	0.01650232	0.01195387	0.04334216	96	2.245284	3.359136	FALSE
5	4	0.01621058	0.01168174	0.03998488	21	2.035167	3.355387	FALSE

Dep_dens

\$all.stats

	i	Mean.i	SD.i	Value	Obs.Num	R.i+1	lambda.i+1	Outlier
1	0	2.543321	3.3054009	30.8349146	76	8.559202	3.370097	TRUE
2	1	2.245515	1.5611623	10.3895004	94	5.216617	3.366490	TRUE
3	2	2.158876	1.3201064	10.3359909	93	6.194284	3.362836	TRUE
4	3	2.070950	1.0134162	9.8408163	95	7.667004	3.359136	TRUE
5	4	1.986495	0.6063594	3.9457420	96	3.231164	3.355387	FALSE
6	5	1.964965	0.5732683	0.3831399	29	2.759311	3.351588	FALSE
7	6	1.982541	0.5512735	0.4018776	30	2.867295	3.347738	FALSE
8	7	2.000301	0.5278682	3.3667701	92	2.588655	3.343836	FALSE
9	8	1.984773	0.5100405	3.1084761	69	2.203164	3.339880	FALSE
10	9	1.971857	0.4983119	3.0746191	21	2.212995	3.335869	FALSE

Auto_dens

```
$all.stats
  i   Mean.i      SD.i   Value Obs.Num   R.i+1 lambda.i+1 Outlier
1  0 0.02831565 0.03791832 0.24555461    94 5.729130   3.370097    TRUE
2  1 0.02602893 0.03075319 0.21224490    95 6.055175   3.366490    TRUE
3  2 0.02404790 0.02406444 0.20501139    93 7.519953   3.362836    TRUE
4  3 0.02210206 0.01502033 0.06466830    13 2.833909   3.359136   FALSE
5  4 0.02163938 0.01442090 0.06032440    70 2.682566   3.355387   FALSE
6  5 0.02121427 0.01390907 0.05646997    79 2.534728   3.351588   FALSE
7  6 0.02082254 0.01347274 0.05297375    96 2.386389   3.347738   FALSE
8  7 0.02046129 0.01310339 0.05051413    63 2.293516   3.343836   FALSE
9  8 0.02011978 0.01277393 0.05032388    60 2.364512   3.339880   FALSE
10 9 0.01977261 0.01242339 0.04456978    81 1.996007   3.335869   FALSE
```

Pluie

Grubbs test for one outlier

```
data: Pluie
G = 3.12307, U = 0.89625, p-value = 0.06588
alternative hypothesis: highest value 1685.8 is an outlier
```

Nb_lit

```
$all.stats
  i   Mean.i      SD.i Value Obs.Num   R.i+1 lambda.i+1 Outlier
1  0 565.5729 111.70202   971     5 3.629541   3.370097    TRUE
2  1 561.3053 104.12994   889    15 3.146979   3.366490   FALSE
3  2 557.8191  98.95801   879    49 3.245628   3.362836   FALSE
4  3 554.3656  93.62585   831    22 2.954680   3.359136   FALSE
5  4 551.3587  89.50997   780    88 2.554367   3.355387   FALSE
6  5 548.8462  86.68230   761    59 2.447488   3.351588   FALSE
7  6 546.4889  84.18375   351     1 2.322169   3.347738   FALSE
8  7 548.6854  82.02613   363    78 2.263735   3.343836   FALSE
9  8 550.7955  80.03005   726    66 2.189235   3.339880   FALSE
10 9 548.7816  78.21919   383    86 2.119449   3.335869   FALSE
```

Pct_foret

Grubbs test for one outlier

```
data: base_filtre$pct_foret
G = 3.41036, U = 0.87628, p-value = 0.02118
alternative hypothesis: highest value 1.00227790432802 is an outlier
```

Part_0_14

```
$all.stats
  i   Mean.i      SD.i    Value Obs.Num   R.i+1 lambda.i+1 Outlier
1 0 0.1636563 0.01762980 0.2169709    94 3.024120   3.370097   FALSE
2 1 0.1630951 0.01683922 0.2136649    96 3.003098   3.366490   FALSE
3 2 0.1625571 0.01608782 0.2010922    92 2.395296   3.362836   FALSE
4 3 0.1621428 0.01566259 0.1992270    78 2.367695   3.359136   FALSE
5 4 0.1617397 0.01525568 0.1966837    79 2.290561   3.355387   FALSE
```

Par_25_44

```
$all.stats
  i   Mean.i      SD.i    Value Obs.Num   R.i+1 lambda.i+1 Outlier
1 0 0.2234211 0.02622033 0.3220274    76 3.760683   3.370097   TRUE
2 1 0.2223831 0.02429594 0.2863961    94 2.634718   3.366490   FALSE
3 2 0.2217021 0.02349702 0.2863894    93 2.753000   3.362836   FALSE
4 3 0.2210066 0.02263049 0.2781017    95 2.522929   3.359136   FALSE
5 4 0.2203860 0.02194436 0.2766609    32 2.564435   3.355387   FALSE
```

Part_homme

```
$all.stats
  i   Mean.i      SD.i    Value Obs.Num   R.i+1 lambda.i+1 Outlier
1 0 48.57434 0.5285489 46.93102    76 3.109120   3.370097   FALSE
2 1 48.59164 0.5032939 50.05219    49 2.901984   3.366490   FALSE
3 2 48.57610 0.4825419 47.22001     6 2.810300   3.362836   FALSE
4 3 48.59068 0.4638683 47.35545    67 2.662887   3.359136   FALSE
5 4 48.60411 0.4478719 49.72204    91 2.496106   3.355387   FALSE
```

Taux_camion

```
$all.stats
  i   Mean.i      SD.i    Value Obs.Num   R.i+1 lambda.i+1 Outlier
1 0 2.9999212 9.5773983 71.579170    94 7.160530   3.370097   TRUE
2 1 2.2780344 6.4917321 51.565465    76 7.592339   3.366490   TRUE
3 2 1.7537000 4.0245339 30.985194    93 7.263324   3.362836   TRUE
4 3 1.4393829 2.6429583 24.559184    95 8.747698   3.359136   TRUE
5 4 1.1880807 1.0603016  6.118469    96 4.649986   3.355387   TRUE
6 5 1.1339006 0.9293363  5.467360    70 4.662962   3.351588   TRUE
7 6 1.0857511 0.8124205  5.404567    92 5.315985   3.347738   TRUE
8 7 1.0372251 0.6731934  3.091302    13 3.051244   3.343836   FALSE
9 8 1.0138833 0.6398050  3.056722    61 3.192908   3.339880   FALSE
10 9 0.9904024 0.6041747  3.000788    79 3.327490   3.335869   FALSE
```

Taux_voiture

No. Outliers <int>	Test Stat. <dbl>	Critical Val. <dbl>
1	6.929651	3.370097
2	7.493821	3.366490
3	6.777985	3.362836
4	8.980733	3.359136
5	5.056258	3.355387
6	4.599838	3.351588
7	4.831563	3.347738
8	4.547396	3.343836
9	4.002370	3.339880
10	3.998127	3.335869
11	2.398934	3.331801
12	2.363966	3.327676
13	2.327700	3.323491
14	2.378307	3.319245
15	2.380067	3.314935


Taux_transport

No. Outliers <int>	Test Stat. <dbl>	Critical Val. <dbl>
1	9.045580	3.370097
2	9.598059	3.366490
3	7.529427	3.362836
4	6.037928	3.359136
5	4.392288	3.355387
6	4.317471	3.351588
7	4.108047	3.347738
8	4.491556	3.343836
9	5.123773	3.339880
10	3.405804	3.335869
11	3.162077	3.331801
12	2.769985	3.327676
13	2.690354	3.323491
14	2.507920	3.319245
15	2.217239	3.314935

Taux_utilitaire

No. Outliers <int>	Test Stat. <dbl>	Critical Val. <dbl>
1	6.881598	3.370097
2	6.511100	3.366490
3	8.259100	3.362836
4	8.994836	3.359136
5	4.792966	3.355387
6	4.710417	3.351588
7	4.627520	3.347738
8	3.748403	3.343836
9	4.044645	3.339880
10	3.423525	3.335869
11	2.384523	3.331801
12	2.115192	3.327676
13	2.093768	3.323491
14	2.101729	3.319245
15	2.143541	3.314935

Annexe 3 - Matrice analytique (corrélacion – nuage de point – histogramme)



Certaines variables (part_0_14, part_25_44, taux_transport) ont été enlevé pour faciliter la lecture.

Annexe 4 : Modele complet

```
lm(formula = taux_mortalité ~ Auto_dens + Dep_dens + Nat_dens +
    heure_soleil + Pluie + taux_voiture + taux_camion + taux_utilitaire +
    taux_transport + diff_alt + pct_foret + Nb_lit + part_homme +
    part_15_24 + part_25_44 + part_45_64 + part_65_plus + Densité,
    data = base_filtre)
```

Residuals:

Min	1Q	Median	3Q	Max
-0.101396	-0.029487	-0.007501	0.016644	0.149694

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-1.534e+00	9.889e-01	-1.552	0.1249
Auto_dens	9.185e-01	6.639e-01	1.384	0.1705
Dep_dens	-1.323e-02	1.201e-02	-1.101	0.2743
Nat_dens	4.556e-01	6.158e-01	0.740	0.4617
heure_soleil	3.760e-05	2.808e-05	1.339	0.1845
Pluie	5.401e-05	2.856e-05	1.892	0.0623
taux_voiture	-1.721e-04	2.877e-04	-0.598	0.5515
taux_camion	-4.544e-04	1.223e-02	-0.037	0.9704
taux_utilitaire	1.798e-05	2.782e-03	0.006	0.9949
taux_transport	6.983e-03	8.427e-03	0.829	0.4098
diff_alt	-1.175e-05	6.521e-06	-1.803	0.0754
pct_foret	9.896e-04	5.413e-02	0.018	0.9855
Nb_lit	-4.109e-05	6.100e-05	-0.674	0.5026
part_homme	2.125e-02	1.338e-02	1.588	0.1163
part_15_24	1.479e+00	1.226e+00	1.207	0.2313
part_25_44	-8.876e-01	1.088e+00	-0.816	0.4171
part_45_64	2.055e+00	1.459e+00	1.408	0.1631
part_65_plus	2.461e-02	7.280e-01	0.034	0.9731
Densité	4.020e-05	4.421e-05	0.909	0.3659

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.04787 on 77 degrees of freedom

Multiple R-squared: 0.4243, Adjusted R-squared: 0.2897

F-statistic: 3.153 on 18 and 77 DF, p-value: 0.0002384

Annexe 5– Vif modèle complet

Auto_dens	Dep_dens	Nat_dens	heure_soleil	Pluie
26.270423	65.373376	5.291662	2.992799	1.996210
taux_voiture	taux_camion	taux_utilitaire	taux_transport	diff_alt
1888.532351	568.393446	3793.464291	245.581603	1.958323
pct_foret	Nb_lit	part_homme	part_15_24	part_25_44
4.596245	1.924797	2.072931	11.865329	33.738114
part_45_64	part_65_plus	Densité		
12.184847	38.150044	463.215026		

Annexe 6 – Critère d'autosélection à partir du modèle complet (seulement la dernière itérations)

Méthode ascendante

Step: AIC=-581.21

```
taux_mortalité ~ part_25_44 + part_homme + Pluie + diff_alt +  
    heure_soleil
```

	Df	Sum of Sq	RSS	AIC
<none>			0.19892	-581.21
+ Auto_dens	1	0.00247523	0.19644	-580.41
+ taux_camion	1	0.00216639	0.19675	-580.26
+ part_45_64	1	0.00214302	0.19677	-580.25
+ taux_transport	1	0.00117838	0.19774	-579.78
+ pct_foret	1	0.00038654	0.19853	-579.39
+ taux_utilitaire	1	0.00034060	0.19858	-579.37
+ Nat_dens	1	0.00033712	0.19858	-579.37
+ part_15_24	1	0.00033037	0.19859	-579.37
+ part_65_plus	1	0.00012434	0.19879	-579.27
+ taux_voiture	1	0.00007923	0.19884	-579.24
+ Dep_dens	1	0.00002388	0.19889	-579.22
+ Nb_lit	1	0.00000326	0.19891	-579.21
+ Densité	1	0.00000272	0.19891	-579.21

Call:

```
lm(formula = taux_mortalité ~ part_25_44 + part_homme + Pluie +  
    diff_alt + heure_soleil, data = base_filttrer)
```

Coefficients:

(Intercept)	part_25_44	part_homme	Pluie	diff_alt
-1.033e+00	-8.595e-01	2.503e-02	6.185e-05	-1.150e-05

heure_soleil
3.034e-05

Méthode descendante

Step: AIC=-579.85

```
taux_mortalité ~ Auto_dens + heure_soleil + Pluie + taux_voiture +  
    taux_transport + diff_alt + part_homme + part_15_24 + part_25_44 +  
    part_45_64
```

	Df	Sum of Sq	RSS	AIC
<none>			0.18178	-579.85
- Auto_dens	1	0.0040166	0.18580	-579.76
- part_15_24	1	0.0054812	0.18726	-579.00
- heure_soleil	1	0.0056242	0.18740	-578.93
- taux_voiture	1	0.0057891	0.18757	-578.84
- part_25_44	1	0.0061070	0.18789	-578.68
- taux_transport	1	0.0067208	0.18850	-578.37
- part_homme	1	0.0079818	0.18976	-577.73
- Pluie	1	0.0084571	0.19024	-577.49
- diff_alt	1	0.0084669	0.19025	-577.48
- part_45_64	1	0.0090200	0.19080	-577.20

Call:

```
lm(formula = taux_mortalité ~ Auto_dens + heure_soleil + Pluie +  
    taux_voiture + taux_transport + diff_alt + part_homme + part_15_24 +  
    part_25_44 + part_45_64, data = base_filttrer)
```

Coefficients:

(Intercept)	Auto_dens	heure_soleil	Pluie	taux_voiture
-1.757e+00	6.622e-01	3.724e-05	4.711e-05	-7.813e-05

taux_transport diff_alt part_homme part_15_24 part_25_44
5.659e-03 -1.184e-05 2.234e-02 1.572e+00 -7.459e-01
part_45_64
2.450e+00

Méthode mixte

Step: AIC=-581.21

```
taux_mortalité ~ part_25_44 + part_homme + Pluie + diff_alt +  
    heure_soleil
```

	Df	Sum of Sq	RSS	AIC
<none>			0.19892	-581.21
- heure_soleil	1	0.004356	0.20327	-581.13
+ Auto_dens	1	0.002475	0.19644	-580.41
+ taux_camion	1	0.002166	0.19675	-580.26
+ part_45_64	1	0.002143	0.19677	-580.25
+ taux_transport	1	0.001178	0.19774	-579.78
+ pct_foret	1	0.000387	0.19853	-579.39
+ taux_utilitaire	1	0.000341	0.19858	-579.37
+ Nat_dens	1	0.000337	0.19858	-579.37
+ part_15_24	1	0.000330	0.19859	-579.37
+ part_65_plus	1	0.000124	0.19879	-579.27
+ taux_voiture	1	0.000079	0.19884	-579.24
+ Dep_dens	1	0.000024	0.19889	-579.22
+ Nb_lit	1	0.000003	0.19891	-579.21
+ Densité	1	0.000003	0.19891	-579.21
- diff_alt	1	0.008950	0.20787	-578.98
- part_homme	1	0.013850	0.21277	-576.74
- Pluie	1	0.016097	0.21501	-575.74
- part_25_44	1	0.044123	0.24304	-563.97

Call:

```
lm(formula = taux_mortalité ~ part_25_44 + part_homme + Pluie +  
    diff_alt + heure_soleil, data = base_filtre)
```

Coefficients:

(Intercept)	part_25_44	part_homme	Pluie	diff_alt
-1.033e+00	-8.595e-01	2.503e-02	6.185e-05	-1.150e-05

heure_soleil
3.034e-05

Annexe 7 – modèle autosélectionné

Call:

```
lm(formula = taux_mortalité ~ part_25_44 + part_homme + Pluie +  
    diff_alt + heure_soleil, data = base_filtre)
```

Residuals:

Min	1Q	Median	3Q	Max
-0.10654	-0.02912	-0.00602	0.01877	0.17623

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-1.033e+00	5.083e-01	-2.032	0.04506 *
part_25_44	-8.595e-01	1.924e-01	-4.468	2.29e-05 ***
part_homme	2.503e-02	9.997e-03	2.503	0.01411 *
Pluie	6.185e-05	2.292e-05	2.699	0.00831 **
diff_alt	-1.150e-05	5.714e-06	-2.012	0.04717 *
heure_soleil	3.034e-05	2.161e-05	1.404	0.16378

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.04701 on 90 degrees of freedom
Multiple R-squared: 0.351, Adjusted R-squared: 0.315
F-statistic: 9.737 on 5 and 90 DF, p-value: 1.852e-07

Annexe 8– tests associés au modèle autosélectionné

Test homoscédasticité des erreurs

```
studentized Breusch-Pagan test  
  
data: modele_autoselection  
BP = 10.784, df = 5, p-value = 0.05583
```

Test forme fonctionnelle

```
RESET test  
  
data: modele_autoselection  
RESET = 0.70466, df1 = 2, df2 = 88, p-value = 0.497
```

Test normalité des résidus

```
Shapiro-Wilk normality test  
  
data: erreur  
W = 0.93152, p-value = 8.527e-05
```

Vif

part_25_44	part_homme	Pluie	diff_alt	heure_soleil
1.093470	1.200066	1.333000	1.559262	1.837494

Annexe 9– modèle log intermédiaire pour méthode stepwise

```
Call:
lm(formula = log(taux_mortalité) ~ Auto_dens + Dep_dens + Nat_dens +
    heure_soleil + Pluie + diff_alt + pct_foret + part_homme +
    Nb_lit + Densité, data = base_filttrer)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-1.32823 -0.21739 -0.03827  0.27438  1.05312
```

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept) -1.035e+01  5.491e+00  -1.885   0.0628 .
Auto_dens    -8.019e+00  1.888e+00  -4.247 5.51e-05 ***
Dep_dens     -1.034e-01  8.801e-02  -1.175   0.2432
Nat_dens     -3.099e+00  3.010e+00  -1.030   0.3062
heure_soleil  1.802e-04  2.518e-04   0.716   0.4763
Pluie         5.365e-04  2.389e-04   2.246   0.0273 *
diff_alt     -1.361e-04  5.795e-05  -2.349   0.0211 *
pct_foret     1.381e-01  4.351e-01   0.317   0.7517
part_homme    1.587e-01  1.080e-01   1.470   0.1454
Nb_lit       -1.685e-04  4.534e-04  -0.372   0.7111
Densité      -6.643e-06  1.278e-04  -0.052   0.9587
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 0.459 on 85 degrees of freedom
Multiple R-squared:  0.6588,    Adjusted R-squared:  0.6187
F-statistic: 16.41 on 10 and 85 DF,  p-value: 4.787e-16
```

Annexe 10– Méthode d'autosélection sur le modèle précédent (dernière itérations)

Méthode ascendante

```
Step: AIC=-143.95
log(taux_mortalité) ~ Densité + Auto_dens + Pluie + diff_alt +
    Dep_dens + part_homme
```

	Df	Sum of Sq	RSS	AIC
<none>			18.523	-143.95
+ heure_soleil	1	0.35027	18.172	-143.79
+ Nat_dens	1	0.33745	18.185	-143.72
+ pct_foret	1	0.11878	18.404	-142.57
+ Nb_lit	1	0.05671	18.466	-142.25

```
Call:
lm(formula = log(taux_mortalité) ~ Densité + Auto_dens + Pluie +
    diff_alt + Dep_dens + part_homme, data = base_filttrer)
```

```
Coefficients:
(Intercept)      Densité    Auto_dens      Pluie    diff_alt    Dep_dens
-8.886e+00    3.442e-06   -8.227e+00   4.815e-04  -9.554e-05  -1.135e-01
part_homme
 1.348e-01
```

Méthode descendante

Step: AIC=-145.95

$\log(\text{taux_mortalité}) \sim \text{Auto_dens} + \text{Dep_dens} + \text{Pluie} + \text{diff_alt} + \text{part_homme}$

	Df	Sum of Sq	RSS	AIC
<none>			18.523	-145.95
- part_homme	1	0.3955	18.919	-145.92
- diff_alt	1	0.8761	19.399	-143.52
- Pluie	1	1.1483	19.671	-142.18
- Auto_dens	1	7.7094	26.232	-114.55
- Dep_dens	1	9.6643	28.187	-107.65

Call:

`lm(formula = log(taux_mortalité) ~ Auto_dens + Dep_dens + Pluie + diff_alt + part_homme, data = base_filttrer)`

Coefficients:

(Intercept)	Auto_dens	Dep_dens	Pluie	diff_alt	part_homme
-8.881e+00	-8.202e+00	-1.112e-01	4.806e-04	-9.518e-05	1.346e-01

Méthode mixte

Step: AIC=-145.95

$\log(\text{taux_mortalité}) \sim \text{Auto_dens} + \text{Pluie} + \text{diff_alt} + \text{Dep_dens} + \text{part_homme}$

	Df	Sum of Sq	RSS	AIC
<none>			18.523	-145.95
- part_homme	1	0.3955	18.919	-145.92
+ heure_soleil	1	0.3503	18.173	-145.78
+ Nat_dens	1	0.3333	18.190	-145.69
+ pct_foret	1	0.0972	18.426	-144.46
+ Nb_lit	1	0.0551	18.468	-144.24
+ Densité	1	0.0002	18.523	-143.95
- diff_alt	1	0.8761	19.399	-143.52
- Pluie	1	1.1483	19.671	-142.18
- Auto_dens	1	7.7094	26.232	-114.55
- Dep_dens	1	9.6643	28.187	-107.65

Call:

`lm(formula = log(taux_mortalité) ~ Auto_dens + Pluie + diff_alt + Dep_dens + part_homme, data = base_filttrer)`

Coefficients:

(Intercept)	Auto_dens	Pluie	diff_alt	Dep_dens	part_homme
-8.881e+00	-8.202e+00	4.806e-04	-9.518e-05	-1.112e-01	1.346e-01

Annexe 11 – Modèle log autosélectionné

Call:

```
lm(formula = log(taux_mortalité) ~ Pluie + part_homme + Auto_dens +  
    diff_alt + Dep_dens, data = base_filttrer)
```

Residuals:

Min	1Q	Median	3Q	Max
-1.37031	-0.25952	-0.00894	0.29208	1.04617

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-8.881e+00	4.682e+00	-1.897	0.0611 .
Pluie	4.806e-04	2.035e-04	2.362	0.0203 *
part_homme	1.346e-01	9.707e-02	1.386	0.1691
Auto_dens	-8.202e+00	1.340e+00	-6.120	2.39e-08 ***
diff_alt	-9.518e-05	4.613e-05	-2.063	0.0420 *
Dep_dens	-1.112e-01	1.623e-02	-6.853	8.75e-10 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.4537 on 90 degrees of freedom

Multiple R-squared: 0.647, Adjusted R-squared: 0.6274

F-statistic: 33 on 5 and 90 DF, p-value: < 2.2e-16

Annexe 12 – tests statistiques sur le modèle log autosélectionné

Test homoscédasticité des erreurs

studentized Breusch-Pagan test

data: a

BP = 1.2365, df = 5, p-value = 0.9413

Test forme fonctionnelle

RESET test

data: a

RESET = 0.24558, df1 = 2, df2 = 88, p-value = 0.7828

Test de normalité des erreurs

Shapiro-Wilk normality test

data: erreur

W = 0.98673, p-value = 0.4495

Vif

Pluie	part_homme	Auto_dens	diff_alt	Dep_dens
1.128295	1.214935	1.192015	1.091402	1.327754

Test d'autocorrélation des erreurs

```
Durbin-Watson test

data: a
DW = 1.9898, p-value = 0.4335
alternative hypothesis: true autocorrelation is greater than 0
```

Moyenne des résidus

```
[1] 1.470336e-17
```

Annexe 13 – Modèle log autosélectionné sans observations influentes

```
Call:
lm(formula = log(taux_mortalité) ~ Pluie + part_homme + Auto_dens +
    diff_alt + Dep_dens, data = b)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-1.31490 -0.24476 -0.00434  0.29190  0.99582
```

```
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -9.1719721  4.6795743  -1.960  0.05312 .
Pluie        0.0005022  0.0002039   2.463  0.01569 *
part_homme   0.1422458  0.0970919   1.465  0.14643
Auto_dens   -5.3748476  2.7647393  -1.944  0.05505 .
diff_alt    -0.0001056  0.0000469  -2.252  0.02679 *
Dep_dens    -0.1886685  0.0682536  -2.764  0.00693 **
```

```
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 0.4527 on 89 degrees of freedom
Multiple R-squared:  0.5755,    Adjusted R-squared:  0.5517
F-statistic: 24.13 on 5 and 89 DF,  p-value: 2.863e-15
```

Annexe 14 – re vérification des hypothèses après suppressions des observations influentes

Test homoscédasticité des erreurs

```
studentized Breusch-Pagan test  
  
data: aa  
BP = 1.0436, df = 5, p-value = 0.959
```

Test forme fonctionnelle

```
RESET test  
  
data: aa  
RESET = 0.21643, df1 = 2, df2 = 87, p-value = 0.8058
```

Test de normalité des erreurs

```
Shapiro-Wilk normality test  
  
data: erreur  
W = 0.98832, p-value = 0.5691
```

Vif

```
1.134760 1.095035 5.080194 1.123412 5.206740
```

Test d'autocorrélation des erreurs

```
Durbin-Watson test  
  
data: aa  
DW = 1.9973, p-value = 0.451  
alternative hypothesis: true autocorrelation is greater than 0
```

Moyenne des résidus

```
[1] -1.195133e-17
```

AIC

```
[1] 126.8399
```

Annexe 15 – Prédiction

MSE & RMSE (resp.)

```
[1] 0.002705082
```

```
[1] 0.05201041
```

Annexe 16: Ensemble des packages utilisées sur le logiciel R

{car}

{lmtest}

{outliers}

{sandwich}

{leaps}

{readxl}

{tidyverse}

{EnvStats}

{corrplot}

Bibliographie

A chacun sa conduite. (s.d.). Récupéré sur Sécurité routière: <https://www.securite-routiere.gouv.fr/chacun-sa-conduite>

Bases de données annuelles des accidents corporels de la circulation routières de 2005 à 2024. (s.d.). Récupéré sur Datagouv: <https://www.data.gouv.fr/datasets/bases-de-donnees-annuelles-des-accidents-corporels-de-la-circulation-routiere-annees-de-2005-a-2024>

Bilan de la sécurité routière 2023. (2023). Récupéré sur Sécurité routière: 1. <https://www.onisr.securite-routiere.gouv.fr/etat-de-linsecurite-routiere/bilans-annuels-de-la-securite-routiere/bilan-2023-de-la-securite-routiere>

Bilan démographique 2023 . (2023). Récupéré sur INSEE.

Bilan démographique 2023. (2023). Récupéré sur INSEE: <https://www.insee.fr/fr/accueil>

Bulletins climatiques de France métropolitaine et outre-mer. (2023). Récupéré sur Météo France:
https://donneespubliques.meteofrance.fr/?fond=produit&id_produit=129&id_rubrique=52

Cazenave-Lacroutz, A. (2025). *Les établissements de santé en 2023.* Récupéré sur DREES: https://drees.solidarites-sante.gouv.fr/publications-communique-de-presse-documents-de-reference/panoramas-de-la-drees/250522_Panorama_etablissements-de-sante2025

Conduire de nuit. (s.d.). Récupéré sur Sécurité routière: <https://www.securite-routiere.gouv.fr/chaque-situation-sa-conduite/conduire-la-nuit>

Conduire par temps de pluie. (s.d.). Récupéré sur Sécurité routière: <https://www.securite-routiere.gouv.fr/node/6238/conduire-par-temps-de-pluie>

Conseils aux conducteurs novices. (s.d.). Récupéré sur Sécurité routière: <https://www.securite-routiere.gouv.fr/chacun-sa-conduite/conseils-aux-conducteurs-novices#:~:text=Les%20accidents%20de%20la%20route,dans%2024%25%20des%20accidents%20mortels>

Dans 49 % des départements, la mortalité routière a stagné ou augmenté après l'instauration du 80 km/h . (s.d.). Récupéré sur Ligue de dépense des conducteurs:

<https://www.liguedesconducteurs.org/dans-47-des-departements-la-mortalite-routiere-a-stagne-ou-augmente-apres-l-instaurat-ion-du-80-km-h/>

Données sur le parc automobile français au 1er janvier 2023 | Données et études statistiques. (2023). Récupéré sur SDES: <https://www.statistiques.developpement-durable.gouv.fr/donnees-sur-le-parc-automobile-francais-au-1er-janvier-2023>

Données sur le parc automobile français au 1er janvier 2023. (2023). Récupéré sur SDES: <https://www.statistiques.developpement-durable.gouv.fr/donnees-sur-le-parc-automobile-francais-au-1er-janvier-2023>

Estimation de population par département, sexe et âge quinquennal - Années 1975 à 2023. (s.d.). Récupéré sur INSEE: <https://www.insee.fr/fr/accueil>

Faits et Chiffres. (s.d.). Récupéré sur Union routière de France: <https://www.unionroutiere.fr/faits-et-chiffres/>

INSEE. (2023). Récupéré sur INSEE.

Inventaire forestier. (2024). Récupéré sur IGN: <https://inventaire-forestier.ign.fr/spip.php?rubrique11>

Les départements les plus ensoleillés de France en 2024. (2023). Récupéré sur linternaute: <https://www.linternaute.com/voyage/climat/classement/departements/soleil>

Les forêts de mon territoire. (s.d.). Récupéré sur Observatoire forêt: <https://observatoire.foret.gouv.fr/mon-territoire?territoireCode=44&territoireLevel=RAD13&compareCode=France&compareLevel=FRA>

Les volumes de précipitations . (s.d.). Récupéré sur Eaufrance: <https://www.eaufrance.fr/les-volumes-de-precipitations>

Pluviométrie définition. (s.d.). Récupéré sur Dictionnaire LeRobert: <https://dictionnaire.lerobert.com/definition/pluviometrie>

Réglementation de l'alcool au volant. (s.d.). Récupéré sur Sécurité routière: <https://www.securite-routiere.gouv.fr/reglementation-liee-aux-risques/reglementation-de-lalcool-au-volant>

Réseau routier au 31 décembre 2023 : comparaisons départementales. (s.d.). Récupéré sur
INSEE: <https://www.insee.fr>

Index

Boxplots : boîtes à moustaches

Breush-Pagan : test d'hétéroscédasticité des résidus

CDSR : commission départementale de la sécurité routière

Cook's Distance : mesure de l'influence d'une observation dans une régression

DREES : Direction de la Recherche, des Études, de l'Évaluation et des Statistiques

Durbin-Watson : test d'autocorrélation des résidus

ESD : Extreme Studentized Deviate test

F-statistique : test global de significativité du modèle de régression

INSEE : Institut National de la Statistique et des Études Économiques

LOM : Loi d'orientation des mobilités

MCO: moindres carrés ordinaires (Ordinary Least Squares)

MSE : Moyenne des carrés des erreurs de prédiction (Mean Squared Error)

ONISR : Observatoire National Interministériel de la Sécurité Routière

Outlier : Valeur aberrante / atypique influençant l'estimation

Proxy : variable de substitution utilisée faute de mesure directe

R^2 : part de variance expliquée par le modèle

R^2 ajusté : R^2 pénalisant l'ajout de variables

RMSE : racine de la moyenne des carrés des erreurs (Root Mean Squared Error)

Shapiro-Wilk : test de normalité d'une variable ou des résidus.

TCP : Transport en Commun collectif de Personnes

VIF : mesure de multicolinéarité (Variance Inflation Factor)

